



全日制硕士学位论文

基于KPCA与改进极限学习机的煤与瓦斯突出预测研究

Research on Prediction of Coal and Gas Outburst Based on KPCA and Improved Extreme Learning Machine

作者姓名： 邱微

导师姓名： 徐耀松 副教授

学科专业： 控制理论与控制工程

研究方向： 信息处理与模式识别

完成日期： 2019 年 6 月 10 日

辽宁工程技术大学

Liaoning Technical University

中图分类号 TP183

学校代码 10147

UDC 621.3

密 级 公 开

辽宁工程技术大学
全日制硕士学位论文

**基于KPCA与改进极限学习机的煤与瓦斯突出预测
研究**

**Research on Prediction of Coal and Gas Outburst
Based on KPCA and Improved Extreme Learning
Machine**

作者姓名 邱微

学 号 471620580

导师姓名 徐耀松（副教授）

副导师姓名

申请学位 工学硕士

培养单位 电气与控制工程学院

学科专业 控制理论与控制工程

研究方向 信息处理与模式识别

二〇一九年六月

致 谢

时光飞逝，三年的研究生学习生活已接近尾声，感激之心，时刻不能忘怀。在论文完成之际，谨向所有给予过我关心、指导、帮助及鼓励的老师、同学和朋友们致以衷心的感谢。

首先，特别感谢我的导师徐耀松老师，本论文从论文选题、技术路线确定、研究方法选取、论文编写的审阅及修改到论文最终完稿，无不是在徐耀松老师的细心指导下完成的。研究生期间，徐老师严谨的治学态度、平易近人的工作作风、刻苦的学习精神时时刻刻激励着我，为我的人生树立了典范。不仅如此，研究生期间徐耀松老师在生活上更是给予了我无微不至的关怀和帮助，这也深深地让我所感动。在此，谨向细心培育教导我的恩师致以最崇高的敬意和最衷心的感谢！

同时，衷心感谢实验室大家庭的诸位老师、付华教授、王雨虹老师及谢国民老师等，感谢他们在每一次学术交流会中毫无保留的经验分享，使我对科研产生浓厚兴趣，为我的学习道路指引了明确的方向。感谢付华劳模创新工作室的所有兄弟姐妹对我的陪伴、帮助和鼓励。

论文编写过程中，大量参考并引用国内外许多相关文献与专著，向有关学者、专家表示衷心的感谢，你们渊博的知识令我敬佩。

最后，向百忙之中参与本论文评审以及参与答辩的各位老师表示衷心的感谢，并由衷地希望得到各位老师的指导！

摘 要

煤与瓦斯的突出现象是目前煤矿开采过程中破坏性最强、危害性最严重的矿井安全事故之一，它的本质是一种极其复杂的矿井动力现象。如何对瓦斯灾害进行有效预测一直是煤矿安全领域中重要的研究课题。但目前鉴于煤与瓦斯突出机理本质尚未彻底清楚，且突出灾害本身受到多种复杂因素的综合作用和影响，是一个具有极强的非线性和复杂性的高维问题，采用传统的预测方法难以进行准确预测。因此，为了提高瓦斯灾害的预测精度和预测效率，本文在分析煤与瓦斯突出机理和影响因素的基础上，借鉴我国《防治煤与瓦斯突出规定》里描述的两种工作面和区域性突出预测方法及其预测指标体系的建立规则，从数据分析的角度深入分析各致突因素，提出了一种新的突出预测指标体系，建立了基于 KPCA 与 IQGA-ELM 的煤与瓦斯突出预测模型，并运用在矿井掘进工作面内的煤与瓦斯突出现象预测中。

本文以准确、快速实现煤与瓦斯突出预测为目标，主要围绕以下几个方面进行工作：

（1）总结目前应用较为广泛的各种煤与瓦斯突出机理假说，通过比较多种形式的煤与瓦斯突出预测方法，分析该领域的研究现状以及目前存在的不足之处，讨论了建立煤与瓦斯突出面域化预测模型的必要性和现实意义。

（2）分析影响煤与瓦斯突出的各相关因素，建立面域化预测指标系统；提出采用核主成分分析方法对煤与瓦斯突出预测指标进行权重分析，并将其作为突出预测模型输入变量的选取原则。

（3）通过对极限学习机原理的深入分析，针对其在学习训练过程中随机生成输入层权值及隐含层阈值的缺点，引入改进量子遗传算法对传统极限学习机网络进行改进，建立了基于 IQGA 算法优化的 ELM 煤与瓦斯突出预测模型。

（4）对建立的基于 KPCA 与 IQGA-ELM 预测模型进行实例验证。采用开滦钱家营煤矿数据进行预测实验，预测结果验证了该预测模型的准确性。并将其与其他模型进行预测性能比较，凸显了该模型的良好预测性能。

该论文有图 18 幅，表 15 个，参考文献 60 篇。

关键词：煤与瓦斯突出；预测；核主成分分析；极限学习机；量子遗传算法

Abstract

Coal and gas outburst is one of the most destructive and most dangerous mine safety accidents in coal mining, and its essence is an extremely complex mine dynamic phenomenon. How to effectively predict gas disasters has always been an important research topic in the field of coal mine safety. However, in view of the fact that the nature of coal and gas outburst mechanism has not been fully understood, and the prominent disaster itself is affected by a variety of complex factors, it is a high-dimensional problem with strong nonlinearity and complexity, which is difficult to use traditional prediction methods to achieve accurate forecasting. Therefore, in order to improve the prediction accuracy and prediction efficiency of gas disasters, based on the analysis of the mechanism and influencing factors of coal and gas outburst, this thesis draws on the two working faces and regional outburst predictions described in China's Regulations on Prevention of Coal and Gas Outburst. The method and the rules for establishing the predictive index system are analyzed from the perspective of data analysis. A new prominent predictive index system is proposed, and a coal and gas outburst prediction model based on KPCA and IQGA-ELM is established. It is used in the prediction of coal and gas outburst prediction in coal mining face.

This thesis aims to accurately and quickly achieve coal and gas outburst prediction, and mainly works on the following aspects:

(1) Summarize the current mainstream coal and gas outburst mechanism hypothesis. By comparing different coal and gas outburst prediction methods, analyze the research status and current deficiencies in this field, and discuss the necessity and realistic meaning of establishing coal and gas outburst prediction model.

(2) The related factors affecting coal and gas outburst are analyzed, and the prediction system of surface area prediction index is established. The kernel principal component analysis method is used to analyze the weight of coal and gas outburst prediction indicators, and it is used as the selection principle of the input variables of the prominent prediction model. The kernel principal component analysis method can simplify the input variables of the prediction model, accelerate the prediction rate, and improve the prediction accuracy.

(3) Through the in-depth analysis of the principle of extreme learning machine, based on the shortcomings of randomly generating the input layer weight and the hidden layer threshold, the improved quantum immune genetic algorithm is used to improve the extreme learning machine, and the ELM coal and gas prediction model based on IQGA algorithm is established.

(4)The established KPCA and IQGA-ELM prediction model is verified by examples. The prediction experiment was carried out using the data of Qianjiaying Mine, and the prediction results verified the accuracy of the prediction model. And as well as comparing this model with other models for predictive performance highlights the good predictive performance of the model.

Keywords: coal and gas outburst; prediction; kernel principal component analysis; extreme learning machine; quantum genetic algorithm

目 录

摘要	I
目录	IV
图清单	VIII
表清单	IX
变量注释表	X
1 绪论	1
1.1 课题研究的背景及意义	1
1.2 煤与瓦斯突出预测方法研究现状	2
1.3 本文研究内容及结构安排	7
2 煤与瓦斯突出机理及影响因素	9
2.1 煤与瓦斯突出机理研究现状	9
2.2 煤与瓦斯突出发展过程及一般规律	11
2.3 煤与瓦斯突出影响因素	12
2.4 煤与瓦斯预测指标的选取	13
2.5 本章小结	15
3 煤与瓦斯突出预测指标系统的核主成分分析	16
3.1 核主成分分析相关理论	16
3.2 基于核主成分分析的特征提取	19
3.3 核主成分分析的适应性分析	21
3.4 本章小结	21
4 基于 KPCA 与 IQGA 算法优化的 ELM 煤与瓦斯突出预测模型	22
4.1 极限学习机神经网络基本理论	22
4.2 量子遗传算法优化的极限学习机	26
4.3 基于 KPCA 与 IQGA-ELM 煤与瓦斯突出预测模型的建立	32
4.4 本章小结	34
5 预测模型在钱家营矿的实例应用	35
5.1 矿井概况	35
5.2 面域化预测指标的测定方法	37
5.3 钱家营矿煤与瓦斯突出预测实例分析	40

5.4 工程应用·····	47
5.5 本章小结·····	47
6 结论与展望·····	48
6.1 结论·····	48
6.2 展望·····	48
参考文献·····	50
作者简介·····	53
论文原创性声明·····	54
学位论文数据集·····	55

Contents

Abstract.....	I
Contents.....	IV
List of Figures.....	VIII
List of Tables.....	IX
List of Variables.....	X
1 Introduction.....	1
1.1 Project Research Background and Significance.....	1
1.2 Research Status of Coal and Gas Outburst Prediction Methods.....	2
1.3 Research Content and Structure of Thesis.....	7
2 Coal and Gas Outburst Mechanism and its Influencing Factors.....	9
2.1 Research Status of Coal and Gas Outburst Mechanism	9
2.2 Coal and Gas Outburst Development Process and General Law	11
2.3 Coal and Gas Outburst Factors.....	12
2.4 Selection of Coal and Gas Prediction Indicators.....	13
2.5 Chapter Summary	15
3 KPCA of Coal and Gas Outburst Prediction Index System.....	16
3.1 Kernel Principal Component Analysis Related Theory.....	16
3.2 Feature Extraction Based on Kernel Principal Component Analysis.....	19
3.3 Adaptability Analysis of Kernel Principal Component Analysis.....	21
3.4 Chapter Summary	21
4 ELM Coal and Gas Outburst Prediction Model Based on KPCA and IQGA Algorithm Optimization.....	22
4.1 Basic Theory of Extreme Learning Machine Neural Network.....	22
4.2 Extreme Learning Machine Optimized by Quantum Genetic Algorithm.....	26
4.3 Establishment of Coal and Gas Outburst Prediction Model Based on KPCA and IQGA-ELM.....	32
4.4 Chapter Summary	34
5 Example Application of Prediction Model in Qianjiaying Mine.....	35
5.1 Mine Overview.....	35

5.2 Method for Measuring Area Prediction Indicators.....	37
5.3 Case Analysis of Coal and Gas Outburst Prediction in Qianjiaying Coal Mine.....	40
5.4 Engineering Applications.....	47
5.5 Chapter Summary	47
6 Conclusions and Prospect.....	48
6.1 Conclusions	48
6.2 Prospect	48
References.....	50
Author's Resume.....	53
Declaration of Thesis Originality.....	54
Thesis Data Collection.....	55

图清单

图序号	图名称	页码
图 1. 1	我国 2004-2014 年煤与瓦斯突出事故人数及死亡人数统计图	1
Figure 1.1	Statistics on the number of coal and gas outburst accidents and deaths in China from 2004 to 2014	1
图 1. 2	技术路线图	8
Figure 1.2	Technical roadmap	8
图 2. 1	面域化预测指标系统	14
Figure 2.1	Area prediction indicator system	14
图 3. 1	核方法映射关系	17
Figure 3.1	Kernel method mapping	17
图 3. 2	KPCA 基本流程图	20
Figure 3.2	KPCA basic flow chart	20
图 4. 1	单隐层前馈神经网络	23
Figure 4.1	Single hidden layer feedforward neural network	23
图 4. 2	极限学习机网络结构	25
Figure 4.2	Extreme learning machine network structure	25
图 4. 3	QGA 算法流程图	27
Figure 4.3	QGA algorithm flow chart	27
图 4. 4	IQGA 算法流程图	32
Figure 4.4	IQGA algorithm flow chart	32
图 4. 5	KPCA-IQGA-ELM 预测模型流程图	33
Figure 4.5	KPCA-IQGA-ELM prediction model flow chart	33
图 5. 1	钱家营煤矿交通位置图	35
Figure 5.1	Qianjiaying coal mine traffic location map	35
图 5. 2	声发射系统	38
Figure 5.2	Acoustic emission system	38
图 5. 3	变容变压式仪器示意图	38
Figure 5.3	Variable capacity variable pressure instrument schematic	38
图 5. 4	KBD5 电磁辐射监测仪	40
Figure 5.4	KBD5 electromagnetic radiation monitor	40
图 5. 5	隐含层节点的选取	43
Figure 5.5	Selection of hidden layer nodes	43
图 5. 6	IQGA-ELM 适应度收敛曲线	44
Figure 5.6	IQGA-ELM fitness convergence curve	44
图 5. 7	测试集预测结果图	45
Figure 5.7	Test set prediction result graph	45
图 5. 8	KPCA 处理后各模型训练误差	46
Figure 5.8	Training error of each model after KPCA processing	46

表清单

表序号	表名称	页码
表 1.1	钻孔瓦斯初速度 q 的突出危险临界值	3
Table 1.1	Outburst hazard threshold for initial velocity of borehole gas	3
表 1.2	预测突出危险性单项指标临界值	4
Table 1.2	Predicting the critical value of individual risk indicators	4
表 1.3	突出危险性临界值	4
Table 1.3	The critical value of outburst danger	4
表 1.4	钻屑指标法各指标的临界值	5
Table 1.4	Critical value of each index of drill cuttings index method	5
表 4.1	旋转角选取方法	29
Table 4.1	Rotation angle selection method	29
表 5.1	各煤层具体情况	36
Table 5.1	Specific conditions of each coal seam	36
表 5.2	各项参数测定结果	39
Table 5.2	Measurement results of various parameters	39
表 5.3	部分煤层压力测试结果	39
Table 5.3	Partial coal seam pressure test results	39
表 5.4	面域化预测指标系统及突出数据集	41
Table 5.4	Area prediction indicator system and prominent data set	41
表 5.5	各主成分贡献率	42
Table 5.5	Principal component contribution rate	42
表 5.6	特征提取后的样本数据表	42
Table 5.6	Sample data table after feature extraction	42
表 5.7	不同激活函数的泛化性能	43
Table 5.7	Generalization performance of different activation functions	43
表 5.8	预测误差及收敛时间对比	45
Table 5.8	Comparison of prediction error and convergence time	45
表 5.9	KPCA 降维后各模型预测效果	46
Table 5.9	Prediction effect of each model after KPCA dimension reduction	46
表 5.10	预测结果	47
Table 5.10	Forecast result	47

变量注释表

S_{max}	每米钻孔钻屑量的最大值
i_{max}	每米钻孔瓦斯放散初速度的最大值
P_g	煤层瓦斯压力
Δp	瓦斯放散初速度
f	煤的坚固性系数
D/K	瓦斯突出综合指标
H	煤层开采深度
Δh_2 、 K_I	钻屑瓦斯解吸指标
S	钻屑量
d_F	<i>Hilbert</i> 空间维度
W_i	ELM 输入层权值
β_i	ELM 隐含层阈值
b_i	隐含层阈值
H	隐含层输出矩阵
θ	量子旋转门旋转角度
δ	量子遗传算法调整步长
f_v 、 C_v	种群个体的适应度以及对应的抗体浓度
N	种群总数
M	免疫记忆库的容量
A_d 、 M_{ad}	煤的灰分和水分
π	孔隙率
γ	煤的容重
G_c	瓦斯含量
G_s	地质构造
H_m	软分层煤体厚度
E	电磁辐射强度
C	声发射事件数
Q	瓦斯涌出量
D_t	破坏类型
P_0	地应力
G	煤与瓦斯突出危险性

1 绪论

1.1 课题研究的背景及其意义

1.1.1 研究的背景

我国是目前世界上煤产量最大的国家之一，煤炭年总产量大概占据全世界煤炭年总产量的 38%。煤炭是我国目前重要的能源之一，煤炭行业的不断发展为我国的国民经济与社会进步带来了很大的提升作用^[1-4]。几十年来，我国煤炭行业发展十分迅速，推动我国经济的逐渐增长，但是由于目前我国对煤矿资源开采速度的逐渐加快，开采垂深的逐步增加，开采范围及区域的不断扩大，瓦斯涌出和煤与瓦斯突出现象也越来越凸显，导致煤矿灾害事故发生率也在不断升高，重大煤矿灾害事故时有发生^[5]。

引起煤矿灾害事故发生的原因有许多种，在所有的煤矿灾害事故当中，只有像煤与瓦斯突出这种由于瓦斯因素引起的煤矿事故给矿井和作业人员造成的后果和危害性是最严重的，对煤矿安全生产的威胁性也最大^[6-7]。由于瓦斯因素引起的煤矿事故是所有类型矿井事故中造成伤亡人数最多、损害财产设施最严重的灾害之一，瓦斯事故带来的危害性是不可估计的。在我国七百多处国家重点煤矿企业中，具有煤与瓦斯突出特性的矿井就大概占据全部煤矿的百分之二十以上^[8]。此外，目前我国煤与瓦斯突出事故的发生率在世界各国中都是比较高的，而且各煤矿发生煤与瓦斯突出的危险程度也排在许多国家前面，极高的煤层瓦斯突出事故发生率很大程度上限制了我国近几年煤炭行业的进步。图 1.1 为 2004~2014 这十年里我国发生的煤与瓦斯突出事故的总数以及其造成的死亡人数^[9]。




图 1.1 2004-2014 年我国煤与瓦斯突出事故起数及死亡人数统计图

Figure.1.1 Statistics on the number of coal and gas outburst accidents and deaths in China from 2004 to 2014

从上图的统计可看出，近十年来，我国煤矿瓦斯突出事故的发生率极高，造成矿井作

业人员死亡人数巨大，我国煤矿的安全生产正在面临着巨大挑战，形势不容乐观。由于煤与瓦斯突出机理的本质十分复杂，影响煤与瓦斯突出的多种因素和各项条件相互制约并相互影响^[10]。且目前各煤矿煤层的开采深度不断加深，也导致了瓦斯突出灾害的发生越来越复杂。因此，采用传统的预测方法并不能有效预防瓦斯突出的发生，近年来国内外学者通过采用合理、科学的方法对煤与瓦斯突出现象进行研究，提出了多种先进的预测理论，如多指标综合预测法、声发射预测法以及神经网络预测法等，应用更加先进的研究理论，更加准确、快速、有效的预测煤与瓦斯的突出现象，一直是众多学者追求的目标。

1.1.2 研究的意义

煤与瓦斯突出现象是包含大量瓦斯的煤体颗粒以非常快的速度及巨大的冲击力向采掘工作面外侧强烈喷出的过程，是最恶劣的瓦斯类事故之一^[11]。煤与瓦斯突出灾害一旦发生在开采矿井中，其所带来的危险程度是无法事先估计的，突出灾害造成的后果也十分严重，影响范围十分广泛，因此，对瓦斯突出事故的精准预测和有效预防是一项十分重要的工作。由于突出煤矿不能通过研究理论来解释，同时产生突出的诱因、突出的发展细节及突出的发生过程均无法准确定论^[12]，所以在研究煤与瓦斯突出危险性预测问题时，首先要对煤与瓦斯突出的机理与本质特征、突出灾害的防治手段进行全面探讨，并对突出影响因素进行系统分析，建立科学、准确、有效的突出预测模型，对煤与瓦斯突出进行准确、有效的预测，对预防瓦斯突出事故的发生具有很大的实用价值。因此，本论文具有很高的理论价值和很大的意义及前景，为有效预防煤矿瓦斯突出灾害提供了重要的理论支撑。

1.2 煤与瓦斯突出预测方法研究现状

世界上首例煤与瓦斯突出事故发生于法国，该突出事故的发生造成了十分恶劣的后果，顿时引起了世界各国人民对煤矿生产安全的高度重视。1914年，法国还专门建立了防治煤与瓦斯突出的委员会^[13]。煤与瓦斯突出现象不但严重破坏了煤矿行业的经济发展，而且给人们的生命和财产安全带来了重度影响，因此研究出可靠有效的煤与瓦斯突出预测方法是保证煤矿正常生产和有效防突的前提。为最大限度地遏制煤与瓦斯突出灾害带来的伤害，近年来国内外学者对如何有效的预测煤与瓦斯突出进行了长期的研究。现阶段，对瓦斯突出现象进行预测时通常采用以下三种方式：静态非连续预测、动态连续预测及现代数学预测等。

1.2.1 静态非连续预测方法

静态非连续预测方法的关键是确定某些相关的煤与瓦斯突出影响因素并对其进行指标量化操作，通过深入分析这些指标与瓦斯突出现象的相关性，将这些指标赋予各自指定的临界值，根据是否超过特定临界值来判断煤与瓦斯突出事故发生的可能性大小。目前，

该方法主要包括如下几种：

(1) **R 指标法**：该预测方法是 1969 年一位前苏联专家第一次提出的，我国针对该方法进行了大量的实验研究并已经将其编排到我国目前正在使用的防治煤与瓦斯突出细则里面^[14]。该法的预测机理是：根据煤层的钻屑煤量以及该处的瓦斯放散初速度来实现瓦斯突出的预测，当某一特定煤层中这两个指标的值很大时，该煤层发生煤与瓦斯突出的可能性也就越大。

R 指标的具体计算公式如式 (1.1) 所示：

$$R_1 = (S_{\max} - 1.8)(i_{\max} - 4) \quad (1.1)$$

式中， S_{\max} ——每米钻孔钻屑量的最大值；

i_{\max} ——每米钻孔瓦斯放散初速度的最大值。

(2) **钻孔瓦斯涌出初速度法**：该法是由前苏联专家通过大量的现场试验及理论研究提出的一种预测方法。它认为煤与瓦斯突出的危险性可以用钻孔瓦斯涌出初速度来反映，即钻孔瓦斯涌出初速度的大小与煤矿发生瓦斯突出危险性的大小存在正比例的关系。通常在使用该方法进行突出预测时，钻孔瓦斯涌出初速度 q 的突出临界值判定方式如表 1.1 所示。此外，煤体的挥发成分也会对钻孔瓦斯涌出初速度 q 产生一定程度的作用与影响，在实际预测时也要将煤体的挥发成分考虑进去。

表 1.1 钻孔瓦斯初速度 q 的突出危险临界值
Table 1.1 Dangerous critical value of outburst of drilling gas velocity

煤的挥发分 (V/%)	5~15	15~20	20~30	>>30
$Q(L \cdot \min^{-1})$	5.0	4.5	4.0	3.5

(3) **V30 及 KV 指标法**^[15]：德国学者通过研究 V30 和 KV 这两个指标得出如下理论：若 V30 值的大小和该煤层崩落煤可解析瓦斯量的百分之四十相等或者已经大于了这个值，那么就表示该煤层具有一定程度的煤与瓦斯突出可能性；进一步，V30 的数值如果已经接近可解析瓦斯量的 60% 或者已经越过了 60% 这个值，就说明该煤层已经具有突出危险性。

(4) **单项指标法**：单项指标法就是对一系列综合特征指标的一种量化。目前，该指标预测方法已经广泛运用在国内外煤矿瓦斯灾害预测中。1958 年，前苏联科学院通过大量的现场实践与理论研究将煤体破坏类型以新的方式进行划分，定义了五种破坏类型，并将第 IV 及第 V 类的煤体判定为存在突出危险的煤层。1991 年，焦作矿业学院的学者对煤体的结构类型进行了深入研究，通过分析各种煤体的结构不同点及其对应的发生突出的难易性，定义了另一种煤体类型表示方式，该方法将煤体结构以四种形式划分，并将处于第 III 型及 IV 型的煤体定义为存在突出可能性的两种煤体，该方法目前已经成功地应用在了煤与瓦斯突出预测领域中^[16-18]。

目前，常用的突出危险性指标的指标临界值如表 1.2 所示：

表 1.2 预测突出危险性单项指标临界值
Table1.2 The single index critical value of forecasting outburst danger

突出危险性	破坏类型	煤层瓦斯压力 P/MPa	瓦斯放散初速度 $\Delta P/\text{mmHg}$	煤的坚固性系数 f
有	III、IV、V	$\geq 0.74\text{MPa}$	≥ 10	< 0.5
无	I、II	$< 0.74\text{MPa}$	< 10	≥ 0.5

(5) D、K 综合指标法：该法是我国煤炭科学研究总院抚顺分院相关领域的众多学者通过对处于不同状态的突出煤矿进行统计和深入分析而提出的一种预测方法^[19-20]，并在实际应用中取得了较好的效果，而且已经被写入到我国煤矿防突细则中，得到了众多学者的认可。D、K 综合指标的求解方式分别如公式 (1.2) 与公式 (1.3) 所示：

$$D = \left(\frac{0.0075H}{f} - 3 \right) (p - 0.74) \quad (1.2)$$

$$K = \frac{\Delta p}{f} \quad (1.3)$$

式 (1.2) 中， D 为预测使用到的一个综合指标； H 为该煤层当前的垂深； P 为该处瓦斯压力的值。式 (1.3) 中， K 为利用该方法预测时用到的另一种综合指标， f 代表的是此处煤岩体的平均坚固性系数； Δp 反映的是该处煤层的瓦斯放散初速度数值的大小。

在测定煤的坚固性系数 f 时，必须采用特定的粒度标准(10~15mm)来进行测试，若在测定过程中，测试选用的煤体粒度无法满足特定的要求，那么就不能直接采用该煤样进行测量，必须要选取粒度为 1~3mm 的粒度煤样去代替原来的煤样进行 f 值测定^[21-22]，粒度的变换公式如式 (1.4) 所示：

$$\begin{aligned} f &= f_1 (f_1 \leq 0.25) \\ f &= 1.57, f_1 = 0.14 (f_1 > 0.25) \end{aligned} \quad (1.4)$$

式中， f_1 为采用替代煤样测定所得出的系数值。

在使用 D、K 综合指标法时，必须要按照具体煤矿的历史实际测量数据来计算 D、K 这两个指标的突出临界值，在临界值没有确定以前，D、K 综合指标临界值的设定可以暂时参考表 1.3。此外，当 D 值中两个括号内的计算值都小于零时，那么就不用考虑其值大小可以直接判断该煤层为突出危险区。

表 1.3 突出危险性临界值
Table1.3 The critical value of outburst danger

突出危险性指标		突出危险性	备注
D	K		
< 0.25	/	无	无烟煤煤层突出 危险性指标 $K=20$
≥ 0.25	< 15	无	
≥ 0.25	≥ 15	有	

(6) 钻屑瓦斯解吸指标法：在我国的《防治煤与瓦斯突出细则》中同样也收录了钻

屑瓦斯解吸指标预测方法。

预测原理为：在工作面正前方煤体区域打出 2-3 个指定大小的小孔，测量钻屑瓦斯解吸指标 K_1 、 Δh_2 以及该处的钻屑量 S ，对钻取 1m 的钻屑量以及 2m 的瓦斯解吸指标 K_1 、 Δh 值也同时进行测定。根据 S 、 K_1 、 Δh 三种指标是否超限和煤层有无突出现象对煤与瓦斯突出危险性进行判断^[23]，各指标临界值如表 1.4 所示：

表 1.4 钻屑指标法各指标的临界值
Table 1.4 Critical value of drilling index method

指标 $\Delta h_2(Pa)$	指标 $K_1 (mL/g \cdot min)$	钻屑量 S	
		(Kg/m)	(L/m)
200	0.5	6	5.4

1.2.2 动态连续预测方法

动态连续预测方法是选取一个或一系列能够较大程度上反映煤与瓦斯突出现象的预测指标作为监测对象，通过对这些指标的不间断监测，根据指标的变化趋势来确定采煤工作面发生煤与瓦斯突出现象的可能性大小^[24]。动态连续预测方法在实际瓦斯突出现象预测过程中，涉及的相关参数较少，工程量也相对较少，预测时间快，比静态非连续预测方法要方便快捷，因此，受到煤矿领域国内外诸多学者的广泛应用，获得了多数矿井安全研究者的支持。目前，该类预测方法主要有以下几种方法：

(1) 电磁辐射强度监测法：俄罗斯学者 Frid 通过研究发现在煤与瓦斯突出的发生过程中往往会伴随着大量的电磁辐射信号，并进一步分析这一现象得出突出过程中伴随的电磁辐射信号异常现象与瓦斯突出灾害的发生及形成存在一定程度的关联性，首次提出可以依靠煤岩破裂时产生的电磁辐射效应对煤与瓦斯突出现象进行预测^[25]。得出结论：煤体破裂时产生的电磁辐射强度若急剧变大，则发生突出事故的可能性就很大。

(2) 声发射监测法：1974 年，前苏联学者深入研究了声发射技术的基本理论并将其应用在了煤与瓦斯突出预测领域中，20 世纪 60 年代，澳大利亚学者发明了双声道声发射突出预警系统^[26]，此外，世界上其他一些国家，包括我国也对声发射预测法进行了不同程度的研究，目前，此法已经成为了有效预测煤与瓦斯突出的一种新形式。

(3) 煤层稀有气体浓度变化预测法：近年来，许多学者将氦气和氡气的变化作为预测突出是否发生的一个重要预测指标。原苏联学者首次提出可以利用煤层中的稀有气体来预测煤与瓦斯突出现象，他们以顿涅茨煤田为研究背景，将该煤矿中全部突出煤层与无突出煤层中所含有的氦气含量进行了统计与研究，得出结论：在瓦斯发生突出时，涌出气体中这两种稀有气体的含量及浓度会突然升高，此时发生突出灾害的可能性也就越大。因此，可以通过检测涌出气体中氦气和氡气的浓度对瓦斯突出现象进行预测^[27]。

(4) 物探法：物探法也称无线电波透视探测技术。学者通过研究煤与瓦斯突出区域

的地质发现,在煤与瓦斯突出的高频突出地区,经常会存在很多地质异常特征,因此用无线电波可以较准确的确定该地质区域的突出危险性,为采煤工作面的安全提供了保障^[28]。

(5) 煤层温度变化法:近年来,煤层温度变化法已经逐渐被应用到煤与瓦斯突出预测领域中。国内外学者通过大量实验和现场测定分析,得出:可以通过计算采煤工作面的煤层温度和煤层原始温度之间的差值来预测煤与瓦斯突出发生的概率大小。煤层温差越大,则发生瓦斯突出危险性越大。

1.2.3 现代数学预测方法

近年来,随着数学领域的快速发展,许多学者根据煤与瓦斯突出现象的复杂性及非线性特点,在分析上述传统预测方法优缺点的基础上,把先进的数学方法与传统预测理论相结合,建立了多种先进的现代化非线性预测模型,并应用在了煤与瓦斯突出预测领域。

第一,基于人工神经网络的预测方法。目前在煤与瓦斯突出领域中已经成功的引用了人工神经网络来进行突出预测。郝吉生^[29]在 BP 神经网络的基础上引入学习系数及惯性系数的调整策略来提高 BP 网络的泛化性能,使基于 BP 网络的煤与瓦斯突出预测模型的预测速度和准确率都有了明显的提高;田云丽等^[30]为提高 BP 模型的收敛速度,将 ULBP 及 LMBP 算法引入到 BP 神经网络中,极大的提高了模型的预测效率。

第二,基于混沌动力学的预测方法。将现有的混沌理论融入到煤与瓦斯突出预测领域中,对预防煤矿瓦斯灾害、瓦斯涌出量预测等方面的研究起到了很大作用。例如;赵志刚等^[31]在深入研究混沌理论的基础上,将混沌时间序列引入到煤与瓦斯突出预测中,提出了基于混沌理论的煤与瓦斯突出预测方法。

第三,基于灰色理论的预测方法。我国邓聚龙教授在现有丰富的数学理论基础上,通过深入研究现代先进的数学方法,并将两者进行有机结合,提出了应用十分广泛的灰色系统理论,随后一些学者将该理论引入到煤与瓦斯突出预测领域中,并取得了较好的效果。例如,郭德勇等^[32]在分析煤与瓦斯突出主要影响因素时采用了灰色系统理论中的灰色关联法,较准确的提取了影响瓦斯突出的主控因素,提高了预测模型的准确率,减少了预测所需的时间。

第四,基于模糊理论的预测方法。孙艳玲等^[33]利用模糊聚类分析方法对原始的突出数据进行处理,将其分成了几种具有不同突出等级的模糊模式,并使用关联分析法对预测样本和不同等级的模糊模式进行了关联性处理,使预测模型的预测准确率有了很大的提高。

第五,其他非线性预测方法。支持向量机与极限学习机也在煤与瓦斯突出预测方面有着很广泛的应用,此外,还有专家系统、信息融合等理论也经常被用来预测煤与瓦斯突出的危险性。

综上所述,这些方法都是通过引入不同的数学方法来建立预测模型,以多种先进的数学理论来对煤与瓦斯突出现象进行预测,对现有的突出预测方法进行改进与创新,极大地

促进了瓦斯突出预测领域的快速发展。

结合煤与瓦斯突出预测目前的研究现状可知,虽然较为成熟的突出预测方法已经有很多,但是由于煤与瓦斯突出机理尚不明确,影响煤与瓦斯突出各相关因素间的关系比较复杂,多种变量之间具有极大的相关性和非线性,现有预测方法仅仅选用几项因素来进行研究,由于某些致突因素的缺少就会导致预测方法的预测速度较慢、预测结果不准确;此外,随着煤矿生产设备和系统的不断更新,需要考虑的影响因素越来越多,现有的预测方法难以满足实际煤矿的预测精度需求。因此,还需进一步深入研究影响突出的致突因素,采用先进的理论来建立煤与瓦斯突出预测模型,以提高煤与瓦斯突出的预测速度和预测准确率,对煤与瓦斯突出现象进行有效防治。

1.3 本文研究内容及结构安排

1.3.1 主要研究内容

本文在深入研究煤与瓦斯突出机理和影响煤与瓦斯突出因素的基础上,提出基于核主成分分析与改进极限学习机的掘进工作面煤与瓦斯突出预测方法。分别从面域化预测指标系统的确定、预测指标的核主成分分析、极限学习机预测模型的建立、预测模型的实现与验证方面进行了研究。主要研究内容为:

(1) 讨论研究煤与瓦斯突出机理及影响突出的致突因素,建立了掘进工作面煤与瓦斯突出预测指标系统,利用核主成分分析对面域化预测指标进行权重分析,提取出了与煤矿实际相符合的主要预测指标。

(2) 提出采用改进量子遗传(IQGA)算法对极限学习机(ELM)输入层权值及隐含层阈值进行优化,构建了一种基于核主成分分析(KPCA)方法与改进 ELM 网络相结合的煤与瓦斯突出预测模型。

(3) 利用矿井历史突出数据进行实例验证,证明了该模型的泛化能力及预测准确性,并与其他模型进行对比,体现了该预测模型的优越性。

1.3.2 论文的结构安排与技术路线图

本文的章节安排如下:

第一章:概述了论文研究煤与瓦斯突出的背景和意义;讨论了目前煤与瓦斯突出预测方法的研究现状;说明了论文所研究的主要内容及文章内部的结构安排。

第二章:阐述了煤与瓦斯的突出机理;总结了现阶段煤与瓦斯突出的各类假说;分析了影响煤与瓦斯突出的主要因素;最后建立了面域化煤与瓦斯突出预测指标系统。

第三章:介绍了核方法理论;阐述了核主成分分析的基本原理;分析了核主成分分析特征提取步骤;最后讨论了核主成分分析法的适应性。

第四章:通过对极限学习机理论及算法的研究,引入改进量子遗传算法对极限学习机

进一步优化，建立了基于 IQGA 算法优化的 ELM 预测模型，并分析该预测模型的可行性。

第五章：建立基于核主成分分析与改进极限学习机的煤与瓦斯突出预测模型，结合矿井实际情况，验证预测模型的有效性。

第六章：对论文的主要内容进行总结与分析，展望该课题需要进一步研究的内容。

本文的技术路线如图 1.2 所示。

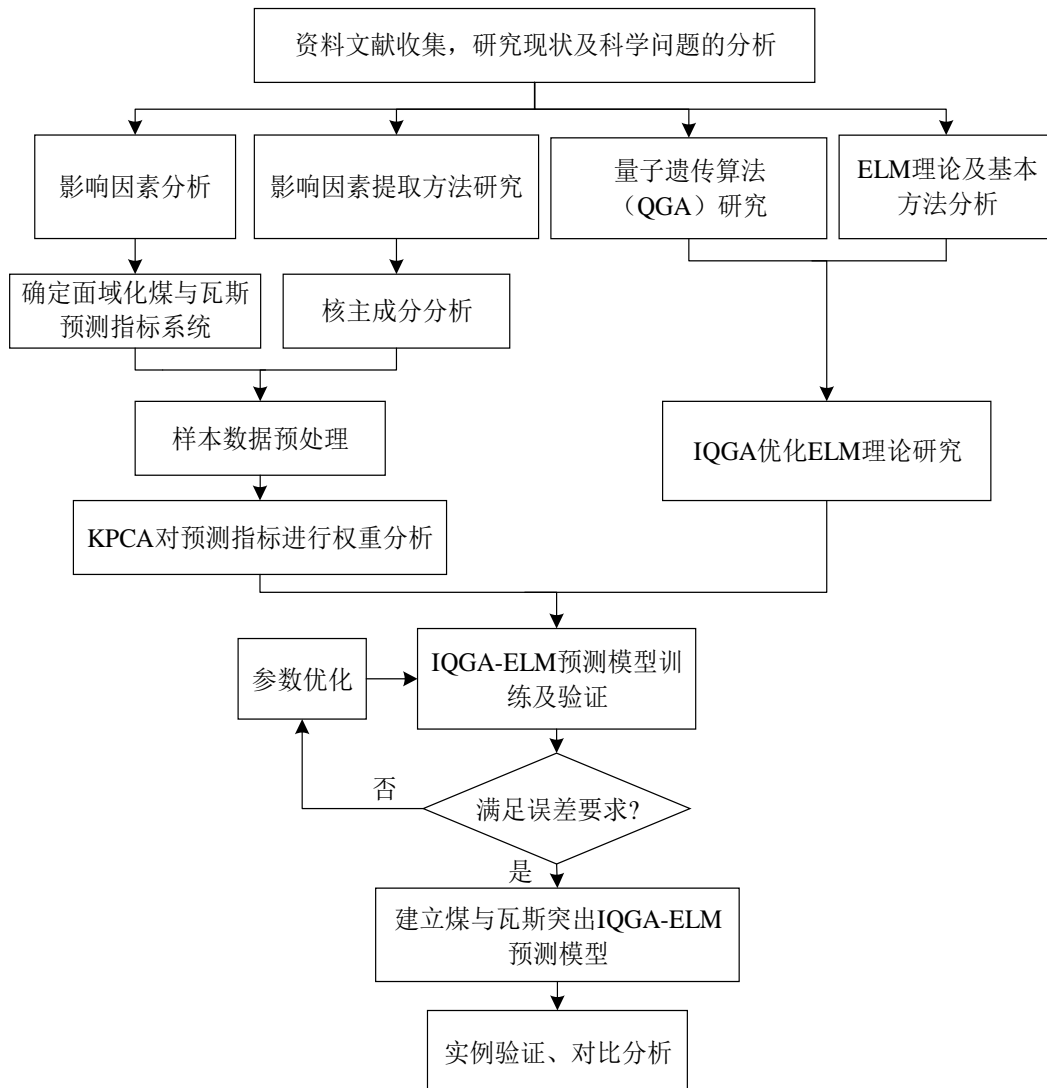


图 1.2 技术路线图

Figure1.2 Technical roadmap

2 煤与瓦斯突出机理及影响因素

2.1 煤与瓦斯突出机理研究现状

矿井煤与瓦斯突出是极其复杂的灾害之一，突出现象的发生会对矿井和工作人员产生不可挽回的恶劣后果。要对瓦斯突出灾害进行有效的预防，就必须对突出产生的内部原因、外部条件、发生过程以及突出的过程进行研究。由于煤与瓦斯突出现象往往发生的比较突然，呈现极不规律性，所以现阶段人们对于煤与瓦斯突出机理的描述通常应用假说形式来体现。国内外学者通过对煤矿煤与瓦斯突出实例的分析与研究，逐渐提出了多种从不同方面来分析突出原理的突出机理假说。

（1）地应力作用假说

在该类假说中，主要论述的是地应力这一种主控指标对突出现象出现的激发作用，假说指出当煤体中的煤层受到较高的地应力作用时，煤层会由于地应力过大而导致煤与瓦斯突出现象的发生。共包括“应力集中说”、“岩石变形潜能说”等八种假说。

其中，岩石变形潜能说认为，在煤层底板或顶板的岩层中存在着以弹性势能存在的构造应力，当开采接近了这样的岩层时，由于人的采动行为就会破坏这种构造应力，此时，弹性势能的释放会将煤体破坏成非常小的煤体颗粒并以十分快的速度将这些煤岩带出煤层，引起大量的瓦斯急剧喷出，就引发了煤与瓦斯的突出。

（2）瓦斯主导作用假说

该类假说主要体现的是瓦斯因素在煤与瓦斯突出发生过程中的主导作用，假说指出煤层会发生瓦斯突出现象的根本原因是煤体结构的内部包含了大量高瓦斯气体，正是内部瓦斯的含量非常高才诱发了煤与瓦斯突出现象的产生。主要有“瓦斯包说”、“瓦斯解吸收说”、“卸压瓦斯说”等十一种不同的假说。

其中，瓦斯包说认为煤层中存在一种这样的煤窝，其煤岩体内的瓦斯含量和瓦斯压力均比临近区域高很多。由于瓦斯压力具有强大的作用力，在开采过程中一旦揭开这个包含强大瓦斯储存的瓦斯包，松软的煤体会由于强作用力的碰撞破碎成小颗粒，并被大量抛出，这样就造成了煤与瓦斯突出灾害的发生。该学说被认为是突出动力的来源，在瓦斯突出机理中是极其重要的一种理论。

（3）化学本质假说

该类假说认为煤与瓦斯突出是因为煤变质时产生了一系列的化学反应，诱发了突出。主要学说有“硝基化合物说”、“重煤说”、“煤体爆炸说”等。

其中，“煤体爆炸说”认为，由于煤的变质作用在煤的介稳区迅速产生了大量的二氧化碳和甲烷，并进一步引发了爆炸，这种爆炸就是煤与瓦斯的突出现象。

（4）综合作用假说

该类假说主要强调的是地应力、瓦斯压力及煤体力学特性这三种因素的综合作用，假说指出煤与瓦斯突出现象的产生是这三种因素在一定条件下的叠加作用结果，而且假说中还描述了突出过程中的动力及阻力这两种力学对瓦斯突出现象起到的作用及影响，由于该假说考虑的影响因素较其他假说更加全面，所以目前该类假说是煤矿领域众多研究者相对比较认可的突出假说。主要有“能量假说”、“振动说”等多种假说。

（5）其他假说

除了上述四种假说之外，近年来，随着对煤与瓦斯突出现象的深入研究，许多新兴的其他假说也逐渐被提出。

球壳失稳假说^[34]就是新型假说的一种，是在 1995 年被中国矿业大学学者提出的一个理论假说。假说指出在石门研究煤与瓦斯突出所产生的动力现象过程时，煤岩的破坏过程具有球盖状球壳的产生、发展以及失稳的主要特征，虽然煤体受到地应力作用时会引起结构破坏产生突出，但这仅仅是突出存在的必要条件，而远远不是该处煤层会发生瓦斯突出现象的充分条件。同时该假说认为当石门揭煤条件在理想状态下时，煤层不具备发生突出的危险性及可能发生突出的概率大小仅仅与瓦斯压力、地应力及煤体强度存在一定的关联性，而且地应力、瓦斯压力及煤体强度这三种因素只对发生破裂后的初始释放瓦斯膨胀能产生作用，因此要想确定某处煤体有无发生煤与瓦斯突出现象的可能性，仅仅需要测量该处煤体的软煤厚度及初始释放瓦斯膨胀能这两个参数即可。

流变假说^[35]是学者在深入分析煤与瓦斯突出机理的基础上而提出的一种其他形式的瓦斯突出机理假说。该假说指出含有瓦斯的煤体受到地应力的作用时，如果没有满足屈服载荷要求，那么煤体的蠕变过程就存在着明显的衰减倾向；一旦满足或越过了载荷时，就会产生明显的变形减速、匀速变形、变形加速这三个过程，煤与瓦斯突出的孕育过程体现在了前两个阶段，突出的发生及发展则体现在了最后一个阶段；所有的煤体只要其含有瓦斯，无论瓦斯含量多少，其都存在一定的流变性质，不同煤体的流变行为都是受到各自煤层的外部状态和煤体自身物理性质这两种因素共同影响的，一旦一个内部包含瓦斯的煤体开始呈现出流变趋势时，就说明该煤层有发生煤与瓦斯突出的倾向。

二相流体假说^[36]也是一种新兴的假说形式，是李萍丰教授通过研究煤岩体的本质特性而提出的一种突出说法。其指出掘进工作面其实是受到地应力的强大作用的，因此处于掘进工作面之前的煤岩区域可以依据该假说被划分成四个部分，并且将这四个区域依次命名为突出阻碍区、控制区、中心区及能量补给区。

迄今为止，国内外学者对煤与瓦斯突出这种复杂现象仍然没有统一的解释，对煤与瓦斯的突出机理仍存在不同意见，各种突出假说虽然有一定程度的片面性，但是却为人们认识并研究煤与瓦斯突出做出了巨大贡献，为学者们进一步深入研究煤与瓦斯突出的防治手段提供了强大的科学基础。

2.2 煤与瓦斯突出发展过程及一般规律

2.2.1 煤与瓦斯突出的发展过程

煤与瓦斯突出的发展演化进程可分成准备、激发、发展及终止这四种阶段。

阶段一：突出准备。在该阶段，煤岩体会出现许多静态或者动态的特征，例如会发出一些特殊声音，或无任何声音，仅内部发生变化。煤岩的受力状态、瓦斯压力以及煤体的物理力学性质等都会产生一定程度的变化。

阶段二：突出激发。多数的突出事故都是因为对采煤工作面的高强度作业破坏了煤体应力的平衡，使煤岩的弹性势能突然释放，大量瓦斯伴随着破碎的煤体被散放出来，不仅导致瓦斯含量与浓度快速升高，瓦斯压力也会大大增大，在这种高压高瓦斯状态下就导致了瓦斯突出灾害的发生。

阶段三：突出发展。该阶段分为两个子过程，一是煤岩体受到地应力、瓦斯压力的影响，煤体开始发生缓慢的粉状变化从而出现层状状态；二是随着煤岩体的不断破坏，大量瓦斯被解吸出来，瓦斯内能逐渐增大，导致被粉碎的煤岩体受到高瓦斯压力的作用陆续向外喷出。影响瓦斯突出发展阶段的主要因素有煤体中的瓦斯放散初速度、煤体破坏程度等，这些因素在瓦斯突出发展阶段起到了非常重要的作用。

阶段四：突出终止。突出终止的条件有以下两种情况：一是由于在突出过程中遇到高硬度煤岩，导致瓦斯突出的线路被堵塞；二是由于突出激发阶段突出的能量已经被完全消耗掉，瓦斯的能量不足以粉碎岩层时达到突出终止阶段。值得注意的是，由于在突出终止后，瓦斯会继续解吸，煤体继续被破坏，瓦斯加剧解吸，导致在突出结束后仍然会出现瓦斯外涌现象。

2.2.2 煤与瓦斯突出一般规律

参考大量矿井煤与瓦斯突出相关文献及理论，对现有研究结论进行分析与总结，可以得出煤与瓦斯突出的一般规律如下：

(1) 始突深度是指发生第一次突出的最浅深度。在同一煤层进行多次开采工作时，煤层所处的开采深度会由于多次采动而不断加深，垂深的每一次加深都代表着多一份发生煤与瓦斯突出危险的可能性，而且发生突出的强度也会愈来愈强。

(2) 瓦斯突出的大小和发生可能性与煤层中软分层厚度具有很大的联系。如果某中软分层的厚度非常大，那么该地区发生煤与瓦斯突出危险的可能性也就越大，而且软分层的厚度越厚，突出灾害发生的危害程度也越严重。

(3) 一般情况下，煤与瓦斯突出危险区域以带状不均匀分布形式存在，这是由于煤与瓦斯突出的发生与否很大程度上受到地质构造控制的影响。

(4) 煤层含水量与发生突出危险性的概率成反比例关系。当煤层足够湿润时，矿井

内的涌水量就会很大，那么发生突出的危险性就会很小。

(5) 煤矿突出气体主要是以瓦斯为主，个别矿井会同时产生二氧化碳。在煤层相同的条件下，瓦斯压力大小与发生突出危险的可能性大小成正比例关系。

(6) 突出的发生和煤自重、煤层倾角的大小有关，煤层倾角较大的区域发生突出的可能性更大。

(7) 在采掘作业过程中，如果所处煤层受到强大的外力影响也极易发生瓦斯突出危险。例如开采过程中的打眼、放炮等测试手段，如果测试操作实施不当，则会引起突出现象的发生。

(8) 存在一定程度的滞后突出危险性。滞后突出指的是在爆破后没有立刻发生瓦斯突出现象，而是在一段时间后会突出。

(9) 煤层发生瓦斯突出的危险性与煤岩周围的围岩结构性质有密切联系，如果围岩非常硬而且特别厚，那么发生突出危险的可能性就越大。

(10) 突出发生之前大多数会呈现出有声预兆与无声预兆。

2.3 煤与瓦斯突出影响因素

通过对煤与瓦斯突出机理和突出发展过程的深入分析可知，导致发生煤与瓦斯突出现象的原因有很多，要想实现高精度的煤与瓦斯突出预测研究，就必须要对引起瓦斯突出现象的各种因素及指标进行深度的讨论与分析。因此依据突出原理，得出影响煤与瓦斯突出的因素至少包括以下几种。

(1) 地应力

地应力是地质构造运动的动力，在其作用下，就会引起各种地质灾害，例如地壳形变、断裂活动等。地应力一旦得到很大程度的升高，那么煤层的瓦斯突出动力也会变得很大，而且同时处于该煤层的煤岩煤体强度也会减少很多，此时瓦斯压力就会获得有利环境，其值会迅速增强，进而导致煤与瓦斯突出^[37]。

(2) 煤体结构

分析资料可以得知煤与瓦斯突出事故中有超过大半的灾害都是出现在地质构造带及煤层各自的软分层周围，这是由于在地质构造带附近的煤岩体受到的地应力要大于其他区域所受到的地应力，而且该处的煤体破坏程度也是最高的^[38-39]。处于软分层中的煤岩体，它们的煤体质量都相对比较松软，很容易被地应力及膨胀的瓦斯所破坏，另外在其孔隙结构中能够储存大量的瓦斯，对瓦斯突出的发生发展起了很大的作用，因此煤体结构也在很大程度上影响着煤与瓦斯突出。此外，煤体结构在煤与瓦斯突出过程中具有双面性，既可以防止瓦斯突出的发生，同时也为突出提供着巨大的能量。

(3) 瓦斯赋存状态

瓦斯膨胀能也为煤与瓦斯突出的发生发展提供能量补充。煤岩中瓦斯的赋存方式存在

两类，一类是游离态，另一类是吸附态。通过查阅资料可以知道，大约 90% 以上的瓦斯通常都是吸附在裂缝及煤体孔隙中，瓦斯的两种状态之间是可以相互转换的，在外界环境条件不变的前提下，瓦斯内在通常保持着一种动态平衡状态^[40]。

在发生煤与瓦斯突出现象时，煤层会将大量的瓦斯从煤层内部向外不断涌出，而从煤层中涌出的瓦斯量是远远多于煤层中瓦斯的含量。因此，在突出过程中，涌出的瓦斯大多是来源于煤体孔隙和裂缝中，由吸附原理可知，煤体孔隙越多，瓦斯吸附的能力就越强，发生瓦斯突出时瓦斯的涌出含量就会越多。一旦煤岩体遭到破坏，瓦斯压力会突然急剧增大，吸附于孔隙中的瓦斯就会被解吸到游离状态，把瓦斯从内能形式转化为瓦斯膨胀能形式。此外，在瓦斯吸附解吸的同时，煤体的硬度会大大降低，更加容易导致煤与瓦斯的突出。因此在突出过程中瓦斯的赋存状态也是导致瓦斯突出的关键指标之一^[41]。

（4）人为因素

在考虑影响煤与瓦斯突出的因素时，往往只考虑了煤体自身的一些因素，很少考虑人为因素。在掘进工作面进行开采时常常会因为开采计划的不合理或不正确的开采顺序导致瓦斯的突出。煤与瓦斯突出最直接的因素其实就是人的采动行为。由于人们对矿井的开采不合理，使煤岩体的应力分布及瓦斯压力分布不均匀，长此以往，最终可能会导致瓦斯突出。因此，在突出预测中人为因素是不可忽略的。

此外，在煤与瓦斯突出的预测研究过程中，我们可以通过采集突出发生发展过程中的各种参量及影响因素来进行灾害预测，建立煤与瓦斯突出预测指标参数集，实现对瓦斯突出现象的有效预测。

2.4 煤与瓦斯预测指标的选取

在对煤与瓦斯突出现象进行实际预测操作时，由于目前人们对煤与瓦斯突出的本质机理研究暂不全面，所以为了更全面、更真切地预测出矿井突出情况，我们通常需要研究包括地应力、瓦斯放散初速度等在内的多种预测指标，该预测指标亦称作模型的输入变量。为使模型的预测准确率更高，我们要尽可能将多种预测指标输入至预测模型中。因此，为了有效预测煤与瓦斯的突出情况，达到高精度的预测效果，在多种影响因素中如何合理的选取指标来作为突出预测指标是十分重要的。

通过查阅煤与瓦斯突出相关资料可以得知，我国 60% 以上的煤与瓦斯突出事故都是发生在煤层掘进工作面上，因此深入研究煤矿掘进工作面区域范围内的瓦斯突出影响指标对提前预测煤与瓦斯突出灾害的出现有着极其重要的意义^[42]。本文通过查阅大量的煤与瓦斯突出文献及相关资料，在深入分析现有突出事故历史数据的基础上，考虑各影响因素选取的难易程度，选取了 13 个掘进工作面影响因素作为本文研究的预测指标，新建了一种基于煤矿掘进工作面的面域化预测指标系统，该系统由地应力因素、瓦斯因素、煤体本质特征、地质特征及其他因素五个方面构成，具体结构如图 2.1 所示。

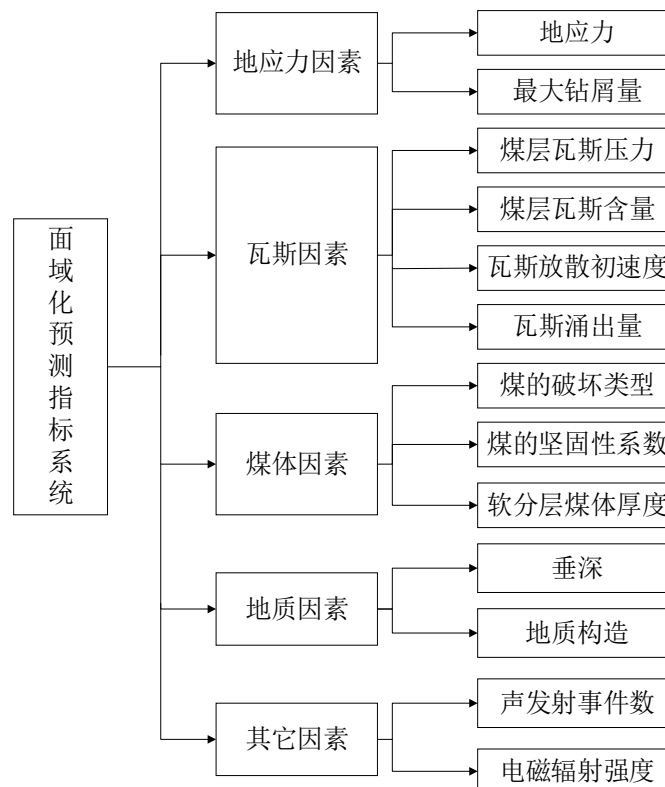


图 2.1 面域化预测指标系统

Figure 2.1 Area prediction indicator system

(1) 地应力：地应力是影响煤层发生煤与瓦斯突出现象的重要主控指标之一，为突出提供了动力基础。

(2) 煤的坚固性系数：当某一煤层中煤体的坚固性系数值比较小时，其出现煤与瓦斯突出现象的概率较大；否则，则不易出现瓦斯突出现象。

(3) 声发射事件数：煤岩体发生破裂时会出现声发射现象，研究煤岩体的声发射现象能够很好的反应出煤体内部的破坏过程和当前煤体所处的状态，当矿井掘进工作面煤体结构稳定时，声发射事件数量较少，当煤体发生破裂时，声发射事件的数量会急剧升高，这种情况则表明该处煤层可能会发生瓦斯突出危险。

(4) 垂深：当煤矿开采深度陆续加深时，该处煤层所受到的地应力也会逐渐慢慢增大，煤层的突出强度自然也会随之变大。

(5) 煤层瓦斯压力：瓦斯压力的特性决定了煤与瓦斯突出的危险程度，是煤与瓦斯突出重要的一项指标。

(6) 瓦斯放散初速度：瓦斯放散初速度值的大小代表了该处煤层向外涌出瓦斯的速度的快慢，如果该值比较大，则表明该煤层发生瓦斯突出的危险性也就越大。

(7) 煤层瓦斯含量：瓦斯含量与瓦斯突出具有极大的相关性，瓦斯含量越高，则该煤层发生突出可能性越大。

(8) 瓦斯涌出量：掘进工作面瓦斯涌出量的多少是判断瓦斯突出与否的重要因素之一，瓦斯涌出量在突出的准备阶段会出现瓦斯浓度降低后骤然升高的不稳定现象，可根据

瓦斯涌出量的大小来判断煤与瓦斯的突出可能性。

(9) 地质构造：地质构造是决定煤层突出与否的关键因素之一，研究发现在煤矿所有的地质类型中，极易出现瓦斯突出灾害的地质构造存在两类，一类是受到局部集中作用的低含量瓦斯煤矿，另一类是自身含有大量高瓦斯的煤矿。

(10) 煤体破坏类型：煤体结构的破坏程度与是否发生瓦斯突出现象存在一定程度的关联性，严重的煤体破坏程度不仅会导致煤体本身的强度大大降低，而且还会使正常的煤体结构遭到严重破碎，造成其构造裂隙不断增加，从而增加了该处煤层发生突出现象的概率。

(11) 软分层煤体厚度：若软分层煤体厚度不均匀，则发生煤与瓦斯突出事故次数越多，因此，突出事故次数及发生突出的强度与软分层煤体厚度是正比例关系。

(12) 最大钻屑量：最大钻屑量综合地反映了地应力、煤体结构和瓦斯压力这三个决定突出危险性的主要因素。

(13) 电磁辐射强度：大量研究表明，煤体变形破裂时会向外辐射电磁能量，而且当电磁辐射信号出现较大异常变化或强度值突然变大，则表明该处煤层存在发生突出危险的可能性。

2.5 本章小结

本章在分析煤与瓦斯突出机理和突出发生发展过程的基础上，研究了影响煤与瓦斯突出的相关因素，并针对掘进工作面突出发生率较高的特点，建立了具有 13 项预测指标的基于煤与瓦斯突出的面域化预测指标系统，为有效、准确的预测瓦斯突出奠定了基础。

3 煤与瓦斯突出预测指标系统的核主成分分析

对于前一节建立的煤与瓦斯突出面域化预测指标系统,为了更好的反映出煤与瓦斯突出的真实情况,本文选择了 13 项影响因素作为预测指标,预测指标选取较多,而直接采用这些指标作为预测模型的输入必然会增加模型的复杂度,在一定程度上影响模型的预测速率及准确率。而且各预测指标间的关系也相对复杂,指标间的相互作用会造成信息数据的大量重叠,使各预测指标之间存在着一定的冗余关系。例如,在煤层地质构造带区域周围往往会存在瓦斯含量、瓦斯压力、煤层厚度等多种因素的改变,而瓦斯压力突变地点也经常出现在地质构造带区域范围内;瓦斯压力与地应力之间具有密不可分的关系,而且处于同一煤层的瓦斯压力与该处的瓦斯含量值往往存在一定程度的内在关联。

各致突因素间的冗余关系不仅会使模型的预测速率减慢,有时更会对结果的准确率产生很大的影响甚至可能会使因素间的内在规律消失。所以,在确定模型的输入变量时,要尽量选取较少的预测指标来最大程度的代表所有原始信息,且保证各指标间的相关性要相对较小。因此本文采用核主成分分析(KPCA)方法来对各预测指标数据进行信息整合,对众多预测指标作权重分析,提取其主成分来反映原预测指标系统的全部信息,使模型的架构更加简单,计算速度更迅速,以提高预测精度。

3.1 核主成分分析相关理论

核主成分分析方法是在主成分分析(PCA)算法基础上提出的一种非线性特征提取理论,可以有效的处理 PCA 算法无法解决的非线性复杂问题,其主要优点就是引入了先进的核方法思想,使算法对非线性数据的处理能力得到了很大程度的提高,因其强大的数据分析能力、快速的处理速度,该方法被众多学者广泛运用在特征降维、模式识别等各种领域。

3.1.1 核方法的基本思想

核方法是线性到非线性之间的一种转换媒介,早在 20 世纪初期数学专家就已经开始对核方法的原理进行了分析研究。近些年来,随着数学理论在实际工程中的广泛应用,核方法理论才逐渐得到了国内外诸多学者的重视和应用,逐步研究出了多种基于核方法的相关数学理论和方法。

核方法是对多种先进数据处理技术的统称,这些处理技术的共同点是都在方法中应用了核映射。它的提出为线性数据与非线性数据之间的转换提供了渠道,近年来,各种基于核方法的理论和研究逐渐应用在各个领域。其本质是在传统方法的基础上采用一种非线性处理能力极强的非线性函数,将原始空间内的大量复杂信息通过引入的函数映射至一个线性可分的高维数据空间内,并在此空间中采用数据处理方法对信息特征提取,减少冗余特征信息,从而大大的减化了运算过程中的计算量^[43]。在核方法的理论中很好的融入了非线

性映射的概念，而非线性映射的原理通常都特别复杂，所以正是由于其这点特性，算法对非线性高维复杂数据信息的处理能力得到了很大的提高。

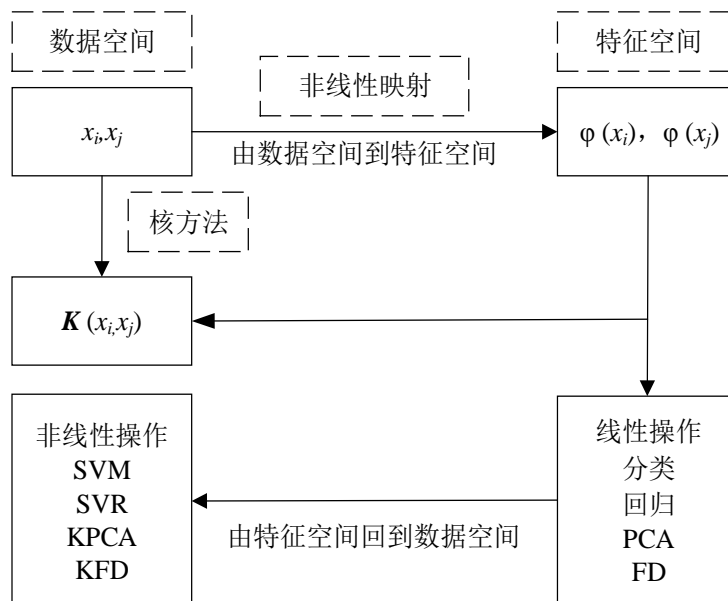


图 3.1 核方法映射关系

Figure3.1 Kernel method mapping

观察图 3.1 可知，若某一数据空间内存在两个不相同的数据点 x_i, x_j ， $\Phi(\bullet)$ 为所选用的映射函数，则数据点一定满足公式 (3.1)：

$$(x_i, x_j) \rightarrow K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j) \quad (3.1)$$

一般，映射函数 $\Phi(\bullet)$ 是十分复杂的，而在实际计算时使用到的核函数 $K(\bullet, \bullet)$ 就相对来说比较简单，这也成为了核方法的巨大优点之一。

所有类型的核函数都一定要符合 *Mercer* 的判断规定：随机给定某对称函数 $K(x_i, x_j)$ ，该对称函数能够充当特征空间 F 里面存在的一个内积运算的充要要求是：其对随机一个不是零的满足 $\int g(x)^2 dx < \infty$ 的函数 $g(x)$ ，有：

$$\int K(x, y) g(x) g(y) dx dy \geq 0 \quad (3.2)$$

若设输入数据为 $x_i \in R^{d_L} (i=1, 2, 3, \dots, N)$ ，对某一随机对称、连续且符合 *Mercer* 规定的函数 $K(x_i, x_j)$ ，一定具有特定的 *Hilbert* 空间 H ，对于映射 $\Phi: R^{d_L} \rightarrow H$ 存在：

$$K(x_i, x_j) = \sum_{n=1}^{d_F} \Phi_n(x_i) \cdot \Phi(x_j) \quad (3.3)$$

式中 d_F 为 *Hilbert* 空间的维度。

常用的核函数有以下几种形式：

线性核函数：
$$K(x, x_i) = x \bullet x_i \quad (3.4)$$

P 阶多项式核函数：
$$K(x, x_i) = [x \bullet x_i + 1]^P \quad (3.5)$$

$$\text{高斯径向基核函数: } K(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{\sigma^2}\right) \quad (3.6)$$

$$\text{多层感知核函数: } K(x, x_i) = \tanh[v(x \bullet x_i) + c] \quad (3.7)$$

在使用核方法时, 如何选择核函数是非常关键的, 针对实际问题, 选取合适的核函数, 可以有效的减少计算量, 提高计算速度。处理实际问题时, 在所有类型的核函数中, 高斯径向基核函数由于其良好的处理性能, 经常被众多学者应用在各个方法研究中, 具有较强的抗干扰能力。

3.1.2 核主成分分析基本原则

KPCA 算法引入一种核映射函数, 把原始空间的样本点非线性映射到某一高维空间中, 再在高维空间对其做 PCA 操作^[44], 进而得到特征主成分。在处理高维非线性数据时, 能够准确获得原始数据的高维特征, 非线性处理能力极强。其基本原则如下:

设 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]^T \in \mathbf{R}^{n \times m}$ 是一组原始样本集, 其中 n 为样本数量, m 为数据维度。在原始空间的基础上融入一种非线性函数 Φ , 这种函数通过映射方式将数据点 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 转换至某一特征空间 \mathbf{F} 中, 记为 $\Phi(\mathbf{x}_k)$, 则 \mathbf{F} 中协方差矩阵如式 (3.8) 所示:

$$\mathbf{C}^F = \frac{1}{N} \sum_{i=1}^N \Phi(\mathbf{x}_i) \Phi(\mathbf{x}_i)^T \quad (3.8)$$

若 λ 为 \mathbf{C}^F 的特征值, \mathbf{v} 为其所对应的特征向量, 则 λ 与 \mathbf{v} 满足以下条件:

$$\mathbf{C}^F \mathbf{v} = \lambda \mathbf{v} \quad (3.9)$$

式中, $\lambda = [\lambda_1, \lambda_2, \dots, \lambda_N]$ 是对 \mathbf{C}^F 求解所得到的一个特征值矩阵, 而且各特征值的大小关系满足 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$, $\alpha_i (i=1, 2, \dots, M)$ 是某一存在系数, 该系数使得式 (3.10) 成立:

$$\mathbf{v} = \sum_{i=1}^N \alpha_i \Phi(\mathbf{x}_i) \quad (3.10)$$

将其代入式 (3.9), 并在式 (3.9) 两边同乘 $\Phi(\mathbf{x}_k)$ 可得:

$$\lambda \left(\Phi(\mathbf{x}_k) \sum_{i=1}^N \alpha_i \Phi(\mathbf{x}_i) \right) = \Phi(\mathbf{x}_k) \mathbf{C}^F \left(\sum_{i=1}^N \alpha_i \Phi(\mathbf{x}_i) \right) \quad (3.11)$$

将式 (3.11) 简化可以得到:

$$N \lambda \alpha = \mathbf{K} \alpha \quad (3.12)$$

式中, \mathbf{K} 为 $N \times N$ 维核矩阵, 其中 $\mathbf{K}_{jk} = \mathbf{K}(\mathbf{x}_j, \mathbf{x}_k) = \Phi(\mathbf{x}_j)^T \Phi(\mathbf{x}_k)$, $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]^T$ 是核矩阵 \mathbf{K} 的特征向量。

实际应用该方法时, 在进行核主成分分析操作之前, 要对矩阵 \mathbf{K} 进行中心化处理, 即把式 (3.12) 中的 \mathbf{K} 换成 $\bar{\mathbf{K}}$:

$$\bar{\mathbf{K}}_{ij} = \left(\Phi(\mathbf{x}_i) - \frac{1}{N} \sum_{m=1}^N \Phi(\mathbf{x}_m) \right) \left(\Phi(\mathbf{x}_j) - \frac{1}{N} \sum_{n=1}^N \Phi(\mathbf{x}_n) \right)^T = (\mathbf{K} - \mathbf{1}_N \mathbf{K} - \mathbf{K} \mathbf{1}_N + \mathbf{1}_N \mathbf{K} \mathbf{1}_N)_{ij} \quad (3.13)$$

式中, $\mathbf{1}_N$ 是每个因素都为 $1/N$ 的 $N \times N$ 矩阵, N 是 \mathbf{K} 的维数。

由式 (3.12) 与式 (3.13), 可以从 \mathbf{K} 矩阵的特征向量 \mathbf{a} 入手来求解出矩阵 \mathbf{C}^F 的特征向量 \mathbf{v} 。

再按式 (3.14) 求解出各特征值的累积方差贡献率, 按照贡献率选取标准可以截取前 P 个特征值, 并利用这几个特征值决定数据特征提取后获得的主成分数量。

$$L(p) = \sum_{k=1}^p \lambda_k / \sum_{k=1}^N \lambda_N \quad (3.14)$$

当选取 P 个特征值作为主成分指标后, 原来的输入数据就会被转换为一个具有 P 组的向量, 如果新观测样本为 x_{new} , 那么可以得到它的分量为:

$$\mathbf{t}_{new} = [t_{new,1}, t_{new,2}, \dots, t_{new,p}]^T \quad (3.15)$$

$$t_{new,l} = v_l \bar{\Phi}(\mathbf{x}_{new}) = \sum_{j=1}^N \alpha_j^l (\bar{\Phi}(\mathbf{x}_j) \bar{\Phi}(\mathbf{x}_{new})) \quad (3.16)$$

其中, $l=1,2,\dots,p$, $\bar{\Phi}(\mathbf{x}_j)$ 是中心化的特征向量。

3.2 基于核主成分分析的特征提取

KPCA 算法的主要优点是在算法的使用过程中不用了解非线性映射的内部实际操作过程, 仅仅需要以某种核函数的内积形式来体现这复杂的非线性过程即可, 而通过研究煤与瓦斯突出影响因素及建立的面域化预测指标系统可知, 多个预测指标间就存在着这种复杂的非线性关系, 并且在很大程度上存在着极强的相关性, 各指标彼此耦合, 这种现象表明多种预测指标间都存在着某些内在的相同因素, 正是这些内在相同因素对煤与瓦斯的突出起到了很大的支配作用。因此, 为了提取出某些内在主要影响因素, 简化煤与瓦斯突出预测模型的输入变量, 提高突出预测的时效性和准确性, 本文利用 KPCA 算法对建立的预测指标系统进行特征提取, 提取出对突出影响权重较大的几项因素作为下一章所建立的煤与瓦斯突出预测模型的输入变量。

KPCA 算法处理预测指标系统的本质就是将选取的原始复杂变量经过非线性映射和线性组合得到几项综合指标, 既较好的集成了原始数据内的绝大部分信息, 也很好的简化了原始数据空间的维度^[45]。在对原始输入指标进行主成分提取操作时, 要注意以下几点:

- (1) 特征主成分本质上是通过对各原始输入指标线性组合获得的。
- (2) 所得特征主成分之间都存在各不相关性。
- (3) 特征主成分数据反映了原始输入指标的大部分信息。
- (4) 进行权重分析后, 所得的特征主成分个数要远远小于原始输入指标的数量。

由于影响煤与瓦斯突出各预测指标存在量纲和数量级不一致的问题, 如果直接采用原始数据来运算会对模型的稳定性和连续性产生很大的影响。因此, 在对预测指标进行核主成分分析之前, 必须要对原始的输入指标做归一化操作, 本文采用最大最小法执行此步骤, 把各指标归一化至 $[0,1]$ 区间内, 公式如下:

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (3.17)$$

式中, x_{\max} 和 x_{\min} 分别为煤与瓦斯突出预测指标系统中某一个影响因素数据信息序列里的最大值及最小值; x'_i 为归一化后的预测指标; x_i 为最初的实际指标。

基于 KPCA 算法的基本原理, 利用 KPCA 对数据实现特征提取的具体实现步骤如图 3.2 所示。

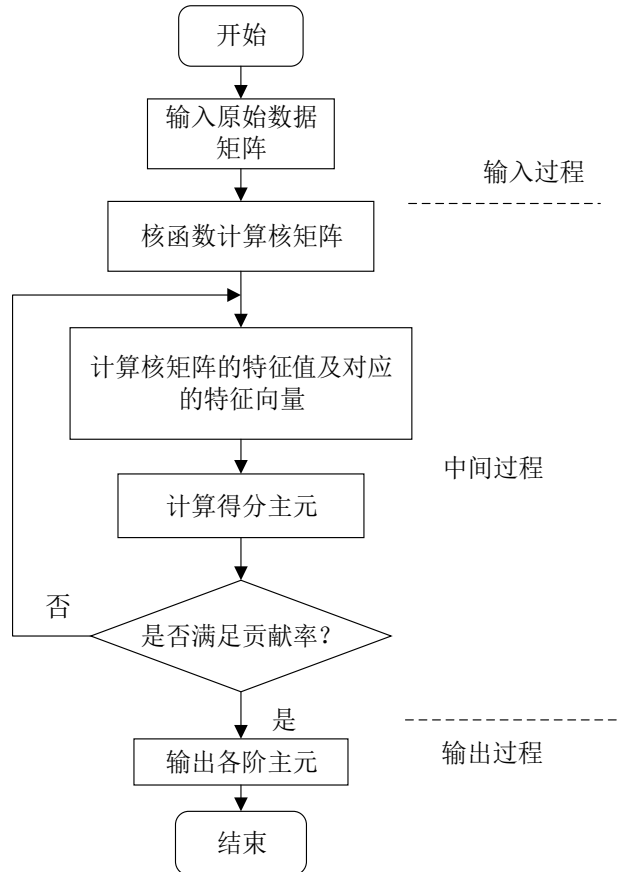


图 3.2 KPCA 基本流程图

Figure3.2 KPCA basic flow chart

其特征提取的具体实现过程如下:

(1) 对煤与瓦斯突出原始预测指标样本集进行处理, 将其写成一个 $n \times m$ 维的数据矩阵 \mathbf{X} 。

$$\mathbf{X} = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} \quad (3.18)$$

(2) 对最初输入指标系统数据按照式 (3.17) 执行归一化操作。

(3) 根据具体研究问题适当选择核函数类型, 并设置有关参数, 计算核矩阵 $\mathbf{K}_{jk} = \mathbf{K}(\mathbf{x}_j, \mathbf{x}_k) = \Phi(\mathbf{x}_j)^T \Phi(\mathbf{x}_k)$ 。

- (4) 利用式 (3.13) 对核函数进行修正得到 \bar{K}_{ij} 。
- (5) 计算核矩阵的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 及相应的特征向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 。
- (6) 将特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 按照数值从大到小排序, 获得数列 $\lambda'_1 > \lambda'_2 > \dots > \lambda'_N$, 并调整特征向量 $\lambda'_1, \lambda'_2, \dots, \lambda'_n$, 进而得到 $\mathbf{v}'_1, \mathbf{v}'_2, \dots, \mathbf{v}'_n$ 。
- (7) 正交单位化特征向量, 得到一组特征向量 $\alpha_1, \alpha_2, \dots, \alpha_n$ 。
- (8) 计算 $\lambda'_1, \lambda'_2, \dots, \lambda'_n$ 累积贡献率, 依据累积贡献率划分标准截取前 P 个特征值, 并将 P 当作提取后所得的主成分数量。
- (9) 在 P 个特征向量上算出 \bar{K}_{ij} 的投影 $Y = KL \cdot \alpha$, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)$, Y 即为原始输入样本集经过 KPCA 处理后所得到的数据。
- (10) 将提取所得的主成分数据作为所设计的预测模型的输入进行下一步研究。

3.3 核主成分分析的适应性分析

主成分分析是一种代数特征分析法, 通常用来对线性数据降维和特征提取, 其处理过程中计算复杂度较高, 而且要有比较大的空间来进行数据存储。采用 PCA 算法进行特征降维时, 通常都是通过在输入空间中进行线性映射操作来完成提取过程的, 但是这种线性操作使算法没有对高于二阶的数据进行有效处理, 所以特征提取的结果有可能不是最优的, 而且 PCA 算法无法处理具有较强非线性关系的数据。核主成分分析则将非线性核函数引入 PCA 算法来进行主成分的提取操作, 它不但能够提供比 PCA 算法更加多的特征数目以及更好的特征质量, 还能最大程度地从原始指标数据中提取出能够反映原始数据的信息, 鉴于上述优点, KPCA 算法被广泛的应用在了各种非线性特征提取领域中。

针对本文研究的煤与瓦斯突出预测问题, 选取的原始预测指标较多, 且各指标之间并不是数据信息的简单叠加, 它们之间存在极其复杂的非线性和关联性, 而且目前 PCA 算法已经在瓦斯预测方面有很多研究, 且对线性数据具有极好处理效果, 因此为了更加稳定且有效的对瓦斯数据内包含的线性及非线性关系均进行快速处理, 本文在比较两种提取方法后, 选择将由 PCA 非线性演化而来的 KPCA 算法应用于本研究中, 该算法可以提供能深入反映瓦斯数据内在关系的特征参数, 既可保证对线性数据的快速处理, 也能加强对复杂非线性数据的提取能力。因此本文采用 KPCA 算法对指标系统进行降维和特征提取, 提取出对突出影响权重较大的几项指标, 为后续进一步创建煤与瓦斯预测模型提供了较强的理论前提。

3.4 本章小结

本章介绍了一种非线性数据处理方法—核主成分分析, 并提出采用该法对预测指标系统进行特征提取。在深入分析核主成分分析基本原则和提取步骤后, 针对煤与瓦斯突出问题进行适应性的讨论, 为合理的处理预测指标进而提高预测精度提供了可靠的科学依据。

4 基于 KPCA 与 IQGA 算法优化的 ELM 煤与瓦斯突出预测模型

随着煤矿系统的更新和发展,对煤与瓦斯突出实现准确预测的难度也越来越大,传统预测方法已经难以满足实际矿井突出的预测要求。近年来,许多学者将人工神经网络运用在煤与瓦斯突出预测领域,建立了多种煤与瓦斯突出预测模型,谭云亮等^[46]采用小波函数对 BP 神经网络的输出函数进行改进,构建了基于小波函数的煤与瓦斯突出神经网络预测模型;桂祥友等^[47]利用灰色关联分析法对各致突因素进行了关联性分析,建立预测模型,提高了煤矿巷道突出危险性的预测准确率;杨飞龙等^[48]通过模糊层次分析法对影响煤与瓦斯突出的各因素进行权重分析,缩短了突出预测时间。但由于实际预测中,不同矿井的地质构造及影响突出的因素均不相同,且致突因素种类繁多,某一单一的影响因素并没有对突出的发生发展起到很大的作用,而是多种影响因素共同影响与作用的结果,导致各预测模型在实际应用中的预测准确率普遍不能满足矿井的实际需求。因此结合矿井实际煤与瓦斯突出特性,有针对性的选择数学模型来建立突出预测模型,并融入先进的数学理论来提高煤与瓦斯突出的预测效率和准确率是十分必要的。本文则采用一种新型神经网络-极限学习机来构建煤与瓦斯突出的预测模型,并引入改进量子遗传算法(IQGA)以提高预测模型的预测速度和预测精度。

4.1 极限学习机神经网络基本理论

由于煤与瓦斯突出是一个非常复杂的非线性动力过程,所以在突出预测过程中总是会伴随着比较明显的非线性特性。而且对于突出的预测结果都是按照突出强度的大小划分的几种固定的类型,因此,预测煤与瓦斯突出的过程可以看成是一个多模式分类问题。因此,本文选择对多模式分类问题具有很强处理能力的极限学习机网络来建立煤与瓦斯突出预测模型。

4.1.1 极限学习机的提出

极限学习机(ELM)是一种用于求解单隐层神经网络的新型算法。该新型学习网络不仅很好的继承了一般神经网络具有的高精度学习等优点,而且还极大的增强了神经网络的学习效率,改进了传统基于梯度下降学习方法的很多缺陷,如学习效率较低、容易陷入局部极小值及迭代次数过多等^[49]。

目前,单隐层前馈神经网络已经受到了国内外学者的广泛应用,在多种领域中已经取得了较好的使用效果,其主要优点有:

(1) 单隐层前馈神经网络对数据的学习能力是十分强大的,它可以在最大程度上逼近任意较为复杂的连续函数。

(2) 单隐层前馈神经网络是一种快速的学习方法,可以有效避免由于传统神经网络

带来的学习效率低、不能满足实际应用需求的问题。

传统前馈神经网络在运算时会耗费很长的计算时间，这是由于这些神经网络在选定参数时都会有一个初始化的过程，然后再经过不断的训练来调整参数，进而导致运算速率大大降低，算法变得相对复杂。传统的基于梯度下降学习方法在使用过程中主要存在以下几项缺点：

- (1) 训练神经网络时，很难设定合适的学习步长，并且需要设置的参数比较多。
- (2) 算法要经过不断的迭代过程才能获得较好的训练性能。
- (3) 训练过程中，不能够较快的获得全局最优值，极易进入局部最优状况。

基于传统前馈神经网络的缺陷和单隐层神经网络的优点，ELM 这种新型单隐层前馈神经网络逐渐诞生^[50]，该算法只要进行简单的一步计算就能够求出学习网络的输出权值。因其独特的优点，近年来，许多学者对 ELM 算法进行了深入研究，大量的实验证明，同传统迭代算法（BP 神经网络、支持向量机等）相比，ELM 算法不仅加快了网络的学习速率，而且结构更加简单，有更强的泛化能力，因此受到了众多学者的支持，在各个学科及领域中都得到了极为广泛的运用。

4.1.2 单隐层前馈神经网络

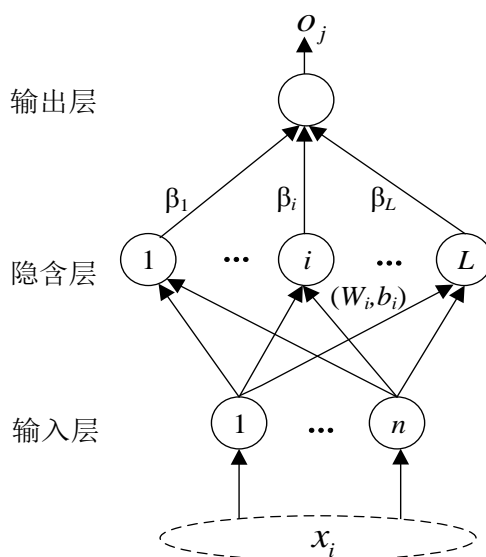


图 4.1 单隐层前馈神经网络

Figure4.1 Single hidden layer feedforward neural network

图 4.1 是单隐层前馈神经网络的结构图。对于这样一个单隐层神经网络,设某一数据集的表达方式是 (t_i, X_i) ，其中 $X_i = [x_{i1}, x_{i2}, \dots, x_{im}]^T$ ， $t_i = [t_{i1}, t_{i2}, \dots, t_{im}]^T \in \mathbf{R}^m$ ， t_i 为该类样本数据集所属的标签。则含有一个隐层节点的单隐层网络可以写成：

$$\sum_{i=1}^L \beta_i g(\mathbf{W}_i \cdot \mathbf{X}_j + \mathbf{b}_i) = o_j, \quad j=1, \dots, N \quad (4.1)$$

其中， $\mathbf{W}_i = [W_{i,1}, W_{i,2}, \dots, W_{i,n}]^T$ 是输入权值； β_i 为输出权值； $g(x)$ 叫作激活函数； \mathbf{b}_i 是第

i 个隐含层的阈值； $\mathbf{W}_i \cdot \mathbf{X}_j$ 为 \mathbf{W}_i 与 \mathbf{X}_j 内积的表达形式。

ELM 网络进行学习训练的根本就是要使神经网络的输出误差降低到最小，即其目标可写为：

$$\sum_{j=1}^N \|\mathbf{o}_j - \mathbf{t}_j\| = 0 \quad (4.2)$$

即存在 β_i , \mathbf{W}_i 和 \mathbf{b}_i , 使其存在以下的关系：

$$\sum_{i=1}^L \beta_i g(\mathbf{W}_i \cdot \mathbf{X}_j + \mathbf{b}_i) = \mathbf{o}_j, \quad j=1, \dots, N \quad (4.3)$$

用矩阵形式可表示为：

$$\mathbf{H}\boldsymbol{\beta} = \mathbf{T} \quad (4.4)$$

式中， \mathbf{H} 代表隐层节点输出， $\boldsymbol{\beta}$ 代表输出权重， \mathbf{T} 代表期望输出。

$$\mathbf{H}(\mathbf{W}_1, \dots, \mathbf{W}_L, \mathbf{b}_1, \dots, \mathbf{b}_L, \mathbf{X}_1, \dots, \mathbf{X}_L) = \begin{bmatrix} g(\mathbf{W}_1 \cdot \mathbf{X}_1 + \mathbf{b}_1) & \cdots & g(\mathbf{W}_L \cdot \mathbf{X}_1 + \mathbf{b}_L) \\ \vdots & \cdots & \vdots \\ g(\mathbf{W}_1 \cdot \mathbf{X}_N + \mathbf{b}_1) & \cdots & g(\mathbf{W}_L \cdot \mathbf{X}_N + \mathbf{b}_L) \end{bmatrix}_{N \times L} \quad (4.5)$$

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_1^T \\ \vdots \\ \beta_L^T \end{bmatrix}_{L \times m}, \quad \mathbf{T} = \begin{bmatrix} \mathbf{T}_1^T \\ \vdots \\ \mathbf{T}_N^T \end{bmatrix}_{N \times m} \quad (4.6)$$

为了能够训练单隐层神经网络，我们希望得到 $\hat{\beta}_i$, $\hat{\mathbf{W}}_i$ 和 $\hat{\mathbf{b}}_i$, 使得

$$\left\| \mathbf{H}(\hat{\mathbf{W}}_i, \hat{\mathbf{b}}_i) \hat{\beta}_i - \mathbf{T} \right\| = \min_{\mathbf{W}, \mathbf{b}, \beta} \left\| \mathbf{H}(\mathbf{W}_i, \mathbf{b}_i) \beta_i - \mathbf{T} \right\| \quad (4.7)$$

在式 (4.7) 中， $i=1, 2, \dots, L$, 这就相当于求解一个最小化损失函数：

$$E = \sum_{j=1}^N \left(\sum_{i=1}^L \beta_i g(\mathbf{W}_i \cdot \mathbf{X}_j + \mathbf{b}_i) - \mathbf{t}_j \right)^2 \quad (4.8)$$

当 \mathbf{H} 没有具体给出时，基于梯度下降的学习算法通常是计算公式 $\|\mathbf{H}\boldsymbol{\beta} - \mathbf{T}\|$ 的最小值。 \mathbf{W} 是 (\mathbf{W}_i, β_i) 和阈值 (\mathbf{b}_i) 的联合向量，在梯度下降的学习算法中通常利用式 (4.9) 来进行调整：

$$\mathbf{W}_k = \mathbf{W}_{k-1} - \eta \frac{\partial E(\mathbf{W})}{\partial \mathbf{W}} \quad (4.9)$$

其中， η 为网络训练过程中的学习速率。BP 算法是现阶段应用最为广泛的前馈神经网络之一，它是利用输出到输入的误差来反向传播有效的计算梯度，一般具有以下几项缺点：

- (1) η 的取值若过大，会对传统神经网络的性能造成一定的影响；如果 η 的值过小，则算法的收敛速率就会变得很慢，使算法学习时耗费的时间较多。
- (2) 在应用学习算法时，网络可能会训练过度导致泛化性能变差。
- (3) 在大多数实际运行及操作中，基于梯度下降学习算法在训练和计算时一般均会

消耗大量的时间。

显然，基于梯度下降学习算法在实际使用过程中伴随着许多不可避免的问题，在过去的几十年里，这很大程度的制约了神经网络的发展。与传统单隐层前馈神经网络不同的是，ELM 模型是一个全新的单隐层前馈神经网络，在实际运用过程中该网络相关参数的具体设置将在下节中进行介绍。

4.1.3 极限学习机的原理

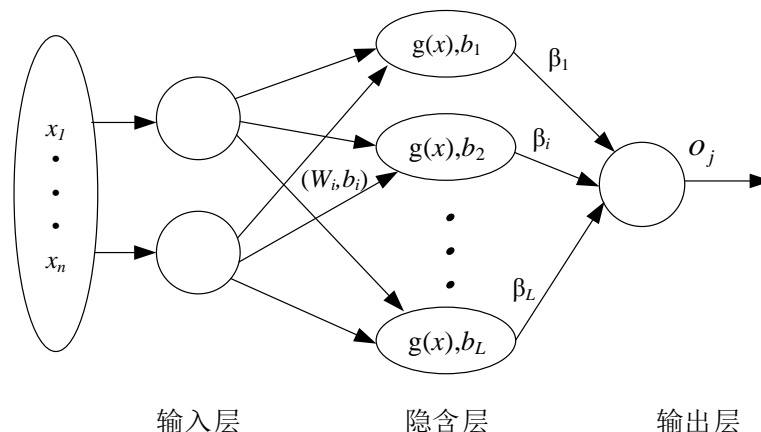


图 4.2 极限学习机网络结构

Figure 4.2 Extreme learning machine network structure

图 4.2 中给出的是 ELM 网络的一种结构图，总共含有输入层、输出层以及存在多个非线性节点的隐含层三部分。上一节中所讨论的隐含层输出矩阵 \mathbf{H} 在 ELM 网络中被叫作极限学习机系数矩阵。

当激活函数 $g(x)$ 满足可以无限进行可微的条件时，有如下定理：

定理 4.1：给定一个具有 N 个隐层节点的标准 ELM， $g(x)$ 在 $\mathbf{R} \rightarrow \mathbf{R}$ 的随机区间满足无限可微这个条件，对随机 N 个离散点 (x_i, t_i) ， $1 \leq i \leq N$ ，其中 $\mathbf{x}_i = [x_{i,1}, x_{i,2}, \dots, x_{i,m}]^T$ ， $\mathbf{t}_i = [t_{i,1}, t_{i,2}, \dots, t_{i,n}]^T \in \mathbf{R}^n$ ，在具有连续概率分布的 \mathbf{R}_m 和 \mathbf{R} 空间中随机选取 β_i 和 W_i ，那么就会存在一种可能，即矩阵 \mathbf{H} 是可逆的且满足 $\|\mathbf{H}\beta - \mathbf{T}\| = 0$ 。

定理 4.1 证明了 β_i 和 W_i 在实际应用时其实是不需要随时调整的，通常在 ELM 算法开始进行的时候，这两个参数就会被确定，而一旦参数确定后，极限学习机系数矩阵 \mathbf{H} 在实际计算与应用时是不会发生任何变化的。当输入一定的 W_i 和 β_i 这两个固定的值时，这个 ELM 网络的学习过程就能看成是求一个线性系统 $\mathbf{H}\beta - \mathbf{T}$ 最小二乘解 $\hat{\beta}_i$ 的过程。

一般情况下，在实际问题的学习训练过程中，训练数据的数量 N 要比隐含节点数量 L 多出很多倍，即 $L \ll N$ ，也就是说 \mathbf{H} 不再以方阵的形式存在，因此，可以根据网络求得 \mathbf{H} 的伪逆：

$$\hat{\beta} = \mathbf{H}^+ \mathbf{T} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{T} \quad (4.10)$$

在式(4.10)中, H^+ 所代表的是矩阵 H 的 MP 伪逆。通常在该求解过程中, 一般使用奇异值分解法来求解上式中的 H^+ , 通过求解得到网络的输出 $\hat{\beta}$ 后, 就完成了对该 ELM 的网络训练步骤。

因此, 若某训练数据为 $D\{(x_i, y_i) | x_i \in R^n, y_i \in R^m, i=1, 2, \dots, n\}$, 激活函数为 $g(x)$, 隐含层节点数为 L 的网络, ELM 算法的步骤可总结为以下几步:

- (1) ELM 神经网络模型随机设置输入权值 W_i 和隐层阈值 b_i 。
- (2) 计算 ELM 网络的隐含层输出矩阵 H 。
- (3) 按照公式 $\beta = H^+T$ 来求解 β 。

虽然极限学习机较传统前馈神经网络有多种优势, 在实际使用过程中无论是学习训练能力, 还是对结果的泛化能力都要在很大程度上优于传统的前馈神经网络模型。该算法在使用时随机设置模型的输入权值和隐含阈值是其一大特色, 该特性使 ELM 网络使用起来更加简单方便, 计算速度也非常快。但就是由于其具有一定的随机性, 致使算法本身存在一定程度的缺陷, 该算法在实际应用时, 会由于这种随机性给所建立的模型带来一定的不稳定性, 从而影响模型的泛化性能。因此, 将该算法应用于对煤与瓦斯突出危险性的预测问题时, 要采用适当的方法对其输入权值和隐含阈值进行优化, 建立稳定性更强, 泛化性能更好的模型。本文则采用量子遗传算法对 ELM 进行优化, 并针对量子遗传算法的缺点, 提出免疫算法改进的量子遗传算法, 进而得到 IQGA-ELM 算法, 改善了 ELM 模型的稳定性和预测精度。

4.2 量子遗传算法优化的极限学习机

在建立基于 ELM 神经网络的煤与瓦斯突出预测模型时, 由于其在初始化时随机设置输入权值和隐含阈值的性质会对预测模型的稳定性及模型预测准确率产生直接影响, 因此, 为了提高预测模型的泛化性能及模型稳定性, 本文采用量子遗传算法(QGA)对 ELM 网络进行优化, 进而建立基于量子遗传算法优化的 ELM 煤与瓦斯突出预测模型。

量子遗传算法(QGA)是上世纪 90 年代由 Narayanan 等人提出的一种智能优化算法, 是近些年应用比较广泛的新型智能算法, 其将量子计算理论与遗传算法进行耦合, 实现了比传统遗传算法更好的效果^[51]。QGA 算法不仅能缩短计算时间、提高收敛速度, 而且最大的优点是能够更好的维持种群中粒子的多样性, 防止出现粒子退化现象。目前, QGA 算法已经被广泛应用在函数寻优、图像处理等领域中。

4.2.1 量子遗传算法原理

量子遗传算法(QGA)在本质上也是一种遗传算法, 它是在遗传算法原理的基础上演化出的一种新算法, 它不仅仅继承了一般遗传算法的各项优点, 而且在很大程度上弥补了遗传算法所存在的不足之处, 由于遗传算法的稳定性较强、适应性更好, 所以由其演化出

的量子遗传算法更是具有更好的泛化特性，它解决了遗传算法种群多样性较单一等缺点，因其处理复杂问题具有高度准确性及较好稳定性，QGA 算法逐渐被越来越多的学者所研究与使用。

QGA 算法最大的特点就是将多状态量子比特编码和量子旋转门概念引入到了遗传算法中^[52]，使遗传算法中种群粒子的多样性大大增加，即使在种群规模较小的情况下也能得到最优解，而且算法的开发能力也有了很大的提高，使算法的收敛性能得到了有效保证。

QGA 算法的流程图如图 4.3 所示：

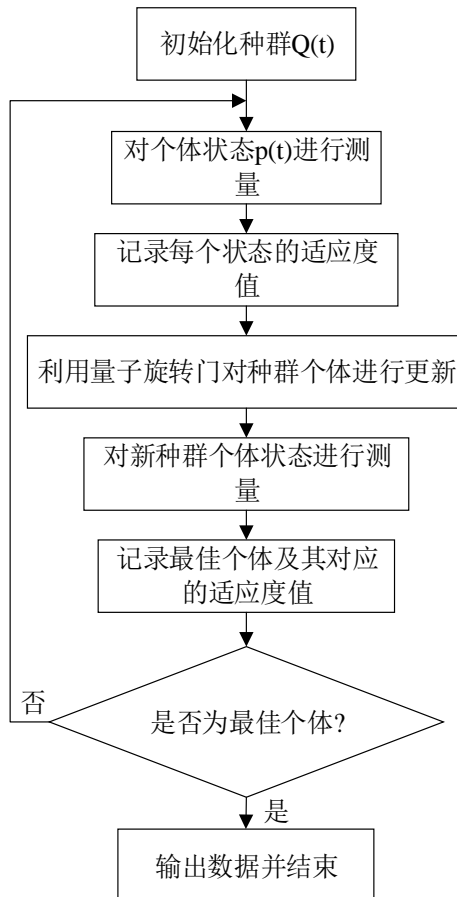


图 4.3 QGA 算法流程图

Figure4.3 QGA algorithm flow chart

(1) 量子比特编码

QGA 算法在对染色体进行编码时，选用了一种量子计算中特有的编码方式，即量子比特编码形式。采用该方式对染色体进行编码可以极大的增加算法初始化种群中种群个体的数量。如果某一系统里面包含了 m 个量子比特位，则该量子系统就可以表述成式 (4.11) 的形式：

$$\begin{bmatrix} \alpha_1 & \alpha_2 & \cdots & \alpha_m \\ \beta_1 & \beta_2 & \cdots & \beta_m \end{bmatrix} \quad (4.11)$$

式中， $|\alpha_i|^2 + |\beta_i|^2 = 1 (i=1,2,\dots,m)$ 。 $|\alpha_i|^2$ 是该量子状态为自旋向下的可能性； $|\beta_i|^2$ 是该量

子状态为自旋向上的可能性。量子比特与经典位的最大差别就是它不仅能单单表示一种或者两种状态，而且能够同时表示两个量子态的叠加态，这种表示方法使染色体的多样性得到了较好的保证，具体的表现形式如式（4.12）：

$$|\varphi\rangle = \alpha|0\rangle + \beta|1\rangle \quad (4.12)$$

式中，0 和 1 分别是量子处在自旋向下态及自旋向上态， $|\varphi\rangle$ 是某一种量子状态的体现方式， α 和 β 为几率幅对。所以一个量子比特可同时包含状态 $|0\rangle$ 和 $|1\rangle$ 的信息，即该基因所代表的是包含所有可能的信息，而不再是某一确定的信息，对该基因的每个操作都会同时作用于所有可能的信息。

例如，一个染色体系统具有三量子比特：

$$\left| \begin{array}{c|c|c} \frac{1}{2} & \frac{1}{\sqrt{2}} & \frac{\sqrt{3}}{2} \\ \hline \frac{\sqrt{3}}{2} & \frac{1}{\sqrt{2}} & \frac{1}{2} \end{array} \right| \quad (4.13)$$

那么这个染色体可以表示为：

$$\begin{aligned} & \frac{\sqrt{3}}{4\sqrt{2}}|000\rangle + \frac{1}{4\sqrt{2}}|001\rangle + \frac{\sqrt{3}}{4\sqrt{2}}|010\rangle + \frac{1}{4\sqrt{2}}|011\rangle + \frac{3}{4\sqrt{2}}|100\rangle + \frac{\sqrt{3}}{4\sqrt{2}}|101\rangle + \\ & \frac{3}{4\sqrt{2}}|110\rangle + \frac{\sqrt{3}}{4\sqrt{2}}|111\rangle \end{aligned} \quad (4.14)$$

因此可以得到该染色体量子编码转换成 $|000\rangle$ 、 $|001\rangle$ 、 $|010\rangle$ 、 $|011\rangle$ 、 $|100\rangle$ 、 $|101\rangle$ 、 $|110\rangle$ 、 $|111\rangle$ 的可能性分别为：3/32、1/32、3/32、1/32、9/32、3/32、9/32、3/32。故该三个量子位构成的系统能够表示成上述 8 种状态。

由上述介绍可知，因为量子态存在的叠加特性和多样性，使得 QGA 算法很好的增加了种群的数量。

（2）量子旋转门

QGA 算法的种群更新操作不同于传统遗传算法，不是通过执行交叉、变异等步骤来对种群中的个体进行更新的，而是采用了量子理论中特有的量子旋转门策略来对种群进行更新，在量子的叠加状态表示上直接实施旋转门处理操作，通过对旋转门的旋转角度进行调整及改变来实现种群中个体的不断更新^[53-55]。

作为染色体演化的执行机构，量子门可以依据具体实际问题进行选取。随着学者对量子遗传算法的深入研究，目前现有的量子门有很多种，通常在研究 QGA 算法时，多数学者一般选择量子旋转门来充当算法种群更新的执行机构。其中量子旋转门 $U(\theta)$ 可以表示为式（4.15）：

$$U(\theta) = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix} \quad (4.15)$$

式中， θ 为旋转角度。 $U(\theta)$ 的具体调整策略如式（4.16）：

$$\begin{pmatrix} \alpha_i' \\ \beta_i' \end{pmatrix} = \begin{pmatrix} \cos(\theta_i) & -\sin(\theta_i) \\ \sin(\theta_i) & \cos(\theta_i) \end{pmatrix} \begin{pmatrix} \alpha_i \\ \beta_i \end{pmatrix} \quad (4.16)$$

在式（4.16）中， (α_i, β_i) 是量子系统中排序为第 i 位的量子比特。 θ_i 为旋转角，一般使用量子旋转门方法来更新物种种群时，旋转门转角所处状态对应的大小与方向往往按照已经制定好的调整方法来选择。

旋转角的表达形式为 $\theta_i = s(\alpha_i, \beta_i) \cdot \Delta\theta_i$ ，其中 $\Delta\theta_i$ 和 $s(\alpha_i, \beta_i)$ 依次代表的是旋转角的角度和该角度所对应的方向，它们的取值及调整策略见表 4.1。

表 4.1 旋转角选取方法
Table 4.1 Rotation angle selection method

x_i	b_i	$f(x) \geq f(b)$	$\Delta\theta_i$	$s(\alpha_i, \beta_i)$			
				$\alpha_i\beta_i > 0$	$\alpha_i\beta_i < 0$	$\alpha_i = 0$	$\beta_i = 0$
0	0	False	0	0	0	0	0
0	0	True	0	0	0	0	0
0	1	False	δ	+1	-1	0	± 1
0	1	True	δ	-1	+1	± 1	0
1	0	False	δ	-1	+1	± 1	0
1	0	True	δ	+1	-1	0	± 1
1	1	False	0	0	0	0	0
1	1	True	0	0	0	0	0

在上表中， $f(x)$ 为当前所求的目标函数， x_i 为当前经过测量所得的某个个体值， b_i 为目前寻优所获得的最优个体目标值，旋转门角度的不断改变会逐渐改变种群中的个体进而实现更新操作。而旋转门的调整策略是通过比较某一个体 q_j' 目前测量的适应度值 $f(x)$ 和 b_i 的适应度值 $f(b_i)$ 的大小来进行改变的。如果 $f(x_i) < f(b_i)$ ，就改变对应的量子比特 ($x_i \neq b_i$)，使 (α_i, β_i) 呈现出有利于 b_i 出现的趋势进行演化；否则则改变对应量子比特位，使 (α_i, β_i) 呈现出有利于 x_i 出现的趋势进行演化。

此外，可以利用静态或动态的调整方法来选择旋转角。在表 4.1 中， δ 称为单次调整的角步长。如何选择 δ 值的大小对算法的有效运行也存在着很大的影响， δ 取值过小可能会导致算法达不到最优效果，若取值太大可能会使结果出现早熟或者结果发散现象，因此要根据具体问题对 δ 值进行合理的设定。

4.2.2 量子遗传算法的特性

对量子遗传算法的基本原理进行分析可知，QGA 算法与传统遗传算法相比不仅具有更强的全局搜索能力，在求解的过程中也要比传统的方法拥有更好的性能。该算法具有以下几点特征^[56-58]：

(1) 计算所需要的种群数量要求相对较少。因为量子比是存在叠加特性的，在对染色体进行求解时可以以多种不一样的方法来解决，因此在计算过程中只需要较少的种群数量即可进行求解。

(2) 能够不断维持种群的多样性。传统的遗传算法执行到计算后期时，种群类别会逐渐减少，算法会由于种群类别的降低而产生许多无用的计算，耗费大量的计算时间，所选出的最优值也有可能不是全局最优值。而在 QGA 算法中，当算法执行到后期逐步达到收敛状态时，能够很好的维持该种群里物种的丰富性与多样性，不会由于种群多样性的问题导致算法无法进行有效寻优。

(3) 较强的整体搜索能力。在 QGA 算法中，由于每个量子比特全部都代表了多种状态，且在计算寻优过程中对每个解的求解过程都具有一定的控制概率，因此每个个体之间的相互关系都相对较小，这样就大大缩短了计算求解的时间和过程，提高了全局的整体搜索性能。

虽然 QGA 算法具有许多传统遗传算法不具备的优点，但在实际优化过程中也存在着一些缺点。由上述对量子旋转门的描述可知，在寻优过程中量子旋转角的选择或者取值通常都是固定的，这就会导致在寻优过程中固定的旋转角就不会随着算法的深入执行而进行调整，就会使算法的灵活性受到一定限制。此外，在实际执行时，QGA 算法也有可能会出现早熟、陷入局部最优的现象。因此，在实际使用过程中，要在一定程度上对 QGA 算法进行优化才能获得更好的寻优结果。

4.2.3 量子遗传算法的改进

针对传统 QGA 算法在寻优过程中所存在的问题及煤与瓦斯突出预测问题的高维复杂性特性，本文选择免疫算法中的抗体多样性保持机制及该算法具有的免疫记忆思想^[59]对基本 QGA 算法改进，并对量子旋转门转角的确方法进行优化，得到了寻优能力更强的改进量子遗传(IQGA)算法。

对 QGA 算法的具体改进策略如下：

(1) 免疫算法：为避免算法出现早熟现象，本文在传统 QGA 算法的基础上引入了免疫算法。在免疫算法中有抗原和抗体两种不同的概念，在算法应用时抗原代表需要解决的问题，而抗体则代表这个问题所对应的解集。用适应度函数 f 来体现种群里某个抗体与其对应抗原之间的亲和力，如果某问题的目标函数为 $E(s)$ ，则其适应度函数 f 可以写为：

$$f = \frac{1}{1 + E(s)} \quad (4.17)$$

本文中以 f 函数来充当免疫算法中的抗原，以算法中的种群个体来充当该抗原所对应的抗体，并引入期望繁殖概率来表达每个个体被选中的可能性大小，采用公式 (4.18) 来对种群中的所有个体进行繁殖概率计算，得到 P 值。

$$P = \lambda \frac{f_v}{\sum f_v} + (1 - \lambda) \frac{C_v}{\sum C_v} \quad (4.18)$$

其中 λ 是免疫算法中的概率常数, f_v 与 C_v 分别是种群个体的适应度以及对应的抗体浓度, C_v 的表达方式如式(4.19):

$$C_v = (\sum_{s \in N+M} S_{v,s}) / (N + M) \quad (4.19)$$

其中, N 为种群总数, M 为免疫记忆库的容量。抗体间亲和力的求解方法如下:

$$S_{v,s} = \frac{K_{v,s}}{L} \quad (4.20)$$

其中 $K_{v,s}$ 表示两种抗体经过比较后所得的相同位数, L 是抗体中被编码参数的总数。

由以上推导能够得出如下结论: 免疫算法不仅能对处于高浓度低适应度状态的抗体起到很好的抑制作用, 同时也可以较好的对处于低浓度高适应度状态下的抗体起到促进作用, 这个机制更好地保证了物种群体的丰富性及多样性。

由于 IQGA 算法在执行过程中, 不仅能够有效抑制高浓度抗体, 而且对高适应度的抗体也会产生一定的抑制作用, 这样就会导致算法获得的最优解存在丢失的可能性。因此, 为避免出现这个问题, 本文选用精英保留策略, 在算法不断运行过程中, 通过比较先把适应度值最高的多个抗体保存在记忆库中, 之后再计算每个个体的期望繁殖概率, 将抗体进行筛选, 较好的抗体再另外储存到记忆库中。

(2) 量子旋转门: 传统 QGA 算法的量子旋转角一般是通过查表方式获得, 在实际应用中, 算法的收敛效果达不到理想效果。IQGA 算法则引入动态旋转门转角调整方法, 将运行过程中获得的最优二进制解直接和当前量子位进行比较, 再根据比较结果来对旋转门转角进行调整。本文将旋转门的进化过程用角度的方式体现出来, 二进制角度的计算公式定义如下:

$$\theta_c = \begin{cases} 0, & c = 0 \\ \frac{\pi}{2}, & c = 1 \end{cases} \quad (4.21)$$

旋转门转角用式(4.22)来求。

$$\Delta\theta_i = (\theta_{ci} - \theta_i) d \quad (4.22)$$

式中, θ_{ci} 为搜索到的最优二进制解第 i 位的角度, 为了确保算法的全局收敛性能, 选择最优保留策略来选取这个最优二进制解; θ_i 为当前所求得的染色体上第 i 位所对应角度; d 称作调整参数, 其定义公式为:

$$d = (\frac{k}{N} + r) h \quad (4.23)$$

式中, K 代表当前种群中第 K 个个体; N 为种群规模; r 、 h 是两个常数, r 的作用是避免由于种群规模 N 的值过大导致 d 值太小, 进而使 $\Delta\theta_i$ 偏小, 导致进化的速度逐渐减慢, h 是在宏观上调节 d 值的一个常数, 为使算法的收敛速度在算法执行过程中得到控制。 r

和 h 的取值要根据实际情况设置。利用上述方法调整旋转门转角能够使种群中每个个体以不同的速度向最优解逐渐发展。不仅能有效避免在相同初始状态下所有染色体始终均以一样的速度进化；使部分个体先快速收敛至最优解附近，再局部寻优；也能使部分个体以较慢的速度先收敛，然后在较长时间里实现全局寻优。

IQGA 算法流程如图 4.4 所示：

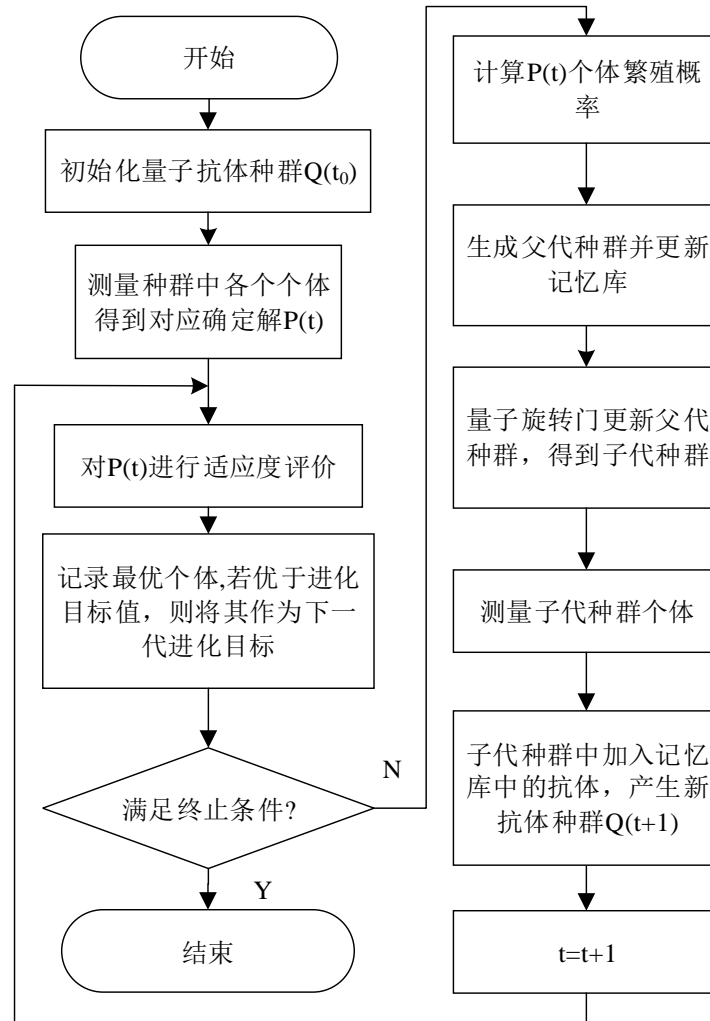


图 4.4 IQGA 算法流程图

Figure4.4 IQGA algorithm flow chart

4.3 基于 KPCA 与 IQGA-ELM 煤与瓦斯突出预测模型的建立

4.3.1 IQGA 算法优化 ELM 网络步骤

由于 ELM 模型的输入层权值与隐含层阈值在训练过程中一般是随机进行设置的，具有一定的不稳定性，会使建立的模型具有预测效率低，泛化性能差等缺点。因此，基于 IQGA 算法稳定性强、收敛速度快等优点，本文将 IQGA 算法应用在对 ELM 网络模型的输入权值与隐含层阈值的选取上，下面列出 ELM 网络参数的具体优化步骤：

Step 1:将种群规模设置为 N ，免疫记忆库容量设置为 M ，同时设置最大进化代数 K 等

参数。

Step 2: 初始化量子抗体种群 $Q(t_0)$ 。将煤与瓦斯突出 ELM 预测模型中待优化输入权值及隐含层阈值采用量子编码方式进行编码操作，并随机生成一个具有 $N+M$ 个抗体的种群。

Step 3: 对抗体种群中的每个个体执行测量操作，获得由二进制串构成的各确定解 $P(t_0)=\{P_1^t, P_2^t, \dots, P_n^t\}$ ，即对每个解中的每一个量子位都随机生成某个 $[0,1]$ 的数值 N_{rand} ，如果 $N_{rand} < |\alpha_i|^2$ ，则对应的量子位取“0”，反之，取“1”。

Step 4: 对各确定解进行解码操作并作适应度评价，将 ELM 实际输出值与期望输出值的均方误差当作目标函数。将迭代过程中所得到的最优个体进行记录，并将记录的最优个体值与目标值比较，若该个体的适应度值好于目标值，以该新个体充当下一代的进化目标；否则，不改变目标值。

Step 5: 判断是否终止算法。若得到的最优个体满足实际要求，则终止；否则，继续执行。

Step 6: 计算 $P(t)$ 每个个体繁殖概率 P ，并根据每个个体的 P 值大小进行降序排列，截取序列中前 N 个个体，将其重组成父代种群。在对免疫记忆库执行更新步骤时选择精英保留方法。

Step 7: 父代群体执行动态量子旋转门更新步骤，对种群内全部个体都进行更新，更新后获得一个子代种群。

Step 8: 对子代种群中全部个体进行测量，并将记忆库中所保存的所有抗体加入至该子代群体中，从而得到一个全新的抗体种群 $Q(t+1)$ 。

Step 9: $t=t+1$ ，转至 Step 3，输出满足实际需要的最优解，至此完成基于 IQGA-ELM 网络突出预测模型的建立。

4.3.2 KPCA-IQGA-ELM 预测模型的建立

综上所述，通过分析第三章及第四章的研究内容，将核主成分分析理论和 IQGA 算法优化的 ELM 神经网络结合起来，可以建立基于 KPCA 与 IQGA-ELM 的掘进工作面煤与瓦斯突出预测模型。

针对实际矿井突出灾害问题进行煤与瓦斯突出预测的具体流程如图 4.5 所示。

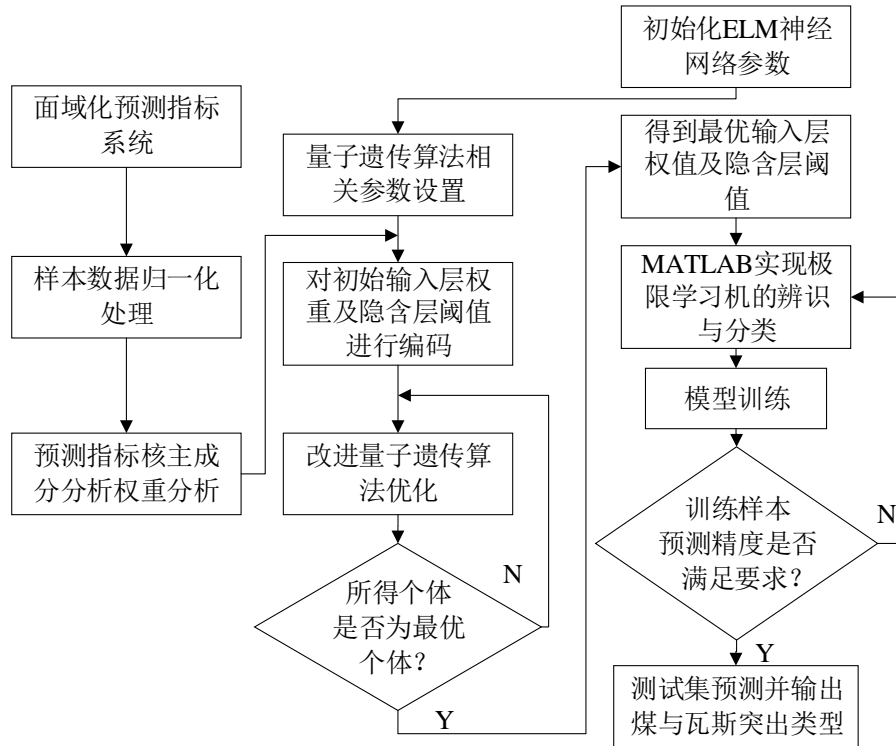


图 4.5 KPCA-IQGA-ELM 预测模型流程图

Figure 4.5 KPCA-IQGA-ELM prediction model flow chart

基于 KPCA 与 IQGA-ELM 模型预测步骤如下：

- (1) 采集矿区掘进工作面内的 13 项预测指标，构成面域化预测指标系统。
- (2) 对原始指标系统进行归一化处理。
- (3) 利用 KPCA 对 13 项预测指标进行权重分析，提取出几项权重比较大的预测指标作为 ELM 模型的输入，提取过程见第三章。
- (4) 设置 ELM 相关参数，利用 IQGA 对 ELM 模型执行参数寻优过程，建立基于 KPCA 与 IQGA-ELM 的煤与瓦斯突出预测模型。
- (5) 将选取的数据分为训练集和测试集两部分，并利用训练集数据对模型进行训练。
- (6) 利用已经训练成熟的预测模型对测试样本预测。
- (7) 验证预测结果，评价模型泛化性能，并得出结论。

4.4 本章小结

本章将极限学习机应用在煤与瓦斯突出预测中，利用其处理多模式分类问题辨识能力强的优点，对瓦斯突出类型进行模式识别。首先从极限学习机的提出和发展出发，论述并研究了一般单隐层前馈神经网络和 ELM 网络的基本计算原理。其次在分析量子遗传算法的原理和特性的基础上，对量子遗传算法进行优化改进，提出免疫算法改进的量子遗传算法。最后运用改进后的量子遗传算法来优化 ELM 模型的输入层权值和隐含层阈值，建立了基于 KPCA 与 IQGA 算法优化的 ELM 煤与瓦斯突出预测模型。

5 预测模型在钱家营矿的实例应用

上一章中分析了极限学习机和量子遗传算法的基本原理，建立了基于 IQGA 算法优化的 ELM 煤与瓦斯突出预测模型，为了验证该预测模型的有效性，本章以开滦钱家营煤矿为研究背景，对预测模型进行性能训练与实际验证。

5.1 矿井概况

5.1.1 井田位置

钱家营煤矿是隶属于开滦集团煤业分公司的大型矿井之一，其地理位置是在河北省唐山市丰南区钱家营镇。矿井内的水、陆交通均十分方便，煤矿的东侧和西侧分别与秦皇岛港、天津新港相互接壤，南侧和北侧则依次与唐山港、曹妃甸港相通，构成了四面水路相通的格局，为煤的运输提供了很大的便利；而陆地运输则有专门的铁路线路，通往林西矿业和京山线古冶车站；井田位置处于各个公路干线的交叉位置，属于京、津、唐三角区范畴。

地理坐标：东经 $118^{\circ}14'12'' \sim 118^{\circ}24'43''$ ，北纬 $39^{\circ}30'13'' \sim 39^{\circ}38'32''$ 。其具体交通位置如图 5.1 所示。

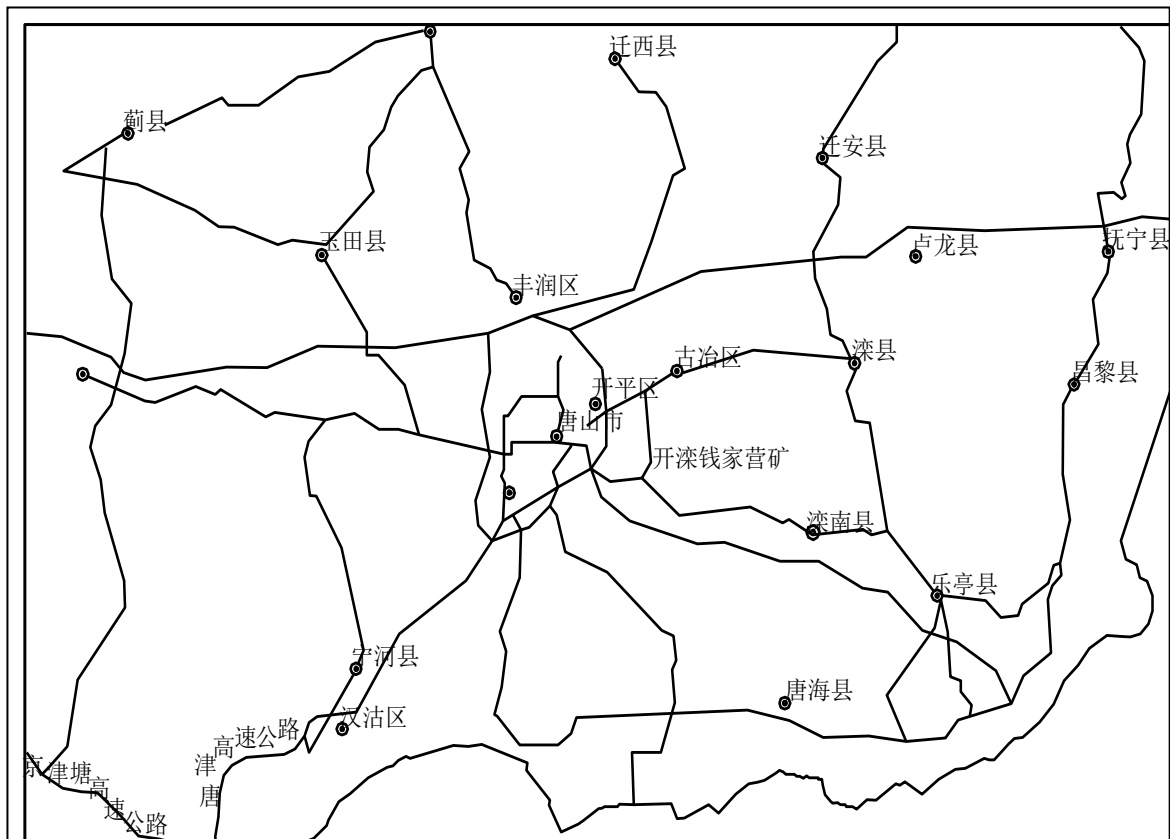


图 5.1 钱家营煤矿交通位置图
Figure 5.1 Qianjiaying coal mine traffic location map

5.1.2 煤层特征

该矿井井田内可采的煤层一共有 7 个，在这些可开采的煤层中全井范围均可开采的煤层有三个，分别为第 7、9、12 煤层，局部可开采煤层有四个，分别为第 5、6、8、11 煤层。所有煤层的具体情况如表 5.1 所示。

表 5.1 各煤层具体情况
Table 5.1 Specific conditions of each coal seam

煤层序号	煤层厚度最小~最大	结构	稳定程度	可采程度
#5	0~3.93	单一结构,时有夹石 1~2 层.	不稳定	局部可采
#6	0~3.13	单一结构,时有夹石 1~2 层	不稳定	局部可采
#7	2.15~7.17	复结构,含夹石 2~3 层	稳定	全区可采
#8	0~3.39	单一结构,时有夹石 1~2 层	不稳定	局部可采
#9	0.35~4.40	单一结构,时有夹石 1~2 层	较稳定	全区可采
#11	0~2.23	单一结构,时有夹石 1 层	极不稳定	局部可采
#12	0.39~6.41	单一结构,时有夹石 1~2 层	较稳	全区可采

在该煤矿的所有井田中能够全区范围内开采的煤层总共有三种，其煤层的赋存状态与特征描述如下：

(1) 煤层#7:

该煤层结构是简单结构，同时也是全区均可开采的煤层，厚度在 2.15~7.17m 范围内，平均厚度为 3.4m，其西北部分较薄，东南部分较厚，厚度存在一定的变化规律。其顶底板全部是粉砂岩，半亮型及半暗淡型种类的煤岩充斥了整个煤体，其中中间的一层及两层分布着暗淡煤，底部主要储藏着大量光亮类型的煤岩。硬度 f 在 0.4~0.9 范围内，容重为 1.4。

(2) 煤层#9:

该煤层结构也是简单结构的一种，亦是全区均可开采的煤层，厚度在 0.35~4.4m 范围内，平均厚度为 2.1m，其顶底板全部是粉砂岩，煤岩大多数都是光亮型的煤体，具有玻璃光泽。硬度 f 在 0.4~0.7 范围内，容重为 1.4。

(3) 煤层#12:

该煤层的结构是属于单一结构的中厚度煤层，同时也为矿井内全区均可开采的一个煤层，厚度在 0.39~6.41m 范围内，平均厚度为 2.1m。顶底板砂岩与煤层 7、煤层 9 有所不同，其底板都是粉砂岩，而顶板则是由粉细砂岩组成。煤岩大多数都是光亮型的煤体，中间掺杂着半光亮型煤体，具有油脂一般的亮度存在。该煤层中的煤岩坚固性系数 f 为 0.3，煤体的容重重量为 1.51。

5.1.3 矿井开拓方式

钱家营矿井中通常使用的开采形式为集中大巷、立井、多水平、阶段石门、各煤层叠加布置的方式^[60]。

全井田被分为三个生产水平，包括一水平（-600 水平），二水平（-850 水平）及三水平（-1050 水平）。划分如下：

（1）一水平（-600 水平）

一水平总共包括 6 个采区，一、二、三、四采区分布在东翼，五、六采区分布在西翼，目前正在生产作业的采区包括 一、二、三、四、六采区。

（2）二水平（-850 水平）

二水平总共包括 8 个采区，十采区、十一采区、十二采区分布在东翼；七采区、八采区、九采区、十三采区、十四采区分布在西翼。

（3）三水平（-1050 水平）

三水平的主要生产设备设置在 -1050m 水平，该水平总共包括 6 个采区，十六采区、十七采区、十八采区、十九采区、二十采区分布在西翼，十五采区分布在东翼。 -1200m 水平是放置辅助生产设备的区域，该水平一共被分为 6 个采区，二十一采区分布在西翼，而二十二采区、二十三采区、二十四采区、二十五采区、二十六采区则分布在东翼。

5.2 面域化预测指标的测定方法

根据第二章煤与瓦斯突出预测指标的选取原则，选择钱家营矿的煤体破坏类型、煤层瓦斯含量、地应力、煤的坚固性系数、声发射事件数、垂深、煤层瓦斯压力、最大钻屑量、电磁辐射强度、瓦斯涌出量、地质构造、软分层煤体厚度及瓦斯放散初速度这 13 项指标来构建其面域化预测指标系统。部分指标的测定方法如下：

（1）煤的坚固性系数：

测定方法：在掘进工作面工作时露出的新煤体上、中、下三个部分分别选取两个块度为 100mm 的样品，将其磨碎为 20-30mm 的状态，并分成均匀的 5 份，每份重量约为 50 克，然后将 5 份样本放到测量筒内。

用重量为 2.4kg 的锤子从 60m 高处自由落体，分别对 5 份煤样做 3 到 5 次的冲击捶打。利用孔径为 0.5mm 的分孔筛对处理过的 5 份煤样进行筛选，把从筛孔中通过的煤样存到计量筒里。

在计量筒内慢慢将通过筛选的煤样敲打并压实，测量其高度值，并进行记录。利用式（5.1）进行计算：

$$f = \frac{20n}{h} \quad (5.1)$$

其中， f 为所求的坚固性系数， h 为所记录的高度， n 为冲击的次数。

采用该方法对三组平行样本进行测量（每组选择 5 份样本），并求取所得数值的平均值，即为所求的煤的坚固性系数。

（2）声发射事件数:

对于声发射事件数的统计，本文选择从矿井声发射检测仪中读取，煤矿上选用的测试仪器是北京声华兴业科技有限公司生产的型号为 SAEU2S-200 的多通道声发射检测仪，仪器设备如图 5.2 所示。该系统可根据煤矿实际情况进行数据采集通道数量的选择，最多可同时选定 200 个数据采集通道，能够很快的实时监测声发射相关参数，并将这些参数进行实时显示。





图 5.2 声发射系统

Figure 5.2 Acoustic emission system

（3）瓦斯放散初速度:

本文采用变容变压式仪器来测量瓦斯放散初速度 Δp 。其示意图如图 5.3 所示。



1-真空泵; 2-玻璃管; 3-二通阀;

4-固定空间; 5-试样瓶; 6-三通阀; 7-真空汞柱计

图 5.3 变容变压式仪器示意图

Figure5.3 Variable capacity variable pressure instrument schematic

测定方法:

首先取 250 克的新煤体，将煤体样本捣碎成粉末状态，筛选出直径在 0.2mm-0.5mm 范

国内的颗粒，并将其平均分成两份，每份重 3.5 克，分别装入试样瓶内。按以下操作：

a) 打开图 5.3 中泵 1 与阀 3，保证 U 型汞柱计两侧液面水平保持一致。

b) 关闭泵 1 与阀 3。转动阀 6，与此同时，选择计数秒表来计时，当所计时间到 10s 时，将标号为 4 的固定空间与标号为 5 的试样瓶之间的连接切断，读取两侧汞柱差 p_1 (mmHg)；当计时达到 45s 时，将试样瓶和固定空间连接；计时达到 60s 时，再次切断固定空间与试样瓶之间的连接，第二次读取 U 型汞柱计两侧汞柱差 p_2 (mmHg)。

c) 根据下式求解： $\Delta p = p_2 - p_1$ ，即可求出瓦斯放散初速度 Δp 。

(4) 瓦斯含量与该处煤层的瓦斯压力：

瓦斯含量的测定选择现场打孔取芯直接测量的方法，其具有操作简单、测定速度快等优点，而直接测量瓦斯压力就会存在预测耗费时间长，选择地点困难等问题。为缩短测定时间，提高测定容易性，本文使用含量推出压力的计算公式：

$$W = \frac{abp}{1+bp} \times \frac{100 - A_d - M_{ad}}{100} \times \frac{1}{1+0.31M_{ad}} + \frac{10\pi p}{\gamma} \quad (5.2)$$

式中， W 是煤层中的瓦斯含量； P 是瓦斯压力； A_d 和 M_{ad} 分别是煤灰分及水分； π 是孔隙率； γ 是容重； a, b 为两种吸附常数。以上各项参数的测定结果如表 5.2 所示。

表 5.2 各项参数测定结果

Table 5.2 Measurement results of various parameters

煤层	9 号煤层
$a(m^3/t)$	22.743
$b(MPa^{-1})$	0.624
$M_{ad}(\%)$	0.48
$A_d(\%)$	7.99
$\pi(m^3/m^3)$	0.0231
$\gamma(t/m^3)$	14.211

将上述参数代入推导公式 (5.2) 中，即可求出瓦斯压力值，如表 5.3 所示。

表 5.3 部分煤层压力测试结果

Table 5.3 Partial coal seam pressure test results

编号	测试地点	瓦斯含量测量值 $W(m^3/t)$	推导瓦斯压力值 $P(MPa)$
1	二采区皮带巷 730m 处南帮	8.81	1.41
2	二采区皮带巷 730m 处南帮	8.78	1.40
3	二采区回风巷 450m 处北帮	12.03	3.01
4	二采区回风巷 450m 处北帮	9.94	1.38

(5) 瓦斯涌出量：

掘进工作面瓦斯涌出量是根据暴露煤壁涌出瓦斯含量以及破落煤壁涌出瓦斯含量两部分来进行计算的，公式如式 (5.3)：

$$q_{掘} = q_1 + q_2 \quad (5.3)$$

$$q_1 = D \times V_{掘} \times q_0 \times (2\sqrt{\frac{L}{V}} - 1) \quad (5.4)$$

$$q_2 = S_{掘} \times V_{掘} \times \gamma \times (W_0 - W_C) \quad (5.5)$$

其中, $q_{掘}$ 为所求的瓦斯涌出量; q_1 为所求煤层的煤壁瓦斯涌出量; q_2 为该处煤层中落煤瓦斯涌出量; D 为巷道断面内暴露煤壁面周边长度; $V_{掘}$ 为巷道平均掘进速度; $L_{掘}$ 为所求掘进工作面的煤巷长度; q_0 为煤壁瓦斯涌出初速度; $S_{掘}$ 为掘进煤巷断面积; γ 为容重。计算结果值详见表 5.4。

(6) 最大钻屑量:

使用重量法来测量最大钻屑量。测定方法: 测定该参数时需要用到容器、弹簧秤和刷子。首先在要进行预测的掘进工作面内某一煤层上面钻出两至三个小孔, 这些小孔必须要同时满足其直径大小为 42mm, 深度在 8m 至 10m 范围内这两种要求, 并选取某一特定容器来收集打钻过程中所磨出的煤屑。小孔深度每增加 1m, 就对煤屑进行一次采集并称重, 记录每次所收集煤屑的重量大小, 最后选择测量的最大值来充当预测指标。

(7) 电磁辐射强度:

本文选用钱家营煤矿上使用的 KBD5 电磁辐射监测仪来对煤矿进行电磁辐射强度的测定, 该测量仪器能够对煤层发射出的电磁辐射信号进行定向接收、设置参数、数据采集、显示及储存等。监测仪装置及控制面板分布如图 5.4 所示。




图 5.4 KBD5 电磁辐射监测仪

Figure 5.4 KBD5 electromagnetic radiation monitor

电磁辐射监测仪信号处理流程: 有瓦斯突出危险性威胁—煤岩体发生变形破裂—产生电磁辐射异常信号—仪器定向接收信号—电磁辐射监测仪显示电磁辐射强度值等参数。

5.3 钱家营矿煤与瓦斯突出预测实例分析

5.3.1 预测指标的核主成分分析

本次实验数据来自于钱家营煤矿的 1376 综采工作面, 该工作面位于矿区三采西翼, 工作面平均走向长度为 729 米, 平均倾斜长度为 173 米, 平均煤层倾角为 8° , 煤层平均厚

度为 3.5 米。工作面地质构造较为复杂，顶板稳定性较差，所受压力较大，容易破碎脱落。

从矿井瓦斯监控数据、现场测定数据及煤矿历史记录数据中，随机选定 200 组代表性的数据构成原始数据集 $\mathbf{X}=[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{200}]^T \in \mathbf{R}^{200 \times 5}$ ，见表 5.4（仅列第 181-200 组），将前 160 组作为训练集，后 40 组作为测试集。表中，煤体破坏类型总共被分成五种，分别用 1~5 代表；地质构造共有四种，数字 0~3 代表地质构造的复杂性为无、简单、中等及复杂。

表 5.4 面域化预测指标系统及突出数据集

Table 5.4 Area prediction indicator system and prominent data set

样 本 编 号	破 坏 类 型 D_t	坚 固 性 系 数 f	最 大 钻 屑 量 S (kg/m)	瓦 斯 含 量 G_c (m^3/t)	瓦 斯 压 力 P_g (Mpa)	放 散 初 速 度 ΔP (L/min)	垂 深 H (m)	地 质 构 造 G_s	软 分 层 煤 体 厚 度 H_m (m)	电 磁 辐 射 强 度 E (mV)	声 发 射 事 件 数 C (次)	地 应 力 P_0 (Mpa)	瓦 斯 涌 出 量 Q (m^3/min)	突 出 危 险 性 G
181	3	0.58	8.88	10.24	2.80	8	425	1	1.83	224	885	12.9	6.3	3
182	3	0.37	8.38	9.01	1.24	8	744	2	1.41	167	735	15.2	5.7	3
183	1	0.54	8.30	4.61	0.44	7	512	1	1.81	12	120	5.7	2.2	0
184	5	0.52	5.06	8.26	1.28	6	484	2	1.78	138	673	16.6	3.9	3
185	1	0.61	4.24	9.05	1.19	5	397	1	1.62	142	332	11.1	2.9	2
186	3	0.16	3.42	10.27	1.20	18	462	1	1.34	129	357	12.4	6.9	3
187	5	0.27	2.97	9.88	1.36	7	399	3	1.65	24	268	4.3	4.2	1
188	1	0.36	2.38	12.49	1.57	13	542	2	1.50	114	387	11.2	2.7	1
189	3	0.23	8.51	13.06	0.94	6	446	1	2.01	241	649	13.2	7.9	3
190	5	0.31	5.02	10.03	2.76	20	621	3	1.19	163	579	7.7	2.6	2
191	1	0.23	7.90	12.42	1.75	14	540	1	0.94	15	294	7.3	3.7	1
192	0	0.54	6.86	11.53	2.79	11	647	2	1.19	142	869	13.8	6.9	3
193	1	0.33	5.11	10.02	2.99	9	512	3	1.44	137	883	15.8	5.8	3
194	1	0.48	8.00	13.10	0.84	18	561	3	1.40	130	467	18.8	3.9	2
195	0	0.22	8.97	8.23	3.92	14	543	1	0.94	23	254	6.8	1.6	1
196	0	0.21	7.10	7.01	0.79	9	442	1	2.02	199	925	15.8	7.9	3
197	0	0.62	5.91	2.01	0.62	6	400	3	1.62	33	223	3.9	1.8	0
198	1	0.47	4.74	9.51	2.00	7	460	2	1.10	98	352	13.8	4.2	1
199	1	0.33	4.31	13.61	1.88	15	622	2	1.21	163	674	14.8	2	2
200	0	0.35	5.19	5.21	0.74	8	750	1	1.40	142	146	7.9	1	1

表 5.4 中给出了煤与瓦斯的突出等级，本文根据煤与瓦斯突出时抛出煤体重量的大小将突出分成四种类型：无突出记作 0、小型突出（50t 以下）记作 1、中型突出（50t-100t 以下）记作 2、大型突出（100t 以下）记作 3。

利用 MATLAB 软件对预处理后的数据指标进行归一化处理及核主成分分析，具体分析方法及处理步骤见第三章，在本研究中选择非线性分析能力较强的高斯径向基核函数来充当 KPCA 算法的核函数，其表达公式如式（3.6）所示，式中 σ 为核函数的超参数，根据

经验本文将 σ 设置为 500，分析处理后得到的各预测指标特征值及对应的贡献率如表 5.5 所示。由表 5.5 可知，前 5 项指标的累积贡献率为 90.460%，满足主成分提取规则，因此选择前 5 项主成分指标来代替原 13 项预测指标，即将 X_1 、 X_2 、 X_3 、 X_4 、 X_5 作为 ELM 模型的输入变量。特征提取后所得新的各变量数据表如表 5.6 所示。

表 5.5 各主成分贡献率
Table 5.5 Principal component contribution rate

项目	特征值	方差贡献率/%	累计贡献率/%
1	5.895	45.3462	45.346
2	2.0577	15.8285	61.175
3	1.7517	13.4746	74.649
4	1.1809	9.0838	83.733
5	0.8745	6.7269	90.460
6	0.4657	3.5823	94.042
7	0.3112	2.3938	96.436
8	0.2458	1.8908	98.327
9	0.1332	1.0246	99.352
10	0.0433	0.3331	99.685
11	0.0276	0.2123	99.897
12	0.0107	0.0823	99.979
13	0.0028	0.0215	100

表 5.6 特征提取后的样本数据表
Table 5.6 Sample data table after feature extraction

序号	综合变量 X_1	综合变量 X_2	综合变量 X_3	综合变量 X_4	综合变量 X_5
181	0.231	-0.095	-0.245	-0.245	0.097
182	0.024	-0.213	-0.456	-0.745	-0.094
183	0.324	0.4431	0.454	0.243	-0.012
184	0.234	0.432	-0.154	-0.453	0.674
185	0.435	-0.552	-0.112	0.446	-0.154
186	-0.26	-0.564	0.657	-0.076	0.111
187	-0.345	-0.568	-0.785	0.225	0.125
188	-0.065	0.326	0.546	0.467	-0.036
189	0.568	-0.054	0.022	-0.241	-0.363
190	-0.123	-0.223	-0.246	-0.245	-0.578
191	0.245	-0.045	-0.004	-0.024	0.446
192	0.456	-0.245	-0.554	-0.556	-0.087
193	0.344	0.455	0.876	0.132	-0.005
194	0.006	0.123	-0.143	-0.453	0.076
195	0.342	-0.334	-0.222	0.456	-0.596
196	-0.346	-0.455	0.547	-0.035	0.156
197	-0.436	-0.222	-0.139	0.109	0.112
198	-0.003	0.386	0.113	0.365	-0.795
199	0.113	-0.075	0.032	-0.121	-0.099
200	-0.276	-0.314	-0.356	-0.286	-0.186

5.3.2 IQGA-ELM 预测模型性能训练

要想使预测模型的性能十分优越，就需要在 MATLAB 软件上对前 160 组训练样本进行批量式学习与训练。在进行批量式学习训练之前，首先需要确定的是在选择 ELM 神经网络进行预测模型建立时，该如何针对煤与瓦斯突出具体问题来对 ELM 预测模型的激活函数和隐含层的节点数目进行设定。

根据第四章介绍的极限学习神经网络的基本原理及相关理论可知，如何选取极限学习机隐含层节点数和激励函数对该学习机的学习性能起到了十分关键的作用。本文根据参数设置的经验，在 MATLAB 程序中先将 ELM 网络隐含层节点的数目设定为 70，并在该相同条件下依次对 Sigmoidal、sin、Radial basis 这三种常用的激活函数进行 ELM 模型学习及训练，将三种激活函数所得出的训练误差、训练时间进行对比，进一步分析各模型的泛化能力。对比结果如表 5.7 所示。

表 5.7 不同激活函数的泛化性能
Table 5.7 Generalization performance of different activation functions

激活函数	网络复杂度	训练相对误差/%	训练时间/s
Sigmoidal	70	4.112	0.729
sin	70	5.856	0.721
Radial basis	70	6.142	0.719

通过 MATLAB 训练比较各激活函数的泛化性能可知，在网络复杂度相等的情况下，各函数的训练时间几乎相等，但 Sigmoidal 函数的相对训练误差要小很多，泛化性能比其他两种激活函数要稳定；采用 Sigmoidal 函数对 ELM 网络的隐含层节点数进行训练选择得出：当 L 取值为 90 时模型的平均误差率最低且逐渐平缓，如图 5.5 所示。

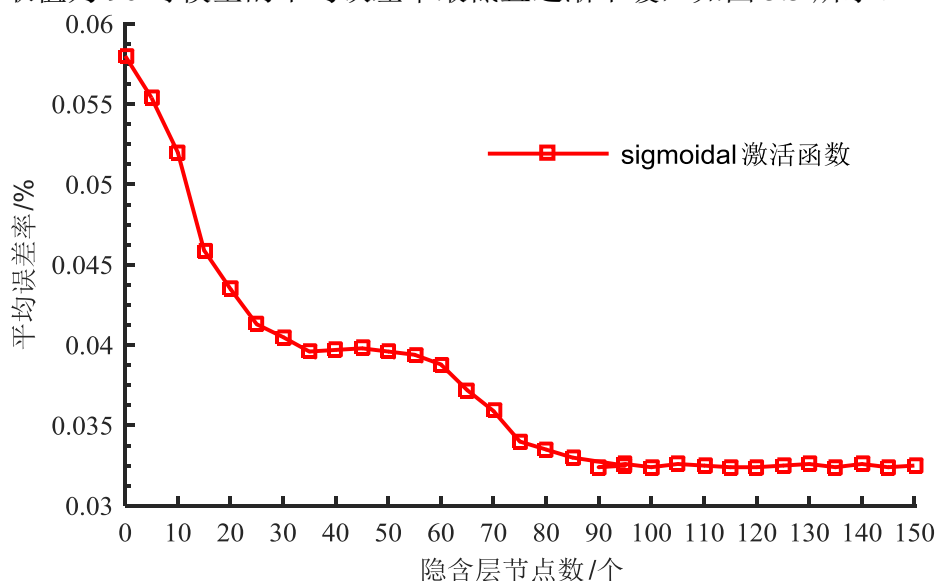


图 5.5 隐含层节点的选取

Figure 5.5 Selection of hidden layer nodes

因此, 本文选择 Sigmoidal 函数来充当 ELM 的激活函数, 并将 ELM 隐层节点的数量设置为 90。

ELM 模型的输入层权值和隐含层阈值则通过 IQGA 算法来优化选取, 具体优化步骤详见第四章。在 MATLAB 软件上初始化 IQGA 算法参数: 设种群规模 N 的数量为 30, 迭代次数为 100, 免疫记忆库容量 M 值为 10, 均采用二十个二进制位来体现每个解中的任意参数, 相似度系数为 0.7, 期望繁殖概率 P 为 95%, 量子旋转角公式中 $r=0.01, h=0.1$ 。由图 5.6 所显示的收敛曲线可知, 算法大约迭代到 20 代时全局最佳适应度值收敛且达到最大, 进而获得全局最优的输入权值和隐含层阈值, 再将寻优所得到的全局最优解当作 ELM 预测模型的输入权值与隐含层阈值来建立最佳的煤与瓦斯突出危险性预测模型。




图 5.6 IQGA-ELM 适应度收敛曲线

Figure 5.6 IQGA-ELM fitness convergence curve

5.3.3 预测结果及对比分析

利用前 160 组样本数据对 KPCA-IQGA-ELM 模型完成训练后, 再使用全部样本数据中的后 40 组数据对测试样本预测, 验证模型的有效性。

本文将该预测模型的预测误差定义为:

$$perror = \frac{2|y - \hat{y}|}{\text{差别空间}} \times 100\% \quad (5.6)$$

其中, 将 y 定义为实际值, \hat{y} 则为预测所得到的预测值, 差别空间大小是对预测值和中心值差值的反映, 本文将其设为 50, 并利用其来判断预测的误差。

训练成熟的模型对后 40 组数据的预测结果如图 5.7 所示。




图 5.7 测试集预测结果图
Figure 5.7 Test set prediction result graph

由预测结果可知，利用本文提出的煤与瓦斯突出预测模型对后 40 组测试样本进行预测，仅有一组预测突出结果与实际突出类型不相同，其余 39 组预测结果均与实际突出类型一致，预测准确率达到了 97.5%，满足了分类辨识的基本要求。因此，将 KPCA 理论与 IQGA 优化的极限学习机相结合建立的预测模型应用在煤与瓦斯突出预测中具有较强的可行性，满足煤与瓦斯突出预测的实际预测要求，能准确的预测出煤与瓦斯突出的危险性。

为了更加突出本文所建立的 IQGA-ELM 预测模型的有效性和先进性，将 IQGA 优化的 ELM 模型、未优化的 ELM 模型及较为成熟的 SVM 煤与瓦斯突出预测模型分别采用 KPCA 与 PCA 方法进行特征提取操作后，对 200 组原始数据训练学习并预测，比较各模型泛化性能。表 5.8 为三种预测模型经 KPCA 与 PCA 处理后的预测误差对比（仅列出后五组）。

表 5.8 预测误差及收敛时间对比
Table 5.8 Comparison of prediction error and convergence time

序号	经 KPCA 处理的预测误差			经 PCA 处理的预测误差		
	SVM	ELM	IQGA-ELM	SVM	ELM	IQGA-ELM
196	0.2456	0.1764	0.0356	0.5564	0.3465	0.0975
197	0.2986	0.1543	0.0463	0.4986	0.3001	0.1109
198	0.2843	0.1654	0.0351	0.5281	0.2179	0.0947
199	0.2853	0.1760	0.0377	0.4690	0.2265	0.0970
200	0.2985	0.1654	0.0473	0.5033	0.3066	0.1199
预测时间/s	1.564	0.997	1.742	1.763	1.448	2.0004

从表 5.8 的误差结果可看出，SVM、ELM 及 IQGA-ELM 三种预测模型采用 KPCA 特征提取后的预测误差均小于 PCA 处理后的预测误差，这表明经 KPCA 处理后的预测模型

稳定性更强，预测偏差更小，更适合用于煤与瓦斯突出的预测。在预测时间上，经 KPCA 提取后的三种预测模型具有更快的预测速度。虽然 IQGA-ELM 模型预测过程中所需的时间略多余其它模型，但对于煤与瓦斯突出预测问题，当预测时间在合理范围内时，预测模型的精度和稳定性要比预测时间更加重要。

表 5.9 和图 5.8 分别为各模型采用 KPCA 方法特征提取后，预测模型的预测效果与训练误差对比。

表 5.9 KPCA 降维后各模型预测效果
Table 5.9 Prediction effect of each model after KPCA dimension reduction

性能指标	IQGA-ELM	ELM	SVM
训练精度/%	98.125	91.875	90.000
预测精度/%	97.500	92.500	90.000




图 5.8 KPCA 处理后各模型训练误差

Figure 5.8 Training error of each model after KPCA processing

在表 5.9 中 IQGA-ELM 预测模型的分类效果要优于其它两种模型，该模型的训练精度与预测精度均高于未优化的 ELM 模型及 SVM 预测模型，具有较强的泛化能力。由图 5.8 可直观发现，三种模型的训练误差均逐渐趋于稳定，表明三种模型性能均较稳定，可以用来对煤与瓦斯的突出进行预测；而 IQGA-ELM 预测模型的训练误差远远小于未优化的 ELM 模型及 SVM 预测模型的训练误差，使得该模型的预测准确率得到了保障。

综上所述，本文所创建的基于 KPCA 与 IQGA-ELM 突出预测模型具有预测精度高、训练误差低、泛化能力强等优点，可以运用在煤矿实际的煤与瓦斯突出灾害预测中，能有效预防瓦斯灾害的发生。

5.4 工程应用

为了验证该预测方法在数据样本较大时的分类能力。笔者在开滦钱家营煤矿 1392 掘进工作面 2008-2018 年的突出事故中截取了 300 组突出数据进行大样本预测。

将截取的这段数据当作预测模型的输入变量，根据突出发生的先后时间顺序依次输入至已经训练好的 KPCA-IQGA-ELM 模型，对这些数据进行突出预测，并将该时间段内矿区真实的突出次数及突出危险程度与模型的预测结果相对比，统计模型预测的准确率。该实验的结果如表 5.10 所示。

表 5.10 预测结果
Table 5.10 Forecast result

模型	平均预测相对误差/%	预测结果正确个数	平均预测正确率/%
IQGA-ELM	0.2131	294	98.00

预测结果显示，该预测结果的平均预测准确率为 98.00%，这表明当样本数据数量较大时，该预测模型同样具有很好的分类效果，该方法对准确预测煤与瓦斯的突出程度有很重要的意义。

5.5 本章小结

本章以开滦钱家营煤矿为研究对象，首先简单介绍了钱家营矿井的概况，其次针对矿井实际突出数据进行瓦斯突出预测仿真实验，包括面域化预测指标的权重分析、预测模型的训练、测试以及结果对比分析，仿真结果表明本文提出的基于 KPCA 与 IQGA-ELM 的煤与瓦斯突出预测方法在实际突出预测中具有十分重要的意义；最后，对预测模型进行了大样本验证，证明了该预测方法在实际煤与瓦斯突出预测中的有效性和准确性。

6 结论与展望

6.1 结论

近年来，煤与瓦斯突出事故的发生率不断升高，因其强大的破坏性和突发特性，给我国社会经济的发展带来了很大的威胁。随着国内外学者对瓦斯突出机理的研究，许多煤与瓦斯突出预测方法已经取得了很好的效果，但由于目前对煤与瓦斯突出机理的说法众说纷纭，传统的预测方法自身也存在一些缺陷，在预测速度及预测精度等方面均不能满足实际矿井的瓦斯预防需求。

因此，本文以高精度快速度预测瓦斯突出危险性为目标，通过分析煤与瓦斯突出机理及影响因素，构建了基于掘进工作面的面域化预测指标系统。并首次将量子遗传算法应用在瓦斯突出预测领域中，建立了具有高精度的基于 KPCA 与 IQGA-ELM 的煤与瓦斯突出预测模型。通过对模型的研究和实例验证，得出以下结论：

本文讨论了研究煤与瓦斯突出预测课题的意义和价值，对煤与瓦斯突出研究现状、突出机理进行深入分析，提出采用核主成分分析理论与改进量子遗传算法优化极限学习机相结合的煤与瓦斯突出预测方法。

在总结煤与瓦斯突出影响因素与高危突出区域的基础上，建立了包含 13 项预测指标的面域化预测指标系统，并采用 KPCA 法针对实际煤矿的面域化预测指标进行特征提取，准确的提取出了对突出影响权重较大的几项指标，将其作为预测模型的输入，极大的提高了模型预测的运算速度。

针对传统 ELM 随机产生输入层权值和隐含层阈值会使模型性能不稳定的问题，引入改进量子遗传算法优化选取这两个参数，提出基于 IQGA 算法优化的 ELM 预测模型，显著的提高了 ELM 模型的稳定性和预测精度。

以开滦钱家营煤矿为例，进行仿真实验和对比分析，结果表明该预测模型泛化能力较强，具有高精度、快速度等特点。因此，本文提出的预测模型对提高煤与瓦斯突出的预测效率和准确率具有较好的可行性，为有效预测煤与瓦斯的突出提供了新方法和新思路。

6.2 展望

(1) 近年来，通过对煤与瓦斯突出现象的深入研究，国内外学者已经提出诸多煤与瓦斯突出预测理论，但是由于人们对煤与瓦斯突出机理和本质还不是十分清楚，而且影响突出的因素也复杂繁多，所以目前还没有一种预测方法可以完全准确的对突出进行提前预测，因此，进一步深入研究瓦斯突出的机理，从本质上解决瓦斯突出预测问题，是今后预防煤与瓦斯突出工作的重中之重。

(2) 由于时间和其它客观原因的限制，预测的实测数据量并不是十分丰富，而且集

中在某一特定煤矿，因此，在以后的研究和实际运用中，要注重采集多个不同煤矿的突出数据，以便对建立的预测模型进行进一步验证与改进。

（3）本文提出的预测模型只是为煤与瓦斯突出预测提供了一种新的方法。现今，突出预测方法有很多，如何在现有突出预测理论的基础上，将多种预测方法进行合理融合，弥补各方法的缺陷，充分发挥各方法的优势，以达到准确预测突出实际情况的效果，是今后研究中不断追求的目标。

参考文献

- [1]李绍泉,李青松,衡献伟,等.煤与瓦斯突出预警技术现状与展望[J].煤矿安全,2013,44(05):160-163.
- [2]闫江伟,张小兵,张子敏.煤与瓦斯突出地质控制机理探讨[J].煤炭学报,2013,38(07):1174-1178.
- [3]Jun T,Chenglin J,Yujia C.Line prediction technology for forecasting coal and gas outbursts during coal roadway tunneling[J].Journal of Natural Gas Science and Engineering,2016,34(01):412-418.
- [4]谢霖.基于 MPSO-LS-SVM 算法的瓦斯涌出量预测研究[D].阜新:辽宁工程技术大学,2014.
- [5]张仁松,卜珍虎,刘万伦.不同突出煤层区域预测临界值指标的确定[J].煤炭技术,2018,37(11):178-180.
- [6]刘艳亮.2002~2016 年我国煤矿事故统计分析及预防措施[J].陕西煤炭,2018,37(03):64-67+40.
- [7]马云波,武甲.煤矿掘进工作面煤与瓦斯突出危险预警及可视化研究[D].北京:中国矿业大学,2017.
- [8]陈娟,赵耀江.近十年来我国煤矿事故统计分析及其启示[J].煤炭工程,2012(03):137-139.
- [9]Finkelman D.Coal geology in China:an overview[J].International Geology Review,2018,60(05):12-16.
- [10]Shugang L,Tianjun Z.Catastrophic mechanism of coal and gas outbursts and their prevention and control[J].Mining Science and Technology (China),2010,20(02):209-214.
- [11]闫孝姮.掘进工作面煤与瓦斯突出非线性动态预测研究[D].阜新:辽宁工程技术大学,2016.
- [12]彭英健.煤中小分子有机物对煤层瓦斯赋存增强效应研究[D].北京:中国矿业大学,2015.
- [13]Wei Y,Hao W,Qinyuan Z,et al.Mechanism of water inhibiting gas outburst and the field experiment of coal seam infusion promoted by blasting[J].Fuel,2019,21(251):383-393.
- [14]张小东,李朋朋,张硕.不同煤体结构煤的瓦斯放散特征及其影响机理[J].煤炭科学技术,2016,09:93-98.
- [15]李心杰.基于 SA-GA-FCM 的煤与瓦斯突出预测研究[D].阜新:辽宁工程技术大学,2015.
- [16]张瑾.基于优化支持向量机的煤与瓦斯突出预测研究[D].阜新:辽宁工程技术大学,2015.
- [17]孙丽娟.基于煤矿瓦斯监测数据的煤与瓦斯突出预警技术研究[D].郑州:河南理工大学,2010.
- [18]Wold M B,Connell L D,Chois S K.The role of spatial variability in coal seam parameters on gas outburst behavior during coal mining[J].International Journal of Coal Geology,2008,75(01):1-14.
- [19]Lichtenberger M.Underground Measurements of Electromagnetic Radiation Related to Stress-induced Fractures in the Odenwald Mountains (Germany) [J].Pure and Applied Geophysics,2006,163(08):1661.
- [20]陈鹏.煤与瓦斯突出区域危险性的直流电法响应及应用研究[D].北京:中国矿业大学,2013.
- [21]赵晶,汪东.中远距离煤层群煤与瓦斯协调开发模式研究[J].煤炭科学技术,2016,44(08):127-131.
- [22]李文娟.改进的极限学习机在煤与瓦斯突出预测中的应用[D].阜新:辽宁工程技术大学,2015.
- [23]Haifeng W,Yuanping C,Liang Y.Coal and gas outburst disasters and the mining technology of key protective seam in coal seam group in the Huainan mining area:A case study of Xinzhuanzi coal mine[J].Safety Science,2013(05):241-231.
- [24]Li T,M F.Cai,M.A review of mining-induced seismicity in China[J].International Journal of Rock Mechanics & Mining Sciences,2007(44):1149-1171.

- [25]方可,卢忠英,方标.煤与瓦斯突出危险性预测指标的现状与分析[J].中国科技信息,2015,5(01): 57-59.
- [26]谢鸿.邻域粗糙集和核极端学习机在煤与瓦斯突出预测中的研究[D].阜新:辽宁工程技术大学,2017.
- [27]张晓铭.基于 PSO 算法优化的自组织竞争神经网络在煤与瓦斯突出预测中的应用研究[D].太原:太原理工大学,2013.
- [28]温廷新,孙红娟,张波,等.煤与瓦斯突出预测的 QGA-LSSVM 模型[J].中国安全生产科学技术,2015,11(05):5-12.
- [29]郝吉生.BP 算法及其在煤与瓦斯突出预测中的应用[J].辽宁工程技术大学学报,2004,21(01):9-11.
- [30]田云丽,周利华.基于 BP 神经网络的煤与瓦斯突出预测方法的研究[J].系统工程理论与实践,2005,11(12):102-106.
- [31]赵志刚,谭云亮.基于混沌理论的煤与瓦斯突出前兆时序预测研究[J].岩土力学,2009,30(07):2186-2190.
- [32]郭德勇,李念友,裴大文,等.煤与瓦斯突出预测灰色理论-神经网络方法[J].北京科技大学学报,2007,11(04):354-357.
- [33]孙艳玲,秦书玉,梁宏友.煤与瓦斯突出预报的模糊聚类关联分析法[J].辽宁工程技术大学学报,2003,12(04):492-493.
- [34]蒋承林,俞启香.煤与瓦斯突出机理的球壳失稳假说[J].煤矿安全,1995,(02):17-24.
- [35]周世宁,何学秋.煤和瓦斯突出机理的流变假说[J].中国矿业大学学报,1990,19(2): 1-8.
- [36]李萍丰.浅谈煤与瓦斯突出机理的假说——二相流体假说[J].煤矿安全,1989,(11):29-35.
- [37]侯福营.基于改进 PCA-ELM 的煤与瓦斯突出软测量研究[D].阜新:辽宁工程技术大学,2014.
- [38]陈全秋.遗传算法与神经网络相结合在煤与瓦斯突出危险预测中的应用研究[D].太原:太原理工大学,2010.
- [39]王昱舒.基于 PCA-AKH-BP 神经网络的面域相结合的煤与瓦斯突出预测模型及其应用研究[D].太原:太原理工大学,2017.
- [40]王刚,程卫民,谢军,等.瓦斯含量在突出过程中的作用分析[J].煤炭学报,2011,36(03):429-434.
- [41]Saruar A,GooRak K.Alzheimer disease classification using KPCA,LDA,and multi - kernel learning SVM[J].International Journal of Imaging Systems and Technology,2017,27(2):133-143.
- [42]翁理国,孔维斌,夏旻,等.基于深度极限学习机的卫星云图云量计算[J].计算机科学,2018,45(04):227-232.
- [43]徐耀松,邱微,王治国.基于小波 KPCA 与 IQGA-ELM 的煤与瓦斯突出预测研究[J].传感技术学报,2018,31(05):720-725.
- [44]Elkhadir Z,Chougali K,Benattou M.Intrusion detection system using PCA and kernel PCA methods[M]. New York :Springer International Publishing,2016:13-22.
- [45]Alam S,Rak Kwon G.Alzheimer disease classification using KPCA,LDA,and multi - kernel learning SVM[J].International Journal of Imaging Systems and Technology,2017,27(2):133-143.

- [46]谭云亮,肖亚勋,孙伟芳.煤与瓦斯突出自适应小波基神经网络辨识和预测模型[J].岩石力学与工程学报,2007,S1:3373-3377.
- [47]桂祥友,郁钟铭.基于灰色系统理论的煤矿瓦斯涌出量预测研究[J].贵州工业大学学报(自然科学版),2007,2(06):9-13.
- [48]杨飞龙,蒋承林,孙鑫,等.煤与瓦斯突出影响因素评价分析的模糊层次分析方法[J].中国安全生产科学技术,2009,5(06):53-56.
- [49]尹健行,王真理,张平野,等.一种基于 KPCA 的绕射信息分离方法[J].地球物理学进展,2017,32(02):799-807.
- [50]ChenWei D,GuangBin H,Jia X,et al.Extreme learning machines: new trends and applications[J].Science China(Information Sciences),2015,58(02):5-20.
- [51]蒋姗姗.基于智能优化算法和支持向量机的心电逆问题研究[D].杭州:浙江理工大学,2014.
- [52]Yuanfang X,Yuanyuan J,Xuemei Z. Gas outburst prediction model based on empirical mode decomposition and extreme learning machine[J].Recent Advances in Electrical & Electronic Engineering,2015,8(1):50-56.
- [53]查全民,汪荣贵,何畏.基于量子遗传聚类的入侵检测方法[J].计算机应用研究,2010, 27(1):240-243.
- [54]田浩杉.基于量子遗传的蒙特卡洛节点定位算法[J].传感器与微系统,2017,36(09):125-128+135.
- [55]梁昌勇,柏桦,蔡美菊,等.量子遗传算法研究进展[J].计算机应用研究,2012,29(7):2401-2405.
- [56]Neelam D,Ram Pal S.ELM-Kernel and reduced kernel ELM based watermarking scheme[J].Journal of Information Security and Applications,2019,46(04):173-192.
- [57]崔翔鹏,黄洪琼.基于 GA 优化 ELM 的船舶交通流预测模型[J].微型机与应用,2017,36(09):15-17+21.
- [58]Akarsh G.Application of genetic algorithm based intuitionistic fuzzy k-mode for clustering categorical data[J].Cybernetics and Information Technologies,2017,17(4):99-113.
- [59]周建平,林韩,温步瀛.改进量子遗传算法在输电网规划中的应用[J].电力系统保护与控制,2012,40(19):90-95.
- [60]夏欢阁.建筑群下特厚松散覆层煤层条带式开采方法的研究与应用[D].阜新:辽宁工程技术大学,2007.

学位论文原创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果。其他同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文与资料若有不实，愿意承担一切的法律责任。

学位论文作者签名： 邱微
2019 年 6 月 10 日

学位论文数据集

关键词*	密 级*	中图分类号*	UDC	论文资助
煤与瓦斯突出； 预测；核主成分 分析；极限学习 机；量子遗传算 法；	公开	TP183	621.3	国家自然科学基金项目 (61601212)； 辽宁省教育厅基 金项目 (LJYL014)
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
辽宁工程技术大学	10147	工学	硕士	
论文题名*		并列题名*	论文语种*	
基于 KPCA 与改进极限学习机的煤与瓦斯突出预测研究		Research on Prediction of Coal and Gas Outburst Based on KPCA and Improved Extreme Learning Machine	中 文	
作者姓名*	邱微	学 号*	471620580	
培养单位名称*	培养单位代码*	培养单位地址	邮 编	
辽宁工程技术大学	10147	辽宁省阜新市	123000	
学科专业*	研究方向*	学 制*	学位授予年*	
控制理论与控制工程	信息处理与模式识别	3	2019	
论文提交日期*		2019 年 6 月		
导师姓名*	徐耀松	职 称*	副教授	
评阅人		答辩委员会主席*	答辩委员会成员	
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ）				
推荐格式: application/msword; application/pdf				
电子版论文出版（发布）者	电子版论文出版（发布）地		权限声明	
论文总页数*		52		
注：共 33 项，其中带*为必填数据，共 22 项。				