



全日制硕士学位论文

基于 LLE-WPA-BP 算法的瓦斯涌出量预测研究

Study of gas emission prediction based on LLE-WPA-BP algorithm

作者姓名: 姜杉杉

导师姓名: 贾进章

学科专业: 安全管理工程

研究方向: 安全信息工程

完成日期: 2022 年 6 月 10 日

辽宁工程技术大学

Liaoning Technical University

中图分类号 X936

学校代码 10147

UDC 622

密 级 公 开

辽宁工程技术大学
全日制硕士学位论文

基于 LLE-WPA-BP 算法的瓦斯涌出量预测研究

**Study of gas emission prediction based on LLE-
WPA-BP algorithm**

作者姓名 姜杉杉

学 号 471921030

导师姓名 贾进章（教授）

副导师姓名 苏立勇（高级工程师）

申请学位 工学硕士

培养单位 安全科学与工程学院

学科专业 安全管理工程

研究方向 安全信息工程

二〇二二年六月

致 谢

在辽宁工程技术大学度过了三年的刻苦学习时光，系统地学习了安全管理工程专业的知识，由衷佩服各位老师的学识，感谢老师们对论文提出的宝贵意见，让我细化完善论文的内容，弥补论文中的不足，提高论文质量，在此表示真挚的感谢。

在论文即将完成之际，我要感谢我的导师贾进章教授。在论文撰写的整个过程中，从论文选题、到撰写开题报告、最后到正文撰写，贾进章老师都提出了很多宝贵意见，老师指出的问题和指导的思路都使我有醍醐灌顶之感。贾老师不厌其烦地给予我及时地纠正和指导，使我能够顺利完成论文写作工作。同时感谢苏立勇老师（教授级高级工程师）对论文的指导，谨向两位导师表示崇高的敬意和衷心的感谢！

感谢在论文中引用、借鉴观点的专家学者，是你们对知识的共享，成就了科研的不断创新与辉煌。感谢在百忙之中对我论文进行评审和参与我论文答辩的老师，恳请批评指正。

最后再次感谢辽宁工程技术大学为我带来宝贵的学习机会，使我能够走上一个新的平台，开启一段新的旅程！

摘 要

我国拥有丰富的天然煤炭资源。根据国家发布的事故统计可知，瓦斯事故发生次数仍在煤矿事故总发生次数的前列。为保证井下工作的安全展开，需对瓦斯含量较高的煤层进行瓦斯抽采工作。瓦斯抽采工作的进行与采煤区工作面瓦斯涌出量相关，故要对瓦斯涌出量进行准确的预测，以提高瓦斯抽采工作的效果、保证矿井作业的安全。

选择 BP 神经网络作为本文所用预测模型。针对 BP 神经网络易陷入局部极小值、收敛速度慢、权值阈值随机产生等问题，采用局部线性嵌入算法（LLE）将原始输入数据进行降维处理。在局部线性嵌入式算法参数设置过程中进行了 6 轮的对比实验，得出最佳参数值。利用 8 种函数测试狼群算法（WPA）、粒子群算法（PSO）、防碰撞算法（FSA）的寻优性能，择优选择出狼群算法来优化 BP 神经网络参数值。将 3 种算法代入 Matlab 软件中构建出 LLE-WPA-BP 预测模型。

通过分析瓦斯涌出规律、影响因素及指标选取的标准构建出模型指标体系。按照指标体系选取出马堡煤矿监测数据代入 LLE-WPA-BP 预测模型中进行数据分析，同时也代入 BP 模型、GA-BP 模型和 WPA-BP 模型进行对比实验。数值模拟的实验结果表明，LLE-WPA-BP 模型预测值与实际检测得到的马堡煤矿瓦斯涌出量真实值拟合程度最好，平均绝对误差、平均相对误差、平均相对变动值最低，分别为 $0.0695\text{m}^3/\text{t}$ 、0.0093、0.0193。可以更加有效地对矿井瓦斯涌出量进行准确预测，应用范围更广。

基于 LLE-WPA-BP 算法的瓦斯涌出量预测的研究，与部分预测模型相比预测性能较强，可较好的应对复杂条件下的瓦斯涌出量预测。进而降低瓦斯事故发生频率，提高矿井作业的安全性。

该论文有图 29 幅，表 21 个，参考文献 73 篇。

关键词：瓦斯涌出量；BP 神经网络；局部线性嵌入式算法；狼群算法；预测技术

Abstract

China is rich in natural coal resources. According to the accident statistics released by the state, the number of gas accidents is still in the forefront of the total number of coal mine accidents. In order to ensure the safety of underground work, it is necessary to carry out gas extraction in coal seams with high gas content. The gas drainage work is determined according to the gas emission of the working face in the coal mining area. Therefore, it is necessary to accurately predict the amount of gas emission in order to improve the effect of gas extraction and ensure the safety of mine operation.

BP neural network is selected as the prediction model used in this thesis. Aiming at the problems that BP neural network is easy to fall into local minimum, slow convergence speed and random generation of weight and threshold, the LLE algorithm is used to reduce the dimension of the original input data. In the process of LLE algorithm parameter setting, six rounds of comparative experiments are carried out to obtain the best parameter value. Eight functions are used to test the optimization performance of WPA algorithm, PSO algorithm, FSA algorithm, and WPA algorithm is selected to optimize the parameter value of BP neural network. Three algorithms are substituted into Matlab software to construct LLE-WPA-BP prediction model.

The model index system is established by analyzing the gas emission law, influencing factors and the standard of index selection. According to the index system, the monitoring data of Mabao Coal Mine is selected and substituted into LLE-WPA-BP prediction model for data analysis. It is also substituted into BP model, GA-BP model and WPA-BP model for comparative experiment. The experimental results of numerical simulation show that the fitting degree between the predicted value of LLE-WPA-BP model and the real value of gas emission from Mabao Coal Mine is the best, and the average absolute error, average relative error and average relative change value are the lowest, which are $0.0695\text{m}^3/\text{t}$, 0.0093 and 0.0193 respectively. It can more effectively predict the mine gas emission accurately and has a wider application range.

The study of gas emission prediction based on LLE-WPA-BP algorithm has stronger prediction performance than some prediction models, and can better deal with the prediction of gas emission under complex conditions. So as to reduce the frequency of gas accidents and improve the safety of coal mine operation.

The thesis has 29 figures, 21 tables and 73 references.

Key words: gas emission; BP neural network; local linear embedding algorithm; wolf pack algorithm; prediction technology

目 录

摘 要.....	I
目 录.....	III
图清单.....	VII
表清单.....	IX
变量注释表.....	XI
1 绪论	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	4
1.3 研究内容.....	11
1.4 技术路线.....	12
2 矿井瓦斯涌出量影响因素研究	13
2.1 瓦斯涌出规律研究.....	13
2.2 瓦斯涌出量影响因素研究.....	14
2.3 瓦斯涌出量的计算.....	17
2.4 瓦斯涌出量预测指标.....	17
2.5 本章小结.....	18
3 瓦斯涌出量预测算法	19
3.1 人工神经网络.....	19
3.2 BP 神经网络.....	22
3.3 寻优算法的选择.....	28
3.4 狼群算法.....	31
3.5 降维算法.....	33
3.6 本章小结.....	35
4 基于 LLE-WPA-BP 算法的瓦斯涌出量预测实验分析	37
4.1 基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型构建.....	37
4.2 预测模型的实验数据.....	38
4.3 实验参数设定.....	40
4.4 局部线性嵌入式算法参数设定.....	41

4.5 基于 LLE-WPA-BP 算法的瓦斯涌出量预测	48
4.6 本章小结	52
5 多种模型瓦斯涌出量预测对比分析	54
5.1 基于 BP 神经网络算法的瓦斯涌出量预测模型	54
5.2 基于 GA-BP 算法的瓦斯涌出量预测模型	55
5.3 基于 WPA-BP 算法的瓦斯涌出量预测模型	55
5.4 多种模型瓦斯涌出量预测结果分析	56
5.5 本章小结	58
6 结论与展望	59
6.1 结论	59
6.2 展望	60
参考文献	61
作者简介	65
学位论文原创性声明	66
学位论文数据集	67

Contents

Abstract	II
Contents	V
List of Figures	VII
List of Tables	IX
List of Variables	XI
1 Introduction	1
1.1 Research Background and Significance	1
1.2 Research Status at Home and Abroad	4
1.3 Research Content	11
1.4 Technical Route	12
2 Study on Influencing Factors of Mine Gas Emission	13
2.1 Study on Gas Emission Law	13
2.2 Study on Influencing Factors of Gas Emission	14
2.3 Calculation of Gas Emission	17
2.4 Prediction Index of Gas Emission	17
2.5 Summary of this Chapter	18
3 Prediction Algorithm of Gas Emission	19
3.1 Artificial Neural Network	19
3.2 BP Neural Network	22
3.3 Selection of Optimization Algorithm	28
3.4 Wolf Pack Algorithm	31
3.5 Dimensionality Reduction Algorithm	33
3.6 Summary of this Chapter	35
4 Experimental Analysis of Gas Emission Prediction Based on LLE-WPA-BP Algorithm	37
4.1 Establishment of Gas Emission Prediction Model Based on LLE-WPA-BP Algorithm	37
4.2 Experimental Data of Prediction Model	38
4.3 Experimental Parameter Setting	40
4.4 LLE Algorithm Parameter Setting	41

4.5 Prediction of Gas Emission Based on LLE-WPA-BP Algorithm.....	48
4.6 Summary of this Chapter.....	52
5 Comparative Analysis of Gas Emission Prediction of Various Models	54
5.1 Prediction Model of Gas Emission Based on BP Neural Network Algorithm.....	54
5.2 Gas Emission Prediction Model Based on GA-BP Algorithm.....	55
5.3 Prediction Model of Gas Emission Based on WPA-BP Algorithm.....	55
5.4 Analysis of Prediction Results of Gas Emission of Various Models.....	56
5.5 Summary of this Chapter.....	58
6 Conclusions and Prospect	59
6.1 Conclusions	59
6.2 Prospect	60
Reference.....	61
Author's Resume	65
Declaration of Thesis Originality	66
Thesis Data Collection	67

图清单

图序号	图名称	页码
图 1.1	2015-2021 年中国原煤产量及增速	1
Figure1.1	China's raw coal output and growth rate from 2015 to 2021	1
图 1.2	2019 年-2021 年中国煤炭月度进口量	2
Figure1.2	China's monthly coal import from 2019 to 2021	2
图 1.3	2011 年-2021 年煤矿事故发生起数和死亡人数	2
Figure1.3	Number of coal mine accidents and deaths from 2011 to 2021	2
图 1.4	2021 年中国煤矿事故严重性分布	3
Figure1.4	Severity distribution of coal mine accidents in China in 2021	3
图 1.5	2020 年中国煤矿事故类型起数及死亡人数情况	3
Figure1.5	Types of coal mine accidents and deaths in China in 2020	3
图 1.6	技术路线图	12
Figure1.6	Technical roadmap	12
图 2.1	瓦斯涌出量预测模型指标体系	18
Figure2.1	Index system of gas emission prediction model	18
图 3.1	作业单元结构模型	19
Figure3.1	Activity structure model	19
图 3.2	人工神经网络结构模型	21
Figure3.2	Structure model of artificial neural network	21
图 3.3	BP 神经网络运行流程	25
Figure3.3	Operation process of BP neural network	25
图 3.4	测试函数图像	31
Figure3.4	Image of test function	31
图 3.5	降维技术的操作流程	33
Figure3.5	Operation process of dimensionality reduction technology	33
图 4.1	瓦斯涌出量预测模型基本流程图	37
Figure4.1	Basic flow chart of gas emission prediction model	37
图 4.2	Matlab 训练工具箱	40
Figure4.2	Matlab training toolbox	40
图 4.3	LLE 算法的部分初始参数值代码	40
Figure4.3	Some initial parameter value codes of LLE algorithm	40
图 4.4	WPA 算法的部分初始参数值代码	40
Figure4.4	Some initial parameter value codes of WPA algorithm	40
图 4.5	BP 算法的部分初始参数值代码	41
Figure4.5	Some initial parameter value codes of BP algorithm	41
图 4.6	$d=5$ 时数值模拟的实验结果	45
Figure4.6	Experimental results of numerical simulation when $d=5$	45
图 4.7	$d=6$ 时数值模拟的实验结果	45
Figure4.7	Experimental results of numerical simulation when $d=6$	45

图 4.8	$d=7$ 时的数值模拟的实验结果	46
Figure4.8	Experimental results of numerical simulation when $d=7$	46
图 4.9	$d=8$ 时的数值模拟的实验结果	47
Figure4.9	Experimental results of numerical simulation when $d=8$	47
图 4.10	$d=9$ 时的数值模拟的实验结果	47
Figure4.10	Experimental results of numerical simulation when $d=9$	47
图 4.11	$d=10$ 时的数值模拟的实验结果	48
Figure4.11	Experimental results of numerical simulation when $d=10$	48
图 4.12	训练组数值模拟的实验结果	51
Figure4.12	Experimental results of numerical simulation of training group	51
图 4.13	$d=8$ 时真实值与预测值的局部放大图	52
Figure4.13	Partial enlargement of $d = 8$ real value and predicted value	52
图 5.1	BP 神经网络预测模型的真实值与预测值	54
Figure5.1	True value and predicted value of BP neural network prediction model	54
图 5.2	GA-BP 神经网络预测模型的真实值与预测值	56
Figure5.2	True value and predicted value of GA-BP neural network prediction model	56
图 5.3	WPA-BP 神经网络预测模型的真实值与预测值	56
Figure5.3	True value and predicted value of WPA-BP neural network prediction model	56
图 5.4	多种模型的真实值与预测值	57
Figure5.4	Real and predicted values of various models	57

表清单

表序号	表名称	页码
表 3.1	狼群算法数值模拟的实验结果	29
Table3.1	Experimental results of numerical simulation of WPA algorithm	29
表 3.2	粒子群算法数值模拟的实验结果	29
Table3.2	Experimental results of numerical simulation of PSO algorithm	29
表 3.3	防碰撞算法数值模拟的实验结果	29
Table3.3	Experimental results of numerical simulation of FSA algorithm	29
表 3.4	局部嵌入式算法基本流程表	35
Table3.4	Basic flow chart of local embedded algorithm	35
表 4.1	$X_1 \sim X_7$ 的瓦斯涌出量和影响因素原始输入数据	39
Table 4.1	Original input data of gas emission and influencing factors of $X_1 \sim X_7$	39
表 4.2	$X_8 \sim Y$ 的瓦斯涌出量和影响因素原始输入数据	39
Table 4.2	Original input data of gas emission and influencing factors of $X_8 \sim Y$	39
表 4.3	$d=5$ 时第 2 次模拟实验结果	42
Table4.3	Results of the second simulation experiment when $d=5$	42
表 4.4	$d=6$ 时第 5 次模拟实验结果	42
Table4.4	Results of the 5th simulation experiment when $d=6$	42
表 4.5	$d=7$ 时第 3 次模拟实验结果	43
Table4.5	Results of the third simulation experiment when $d=7$	43
表 4.6	$d=8$ 时第 4 次模拟实验结果	43
Table4.6	Results of the 4th simulation experiment when $d=8$	43
表 4.7	$d=9$ 时第 5 次模拟实验结果	44
Table4.7	Results of the 5th simulation experiment when $d=9$	44
表 4.8	$d=10$ 时第 3 次模拟实验结果	44
Table4.8	Results of the third simulation experiment when $d=10$	44
表 4.9	不同 d 值数值模拟的实验结果	48
Table4.9	Experimental results of numerical simulation with different d values	48
表 4.10	重构权值矩阵 (序号 1~5)	49
Table4.10	Reconstructed weight matrix (No. 1 ~ 5)	49
表 4.11	重构权值矩阵 (序号 6~10)	49
Table4.11	Reconstructed weight matrix (No. 6 ~ 10)	49
表 4.12	BP 神经网络输入数据	50
Table4.12	Input data of Back Propagation Neural Network	50
表 4.13	训练组数值模拟的实验结果	52
Table4.13	Experimental results of numerical simulation of training groups	52
表 5.1	BP 模型测试组数值模拟的实验结果	55
Table5.1	Experimental results of numerical simulation of BP model test groups	55
表 5.2	GA-BP 模型测试组数值模拟的实验结果	55
Table5.2	Experimental results of numerical simulation of GA-BP model test groups	55

表 5.3	WPA-BP 模型测试组数值模拟的实验结果	56
Table5.3	Experimental results of numerical simulation of WPA-BP model test groups	56
表 5.4	4 种模型数值模拟的实验结果	58
Table5.4	Experimental results of numerical simulation of four models	58

变量注释表

q_1	经过一定时间后采空区瓦斯涌出量, m^3/min
q_0	采空区瓦斯初始瓦斯涌出量, m^3/min
β	采空区瓦斯涌出量衰减系数
t	时间, min
q_3	经过一定时间后煤帮位置瓦斯涌出量, m^3/min
q_2	煤帮位置初始瓦斯涌出量, m^3/min
α	煤帮位置瓦斯涌出量衰减系数
q_4	邻近煤层瓦斯涌出量, m^3/min
h_i	邻近层 i 的厚度, m
h_1	开采深度, m
X_{0i}	邻近层 i 的初始瓦斯含量, m^3/min
X_{1i}	邻近层 i 的剩余瓦斯含量, m^3/min
k_i	瓦斯含量变化系数
Q_j	绝对瓦斯涌出量, m^3/min
C	回风流中瓦斯的平均浓度, %
Q	矿井通风量, m^3/min
Q_x	相对瓦斯涌出量, m^3/t
A	日产煤量, t/d
u_i	输入值加权求和后的输出值
w_{ij}	权重值
x_j	作业单元的输入值
v_i	根据误差范围调节后的输入值
b_i	作业单元的阈值
y_i	输出值
f	激活函数
v	人工神经网络输入值
a	斜率
b	截距
E	人工神经网络输出值间的误差
T_{ij}	期望输出值
y_{ij}	人工神经网络输出值
$\{x_i\}$	人工神经网络输入向量
$\{y_j\}$	人工神经网络输出向量
G	实际映射函数
I	隐含层作业单元个数
M	输入层作业单元个数
P	输出层作业单元个数
B	介于 1 到 10 之间的随机整数值
u_i^I	隐含层第 i 个作业单元的输入值
w_{mi}	输入层和隐含层间的权重值
x_{km}	任意一组输入值

v_i^I	隐含层第 i 个作业单元的输入值经过激活函数后的数值
u_p^P	输出层第 p 个作业单位的输入值
w_{ip}	隐含层和输出层间的权重值
y_{kp}	k 组第 p 作业单位输出值
v_p^P	输出层第 p 个作业单位的输入值经过激活函数后的数值
$e_{kp}(n)$	k 组第 p 作业单位误差值
$d_{kp}(n)$	k 组第 p 作业单位期望值
n	迭代次数
$\Delta w_{ip}(n)$	隐含层到输出层间的权重调整值
δ_p^P	输出层局部梯度
η	学习速率
$\Delta w_{mi}(n)$	输入层到隐含层间的权重调整值
δ_i^I	隐含层局部梯度
x_{km}	k 组第 m 作业单位输入值
F	最佳函数值
F^*	理想最优值
x_{id}^p	探狼 i 向 p 个方向探寻后在 d 维空间中处于的位置
x_{id}	探狼 i 在 d 维空间中处于的位置
p	第 p 个方向
h	h 个方向
$step_a^d$	探狼游走步长
x_{id}^{k+1}	凶狼 i 在第 $k+1$ 次迭代后 d 维空间中处于的位置
x_{id}^k	凶狼 i 在第 k 次迭代后 d 维空间中处于的位置
$step_b^d$	凶狼游走步长
g_d^k	第 k 次迭代后 d 维空间中头狼位置
d_{near}	凶狼与头狼之间的距离
D	凶狼与头狼之间的最初距离
w	距离判定因子
λ	[-1,1]中的随机数字
$step_c^d$	凶狼围攻步长
G_d^k	经历 k 次迭代后的头狼位置
S	步长因子
W_{ij}	权值矩阵
x_{ij}	邻近数据点
I	单位矩阵
Y_n	归一化后的数据
Y	重构有效因子
Y_{max}	重构有效因子最大值
Y_{min}	重构有效因子最小值
ARV	平均相对变动值
x_i	真实值
x_i'	预测值
K	开采层与邻近层间围岩硬度加权平均值

r	围岩所含岩层数量
f_m	第 m 层岩层硬度
h_m	第 m 层岩层厚度
H	开采层与邻近层之间的围岩总厚度

1 绪论

1.1 研究背景与意义

我国拥有丰富的天然煤炭资源，煤炭开采产业是我国的重要社会经济支柱之一。根据国家统计局发布于 2021 年 1 月 17 日的煤炭统计数据显示，2021 年我国产出的原煤达 40.7 亿吨，较 2020 年的原煤产出量增长了 5.99%。如图 1.1 所示。




图 1.1 2015-2021 年中国原煤产量及增速

Figure 1.1 China's raw coal output and growth rate from 2015 to 2021

按照我国海关部门截止到 2021 年 12 月发布的进口煤炭量的统计数据可知，2021 年 12 月份进口煤炭总量为 3095 万吨，与 2020 年 12 月份比较降低了 20.8%，与 2021 年 11 月份比较降低了 11.7%，同环比都呈现下降状态。而 2021 年我国进口煤炭量达 3.2 亿吨，同比增长 6.6%。如图 1.2 所示。因为我国复杂的地形和地质条件，导致目前我国大部分地区的矿井建设和开采的难度较大，进而使得我国煤矿开采工作成为安全生产事故发生率最高的行业。2011 年以来我国重点加强了安全应急方面的管理，严格要求了煤矿生产的工作安全规程，进而发生的煤矿安全事故逐渐减少，由此引发的伤亡人数也大幅度下降。2021 年，我国发生的矿山事故总计 357 起，由此导致的人员死亡为 496 人。同比 2020 年消减了 67 起矿山事故，减少 15.8 个百分点，死亡人数降低了 80 人，下降了 13.9 个百分点^[1]。其中关于煤矿事故发生次数为 91 起，同比 2020 年减少 31 起，下降了 34 个百分点。煤矿事故造成的人员死亡 178 人，相比 2020 年人员死亡数目减少 47 人，同比下降 21 个百分点。如图 1.3 所示。其中，一般煤矿事故发生 78 起，导致 89 人死亡。较大型煤矿事故发生 11 起，导致 48 人死亡。重大型煤矿事故发生 2 起，导致 41 人死亡^[2]。




图 1.2 2019 年-2021 年中国煤炭月度进口量
Figure1.2 China's monthly coal import from 2019 to 2021




图 1.3 2011 年-2021 年煤矿事故发生起数和死亡人数
Figure1.3 Number of coal mine accidents and deaths from 2011 to 2021

2021年中国煤矿事故严重性分布




图 1.4 2021 年中国煤矿事故严重性分布

Figure 1.4 Severity distribution of coal mine accidents in China in 2021

2020 年我国煤矿事故主要分为顶板事故、冲击地压、瓦斯事故、煤尘事故、机电事故、运输事故、爆破事故、水害事故、火灾事故等^[3]。据统计，2020 年发生顶板事故共 40 起，共造成 55 人死亡。冲击地压事故 1 起，造成 4 人死亡。瓦斯事故 5 起，造成 22 人死亡。机电事故 17 起，造成 8 人死亡。运输事故 23 起，造成 26 人死亡。爆破事故 3 起，造成 3 人死亡。水害事故 7 起，造成 25 人死亡。火灾事故 2 起，造成 39 人死亡^[4]。如图 1.5 所示。顶板事故、瓦斯事故、运输事故、水害事故和火灾事故是危害最大的事故类型，造成的人员伤害及财产损失最为严重。

2020年中国煤矿事故类型起数及死亡人数情况




图 1.5 2020 年中国煤矿事故类型起数及死亡人数情况

Figure 1.5 Types of coal mine accidents and deaths in China in 2020

根据国家发布的事故统计可知，瓦斯事故仍在煤矿事故发生次数中位于前列，由此引

发的事故后果是不容小觑的。通常情况下,矿井中的瓦斯含量较高。因为瓦斯容易燃烧容易爆炸的特点,所以在矿井灾害事故中瓦斯事故占比一直高居不下。2001—2020 年,我国共发生瓦斯爆炸事故 484 起、死亡 3195 人。这个统计数字说明瓦斯事故的风险防治工作依旧严峻。按照《煤矿安全规程》的规定,在煤矿挖掘工作开始之前,务必要对瓦斯含量较高的煤层进行瓦斯抽采工作。瓦斯抽采工作的进行是根据采煤区工作面瓦斯涌出量决定的,故需要对采煤区工作面的瓦斯涌出量进行准确的预测,便于合理的安排瓦斯抽采工作,提高瓦斯抽采工作的效果,进而大幅度保证矿井作业的安全性。

随着我国信息技术的发展,对瓦斯涌出量的预测不局限于传统瓦斯涌出量预测方法。越来越多的瓦斯涌出量预测方法被提出。近些年,人工智能算法对瓦斯涌出量的预测较为常用,渐渐代替了传统瓦斯涌出量预测方法。通过人工智能算法对瓦斯涌出量预测可以在提高准确性的同时,大大减小预测时间。人工神经网络中的 BP 神经网络被广泛应用于瓦斯涌出量预测。由于 BP 神经网络自身的特性,仅用 BP 神经网络预测瓦斯涌出量的精确度没办法满足目前实际应用所需的精确度。所以专家学者们常利用其它智能算法与之结合,对 BP 神经网络的运行模式进行改进,进而弥补 BP 神经网络存在的不足,提高 BP 神经网络瓦斯涌出量预测模型的训练性能^[5]。

1.2 国内外研究现状

我国目前的煤矿开采行业主要运用的作业方式是深度大于 600 m 的地下开采作业。这种深度开采的作业模式就会导致开采工作面的瓦斯含量很容易超过安全临界点。当瓦斯总含量越过安全临界点的时候,易会发生瓦斯事故,影响煤矿开采工作进度,严重的则会造成重大人员伤亡及财产损失。因此国内外的专家学者针对瓦斯涌出量预测提出来很多模型,从不同角度研究分析瓦斯涌出规律,达到高效预测瓦斯涌出量。

早在 20 世纪初期,国外的专家学者就瓦斯涌出量大小对瓦斯事故的影响做了研究和分析,结合本国煤矿产业实际情况研究出很多科学系统的预测方法。俄罗斯的煤矿地质学家最早开始着眼于瓦斯涌出量预测的技术开发。由于当时还未有一个对矿井瓦斯预测的合理依据,因此俄罗斯专家学者们研究制定出一套瓦斯涌出量预测的范本标准。

英国煤炭专家 Dunmore R^[6]提出一种预测瓦斯排放的实用方法。该方法基于对煤层瓦斯涌出的理论处理,使用计算机程序计算地层中的预计瓦斯涌出量。该涌出量根据初始气体含量、震源厚度和预期排放程度获得。后一个函数是根据该理论推导出来的,它取决于工作深度、震源与被工作煤层的距离、区域的年龄和工作面的推进速度。为了完成预测,分析了该地区的通风和排放要求,并适当考虑了排放峰值。

澳大利亚煤炭专家 Lunarzewski L^[7]在采矿期间的瓦斯排放预测表明,可能存在瓦斯涌出量过多和通风速度过慢的问题,必须进行瓦斯抽放工作,并保持通风系统中必要的风量,以满足各种煤炭生产率的法定瓦斯限制。他提出地质力学和气体排放模型为这些问题提供

了有效的解决方案。

德国煤炭专家 Noack K^[8]介绍了工作面瓦斯涌出量的预测方法。还提到了工作煤层瓦斯涌出量的预测和巷道瓦斯涌出量。通过安装基于排水道路或大直径钻孔的瓦斯排放系统,可以改善回采工作面回采端的瓦斯排放控制问题。

Patrick B^[9]等人发现与瓦斯涌出期间排放的瓦斯和在矿井中留存的有毒可燃气体,其风险的量化和治理均基于有效的预测。因此利用改进后的空间数据集所得出的预测和结合基本物理和能源相关原则的分析技术来解决与目前传统预测方法的变异性和局限性。

Karacan C Ö^[10]等根据地质统计学方法对矿井瓦斯涌出区的瓦斯量进行建模和预测,并评估其相关的不确定性。在确定瓦斯涌出区的重要煤层和非煤层后,对来自不同地层的数据进行了单变量统计和半变异函数分析,以确定各种属性的分布和连续性。

Shepherd^[11]和 Bible^[12]提出了的时空序列瓦斯涌出量预测法,对开采条件和瓦斯赋存状态发生变化的情况下对工作面瓦斯涌出量进行预测,仍能得到一定的精度,并且基于预测数据反馈调节工作面风量,调整瓦斯抽采方式,最终证明该预测方法能够满足工程需要。

Airey^[13]将开采技术和时间因素作为重要的影响因素引入瓦斯涌出量预测过程,对于破碎煤的瓦斯解析量给出了经验公式。Banerjee^[14]对 Airey 的经验公式进行改进优化,对微观煤层面进行解析,得出可对 5-8mm 粒径煤瓦斯涌出量进行预估的新经验公式。

Wang N^[15]研发出基于 GIS 的对煤体瓦斯预测系统,实现了对瓦斯涌出量预测的可视化、图形化。

Javier Toraño^[16]对工作面瓦斯数据大量采集,采用统计学方法对采集的数据指标进行优劣分析,并将分析后结果用于瓦斯涌出量预测。

Karacan C^[17]采用多层感知机(MLP)型人工神经网络(ANN)对瓦斯通气孔总瓦斯流量和甲烷百分比进行预测,研究结果表明,双隐层模型预测 GGV 的总产量准确率达 90% 以上,使用人工神经网络对输入对各种因素的影响进行研究,如钻孔参数、钻孔位置、抽风机参数进行敏感度分析,以确定每一个输入变量对预测结果的影响。

Palchik^[18]提出一种基于高斯分布函数和高斯密度函数的数学模型用于预测乌克兰斯涅日扬斯基矿区采空区瓦斯生产率,针对所研究地质开采条件,确立了瓦斯涌出量与矿井生产持续时间的关系。

Leszek(Les)^[19]利用地质力学和瓦斯气体运移模型来研究瓦斯涌出源对矿井瓦斯含量的影响,研究成果为瓦斯合理控制,以及瓦斯高效采集以及通风系统的改进具有一定的指导意义。

Dougherty^[20]开发了一种用于解决长臂煤矿甲烷控制和预测的软件(MCP)该软件集成了统计、数学、预测和分类以及人工神经网络(ANN)方法。通过回采工作面上传感器数据的收集,该软件集成了四个模块,可以很好实现对煤矿采取瓦斯涌出量的预测。

Noack^[21]提出了关于扰动和未扰动长臂工作面、巷道瓦斯涌出量预测的方法,根据预测结果对通风系统进行调节,结合气体排放,规划气流的最佳分布。提出基于排水通道的大直径、长通道的钻孔瓦斯排放系统,对回采工作面回采端瓦斯排放进行良好的控制。

Padgett^[22]优化了神经网络在时间序列上的预测模型,提高了神经网络的预测精度。提出人工神经网络适用于处理瓦斯涌出这类非线性问题。在瓦斯预测领域提供新方法。

有效避免瓦斯事故发生的较为重要技术就是对瓦斯涌出量的计算和预测。我国在瓦斯涌出量的预测及瓦斯含量计算等方面的研究起步较晚。在 20 世纪 50 年代,我国专家学者才开始接触煤炭瓦斯涌出量计算预测的研究。经过大量的实验对比建立了测量矿井瓦斯浓度含量的技术。并创新性的提出使用矿井统计法进行矿井瓦斯含量、浓度、涌出强度计算和预测。

在 20 世纪 80 年代,我国提出了不同源头的气体涌出量的预测技术。随后这种技术不断的更新得到了瓦斯地质数学模拟法、类比法、速度法等基于气体涌出量预测技术的新型预算方法以适用于各种实际气体预测。我国煤炭领域专家学者数十年的潜心研究和探索,使得我国煤炭瓦斯涌出量预测技术逐渐规模化、系统化。各种预测技术趋于成熟。随着我国煤炭需求的大幅度增长,矿井开采强度及规模也持续扩大。对瓦斯涌出量的准确性及时效性的要求也越来越高。人们开始着眼于计算机智能技术、数学理论延伸、线性与非线性理论的研究。目前常用的新型预测技术有人工神经网络技术、多元线性回归技术、小波神经网络技术、支持向量机技术、灰色系统理论、深度学习法、证据理论、混沌理论、分形理论、粗糙集理论以及可拓理论等方法^[23]。

薛鹏骞^[24]等,提出了一种充分利用小波神经网络的时频特性,结合神经网络的自主学习能力,建立了收敛速度更快、预测精度更高、逼近能力更强的矿井瓦斯涌出量预测模型的新方法。并基于该模型,利用 Matlab 6.5 设计了小波和 BP 神经网络的模拟器。

潘云明^[25]等,提出了一种基于小波神经网络工具箱的瓦斯涌出量动态预测方法。该方法通过训练具有偶数个时间间隔样本的小波神经网络,能够预测相邻后续时间间隔内的气体排放量。该方法在滑动窗口宽度不变的情况下建立连续的新模型,从而得到瓦斯涌出量的动态预测方法。此外,该方法利用自行开发的 WNN 工具箱进行预测。实验表明,该模型克服了传统静态预测模型的不足,能够充分利用小波基函数的特征提取能力,动态反映瓦斯涌出量的地质特征。该方法具有简单、灵活、数据量小、收敛速度快、预测精度高等特点。此外,该方法还具有预测结果的确定性和可重复性。仿真结果验证了该方法的有效性。因此,该方法对推广小波神经网络的应用具有实际意义。

王伟^[26]等,基于可拓理论构建了煤与瓦斯突出风险预测系统和风险等级指标值体系。该预测系统包括 6 个指标和 4 个风险等级,根据模糊层次分析法和简单相关函数分别确定预测指标的主客观权重。最后,通过风险水平的关联度,建立了突出风险定量表征的预测

模型。利用该预测模型对 12 个高瓦斯矿井的突出危险性进行了预测。结果表明,突出危险度预测结果与实际突出灾害发生情况一致,实际突出煤岩质量的变化与最大危险度的相关程度一致。针对典型的煤层突出,逐步降低瓦斯压力和煤层瓦斯含量,然后将调整后的值代入预测模型,当煤层瓦斯压力降至 0.75 MPa 时,突出风险水平降至低风险水平。该值与用于定义煤矿现场煤层突出的经验值 (0.74 MPa) 一致。

陈康平^[27]等,提出了一个结合断裂力学、气体动力学和岩石力学的新模型,以阐明导致瞬时突出的物理机制。该模型表明,多米诺骨牌效应会导致煤炭灾难性破坏和瞬时突出,确定了瞬时爆发的临界条件,并成功地预测了爆发之前的所有观测现象。模型还预测了裂缝孔径尺寸效应,并且该效应由现有的用于评估突出倾向性的基于观测的裂缝分类方案所证实。

兰天伟^[28]等,利用人工智能技术建立了多因素模式识别模型。利用神经网络和模糊数学的方法,确定了矿山动态灾害的风险概率预测准则和预测区内各单元的风险概率值。划分矿山动态灾害的危险区、威胁区和安全区,以评价矿山动态灾害的危险程度。并针对不同的危险区域,提出了相应的控制措施。应用基于模式识别的矿井动态灾害因素预测方法,提高了矿井动态灾害预测与控制措施的实施水平,保障煤矿安全生产。

董国伟^[29]等,针对煤与瓦斯突出难以预测的事实,基于煤与瓦斯突出的发生机理,提出了一种预测煤与瓦斯突出的新方法,该方法与煤体强度、瓦斯压力和地应力有关。结果表明,我国煤矿煤与瓦斯突出的发生率为 5%~10%,浅部煤矿和深部煤矿煤与瓦斯突出的瓦斯压力分别大于 0.74 MPa 和 0.6 MPa。基于瓦斯因素的煤与瓦斯突出预测指标是钻屑的瓦斯解吸指数 (K_1),它是指钻孔第一分钟从煤体解吸的瓦斯含量。基于煤体强度的煤与瓦斯突出预测指标是可以用手捻成粉末的软层厚度。根据许多煤与瓦斯突出案例,发现软层的临界厚度为 0.2 m。基于地应力的煤与瓦斯突出预测指标是钻屑重量,它表示每延米直径为 42 mm 或 75 mm 的钻孔的钻屑质量。最后,通过工业应用试验,验证了新的煤与瓦斯突出预测方法和预测指标临界值,同时该方法在现场得到了广泛应用,取得了良好的预测效果。

李英杰^[30]等,开发了一种基于多源信息融合的煤与瓦斯突出灾害预测模型。通过应用多源信息融合方法 Dempster-Shafer 理论,该模型综合了传统技术和基于人工智能的新兴方法的不同预测方法的结果。为了提高所建立模型的性能,研究改进了 Dempster-Shafer 理论,并验证了其在处理高度冲突信息方面的有效性。该模型应用于中国山西省新井煤矿的 3 号煤层,可准确地反映了突出危险源的情况。

为了更进一步增加预测的准确性、便捷性、时效性、稳定性等性能,近些年来常使用智能算法与预测技术相结合,利用智能算法的优越性优化预测技术,减少预测误差,提高预测速度,提高预测准确性。常用的智能算法有遗传算法、蚁群算法、果蝇算法、模拟退

火算法、粒子群算法、狼群算法等^[31]。这些新型预测技术的实际应用，提高了我国煤炭开采的安全性，保障了煤炭行业从业人员的人身安全。

目前我国煤炭行业使用广泛的瓦斯预测方法有以下几种^[32]：

（1）矿山统计预测法

该方法的使用需要建立在矿井煤层的开采模式和地质水平这两个方面的程度相似性的前提研究分析以往开采煤矿时的瓦斯涌出量，根据以往瓦斯涌出量的含量梯度，得出瓦斯涌出量与开采深度之间的比例规律。再利用含量梯度演绎出矿井中深部煤层的瓦斯涌出量。这种统计方式使用范围较小，比较适合位置接近的矿井。且这种统计方法建立在大规模历史数据的研究下。一旦收集的数据不全、有缺失或者数据有误差都会影响瓦斯涌出量预测的准确性。即使数据收集的全面准确也面临着计算过程的繁杂冗长易错。

（2）分源预测法

该方法需要依据矿井开采工作中可涌出瓦斯的原始位置的个数和其细分的涌出量大小来进行矿井瓦斯涌出量预测的。通过计算和研究瓦斯涌出的规律、开采规模、煤层间瓦斯的浓度来得到细分瓦斯涌出来源的各自瓦斯涌出量。这种技术适合用在新开采的矿井瓦斯涌出量预测。但是这种预测方法在实际应用过程中往往因大量参数的实测导致其在应用方面存在一定范围内的局限性。需要根据不同的矿区调整大量的参数，不具备普遍使用能力。

（3）类比预测法

该方法的使用的前提条件是需要在同一个矿区或者地质水平相似的矿区。将该矿区的煤矿瓦斯涌出量除以钻孔煤层间的瓦斯储量，得到二者之间的比例值。从而类比出相似地质条件的矿区的煤矿瓦斯涌出量的近似值。这种方法很明显的缺点就是预测精度较低。但在多种相邻煤矿的瓦斯涌出量的定性分析时可以体现出这种方法的优点。

（4）速度预测法

该方法使用的原理在于瓦斯涌出量大小与煤层瓦斯含量、煤体内部与外部之间的压力差值、煤体本身的透气度等因素相关。速度预测法这个方式的主要切入点是瓦斯涌出量的速度。利用瓦斯动力学结合瓦斯涌出速度及相关因素对瓦斯涌出量进行预测。这种预测方式需要在实际矿区测量出准确的衰减指数和瓦斯涌出初速度。但是这两组参数的测量不易测量且在一定时间内也许会发生变化，仅适用局部范围局部时间段的瓦斯涌出量预测。

（5）瓦斯地质数学模型预测法

该方法建立在数学方法的使用基础上，建立瓦斯涌出量和预测模型。构建瓦斯涌出量预测模型需要考虑矿井瓦斯的地质规律，通过不同地质得出瓦斯涌出量的变化趋势。从其变化趋势中分析得出影响瓦斯涌出量大小的地质因素。最后与以往该区域瓦斯涌出量情况、地质条件和开采深度并行分析，得到瓦斯涌出量的预测模型。根据其原理可知，这种方法

的使用需建立在收集到大量以往的瓦斯涌出量、开采深度等数据的基础上。在拥有大量庞杂的数据前提下才可以实现准确的预测。郎咸民^[33]提出了瓦斯地质理论技术,该技术可以有效地预测瓦斯的分布位置。将预测模型作用到实际矿井瓦斯分布预测中,实验结果表明该预测模型可以很好地反映出矿井瓦斯真实分布。

(6) 灰色系统预测法

灰色系统包含白色特征和黑色特征的一种综合系统。白色特征是既定内容的系统。黑色特征是未定内容的系统。而灰色系统里包括既定内容和未定内容^[34]。灰色系统预测利用对过往数据的分析摸索出相同系统的发展趋势的变化规律。灰色系统预测适用于矿井瓦斯涌出量预测的原因在于瓦斯涌出量影响因素间的关系既不是完全确定的也不是完全未知。而灰色系统预测的原理正能解决这个问题。但在影响因素过多的情况下,这种方法的建模和计算会十分困难。灰色系统也广泛应用于很多因素模糊的领域里,诸如经济发展预测、安全风险评估等。黄凯波^[35]等结合灰色理论与 BP 神经网络构建了瓦斯涌出量预测系统,可以较为准确地预测矿井瓦斯涌出量。

(7) 混沌时间序列预测法

混沌理论适用于处理动态系统里必须利用整体数据才能进行预测的问题。混沌时间序列预测法其目的是要发现好像没有特定预设的外在表象背后可能隐蔽的浅显定律,最终总结出一个拥有繁杂困难问题的系统内在运行的普遍定律。20 世纪 90 年代以来混沌时序预测法便开始广泛应用于矿井瓦斯事故领域。赵亮^[36]提出基于混沌时间序列法的瓦斯浓度预测模型,重新建立起一个瓦斯浓度的时间序列系统,提高了瓦斯浓度的预测准确性。

(8) 神经网络预测法

近些年,国内外专家学者常采用人工神经网络模型的模拟预测能力结合矿井实际情况所得数据来预测瓦斯涌出量。人工神经网络是对人类大脑的运行模式的模拟。可以利用其自身的适应性功能应用于很多非线性、不明确规律的因素的预测。在数学的角度上看待人工神经网络,其可以随意的拟合出各种非线性函数表达式。这种非线性函数表达式可以储存大量的数据样本,并可以分析繁多的影响因素等。在对矿井瓦斯涌出量影响因素分析的过程中发现,其影响因素存在大量非线性关系。利用人工神经网络可以更好的拟合出这些非线性因素的函数关系式。使用人工神经网络这种算法可以准确的对收集到的样本数据进行计算拟合,拟合所得到的数学曲线有很好的近似效果。人工神经网络在模拟多个变量的时候,仅对输入资料和输出资料进行训练,从输入与输出间的映照联系得到结果。不需要对输入样本的多种变量和他们之间的函数对应关系进行假设。这样的计算方式在处理瓦斯涌出量和影响因素之间繁乱复杂的非线性关联很有优越性。但是在使用人工神经网络对瓦斯涌出量预测的工作中,所输入的样本数据往往维度较高。庞杂的数据网络会导致人工神经网络的运行规模加大,使得人工神经网络的运行速率降低。

人工神经网络已经延伸出误差反向传播、回归式传播、自组织映射网络、双向联想记忆系统、径向基函数网络等众多神经网络模型。其中,误差反向传播(BP神经网络)算法较为简单,运行的步骤清晰明了,可操作性强。具有并行分布结构、非线性相关、自主学习及自我适应等。故本文选用该算法作为预测模型的基础算法。

结合国内外专家学者的研究现状,目前对瓦斯涌出量预测仍存在下述问题:

(1)随着科技的不断发展,对于煤矿行业的工作技术也面临着大量的更新换代。新型开采设备逐渐应用起来,使得整个煤矿行业的操作系统越来越高深复杂。因此在做瓦斯涌出量预测时分析影响因素的过程中要比以往困难很多。并且在实际操作过程中所得出的数据也比以往煤矿开采时得到的数据多。对于这种影响因素错综复杂,输入数据样本过多的现象,必然会导致预测训练时间过长,预测结果与真实数据差距较大,收敛性较差等问题出现。

(2)影响瓦斯涌出量大小的因素有很多并且是各因素之间存在一定相关性。这种相关性会使很多信息出现重复部分和干扰部分。嘈杂的信息过多会导致预测训练速度、训练准确性降低。

(3)瓦斯预测模型的算法构造过于单一,导致很多模型仅适用于特定的矿区。

针对上述预测模型存在的问题,目前专家们常选用智能算法与预测模型相结合的方法来解决,如:

付华等^[37]提出了用局部线性嵌入式算法与蝙蝠算法相结合的智能组合算法,用来优化神经网络,得到动态式的瓦斯涌出量预测模型。使用局部线性嵌入式算法降低原始数据的维度。使其输入资料的复杂性降低。同时用蝙蝠算法进行优化 Elman 模型,目的是提高模型预测的精确度和泛化性。

李俊哲等^[38]为解决瓦斯涌出量的输入样本过多的问题,构建了限定记忆模式的高斯混合概率神经网络的瓦斯涌出量预测模型。该模型的原理是根据软测量的理念引进输入样本,将低维数据化为高维数据库。

林海飞等^[39]构建了粒子群算法优化的 BP 神经网络瓦斯含量预测模型。该实验研究了矿井中瓦斯的含量和其他影响因素的关系,并得到了模型预测数据。

李心杰等^[40]将主成分分析法与遗传算法结合构成智能组合算法,再运用该组合算法优化神经网络预测模型。利用主成分分析法计算样本信息,得到精炼的信息样本,其计算结果输入 BP 神经网络当中,再利用遗传算法对 BP 神经网络的参数值优化,进而避免预测模型出现较大误差。

肖鹏等^[41]构造 KPCA 和 CMGANN 算法结合的预测模型。该论文利用核主成分分析法对大规模样本数据进行降维计算,采用压缩映射遗传算法优化 BP 神经网络,构建出 CMGA 与 BPNN 相结合的算法。

郑晓亮等^[42]使用 MI 和 SVM 算法结合的预测模型。提出采用数据挖掘多重填补算法填补事故数据中缺失参数,增大可用数据集,并将填补后的数据用于支持向量机预测模型的训练与测试。

苏筱丽^[43]将主成分分析和 SVM 算法结合构造预测模型。通过分析比较剔除了影响模型准确率的扰动学习样本,在对决定煤与瓦斯突出的五个关键归因进行主成分降维处理之后,构建了预测煤与瓦斯突出的降维 SVM 回归模型。

曹博等^[44]将 PCA 与 GA 算法结合优化 BP 神经网络等。提出了先采用主成份分析 (PCA) 方法来降低变量间的相关性,然后将遗传算法与 BP 神经网络相结合的煤层瓦斯含量预测的新方法。采用 GA 算法对 BP 神经网络的权值和阈值进行优化。

王昱舒^[45]提出 PCA-AKH-BP 预测模型。利用 PCA 算法对输入样本进行降维处理,目的是使输入样本互相无关联,然后再对无关联的输入样本归一化处理,从而降低了输入样本的方差,提高了 BP 神经网络的收敛速率。

谢雨诗^[46]提出将果蝇算法与 BP 算法相结合的预测模型。等利用果蝇算法进行寻优训练,防止了预测模型在训练过程中困在某一相对极小的数组中,使得经该模型预测出的数值与实际值具有较高的拟合度。

1.3 研究内容

根据上述研究背景与意义及研究现状,通过研究分析多种瓦斯涌出量预测方法,结合瓦斯涌出量关联指标的特点。本文选用 BP 神经网络系统对矿井瓦斯涌出量进行实验预测。根据瓦斯涌出规律、影响因素、预测指标筛选原则得到了矿井瓦斯涌出量影响因素指标。运用局部线性嵌入算法提取由影响因素构成的高维数据中的特征因子,降维得到携带原数据全部特征的低维重构因子。以达到降低预测时长及复杂度的目的。进一步分析 BP 神经网络对预测矿井瓦斯涌出量的适用性和缺陷。利用狼群算法的高效寻优性优化 BP 神经网络的预测性能。最后将该预测模型与其他预测模型进行效能对比。

具体研究内容如下:

(1) 由于矿井瓦斯涌出量影响因素存在大量非线性关系,因此选用较为简单、运行步骤清晰明了、可操作性强的 BP 神经网络来预测瓦斯涌出量,BP 神经网络可以很好的拟合出这些非线性因素的函数关系式;

(2) 通过分析瓦斯涌出规律、影响因素、预测指标筛选原则得到本文的煤矿瓦斯涌出量影响因素指标体系;

(3) 由于 BP 神经网络在预测的过程中会输入数据,会降低运行速度及精准度,本文应用局部线性嵌入式算法 (LLE) 将瓦斯涌出量影响因素的高维数据进行降维计算,从而得到携带全部特征因子的低维数据。根据 BP 神经网络的预测优缺点,选择适当算法对 BP 神经网络的参数值优化。通过对比实验得到本文选择的狼群算法 (WPA),利用狼群算法的

高效寻优能力优化 BP 神经网络的权值和阈值^[47];

(4) 建立 LLE-WPA-BP 瓦斯涌出量预测模型, 研究并分析该模型的运行方式和运行步骤, 总结 LLE-WPA-BP 瓦斯涌出量预测模型的适用性。并进行对马堡煤矿的实际案例预测, 得到该预测模型在预测可行性、预测速率、容错性等方面的具体表现;

(5) LLE-WPA-BP 瓦斯涌出量预测模型与 WPA-BP 预测模型、GA-BP 预测模型、BP 预测模型进行性能对比, 从而进一步论证 LLE-WPA-BP 瓦斯涌出量预测模型的性能优越。

1.4 技术路线

按照上述的研究分析, 设计得到本文所研究的矿井瓦斯涌出量的技术路线, 如图 1.6 所示。

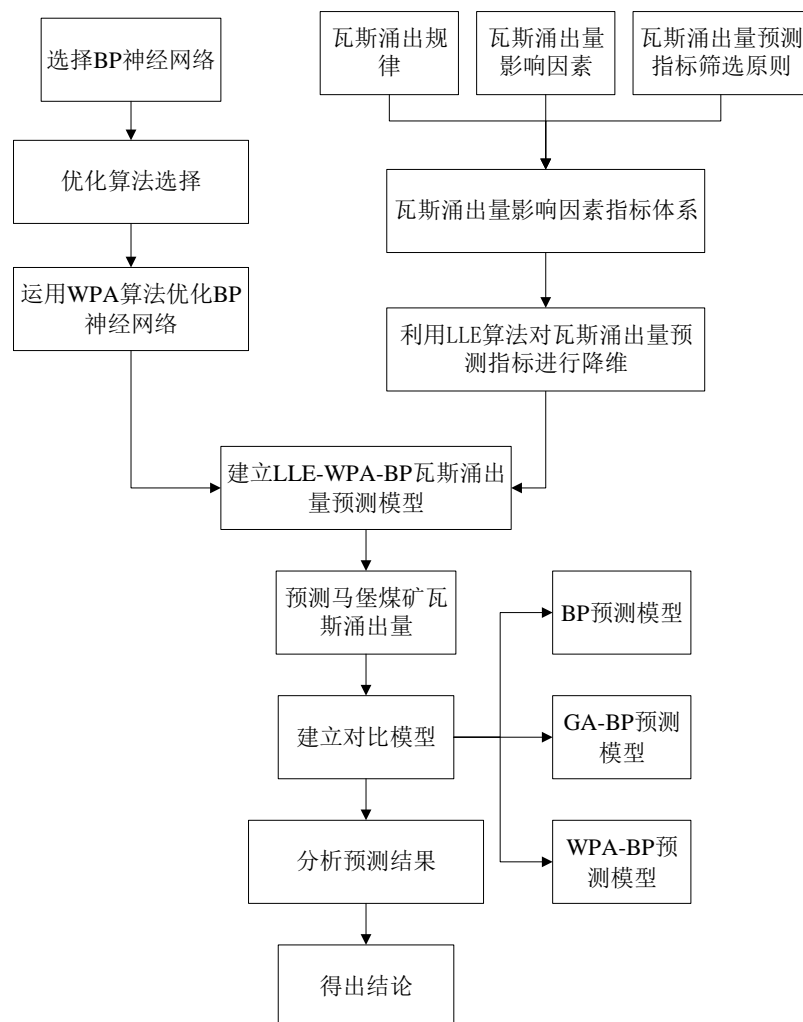


图 1.6 技术路线图

Figure1.6 Technical roadmap

2 矿井瓦斯涌出量影响因素研究

2.1 瓦斯涌出规律研究

基于对煤炭开采第一生产现场的研究得到瓦斯涌出的源头位置为煤岩壁、采落煤炭区域、采空区、邻近煤层。四个源头的瓦斯涌出方式分别为^[48]:

(1) 煤岩壁瓦斯涌出方式一种为源于开采挖掘的煤层暴露面直接的瓦斯涌出;另一种为顶部煤层因矿山重力作用导致应力失衡,产生地应力降低带。从而导致瓦斯从地应力降低带流向矿井裂隙带。

(2) 采落煤炭区域瓦斯涌出方式一种为放落上部煤层时煤炭岩石垮塌而导致瓦斯涌出;另一种为采集落煤时导致的瓦斯涌出。

(3) 采空区的瓦斯涌出方式为该区域挖掘煤炭工作结束后残存的煤炭随时间不断释放出瓦斯的过程。

(4) 邻近煤层瓦斯涌出方式为煤炭岩隙层与邻近煤层之间的瓦斯涌出。

在矿井煤层建造进程中,瓦斯进行多种物理、化学变化,时而吸附于、时而分散储存于煤层之间,是矿井结构中极为普遍的存在。在煤体开采过程中,瓦斯被释放出来,在相应条件作用下会发生燃烧,甚至爆炸。根据瓦斯的自身特性可知,它可以在生产作业中使用,也可以在日常生活中使用。但在矿井开采进程中则是需要预测防护的危险气体。因此在这种情况下,更加需要提前做好预防预测及应急管理的准备。为了更好的做出瓦斯涌出量的准确预测应该对瓦斯涌出规律进行研究。

煤矿瓦斯涌出是因为在开采煤体的过程中,外部力量的反复作用,导致矿井煤层结构的破坏,瓦斯便从煤层间的缝隙外溢出来,使得矿井中瓦斯压力产生了变化。瓦斯外泄的源头及瓦斯涌出的趋势强度等因素影响着瓦斯涌出的规律变化。采空区和邻近煤层瓦斯涌出趋势与时间有一定的联系,时间越长其瓦斯涌出量越少。从采空区煤体裂隙中外溢出的瓦斯涌出强度则较为稳定^[49]。采空区瓦斯涌出量和煤体暴露于空气中的时间之间的关系为指数型关系,用公式(2.1)表示:

$$q_1 = q_0 e^{(-\beta t)} \quad (2.1)$$

式中: q_1 —经过一定时间后采空区瓦斯涌出量, m^3/min ;

q_0 —采空区瓦斯初始瓦斯涌出量, m^3/min ;

β —采空区瓦斯涌出量衰减系数;

t —时间, min 。

煤帮处瓦斯涌出量与时间成反比,时间越长,瓦斯涌出量越少。其关系用公式(2.2)表示:

$$q_3 = q_2 / (1+t)^\alpha \quad (2.2)$$

式中: q_3 —经过一定时间后煤帮位置瓦斯涌出量, m^3/min ;

q_2 —煤帮位置初始瓦斯涌出量, m^3/min ;

a —煤帮位置瓦斯涌出量衰减系数。

邻近煤层的瓦斯涌出量则与开采深度有关, 其关系用公式 (2.3) 表示:

$$q_4 = \sum_{i=1}^n \frac{h_i}{h_1} k_i (X_{0i} - X_{1i}) \quad (2.3)$$

式中: q_4 —邻近煤层瓦斯涌出量, m^3/min ;

h_i —邻近层 i 的厚度, m ;

h_1 —开采深度, m ;

X_{0i} —邻近层 i 的初始瓦斯含量, m^3/min ;

X_{1i} —邻近层 i 剩余瓦斯含量, m^3/min ;

k_i —瓦斯含量变化系数。

由公式 (2.3) 可知, 煤体开采深度越大, 瓦斯涌出量越大。上述未提到的瓦斯涌出量的影响因素对瓦斯涌出特征规律也有所影响。为保障矿井施工安全、人员作业安全, 应该深度掌控瓦斯涌出规律。不同矿井的周遭环境及内部构造对瓦斯涌出规律的变化也是不同的。因此在研究瓦斯涌出量时, 须将瓦斯涌出量的影响因素研究视为重要前提。

2.2 瓦斯涌出量影响因素研究

我国矿井地质条件多样、煤层之间的瓦斯存储量较高。因此在进行矿井作业过程中, 易发生瓦斯的燃烧和爆炸等事故。瓦斯事故往往是多种因素叠加导致而成的, 为高效防止瓦斯事故造成的危害, 需要进行工作面瓦斯抽采工作, 对瓦斯涌出量进行准确的预测起到工作指示作用。对瓦斯涌出量影响因素分析的全方位研究有助于准确预测瓦斯涌出量, 进而降低瓦斯事故发生频率。随着我国煤炭行业的发展, 对矿井开采的工作越来越科学化、规范化和模式化。研究出多种多样矿井开采技术, 更有利于对深层煤炭的开采与挖掘。开采速率逐年增加, 导致瓦斯涌出量影响因素更为复杂更为多样^[50]。

矿井瓦斯涌出量是在现场开采煤矿时溢到采煤区的瓦斯含量。瓦斯涌出的方式及浓度含量在不同的矿井、不同的煤体及不同的煤层都有不同的变化方式, 涌出规律并不是一成不变的。其规律受到了地质条件、煤层特征、通风条件、开采模式及气候因素等影响, 在做矿井瓦斯涌出量预测时需要对影响因素分析选择出相关的影响指标。以下内容对地质条件、煤层特征、通风条件、开采模式及气候因素等影响因素对矿井瓦斯涌出量的影响效果分析^[51]:

(1) 地质条件

瓦斯含量的累计与瓦斯的涌出和矿井地质结构息息相关。煤层间的塑性能力于煤岩层

间的相互作用力有关。塑性能力越大，瓦斯吸附能力越强。皱褶结构的形成对瓦斯含量造成直接的影响，褶皱构造向下弯曲拗陷的部分对瓦斯储存效果要比褶皱构造的向上拱起的部分储存效果要好。这是源于向下弯曲拗陷的部分煤岩石的密闭性能要好于向上拱起的部分。断裂结构也会对瓦斯的存储和涌出产生影响。开放式断裂结构加快了瓦斯的涌出速度，是瓦斯更易流动。反之封闭式断裂结构易储存瓦斯。区域岩浆热变质作用造成煤体变质速度加快，使得煤层间对瓦斯的吸附作用加大，进而在岩浆活动的周围区域瓦斯含量较高，瓦斯涌出量较大。

矿井区域的地下水对瓦斯涌出量也产生一定影响。由于煤体间吸附着瓦斯，地下水流通于煤层间，将吸附于煤体间的瓦斯转化为可活动的游走状态，瓦斯随流水转移，大大的降低煤层间储存的瓦斯，进而使得瓦斯涌出量大幅度减少。地下水以及煤岩石间的裂缝为瓦斯的移动游走提供了道路，瓦斯通过地下水游走于煤岩石的裂缝之中。再加上地下水本身对瓦斯有吸溶作用，更加加速瓦斯的扩散，降低瓦斯的含量。

因为瓦斯吸附于煤体之间，所以煤矿开采过程中遗落的煤块也影响着瓦斯涌出量。煤块的大小、内部结构、暴露于空气中的时间都对瓦斯涌出量有影响。开采速度越快，落煤越多，故瓦斯涌出量也越大。

矿井不断的开采，一层层煤帮渐渐暴露，煤层间的作用力、煤层周围的煤岩石应力结构被施工挖掘所破坏，产生煤层之间的卸压带和煤层间的裂隙。由于内部应力结构被破坏，所以产生了压力梯度，从而吸附在煤体中的瓦斯沿着煤帮方向和邻近煤层裂缝间移动涌出。导致工作面的瓦斯含量增加。瓦斯涌出量随着时间的延长而含量降低。

（2）煤层特征

煤层掩埋程度影响着瓦斯涌出量的变化。煤层掩埋程度越高瓦斯含量越高。这是由于，煤层掩埋程度逐渐增加，导致煤层间的压力逐渐提高，煤体间的密封性逐渐加强。从而影响着瓦斯含量的源头和瓦斯移动的通道，导致瓦斯涌出量随着煤层埋藏深度加大呈正比例关系。另一方面原因就在于埋藏深度与瓦斯挥发之间的关系，埋藏深度越大瓦斯的挥发程度越小，煤体的变质速度大大加快，煤体的变质状况也影响着煤体中瓦斯的储存。

煤体的腐坏程度与煤体间的瓦斯含量呈正相关，腐坏越严重煤体中的瓦斯含量越大。煤体的腐坏程度也影响着煤体间的结构，同时影响着煤体间的孔间隙数目。煤体的孔间隙数量增加，致使瓦斯的吸附能力变强，进而导致瓦斯含量增加，涌出量增大。

煤层的厚度也会影响孔间隙数目，同理煤层厚度越大、孔间隙越多、瓦斯对煤体的依附性越大、煤体间瓦斯储存量越高。在实际的矿井开采中，在对煤层较厚的地方施工开采时，会发生瓦斯含量超标的现象，防控措施做不好则会引发瓦斯事故的发生，因此须在煤层厚度较深的位置进行更高严格的应急防范管控。

瓦斯的涌出与煤层间的空气流动相关，煤层透气性好的部位利于瓦斯的涌出，顺方向

的煤层透气性好,因此煤层间倾角越大瓦斯涌出量越大。其次煤层间倾斜角度大方便开采工作完成后煤体的掉落,加大了煤层间的瓦斯的移动速度。并且对于倾角较大的煤层对瓦斯的移动的阻力较小,利于瓦斯的涌出,综上所述煤层间倾斜角度越大瓦斯涌出量越大。

层间岩性指的是煤层中的岩石特性,岩石空隙越大煤矿越容易释放瓦斯。在矿井进行煤矿挖掘工作时,瓦斯游走于煤体层和周围岩体之中。因为在开采煤矿的时候破坏了原本煤层间和岩石间的平衡作用力,使得煤层与围岩之中的压力值改变,瓦斯沿着煤层间的裂缝涌出。因煤层围岩中影响瓦斯涌出卸压范围的重要特性是围岩硬度,因此,在量化层间岩性时,采用围岩硬度加权平均值作为输入值^[52]。

(3) 通风条件

矿井中的通风风量增加,使得回风过程中的瓦斯含量增大。同理通风风量减小,回风过程中的瓦斯含量减小。如果在实际开采过程中,矿井采空区的密封性较差,而矿井内通过自然风含量又较大,会导致采空区的瓦斯大规模涌出,易引发瓦斯事故。因此需要对采空区实时的检测与合理的抽放,从而减少瓦斯含量,降低事故发生率。并且将科学规划矿井通风系统,控制好通风的风量。

(4) 开采模式

对煤矿的开采推进速度影响着煤矿的产出率,产出率影响着瓦斯涌出量。开采推进速度越快,瓦斯涌出量越大。当开采推进速度达到一个峰值的时候,瓦斯涌出量的速率逐渐减小。在煤矿开采进程中运输巷道到回风巷道之间的工作面长度逐渐增加,工作面所受压力也随着开采进程而发生变化,从而使得瓦斯涌出量逐渐增加。

伴随着矿井的开采程度及规模逐步扩大,煤体间的瓦斯含量及瓦斯涌出量也越来越大。在对煤体层较为深的工作区域挖掘开采时,会对煤体层产生破坏,导致近邻层和煤岩石层的瓦斯大量涌出开采工作层,从而使得开采工作层的瓦斯含量大幅度增高。矿井开采过程中在一定时间内回采煤矿的快慢程度也影响着瓦斯涌出量。开采程度扩大、回采煤矿进程越快以及煤产量也就增加,因此瓦斯涌出量也越大。但是在煤产量到达一定规模时,瓦斯涌出量的涌出速率慢慢减缓。

由于矿井开采初期会快速破坏煤体间的应力作用,导致出现煤体裂缝,临近层也受到了影响,伴随压力梯度的作用,瓦斯在临近层间移动,使得开采煤层瓦斯含量剧增,易发生瓦斯事故。因此矿井的开采顺序也需要进行科学的合理的规划。防止开采工作进行中发生瓦斯含量涨幅过快的现象。在开采矿井时对煤体本身的破坏程度与瓦斯涌出量大小相关。煤在开采过程中被破坏的越严重,瓦斯游离程度越高,瓦斯涌出量也就越大。因此采用合理的开采技术尤为重要。

(5) 气候因素

大气压的变化影响着煤帮和采空区瓦斯涌出量速率,是因为内外出现了压力梯度。当

大气压上升的时候，地表的压力大于煤帮内的压力，在压力梯度的作用下瓦斯储存在煤帮之中。反之如果大气压力下降，在内外压力差的作用瓦斯会大量涌出。气温和湿度对瓦斯涌出量的影响亦是如此。气温影响着气压，湿度也影响着气压，气压产生压力差作用于瓦斯。气温越高，气压越低，瓦斯涌出量越大。湿度越高，空气密度越低，大气压力越低，瓦斯涌出量越大。

2.3 瓦斯涌出量的计算

在对矿井施工开采的工作中，瓦斯利用煤层间的裂隙向工作面涌出。涌出方式有两种，一种是涌出速率较为缓慢、所用时间较长的普通涌出，另一种是短时间急速涌出的特殊涌出。在对矿井工作面的瓦斯涌出量计量方式有两种表达形式，一种是绝对瓦斯涌出量，单位时间内涌入矿井的瓦斯含量。另一种是相对瓦斯涌出量，日均产出 1 吨煤所涌出的瓦斯含量^[53]。

绝对瓦斯涌出量计算公式为：

$$Q_j = \frac{QC}{100} \quad (2.4)$$

式中： Q_j —绝对瓦斯涌出量， m^3/min ；

C —回风流中瓦斯的平均浓度，%；

Q —矿井通风量， m^3/min 。

相对瓦斯涌出量计算公式为：

$$Q_x = \frac{Q_j}{A} \quad (2.5)$$

式中： Q_x —相对瓦斯涌出量， m^3/t ；

A —日产煤量， t/d 。

煤矿等级划分按照国家安监总局的标准执行，每个等级的煤矿都有相对应的瓦斯涌出量。也有一个安全临界点，一旦超出这个安全临界点便是高瓦斯矿井，易发生瓦斯事故。高瓦斯矿井是绝对瓦斯涌出量不超过 $40 \text{ m}^3/\text{min}$ 或相对瓦斯涌出量不超过 $10 \text{ m}^3/\text{t}$ 。

2.4 瓦斯涌出量预测指标

构造瓦斯涌出量预测指标体系时，要严格按照以下指标筛选原则来提取指标^[54]：

(1) 筛选出的指标不可笼统不明确，其指标要有具体的含义，并且要合理的进行细分，筛选出的指标要能够伴随着矿井周遭变化而进行变化；

(2) 筛选出的指标要可以全局映射出各种影响因素对瓦斯涌出量造成的真实影响变化，指标的选择要有全面覆盖性；

(3) 筛选指标的目的在于进行以后的数据实验处理, 因此筛选出的指标要可以定性定量, 并且方便数值模拟的数据提取。

综合考虑矿井瓦斯涌出规律、影响因素、影响因素指标筛选原则将开采层原始瓦斯含量、煤层埋藏深度、煤层厚度、煤层倾角、开采高度、工作面长度、推进速度、采出率、邻近层原始瓦斯含量、邻近层厚度、邻近煤层层间距、层间岩性、开采强度、井下气压作为瓦斯涌出量的预测指标并构成瓦斯涌出量预测模型指标体系。如图 2.1 所示。

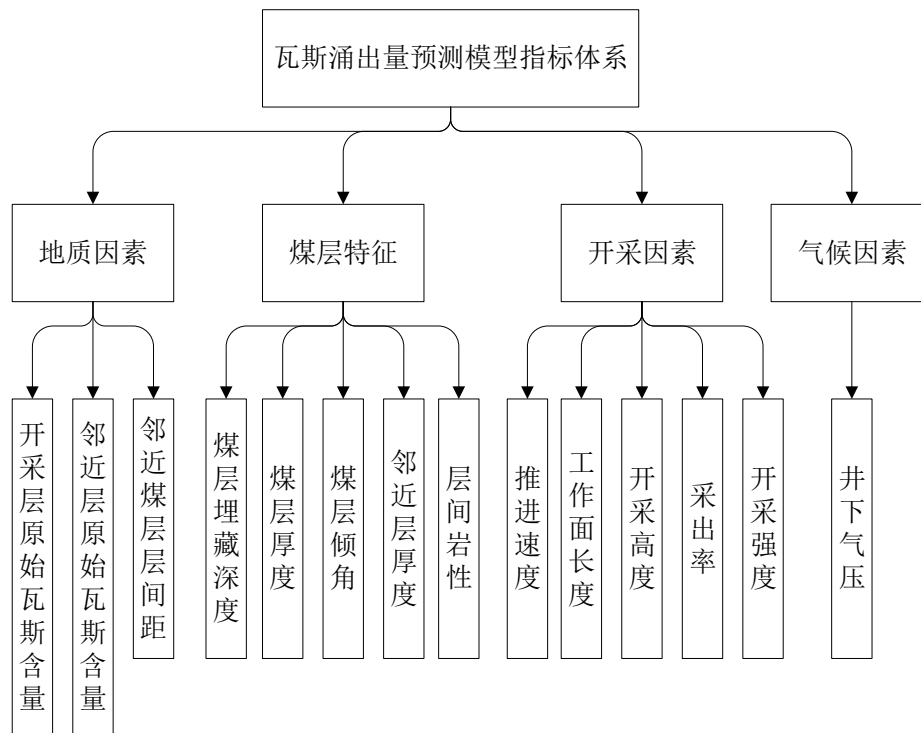


图 2.1 瓦斯涌出量预测模型指标体系

Figure2.1 Index system of gas emission prediction model

2.5 本章小结

(1) 对瓦斯涌出量的源头进行分析总结, 得到了源头位置与瓦斯涌出量之间的存在规律。为保障矿井施工安全、人员作业安全, 必须将瓦斯涌出量的影响因素研究视为重要前提;

(2) 从地质因素、煤层条件、通风条件、开采规模和气候因素这 5 个方面对瓦斯涌出量影响因素进行了系统性分析, 得到不同因素对瓦斯涌出产生的不同影响, 从而可以有利于准确得出瓦斯涌出量影响因素指标;

(3) 根据瓦斯涌出规律、影响因素、影响因素指标筛选原则把开采层原始瓦斯含量、煤层埋藏深度、煤层厚度、煤层倾角、开采高度、工作面长度、推进速度、采出率、邻近层原始瓦斯含量等因素作为瓦斯涌出量预测指标, 构成瓦斯涌出量预测指标体系。

3 瓦斯涌出量预测算法

3.1 人工神经网络

人工神经网络是多种作业单元相互链接且并行分布组合而成的结构型网络。将该作业单元线性分布构成人工神经网络的层。每种作业单元都包含一定数目的输入量，并且每个输入量都对应一个强关联性的权重值，作业单元将输入量根据权重比例相加求和并通过激活函数处理计算后得到输出量，再将输出量导入到下级作业单元进行训练^[55]。

人工神经元结构模型通常具备的基础要素为：

- (1) 突触，即连接两个作业单元的权重值；
- (2) 求和器，输入量加权求和处理器；
- (3) 激活函数，控制神经网络系统的输出值，保证输出值稳定在可接受范围内。

人工神经网络运行结构模型如图 3.1 所示， $x_j(j=1,2,\dots,n)$ 是作业单元的输入值， v_i 是根据误差范围调节后的值， y_i 是输出值，计算公式为：

$$u_i = \sum_j^n w_{ij} x_j \quad (3.1)$$

式中： u_i —输入值加权求和后的输出值；

w_{ij} —权重值；

x_j —作业单元的输入值。

$$v_i = u_i + b_i \quad (3.2)$$

式中： v_i —根据误差范围调节后的输入值；

b_i —作业单元的阈值。

$$y_i = f\left(\sum_j^n w_{ij} x_j + b_i\right) \quad (3.3)$$

式中： y_i —输出值；

f —激活函数。




图 3.1 作业单元结构模型
Figure3.1 Activity structure model

激活函数在整个人工神经网络系统中占据关键位置，不同激活函数所解决的问题也不同。目前人工神经网络系统中频繁使用阈值函数、符号函数、分段函数、sigmoid 函数、purelin 函数作为激活函数。

(1) 阈值函数

$$f(v) = \begin{cases} 1, v \geq 0 \\ 0, v < 0 \end{cases} \quad (3.4)$$

(2) 符号函数

$$\text{Sgn}(v) = \begin{cases} 1, v \geq 0 \\ -1, v < 0 \end{cases} \quad (3.5)$$

(3) 分段函数

$$f(v) = \begin{cases} 1, v \geq 1 \\ v, -1 < v < 1 \\ -1, v \leq -1 \end{cases} \quad (3.6)$$

(4) log-sigmoid 函数

$$f(v) = \frac{1}{1 + e^{(-v)}} \quad (3.7)$$

(5) tan-sigmoid 函数

$$f(v) = \frac{2}{1 + e^{(-2v)}} - 1 \quad (3.8)$$

(6) purelin 函数

$$f(v) = av + b \quad (3.9)$$

式中： v —人工神经网络输入值；

$f(v)$ —经过激活函数后的输出值；

a —斜率；

b —截距。

人工神经网络的工作流程由训练过程和回忆过程两方面组成。训练过程指的是运行过程按照指定算法不断调试各单元间的权值，使输入进网络训练的信息可以得到相对应的输出值且误差达到最小值。即设定有 S 组训练样本 $\{x_{1s}, x_{2s}, \dots, x_{ns}\}$, $j=1, 2, \dots, s$, 及有 S 组期望输出序列 $\{T_{1s}, T_{2s}, \dots, T_{ms}\}$, $j=1, 2, \dots, s$, 训练启动之前，先设置初始的权值和阈值，然后将第一组训练样本 $\{x_1, x_2, \dots, x_n\}^1$ 和期望输出值 $\{T_1, T_2, \dots, T_m\}^1$ 代入到神经网络系统中，可预测出神经网络的输出值 $\{y_1, y_2, \dots, y_m\}^1$ 其余 $S-1$ 组按上述步骤依次进行计算，得到相对应的输出值。

人工神经网络输出值和期望输出值之间的误差公式为：

$$E = \frac{1}{2} \sum_{j=1}^s \sum_{i=1}^m (T_{ij} - y_{ij})^2 \quad (3.10)$$

式中：\$E\$—人工神经网络输出值间的误差；

\$T_{ij}\$—期望输出值。

\$y_{ij}\$—人工神经网络输出值。

回忆过程指的是，使用调试好权值的人工神经网络输出与真实输出相近的目标值。人工神经网络是输入组对输出组的映射过程，而在含有隐含层的神经网络中可求得实际映射函数 \$G\$，\$G\$ 就是映射函数的最佳逼近函数，即公式（3.11）所示：

$$\{y_j\} = G(\{x_i\}) (i=1,2,\dots,n; j=1,2,\dots,m) \quad (3.11)$$

式中：\$G\$—实际映射函数。




图 3.2 人工神经网络结构模型

Figure3.2 Structure model of artificial neural network

近些年，专家学者们广泛利用人工神经网络模型对矿井瓦斯涌出量进行预测，如李心杰等将主成分分析法与遗传算法结合构成智能组合算法，张宝^[56]等对小断层构造区域进行瓦斯涌出量的预测，肖鹏等构造 KPCA 和 CMGANN 算法结合的预测模型，郑晓亮等使用 MI 和 SVM 算法结合的预测模型，苏筱丽将主成分分析和 SVM 算法结合构造预测模型，曹博等将 PCA 与 GA 算法结合优化 BP 神经网络等。运用人工神经网络对瓦斯涌出量预测有极强优异性，如并行结构可以将信息分散储存，在系统发生故障时，不会直接使系统功能失效，有宏观掌控能力。回忆工作过程面对处理信息不明确的输入样本同样可以到与期待值相近的输出值。人工神经网络的非线性处理能力适用于瓦斯涌出量影响因素这种较为复杂的关系网。自主学习能力及自我适应能力保证了瓦斯涌出量预测的精度等。

人工神经网络的结构模式分为前馈型结构和反馈型结构。前馈型结构指的是每个作业单元单向传递给下一个作业单元。该网络结构模型适合处理函数逼近问题及识别预判问题

等。前馈型结构又分为单层的前馈结构和多层的前馈结构。反馈型结构指的是作业单元双向传递模式，网络节点既得到输入值又传递输出值。该网络结构模型适合处理最优解、联想储蓄等问题^[57]，如图 3.2 人工神经网络结构模型所示。

3.2 BP 神经网络

BP 神经网络是单一方向传播的多结构正向网络，是样本信息的正向传输、误差数据负向传输的过程^[58]。包括输入节点、隐含层节点、输出节点，且同结构数据节点之间不会相互传输交流。输入数据从输入结构层数据节点开始，通过隐含结构层数据节点，最后到达输出结构层的数据节点，每一个结构数据节点的输出仅对下一结构数据节点的输出产生关联^[59]。因此 BP 神经网络系统的组成构造简易、塑造性能优越，具有很强的非线性拟合逼近能力等。在正向传递信号时，将输入结构层数据通过隐含结构层的函数进行计算。计算结果传入到输出结构层得到输出数据值。将输出样本数据值与期望样本数据值进行减法运算，得到二者的相距差值，再将相差值负向传递。误差负向传递时，将其分为若干个小部分分配给各种作业单元，各种作业单元经过处理后发出本单元的误差信号，目的时调节各单元内的参数值。通过不断调整神经网络的参数值，减少输出值与期望值间的差值，使 BP 神经网络训练出的结果尽可能的接近期望结果。BP 神经网络运行过程中输入变量 x 和对应的权值向量 w 加上阈值 v 需要传入激活函数中，通过数据计算后得到神经网络输出数据，激活函数通常取可以微分的单调递增函数，比如 S 型对数函数，S 型正切函数和线性函数 `purelin` 等^[60]。S 型对数函数、S 型正切函数是在线性和非线性之间的函数，具备线性及非线性特征。若 BP 神经网络使用 S 型函数，对模型的输出值有特定要求，需要满足在 ± 1 之间的范围。而使用线性函数 `purelin` 时，对模型的输出值不做任何规定。

3.2.1 隐含层节点

本文利用三层 BP 神经网络结构预测矿井瓦斯涌出量。输入层信息为实际瓦斯涌出量和其影响因素，输出信息为预测瓦斯涌出量。隐含层的节点个数影响着整个预测系统的精确度和训练速度等问题。因此需要多方面考量进行选取。计算隐含层节点个数的常用公式为：

(1) Kolmogorov 公式

$$I = A + \sqrt{M + P + 1} \quad (3.12)$$

(2) R.P.Lippmannn 公式

$$I = \log_2 M \quad (3.13)$$

(3) Hhcht Nielsen 公式

$$I = 2M + 1 \quad (3.14)$$

式中： I —隐含层作业单元个数；
 M —输入层作业单元个数；
 P —输出层作业单元个数；
 A —介于 1 到 10 之间的随机整数值。

3.2.2 BP 神经网络结构及计算

设置输入层有 M 个输入节点，任意位置的输入节点为 m ；隐含层有 I 个作业单位，任意一个作业单位为 i ；输出层有 P 个输出节点，任意位置的输出节点为 p 。用 w_{mi} 表示输入层和隐含层间的权重值， v_{mi} 表示输入层和隐含层间的阈值。用 w_{ip} 表示隐含层和输出层间的权重值， v_{ip} 表示隐含层和输出层间的阈值。每个作业单元的输入为 u ，作业单元输入经过激活函数后为 v 。设输入样本集合为 $X=[X_1, X_2, \dots, X_N]$ ，则任意一组输入样本为 $X_k=[x_{k1}, x_{k2}, \dots, x_{km}]^T (k=1, 2, \dots, N)$ ，其输出为 $Y_k=[y_{k1}, y_{k2}, \dots, y_{kp}]^T$ ，期望输出为 $d_k=[d_{k1}, d_{k2}, \dots, d_{kp}]^T$ 。输入层中作业单元输入到隐含层第 i 个作业单元的输入公式为：

$$u_i^I = \sum_{m=1}^M w_{mi} x_{km} \quad (3.15)$$

式中： u_i^I —隐含层第 i 个作业单元的输入值；
 w_{mi} —输入层和隐含层间的权重值；
 x_{km} —任意一组输入值。

经过公式（3.8）的激活函数计算后的公式为：

$$v_i^I = f\left(\sum_{m=1}^M w_{mi} x_{km}\right) \quad (3.16)$$

式中： v_i^I —隐含层第 i 个作业单元的输入值经过激活函数后的数值。

因此，输出层第 p 个作业单位的输入公式为：

$$u_p^P = \sum_{i=1}^I w_{ip} v_i^I \quad (3.17)$$

式中： u_p^P —输出层第 p 个作业单位的输入值；
 w_{ip} —隐含层和输出层间的权重值。

该作业单位经过公式（3.9）的激活函数计算后得到其输出公式：

$$y_{kp} = v_p^P = f(u_p^P) = f\left(\sum_{i=1}^I w_{ip} v_i^I\right) \quad (3.18)$$

式中： y_{kp} — k 组第 p 个作业单位输出值；
 v_p^P —输出层第 p 个作业单位的输入值经过激活函数后的数值。
 该作业单元的误差公式为：

$$e_{kp}(n) = d_{kp}(n) - y_{kp}(n) \quad (3.19)$$

式中： $e_{kp}(n)$ — k 组第 p 个作业单位误差值；

$d_{kp}(n)$ — k 组第 p 个作业单位期望值。

n —迭代次数。

因此输出层的误差和为：

$$E = \frac{1}{2} \sum_{p=1}^P (d_{kp}(n) - y_{kp}(n))^2 \quad (3.20)$$

误差值在反向传递的工作中，各层之间的权重值被逐次调整，使得调整值和误差值对权重值微偏分处理结果成正比：

$$\Delta w_{ip}(n) \propto \frac{\partial E(n)}{\partial w_{ip}(n)} \quad (3.21)$$

式中： $\Delta w_{ip}(n)$ —隐含层到输出层间的权重调整值。

根据公式 (3.21) 可得到：

$$\frac{\partial E(n)}{\partial w_{ip}(n)} = -e_{kp}(n) y'_{kp} v_i^l \quad (3.22)$$

误差权重值调节的目的是减少误差值，因此将局部梯度设为：

$$\delta_p^p = -\frac{\partial E(n)}{\partial u_p^p(n)} = e_{kp}(n) y'_{kp} \quad (3.23)$$

式中： δ_p^p —输出层局部梯度。

利用 Levenberg-Marquardt 法得到输出层权值阈值调整公式：

$$\Delta w_{ip}(n) = -\eta \frac{\partial E(n)}{\partial w_{ip}(n)} = \eta \delta_p^p(n) v_i^l(n) \quad (3.24)$$

$$\Delta w_{ip}(n+1) = w_{ip}(n) + \Delta w_{ip}(n) \quad (3.25)$$

$$\Delta v_{ip}(n) = -\eta \frac{\partial E(n)}{\partial v_{ip}(n)} = \eta \delta_p^p(n) \quad (3.26)$$

式中： η —学习速率；

$\Delta v_{ip}(n)$ —隐含层到输出层间的阈值调整值。

隐含层的局部梯度设为：

$$\delta_i^l(n) = f'(u_i^l(n)) \sum_{j=1}^J \delta_j^p w_{ij}(n) \quad (3.27)$$

利用 Levenberg-Marquardt 法得到输入层 M 到隐含层 I 之间的权值调整公式和阈值调整公式为：

$$\Delta w_{mi}(n) = \eta \delta_i^l(n) x_{km}(n) \quad (3.28)$$

$$f'(u_i^l(n)) = \frac{\partial v_i^l(n)}{\partial u_i^l(n)} = v_i^l(n)(1-v_i^l(n)) \quad (3.29)$$

$$\Delta w_{mi}(n+1) = w_{mi}(n) + \Delta w_{mi}(n) \quad (3.30)$$

$$\Delta v_{mi}(n) = \eta \delta_i^l(n) \quad (3.31)$$

式中： $\Delta w_{mi}(n)$ —输入层到隐含层间的权重调整值；

δ_i^l —隐含层局部梯度；

x_{km} — k 组第 m 个作业单位输入值；

$\Delta v_{mi}(n)$ —输入层到隐含层间的阈值调整值。

3.2.3 BP 神经网络运行步骤

BP 神经网络运行步骤及基本运行流程图 3.3 如下所示：

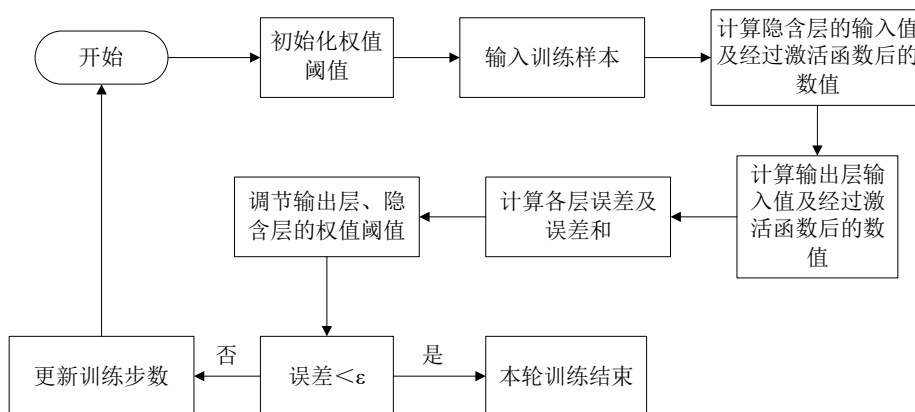


图 3.3 BP 神经网络运行流程

Figure3.3 Operation process of BP neural network

- (1) 构建 BP 神经网络结构，初始化权值阈值，输入训练样本；
- (2) 计算输入层作业单元输入到隐含层的输入值，即输入值经过激活函数后的数值；
- (3) 计算隐含层作业单元输入到输出层输入值，即隐含层数值经过激活函数后的数值；
- (4) 计算各层误差及误差和；
- (5) 调节输出层、隐含层的权值和阈值；
- (6) 输出满足误差范围的训练结果。反之重新进行 BP 神经网络训练。

3.2.4 BP 神经网络的特征

BP 神经网络的优势：

- (1) 并行分布结构特征

BP 神经网络是多种作业单元相互链接且并行分布组合而成的结构型网络。并行分布这一特性使得神经网络储存信息的方式是分散的，不会将信息局限与一个单元，因此 BP 神

神经网络不会因其中某一单元的故障有引发整个网络结构的瘫痪，具备较好的包容故障，全局掌控的能力。通过并行能力和回忆工作过程，将训练方式储存，从而使不明确的输入信息仍然可以被正确识别。适用于不同状态下矿井瓦斯涌出量的实时监测及控制。

（2）非线性相关特征

BP 神经网络训练和学习输入输出信息，在此过程中总结出不同的映射方式，进而按照适合的精度连接多种多样的非线性函数。矿井瓦斯涌出量由多个因素共同影响，且每个因素之间关系较为复杂，是很不确定的非线性系统。因此采用 BP 神经网络能够很好地优化传统预测方法产生的诸多问题，进而实现矿井瓦斯涌出量的快速准确预测。

（3）自主学习及自我适应特征

BP 神经网络可以根据周遭环境的变化趋势改变自身特性，并且自主进行学习训练，通过自行调整神经网络内部参数值，使网络结构可以顺利得到相应输出值，并适应不同的训练环境。通过以上特征可以收集大量输入数据且保持一定精度，有利于构建瓦斯涌出量预测模型。

BP 神经网络的缺点：

（1）易陷入局部极小值

BP 神经网络适用于处理复杂的具有非线性特征的输入样本，这种输入样本往往具有多个极小值。并且 BP 神经网络的误差函数拥有较多的极值，且这些数值中有且仅有一个 BP 神经网络所需的最小值，故 BP 神经网络容易被多个极小值扰乱寻优能力，导致陷入局部极小值。

（2）收敛速度慢

由于 BP 神经网络的训练方法是梯度下降法（Levenberg-Marquardt），且输入样本通常是较为复杂的非线性样本。因此在误差收敛进程中会出现波动程度不易观察的部分。尤其是在训练末期，误差值越来越接近临界值时，由于误差越来越小，导致权重值调整量也同样等比例变小，加之 BP 神经网络的学习步长是不变的，故权重值调整时间延长，从而影响 BP 神经网络的收敛速度。

（3）隐含层节点个数难以准确确定

隐含层节点个数影响整个 BP 神经网络系统的训练速度和误差收敛情况。设置过多的节点个数，训练速度会因为神经网络结构过于复杂而下降，并且影响输出结果的精度。设置过少的节点个数不能与期待值较好的拟合。但截止到目前研究，仍未有一个准确的公式来确定隐含层节点个数。

（4）随机的权值与阈值

一般在构造 BP 神经网络的时候，都是在没有特定设置的条件下任意取得的权值和阈值。但是随机生成的权值和阈值可能会影响神经网络系统的训练效果。要想达到神经网络

的最佳训练效果就需要把初始值设置为无限接近全局最小值的地方，实际应用过程中我们是无法知道该点所处位置的，因此权值与阈值的确定也是 BP 神经网络的一个难点。

改进 BP 神经网络的常用方法：

（1）附加动量法

对于 BP 神经网络的步长设置大小对神经网络训练效果的影响，采用附加动量法适度调节权重调整值，进而防止 BP 神经网络陷入局部极小值。具体方式为，通过加入动量值是步长发生动态变化，该变化是随着权重值的变化而变化的。这种动态变化模式可以加强 BP 神经网络的训练效果，提高训练速度。陈正^[61]等利用附加动量法和自适应学习速率法改进 BP 神经网络。利用附加动量连续调整预测模型的权重，提高预测模型的收敛效果，降低训练时长。在训练过程中对学习效果进行合理修整，降低训练次数。黄伟军^[62]等为了解决 BP 神经网络预测值与真实值间的差值较大、收敛性能差、易陷入局部极值的缺点，利用加入变量的方法和自动调节学习效率的方法改进了 BP 网络模型。

（2）输入样本降维法

在输入量为大规模数据组的时候使用 BP 神经网络系统会暴露其运行中的缺点。如训练效率降低、容易困在某一相对极小的数组中等问题。可使用特征性能提取的技术来解决。特征性能提取技术重点在于保留原数据组的核心特征信息，舍弃没有关联性的特征信息和关联性较小的特征信息，进而达到减小整体数据组维度的目的。由于瓦斯涌出量大小和影响指标之间具有显著的非线性关联特征，因此需使用非线性降维技术。王昱舒^[63]利用 PCA 算法对输入样本进行降维处理，然后再对无关联的输入样本归一化处理，从而降低了输入样本的方差，提高了 BP 神经网络的收敛速率。本文使用局部线性嵌入式算法（LLE）处理原始样本数据，将高维空间数据点按一定维数映射，得到携带原始数据特征的低维有效因子空间，并将降维得到的有效因子作为 BP 神经网络的输入变量。实现矿井瓦斯涌出量的快速、准确的预测。

（3）智能算法优化 BP 神经网络

近些年，许多专家学者善用智能算法的寻优能力来选取 BP 神经网络的权值与阈值，改善 BP 神经网络在运行过程中出现的问题，从而提高其预测能力。谢雨诗等利用果蝇算法进行寻优训练，防止了预测模型在训练过程中困在某一相对极小的数组中，使得经该模型预测出的数值与实际值具有较高的拟合度。本文使用狼群算法选取出 BP 神经网络的初始参数值，利用狼群算法的全面探索性能寻优得到最佳狼的位置，该最佳狼的位置便是 BP 神经网络的权值与阈值。经过寻优后得到的权值阈值更加适用于 BP 神经网络的训练，经误差分析反复迭代的次数大幅度减少。

综上所述未解决 BP 神经网络的缺陷性问题，本文在使用 BP 神经网络预测的前提下加入局部嵌入式算法和狼群算法对其进行优化，以解决 BP 神经网络存在的预测问题。

3.3 寻优算法的选择

选择常用于测试智能算法优越性的 8 个函数 Matyas、Booth、Bohachevsky1、Bohachevsky3、Eggcrate、Sphere、Rastrigin、Ackley 作为验证狼群算法寻优优越性的测试对象，分别对狼群算法（WPA）、粒子群算法（PSO）、防碰撞算法（FSA）的寻优性能进行分析比较，迭代次数设为 2000，原始值设为 50。以下为 8 个函数具体公式及函数图像，如图 3.4 所示。

(1) Matyas 函数，取值范围为 $[-10, 10]$ ，公式如下：

$$f(x) = 0.26(x_1^2 + x_2^2) - 0.48x_1x_2 \quad (3.32)$$

(2) Booth 函数，取值范围为 $[-10, 10]$ ，公式如下：

$$f(x) = (x_1 + 2x_2 - 7)^2 + (2x_1 + x_2 - 5)^2 \quad (3.33)$$

(3) Bohachevsky1 函数，取值范围为 $[-100, 100]$ ，公式如下：

$$f(x) = x_1^2 + 2x_2^2 - 0.3\cos(3\pi x_1) - 0.4\cos(4\pi x_2) + 0.7 \quad (3.34)$$

(4) Bohachevsky3 函数，取值范围为 $[-100, 100]$ ，公式如下：

$$f(x) = x_1^2 + 2x_2^2 - 0.3\cos(3\pi x_1 + 4\pi x_2) + 0.3 \quad (3.35)$$

(5) Eggcrate 函数，取值范围为 $[-\pi, \pi]$ ，公式如下：

$$f(x) = x_1^2 + x_2^2 + 25(\sin^2 x_1 + \sin^2 x_2) \quad (3.36)$$

(6) Sphere 函数，取值范围为 $[-1.5, 1.5]$ ，公式如下：

$$f(x) = \sum_{i=1}^D x_i^2 \quad (3.37)$$

(7) Rastrigin 函数，取值范围为 $[-10, 10]$ ，公式如下：

$$f(x) = 20 + x_1^2 + x_2^2 - 10(\cos 2\pi x_1 + \cos 2\pi x_2) \quad (3.38)$$

(8) Ackley 函数，取值范围为 $[-32, 32]$ ，公式如下：

$$f(x) = -20\exp\left(-0.2\sqrt{1/D}\sum_{i=1}^D x_i^2\right) - \exp\left(1/D\sum_{i=1}^D \cos 2\pi x_i\right) + 20 + e \quad (3.39)$$

用上述 8 个函数作为狼群算法（WPA）、粒子群算法（PSO）、防碰撞算法（FSA）的测试对象进行寻优训练，同时从不同角度对这 8 个函数进行评价，评价公式如下：

$$|F - F^*| / F < 0.001, \quad F \neq 0 \quad (3.40)$$

$$|F - F^*| < 0.001, \quad F = 0 \quad (3.41)$$

式中： F —最佳函数值；

F^* —理想最佳值。

以上三种算法在 Matlab 软件训练中所得到的数值模拟实验结果如表 3.1-3.3 所示。

表 3.1 狼群算法数值模拟的实验结果

Table3.1 Experimental results of numerical simulation of WPA algorithm

函数	最优值	最差值	平均值	标准差	成功率/%
Matyas	0	0	0	0	100
Booth	9.24e-11	8.34e-6	2.78e-6	2.55e-6	100
Bohachevsky1	0	0	0	0	100
Bohachevsky3	0	0	0	0	100
Eggcrate	0	0	0	0	100
Sphere	0	0	0	0	100
Rastrigin	0	0	0	0	100
Ackley	8.87e-16	8.87e-16	8.87e-16	8.87e-16	100

表 3.2 粒子群算法数值模拟的实验结果

Table3.2 Experimental results of numerical simulation of PSO algorithm

函数	最优值	最差值	平均值	标准差	成功率/%
Matyas	3.17e-14	3.32e-10	4.69e-11	6.51e-11	100
Booth	2.02e-11	1.67e-8	1.84e-9	3.07e-9	100
Bohachevsky1	2.82e-11	1.13e-7	1.84e-8	2.28e-8	100
Bohachevsky3	1.52e-11	4.38e-8	4.68e-9	7.03e-9	100
Eggcrate	9.45e-12	3.57e-7	2.77e-8	5.34e-8	100
Sphere	9.04e-4	5.70e-3	2.49e-3	9.13e-4	2
Rastrigin	22.3115	73.7042	40.8739	9.2637	0
Ackley	1.6895	2.4775	2.0781	0.1530	0


表 3.3 防碰撞算法数值模拟的实验结果

Table3.3 Experimental results of numerical simulation of FSA algorithm

函数	最优值	最差值	平均值	标准差	成功率/%
Matyas	2.19e-14	3.14e-11	1.12e-11	9.05e-12	100
Booth	5.34e-11	1.36e-8	2.57e-9	2.98e-9	100
Bohachevsky1	4.17e-13	1.21e-9	2.35e-10	2.52e-10	100
Bohachevsky3	1.42e-11	2.18e-9	4.14e-10	4.85e-10	100
Eggcrate	2.87e-7	0.0024	3.22e-4	5.36e-4	88
Sphere	5.3874	10.5523	8.9021	0.7894	0
Rastrigin	9.79e+2	1.21e+3	1.11e+2	58.4406	0
Ackley	20.8254	20.9722	20.9014	0.0351	0

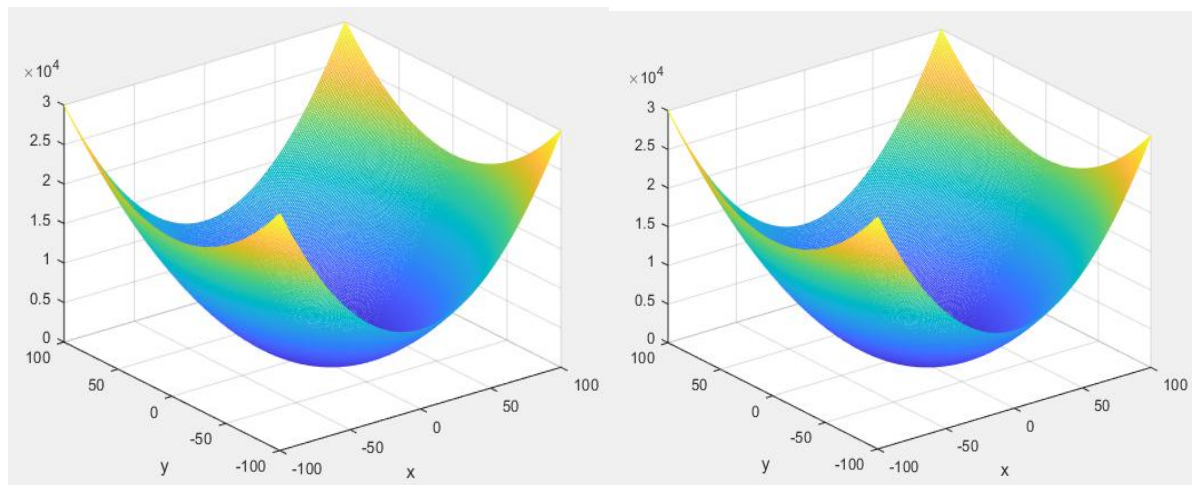
分析表 3.1-3.3 的实验结果可知，利用狼群算法（WPA）、粒子群算法（PSO）、防碰撞算法（FSA）训练 Mayas、Booth、Bohachevsky1、Bohachevsky3 函数在最佳值、平均值、成功率、寻优能力这几方面的表现都很优越。但粒子群算法（PSO）、防碰撞算法（FSA）在训练 Sphere、Rastrigin、Ackley 函数时以上几种训练表现均不如狼群算法（WPA）。因此狼群算法（WPA）具有较强的样本寻优能力和较高的运行稳定性。故本文选择狼群算法

(WPA) 作为优化 BP 神经网络参数值的智能算法。




(a) Matyas 函数图像

(b) Booth 函数图像




(c) Bohachevsky1 函数图像

(d) Bohachevsky2 函数图像



(e) Eggcrate 函数图像

(f) Sphere 函数图像



(g) Rastrigin 函数图像

(h) Ackley 函数图像

图 3.4 测试函数图像

Figure3.4 Image of test function

3.4 狼群算法

狼群算法（WPA）的构建起源于对大自然中狼群生态活动的观察。狼群算法中的智能狼分别为头狼、探狼和凶狼。一个狼群仅有一只头狼，头狼是通过竞争机制产生的，头狼担负领导职责，指挥狼群捕食^[64]。狼群中的探狼通过感知猎物气味搜寻猎物的位置并将捕获的信息上报给头狼。凶狼在得到头狼围捕指令后开始捕捉猎物。猎物优先会分配给能力强的狼，然后逐级分配下去。因此狼群算法的主要流程就是：头狼产生规则、游走行为、召集行为、围攻行为和狼群更新机制^[65]。

(1) 头狼产生规则

初始数据空间中，头狼是拥有最佳输出值的智能狼。狼群算法层层迭代，每经历一次迭代都需要将最佳狼的输出值与上一代中的头狼进行比较。如果该最佳输出值优于上一代头狼，则更新头狼位置（如若有两个及以上的最优狼则需要随机产生一匹智能狼作为新任头狼）。反之如果没有上一代头狼优秀则保留上一代头狼位置，再进行下一次迭代。

(2) 游走行为

在数据空间中随机取 $[n/\alpha+1, n/\alpha]$ 之间的整数，生成 S 匹探狼， α 为探狼比例因子。探狼 i 的嗅觉感知系统搜寻猎物气味，设 Y_i 为该探狼当前位置嗅到的猎物气味浓度。如果 Y_i 大于头狼嗅觉感知系统搜寻到的猎物气味浓度 Y_{lead} ，则该探狼比头狼更加有机会捕捉猎物，所以将探狼 i 作为头狼对群狼进行召唤。如果 $Y_i < Y_{lead}$ ，此时探狼需要面向各个方向探寻一步，即步长为游走步 $step_a^d$ 。并记录探寻到的猎物气味浓度后再回到上一步的位置。因此探狼 i 向 p 个方向探寻后在 d 维空间中处于的位置公式为：

$$x_{id}^p = x_{id} + \sin\left(2\pi \times \frac{p}{h}\right) \times step_a^d \quad (3.42)$$

式中: x_{id}^p —探狼 i 向 p 个方向探寻后在 d 维空间中处于的位置;

x_{id} —探狼 i 在 d 维空间中处于的位置;

p —第 p 个方向;

h — h 个方向;

$step_a^d$ —探狼游走步长。

探狼 i 分辨哪个方向的猎物气味最浓且浓于当前位置, 探狼 i 需向该方向探寻一步, 并更新探狼的位置。不停的迭代探寻猎物气味, 截止到探狼感知系统探寻的气味浓度 $Y_i > Y_{lead}$ 或者迭代次数到达最大点 $T_i > T_{max}$ 。

(3) 召集行为

头狼召集周边的凶狼, 凶狼按照 $step_b$ 的步长向头狼聚集。因此凶狼 i 在到第 $k+1$ 次迭代后, 在 d 维数据空间中的位置公式为:

$$x_{id}^{k+1} = x_{id}^k + step_b^d \times (g_d^k - x_{id}^k) / |g_d^k - x_{id}^k| \quad (3.43)$$

式中: x_{id}^{k+1} —凶狼 i 在第 $k+1$ 次迭代后 d 维空间中处于的位置;

x_{id}^k —凶狼 i 在第 k 次迭代后 d 维空间中处于的位置;

$step_b^d$ —凶狼游走步长;

g_d^k —第 k 次迭代后 d 维空间中头狼位置。

群狼捕捉猎物时, 若凶狼 i 感知系统嗅到的猎物气味浓度高于头狼嗅到的气味浓度则 $Y_i = Y_{lead}$, 将该凶狼作为头狼发布召集号令。若 $Y_i < Y_{lead}$, 则需要凶狼 i 持续的捕捉进攻猎物, 直至凶狼与头狼之间的距离小于:

$$d_{near} = 1 / D_w \cdot \sum_{d=1}^D |\min d - \max d| \quad (3.44)$$

式中: d_{near} —凶狼与头狼之间的距离;

D —凶狼与头狼之间的最初距离;

w —距离判定因子。

(4) 围攻行为

凶狼在捕捉猎物时, 与猎物距离相对近的时候, 凶狼召集探狼一起围攻猎物, 围攻行为的公式为:

$$x_{id}^{k+1} = x_{id}^k + \lambda \cdot step_c^d \times |G_d^k - x_{id}^k| \quad (3.45)$$

式中: λ — $[-1, 1]$ 中的随机数字;

$step_c^d$ —凶狼围攻步长;

G_d^k —经历 k 次迭代后的头狼位置。

以上所提到的游走步长, 召集步长和围攻步长的比例关系如下:

$$\text{step}_a^d = \frac{\text{step}_b^d}{2} = 2 \text{step}_c^d = |\max_d - \min_d| / S \quad (3.46)$$

式中： S —步长因子。

(5)狼群更新机制

狼群经过围捕得到的猎物按照狼的健壮程度依次分配，越健硕的狼得到的食物越多。瘦小的狼甚至分不到食物会被饿死。在狼群算法中的意义是排除最佳输出值差的智能狼，并且随机产生对应数量的智能狼。舍弃的智能狼越多，狼群越易产生个体差异化。舍弃的狼个数用 R 来表示， R 的范围是 $[n/2\beta, n/\beta]$ ， β 是更新比例因子。

3.5 降维算法

降维的实质目的是利用线性算法或非线性算法对原始数据库进行映射。通俗来讲，由于原始数据库之间的数据过于复杂与庞大，导致其数据本质特征无法简单的显示出来，利用降维技术可以将过于冗杂的数据库通过适当的函数计算投影到较低维的数据空间，以方便日后进行试验时快速提取到目标数据库的特征。降维技术的操作流程如图 3.5 所示。

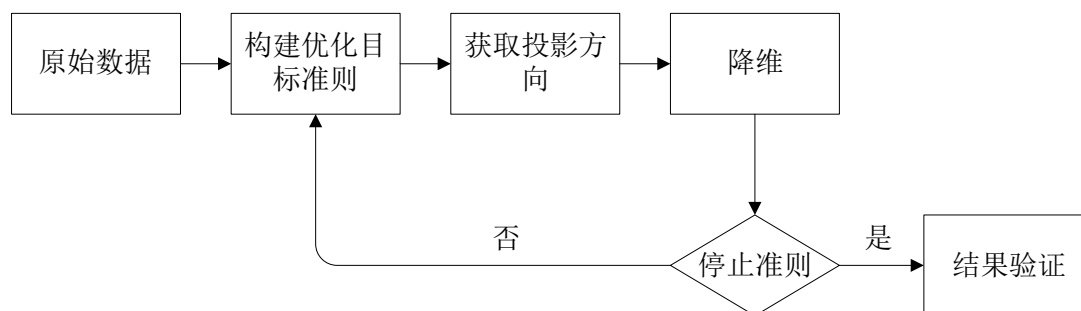


图 3.5 降维技术的操作流程

Figure3.5 Operation process of dimensionality reduction technology

目前，在各种试验项目中常用的降维技术往往是通过一次更新迭代进行降维处理数据库的。进行降维工作处理必须达到以下三个标准：

- (1) 降维工作必须是建立在利于后续试验基础上进行的；
- (2) 降维工作必须清楚简明的映射出高维数据库的核心特性，且提取的特性需全方位覆盖高位数据库的所有特性；
- (3) 按照实验前后需求选择适合的降维技术算法，注意不同实验之间的差异性。

3.5.1 降维方法

在 2000 年流形学习方法被提出后广泛应用于各类科学实验。流形学习方法中的流形指的是普通几何对象，其中包含多种维数的曲型线和曲型面。流形学习方法的本质原理是，

以数据库是均匀地从高维欧几里得空间提取出的低维流形为前提，将低维流形结构从高维欧几里得数据空间中复原，进而得到具备全覆盖性特征的映射结构。达到将原数据库简化的目的。和其他降维技术差异之处在于，利用流形学习方法所计算的样本是在一个未显露出的流形上提取的。流形内的数据并没有用坐标表示，需要将流形置于外部空间，间接性的用外部空间的坐标点来代替流形数据点^[66]。

利用流形学习法计算的对象可以是具有线性关系的样本也可以是具有非线性关系的样本。当作用对象之间是线性关系使用线性流形学习算法，主要包括主成分分析法、多维尺度变换法等算法。当作用对象之间是非线性关系使用非线性流形学习算法，主要包括等距映射，拉普拉斯特征映射，局部线性嵌入等算法。

3.5.2 局部线性嵌入式算法

使用局部线性嵌入式算法的前提条件：实验数据库的局部样本区域的流形是稳定平坦的，默认数据库的样本可以被临近数据点线性映射的。局部线性嵌入式算法利用线性映射中的不变系数使大数据库在降维过程中仍然保留其全部特性^[67]。由于瓦斯涌出量与影响因素之间具有显著的非线性特征，因此选择参数设置少，收敛速度快，常用于非线性数据特征提取的局部嵌入式算法（LLE）对 BP 神经网络输入量进行简化。该算法利用线性重构的局部对称性找出高维数据空间中的非线性结构，并在保持与数据点临近关系的前提下，把高维空间数据点映射到低维空间对应的数据点，且降维后的数据可较好地保持原有的拓扑结构^[68]。

LLE 算法输入数据有 N 个，即 $X=\{x_1, x_2, \dots, x_N\}$ ，具体运算步骤如下，局部嵌入式算法的基本流程如表 3.4 所示。

(1) 寻找最邻近数据点。利用度量欧几里得距离公式计算出数据样本之间的欧式距离，通过对比找到每个数据点 $x_i(i=1, 2, \dots, N)$ 的 K 个最邻近数据点，记为 $X=\{x_{i1}, x_{i2}, \dots, x_{ik}\}$ 。欧几里得距离公式为：

$$D = \left[\sum_{i=1}^N |x_i - x_{i-1}|^2 \right]^{1/2} \quad (3.47)$$

(2) 计算局部重建权值矩阵 W 。为得到合适权值需对成本函数进行最小值计算，并且保证权值矩阵每行的元素相加为 1，每个数据点仅能由其邻近数据点来构造。若上述条件无法满足矩阵为 0^[69]，即：

$$\begin{cases} \min \varepsilon(W) = \sum_{i=1}^N \|x_i - \sum_{j=1}^k w_{ij} x_{ij}\|_2^2 \\ \sum_{j=1}^k w_{ij} = 1 \\ w_{ij} = 0 \end{cases} \quad (3.48)$$

式中： W_{ij} —权值矩阵；

x_{ij} —邻近数据点。

(3) 通过权重矩阵 W 完成重构，将 $X=\{x_1, x_2, \dots, x_N\}$ 映射 $Y=\{y_1, y_2, \dots, y_N\}$ ，为最大限度保留高维空间的特性，设置约束条件^[70]，即：

$$\begin{cases} \min \phi(Y) = \sum_{i=1}^N \|Y_i - \sum_{j=1}^N w_{ij} Y_j\|_2^2 \\ \sum_{i=1}^N Y_i = 0 \\ \frac{1}{N} \sum_{i=1}^N Y_i Y_i^T = I \end{cases} \quad (3.49)$$

式中： I —单位矩阵。

表 3.4 局部嵌入式算法基本流程表

Table 3.4 Basic flow chart of local embeded algorithm

局部嵌入式算法基本流程
Input X, d
Output Y
$D = \left[\sum_{i=1}^N x_i - x_{i-1} ^2 \right]^{\frac{1}{2}}$ 计算出数据样本之间的距离
输出临近点 $X = \{x_{i1}, x_{i2}, \dots, x_{ik}\}$
$\varepsilon(\omega) = \sum_{i=1}^N \ x_i - \sum_{j=1}^k w_{ij} x_{ij}\ _2^2, \sum_{j=1}^k w_{ij} = 1$, 输出 W
$\varepsilon(Y) = \sum_{i=1}^N \ y_i - \sum_{j=1}^N w_{ij} x_{ij}\ _2^2$ s.t. $\sum_{i=1}^N y_i = 0, \frac{1}{N} \sum_{i=1}^N y_i y_i^T = 1$
输出 Y

3.6 本章小结

(1) 阐述了人工神经网络的特性，并根据矿井瓦斯涌出量影响因素间的非线性关系等特征选择使用人工神经网络中的 BP 神经网络进行预测。从并行分布结构特征、非线性相关特征、和自主学习及自我适应特征方面分析了 BP 神经网络算法在矿井瓦斯涌出量预测方面的优越性，并阐述了 BP 神经网络的缺点及附加动量法、输入样本降维法和智能算法优化法等改进 BP 神经网络的方法；

(2) 针对 BP 神经网络求解最佳值困难及训练时间过长等问题，选择利用智能算法对 BP 神经网络的参数值进行优化。通过对比狼群算法 (WPA)、粒子群算法 (PSO)、防碰撞算法 (FSA) 的训练性能，得到狼群算法 (WPA) 具有较强的样本寻优能力和较高的运行稳定性，于是选出狼群算法 (WPA) 作为最优算法。并详细阐述了狼群算法的运算步骤及计算公式；

(3) 针对 BP 神经网络由于输入数据过于庞杂导致运算速率过慢的问题, 提出使用降维算法解决。由于 BP 神经网络输入数据具有非线性关系等特征, 因此选择局部嵌入式算法 (LLE) 进行高维数据的特征提取, 可保持其原有的拓扑结构。并阐述其运算步骤及计算公式。

4 基于 LLE-WPA-BP 算法的瓦斯涌出量预测实验分析

4.1 基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型构建

本文运用 BP 神经网络算法对瓦斯涌出量进行预测。由第三章可知，BP 神经网络算法存在容易进入局部最小，导致无法得到最优解的情况以及训练速度较慢的问题。因此需要恰当的选择其他算法 BP 神经网络算法进行优化。由于瓦斯涌出量与影响因素之间具有显著的非线性特征，因此选择参数设置少，收敛速度快，常用于非线性数据特征提取的局部嵌入式算法（LLE）对 BP 神经网络输入量简化。再运用优化能力较强的狼群算法对 BP 神经网络的参数值进行迭代寻优。综上所述，本文运用 LLE-WPA-BP 算法对瓦斯涌出量进行预测。利用 Matlab 软件编码实现对 LLE-WPA-BP 预测模型的构建。预测流程图如图 4.1 所示。

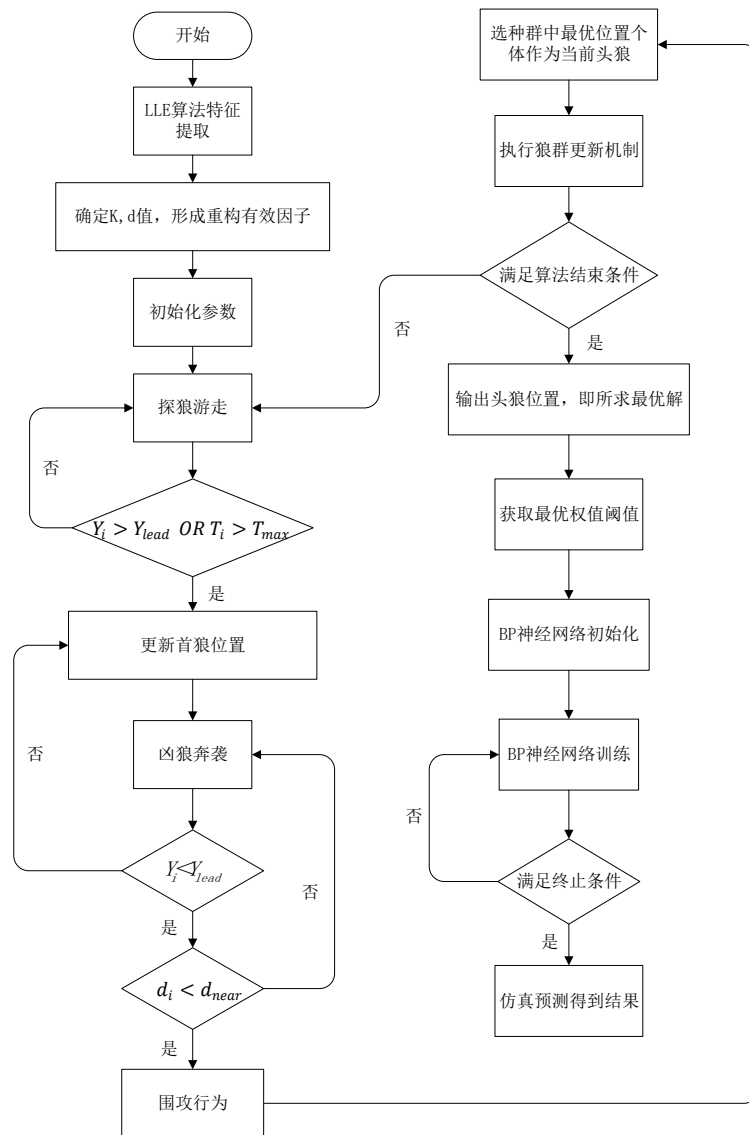


图 4.1 瓦斯涌出量预测模型基本流程图

Figure4.1 Basic flow chart of gas emission prediction model

预测模型训练步骤为:

- (1) 用 LLE 算法进行特征提取, 确定 K , d 值, 形成重构因子作为 BP 神经网络的输入值;
- (2) 设狼群捕猎范围为 $N \times D$ 的欧式空间, 设置狼群中个体狼 i 的位置 x_i , 数量 N , 空间的变量维数为 D , 最大迭代次数 k_{max} , 游走上限 T_{max} , 狼群中探狼进行游走的因子为 s , 判断因子 w , 狼群中个体更新比例为 β , 生成初始种群, 对每匹狼的位置进行初始化;
- (3) 根据第三章狼群算法步骤中头狼产生规则选择出头狼, 位置记 x_{lead} , 最佳输出值记 Y_{lead} , 选择除头狼之外的目标值最大的狼为探狼, 按公式 (3.42) 进行游走行为, 直到某只探狼得到的 Y_i 大于 Y_{lead} 或达到 T_{max} ;
- (4) 从除头狼之外的狼群个体中随机选择凶狼按公式 (3.43) 向猎物发起进攻, 当凶狼闻到猎物气味 $Y_i > Y_{lead}$, 则 $Y_{lead} = Y_i$ 代替头狼发起号召行动。反之继续进攻, 直到距离小于公式 (3.44);
- (5) 根据公式 (3.45) 进行围捕行为;
- (6) 根据头狼产生规律更新头狼位置, 按更新规则进行群体更替;
- (7) 判断优化是否达到精度或迭代次数是否到达 T_{max} , 若达到则输出头狼的位置即问题的最优解, 否则执行 (2) 步骤;
- (8) 将寻优结果设定为 BP 神经网络的权值和阈值, 然后进行训练、检验和预测。

4.2 预测模型的实验数据

本文选取马堡煤矿 2018 年 6 月至 2019 年 5 月的实际监测数据作为 LLE-WPA-BP 瓦斯涌出量预测模型的实验数据。对应指标为开采层原始瓦斯含量 $X_1(\text{m}^3/\text{t})$ 、煤层埋藏深度 $X_2(\text{m})$ 、煤层厚度 $X_3(\text{m})$ 、煤层倾角 $X_4(^{\circ})$ 、开采高度 $X_5(\text{m})$ 、工作面长度 $X_6(\text{m})$ 、推进速度 $X_7(\text{m}/\text{d})$ 、采出率 X_8 、邻近层原始瓦斯含量 $X_9(\text{m}^3/\text{t})$ 、邻近层厚度 $X_{10}(\text{m})$ 、邻近煤层层间距 $X_{11}(\text{m})$ 、开采强度 $X_{13}(\text{t}/\text{d})$ 、井下气压 $X_{14}(\text{kPa})$, $Y(\text{m}^3/\text{t})$ 表示实际瓦斯涌出量大小。其中层间岩性 X_{12} 属于定性指标, 需要进行数量化处理, 采用围岩硬度加权平均值作为输入值, 岩层硬度采用莫氏硬度计量法计算^[71], 即为公式 (4.1)。马堡煤矿实际监测数据和数量化处理后的层间岩性数据共 18 组, 如表 4.1 所示, 1 至 13 组为训练组, 14 至 18 组为测试组。

$$K = \sum_{m=1}^r f_m \frac{h_m}{H} \quad (4.1)$$

式中: K —开采层与邻近层间围岩硬度加权平均值;

r —围岩所含岩层数量;

f_m —第 m 层岩层硬度;

h_m —第 m 层岩层厚度;

H —开采层与邻近层之间的围岩总厚度。

表 4.1 $X_1 \sim X_7$ 的瓦斯涌出量和影响因素原始输入数据

Table 4.1 Original input data of gas emission and influencing factors of $X_1 \sim X_7$

序号	X_1	X_2	X_3	X_4	X_5	X_6	X_7
1	1.89	410	2.1	11	2.0	156	4.42
2	2.17	409	1.9	9	2.1	140	4.18
3	2.13	421	1.8	10	1.9	175	4.14
4	2.58	433	2.3	10	2.3	144	4.67
5	2.39	456	2.4	14	2.4	161	4.49
6	3.23	517	2.7	13	2.7	179	3.46
7	2.81	526	2.4	16	2.6	180	3.29
8	3.36	529	2.8	10	2.8	164	3.67
9	3.62	549	2.9	12	2.9	156	4.01
10	3.69	562	3.1	11	3.1	175	3.52
11	4.22	591	5.8	9	5.8	169	2.86
12	4.01	605	6.1	8	6.1	179	2.65
13	4.36	607	5.9	9	6.2	165	2.77
14	4.81	632	6.4	11	6.4	175	2.93
15	2.43	641	6.3	12	6.2	176	2.76
16	2.46	448	2.3	11	2.1	159	4.33
17	3.12	541	2.6	13	2.8	166	3.82
18	4.65	630	6.3	12	6.3	170	2.81

表 4.2 $X_8 \sim Y$ 的瓦斯涌出量和影响因素原始输入数据

Table 4.2 Original input data of gas emission and influencing factors of $X_8 \sim Y$

序号	X_8	X_9	X_{10}	X_{11}	X_{12}	X_{13}	X_{14}	Y
1	0.960	2.01	1.51	21	5.04	1825	87.75	3.41
2	0.950	2.11	1.20	21	4.86	1528	87.63	2.96
3	0.950	2.63	1.63	20	4.75	1750	87.43	3.57
4	0.949	2.42	1.49	17	4.92	2079	87.12	3.62
5	0.941	2.56	1.76	18	4.64	2103	86.93	4.16
6	0.930	2.23	1.73	11	4.79	2241	87.05	4.61
7	0.940	2.81	1.82	14	4.52	1979	87.96	4.92
8	0.932	1.89	1.43	15	4.79	2289	88.13	4.78
9	0.920	2.13	1.59	11	4.81	2326	87.23	5.23
10	0.941	3.14	1.47	17	4.52	2409	87.16	5.56
11	0.796	3.39	1.49	15	4.76	3138	88.02	7.25
12	0.813	3.12	1.79	17	4.71	3356	87.12	7.79
13	0.786	3.04	1.75	16	4.63	3089	87.49	7.68
14	0.773	2.97	1.93	14	4.53	3621	86.76	8.51
15	0.803	2.57	1.76	15	4.61	3412	87.71	7.94
16	0.950	2.01	1.69	17	4.85	1998	87.49	4.07
17	0.940	2.30	1.81	14	4.89	2207	88.77	4.92
18	0.802	3.34	1.62	19	4.64	3457	87.83	8.05

4.3 实验参数设定

LLE-WPA-BP 瓦斯涌出量预测模型在 Matlab 软件上进行数值模拟实验。具体的实验参数设置如下：设置 BP 神经网络的输入节点为重构的因子维数，本文为预测矿井瓦斯涌出量，故输出节点为 1，根据公式 (3.12) 计算出适合的隐含层节点数，将其设为 12。根据第三章第二节 BP 算法所用函数介绍，隐含层神经元传递函数选用 tansig 函数，输出层神经元传递函数用 purelin 函数，训练函数用 trainlm 函数。设最大训练次数为 10000，训练速率为 0.01，训练精度为 10^{-4} ，如图 4.5 所示。狼群算法种群规模为 100，最大迭代次数为 100，如图 4.4 所示。局部嵌入式算法 (LLE) K 值设置为 10， d 取[5,10]的范围之内^[72]。需要通过实验对比得出预测效果最好的 d 值，如图 4.3 所示。图 4.2 为 Matlab 训练工具箱。

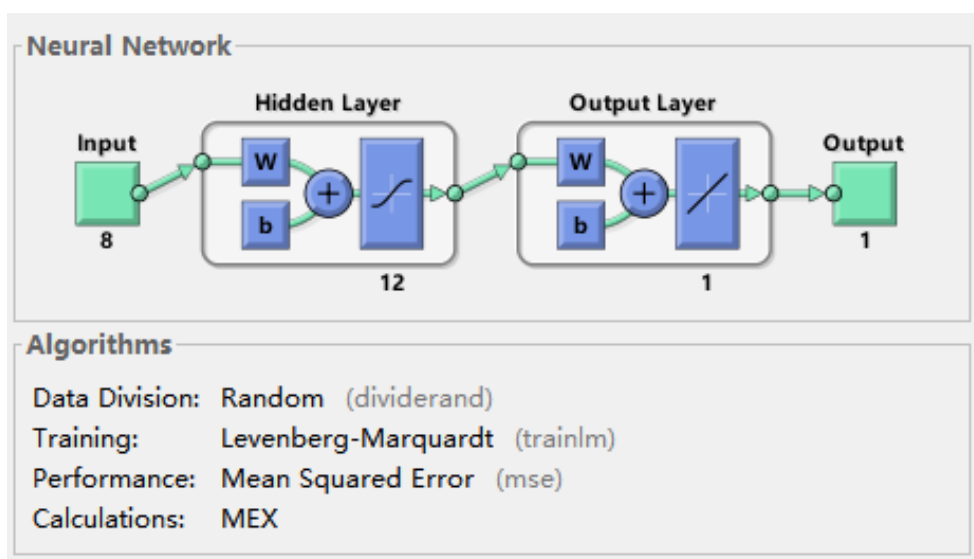


图 4.2 Matlab 训练工具箱

Figure4.2 Matlab training toolbox

```
close all;
clc;
data1=xlsread('data.xlsx','Sheet1','A2:O19');%读取数据
k=10;
d=8;%5 6 7 8 9 10 降低维数
[data,W] = LLE(data1, k, d);
[M,NN]=size(data);%M是样本数，N是变量数
inputn=data(:,1:NN)';%训练样本输入
outputn=data(:,NN)';%训练样本输出
%节点个数
inputnum=NN;%输入个数
hiddennum=12;%隐藏层
outputnum=1;%输出个数
%构建网络
net=newff(inputn,outputn,hiddennum,{'tansig','purelin'},'trainlm');
```

图 4.3 LLE 算法的部分初始参数值代码

Figure4.3 Some initial parameter value codes of LLE algorithm

```
%% 狼群算法参数设置
tic
numWolf = 100; % 狼群数里
maxiter = 100;
N=inputnum*hiddennum+hiddennum+hiddennum*outputnum+outputnum;
pop = zeros(numWolf,N);
```

图 4.4 WPA 算法的部分初始参数值代码

Figure4.4 Some initial parameter value codes of WPA algorithm

```
%% BP网络训练
%网络进化参数
net.trainParam.epochs=10000;%bp神经网络的代数
net.trainParam.lr=0.01;
net.trainParam.goal=0.0001;
inputn_test=data(14:18,1:NN)';%测试数据输入
outputn_test=data(14:18,NN)';%测试数据输出
```

图 4.5 BP 算法的部分初始参数值代码

Figure4.5 Some initial parameter value codes of BP algorithm

4.4 局部线性嵌入式算法参数设定

通过局部嵌入式算法（LLE）对初始数据样本进行降维处理，构造有效因子。需设定 LLE 算法中的 K 值和 d 值。 K 、 d 值的选择影响算法的精确度，若参数值取太大，则计算出的新因子无法体现局部特性。如果参数值取太小，则无法体现初始数据在降维处理后的初始性能特征及初始结构特征。本文中取 K 为 10， d 取值范围定在[5,10]，以步长为 1 逐个输入 BP 神经网络模型中模拟，进行对比实验。不同 d 值模拟 5 次取多种参考数据的平均值，通过对比实验得到预测效果最好的 d 值。最佳 d 值作为 LLE 算法的确定 d 值，再在模型中模拟 5 次，共 10 次。以确保数据的准确性。

当 d 取 5 时模拟 5 次所得实验结果是：平均时长为 290.9080s。平均绝对误差为 0.0999 m^3/t ，其中第 14 组测试样本平均绝对误差为 0.0081 m^3/t ，第 15 组测试样本平均绝对误差为 0.0929 m^3/t ，第 16 组测试样本平均绝对误差为 0.1214 m^3/t ，第 17 组测试样本平均绝对误差为 0.1554 m^3/t ，第 18 组测试样本平均绝对误差为 0.1217 m^3/t 。平均相对误差为 0.0178，其中第 14 组测试样本平均相对误差为 0.0009，第 15 组测试样本平均相对误差为 0.0117，第 16 组测试样本平均相对误差为 0.0298，第 17 组测试样本平均相对误差为 0.0316，第 18 组测试样本平均相对误差为 0.0151。训练集合回归拟合 R 值为 0.5730。全部数据回归拟合 R 值为 0.3908。在 Matlab 软件上多次模拟操作，所得实验结果与平均误差最为接近的是第 2 次数值模拟的实验结果，故以第 2 次数值模拟的实验结果为例，即表 4.3 和图 4.6。

表 4.3 $d=5$ 时第 2 次模拟实验结果

Table4.3 Results of the second simulation experiment when $d=5$

序号	绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$
14	0.0074	0.0009	8.5100	8.5026
15	0.0721	0.0091	7.9400	7.8679
16	0.0681	0.0167	4.0700	4.0019
17	0.2012	0.0409	4.9200	5.1212
18	0.1267	0.0157	8.0500	7.9233

当 d 取 6 时模拟 5 次所得实验结果是：平均时长为 293.8092s。平均绝对误差为 0.1423 m^3/t ，其中第 14 组测试样本平均绝对误差为 0.2267 m^3/t ，第 15 组测试样本平均绝对误差为 0.3509 m^3/t ，第 16 组测试样本平均绝对误差为 0.0478 m^3/t ，第 17 组测试样本平均绝对误差为 0.0212 m^3/t ，第 18 组测试样本平均绝对误差为 0.0648 m^3/t 。平均相对误差为 0.0157，其中第 14 组测试样本平均相对误差为 0.0133，第 15 组测试样本平均相对误差为 0.0443，第 16 组测试样本平均相对误差为 0.0118，第 17 组测试样本平均相对误差为 0.0011，第 18 组测试样本平均相对误差为 0.0080。训练集合回归拟合 R 值为 0.5015。全部数据回归拟合 R 值为 0.0848。在 Matlab 软件上进行多次模拟操作，所得实验结果与平均误差最为接近的是第 5 次数值模拟的实验结果，故以第 5 次数值模拟的实验结果为例，即表 4.4 和图 4.7。

表 4.4 $d=6$ 时第 5 次模拟实验结果

Table4.4 Results of the 5th simulation experiment when $d=6$

序号	绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$
14	0.0770	0.0090	8.5100	8.4330
15	0.4774	0.0601	7.9400	8.4174
16	0.0911	0.0224	4.0700	3.9789
17	0.0282	0.0057	4.9200	4.8918
18	0.1401	0.0174	8.0500	8.1901

当 d 取 7 时模拟 5 次所得实验结果是：平均时长为 334.0932s。平均绝对误差为 0.2396 m^3/t ，其中第 14 组测试样本平均绝对误差为 0.1551 m^3/t ，第 15 组测试样本平均绝对误差为 0.1652 m^3/t ，第 16 组测试样本平均绝对误差为 0.0722 m^3/t ，第 17 组测试样本平均绝对误差为 0.0803 m^3/t ，第 18 组测试样本平均绝对误差为 0.7254 m^3/t 。平均相对误差为 0.0326，其中第 14 组测试样本平均相对误差为 0.0182，第 15 组测试样本平均相对误差为 0.0208，第 16 组测试样本平均相对误差为 0.0176，第 17 组测试样本平均相对误差为 0.0163，第 18 组测试样本平均相对误差为 0.0901。训练集合回归拟合 R 值为 0.5232。全部数据回归拟合 R 值为 0.3758。在 Matlab 软件上进行多次模拟操作，所得实验结果与平均误差最为接近的是第 3 次数值模拟的实验结果，故以第 3 次数值模拟的实验结果为例，即表 4.5 和图 4.8。

当 d 取 8 时模拟 5 次所得实验结果是：平均时长为 289.5418s。平均绝对误差为 0.0695 m^3/t ，其中第 14 组测试样本平均绝对误差为 0.0388 m^3/t ，第 15 组测试样本平均绝对误差为 0.2479 m^3/t ，第 16 组测试样本平均绝对误差为 0.0126 m^3/t ，第 17 组测试样本平均绝对误差

为 $0.0346\text{m}^3/\text{t}$ ，第 18 组测试样本平均绝对误差为 $0.0137\text{m}^3/\text{t}$ 。平均相对误差为 0.0093，其中第 14 组测试样本平均相对误差为 0.0045，第 15 组测试样本平均相对误差为 0.0312，第 16 组测试样本平均相对误差为 0.0031，第 17 组测试样本平均相对误差为 0.0070，第 18 组测试样本平均相对误差为 0.0005。训练集合回归拟合 R 值为 0.9999。全部数据回归拟合 R 值为 0.9995。在 Matlab 软件上进行多次模拟操作，所得实验结果与平均误差最为接近的是第 4 次数值模拟的实验结果，故以第 4 次数值模拟的实验结果为例，即表 4.6 和图 4.9。

表 4.5 $d=7$ 时第 3 次模拟实验结果

Table4.5 Results of the third simulation experiment when $d=7$

序号	绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$
14	0.1442	0.0169	8.5100	8.3658
15	0.2393	0.0301	7.9400	8.1793
16	0.0173	0.0035	4.0700	4.0873
17	0.0157	0.0032	4.9200	4.9357
18	0.7671	0.0953	8.0500	7.2829

表 4.6 $d=8$ 时第 4 次模拟实验结果

Table4.6 Results of the 4th simulation experiment when $d=8$

序号	绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$
14	0.0437	0.0051	8.5100	8.4665
15	0.3538	0.0446	7.9400	7.5862
16	0.0128	0.0031	4.0700	4.0828
17	0.0085	0.0017	4.9200	4.9115
18	0.0114	0.0014	8.0500	8.0386

当 d 取 9 时模拟 5 次所得实验结果是：平均时长为 290.0725s。平均绝对误差为 $0.0831\text{m}^3/\text{t}$ ，其中第 14 组测试样本平均绝对误差为 $0.0776\text{m}^3/\text{t}$ ，第 15 组测试样本平均绝对误差为 $0.1135\text{m}^3/\text{t}$ ，第 16 组测试样本平均绝对误差为 $0.0288\text{m}^3/\text{t}$ ，第 17 组测试样本平均绝对误差为 $0.0592\text{m}^3/\text{t}$ ，第 18 组测试样本平均绝对误差为 $0.1368\text{m}^3/\text{t}$ 。平均相对误差为 0.0119，其中第 14 组测试样本平均相对误差为 0.0091，第 15 组测试样本平均相对误差为 0.0143，第 16 组测试样本平均相对误差为 0.0071，第 17 组测试样本平均相对误差为 0.0120，第 18 组测试样本平均相对误差为 0.0170。训练集合回归拟合 R 值为 0.6104。全部数据回归拟合 R 值为 0.9479。在 Matlab 软件上进行多次模拟操作，所得实验结果与平均误差最为接近的是第 5 次数值模拟的实验结果，故以第 5 次数值模拟的实验结果为例，即表 4.7 和图 4.10。

当 d 取 10 时模拟 5 次所得实验结果是：平均时长为 290.5067s。平均绝对误差为 $0.0809\text{m}^3/\text{t}$ ，其中第 14 组测试样本平均绝对误差为 $0.1221\text{m}^3/\text{t}$ ，第 15 组测试样本平均绝对误差为 $0.0839\text{m}^3/\text{t}$ ，第 16 组测试样本平均绝对误差为 $0.0434\text{m}^3/\text{t}$ ，第 17 组测试样本平均绝对误差为 $0.0615\text{m}^3/\text{t}$ ，第 18 组测试样本平均绝对误差为 $0.0937\text{m}^3/\text{t}$ 。平均相对误差为 0.0120，其中第 14 组测试样本平均相对误差为 0.01432，第 15 组测试样本平均相对误差为 0.0106，

第 16 组测试样本平均相对误差为 0.0107, 第 17 组测试样本平均相对误差为 0.0125, 第 18 组测试样本平均相对误差为 0.0116。训练集合回归拟合 R 值为 0.9035。全部数据回归拟合 R 值为 0.6528。在 Matlab 软件上进行多次模拟操作, 所得实验结果与平均误差最为接近的是第 3 次数值模拟的实验结果, 故以第 3 次数值模拟的实验结果为例, 即表 4.8 和图 4.11。

表 4.7 $d=9$ 时第 5 次模拟实验结果

Table4.7 Results of the 5th simulation experiment when $d=9$

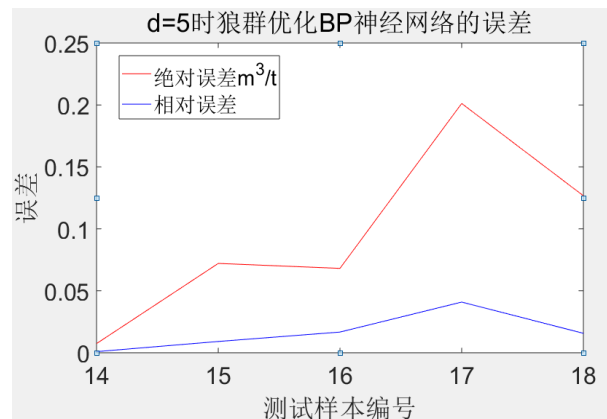
序号	绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$
14	0.1417	0.0167	8.5100	8.6517
15	0.0211	0.0027	7.9400	7.9611
16	0.0130	0.0032	4.0700	4.0570
17	0.0946	0.0192	4.9200	4.8254
18	0.1153	0.0143	8.0500	7.9347

表 4.8 $d=10$ 时第 3 次模拟实验结果


Table4.8 Results of the third simulation experiment when $d=10$

序号	绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$
14	0.0377	0.0044	8.5100	8.4723
15	0.2145	0.0270	7.9400	8.1545
16	0.0210	0.0052	4.0700	4.0490
17	0.0699	0.0142	4.9200	4.9899
18	0.0619	0.0077	8.0500	8.1119

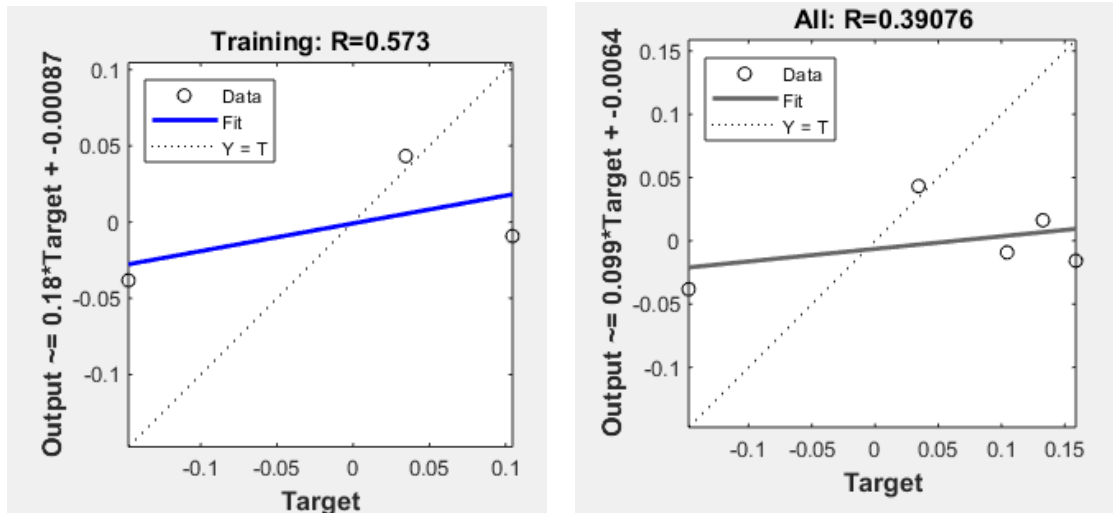
分别将 5、6、7、8、9、10 代入 d 值进行对比实验后, 从平均绝对误差、平均相对误差、训练时长、训练集合回归拟合 R 值、全部数据回归拟合 R 值这 5 方面对比 6 组实验结果, 如表 4.9 所示。回归拟合 R 值代表着预测实验结果拟合程度效果的好坏, R 值与数值 1 越相近代表拟合结果越优秀。分析得到 $d=8$ 时时长最短、误差最小、与实际检测得到的马堡煤矿瓦斯涌出量真实值的拟合效果最好。因此本文选用 8 作为 d 值进行瓦斯涌出量预测实验。为了得到给更准确的数据, 使用 $d=8$ 再次运行 5 次模拟实验, 共计 10 次实验。



(a) $d=5$ 时的误差值



(b) $d=5$ 时的真实值与预测值




(c) $d=5$ 时的训练集回归拟合图

(d) $d=5$ 时的全部数据回归拟合图


图 4.6 $d=5$ 时数值模拟的实验结果

Figure 4.6 Experimental results of numerical simulation when $d=5$



(a) $d=6$ 时的误差值

(b) $d=6$ 时的真实值与预测值




(c) $d=6$ 时的训练集回归拟合图


(d) $d=6$ 时的全部数据回归拟合图

图 4.7 $d=6$ 时数值模拟的实验结果


Figure 4.7 Experimental results of numerical simulation when $d=6$




(a) $d=7$ 时的误差值



(b) $d=7$ 时的真实值与预测值



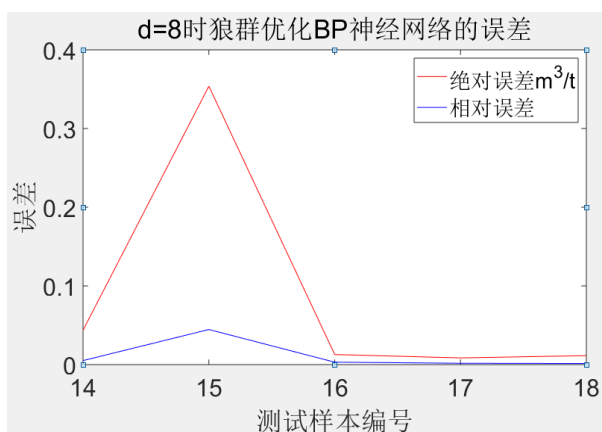
(c) $d=7$ 时的训练集回归拟合图




(d) $d=7$ 时的全部数据回归拟合图

图 4.8 $d=7$ 时数值模拟的实验结果


Figure 4.8 Experimental results of numerical simulation when $d=7$




(a) $d=8$ 时的误差值



(d) $d=8$ 时的真实值与预测值




(c) $d=8$ 时训练集回归拟合图




(d) $d=8$ 时的全部数据回归拟合图

图 4.9 $d=8$ 时数值模拟的实验结果


Figure 4.9 Experimental results of numerical simulation when $d=8$




(a) $d=9$ 时的误差值



(b) $d=9$ 时的真实值与预测值




(c) $d=9$ 时训练集回归拟合图




(d) $d=9$ 时的全部数据回归拟合图

图 4.10 $d=9$ 时数值模拟的实验结果


Figure 4.10 Experimental results of numerical simulation when $d=9$




(a) $d=10$ 时的误差值



(b) $d=10$ 时的真实值与预测值



(c) $d=10$ 时训练集回归拟合图



(d) $d=10$ 时的全部数据回归拟合图

图 4.11 $d=10$ 时数值模拟的实验结果

Figure4.11 Experimental results of numerical simulation when $d=10$

表 4.9 不同 d 值数值模拟的实验结果

Table4.9 Experimental results of numerical simulation with different d values

d 值	平均绝对误差/ m^3t^{-1}	平均相对误差	训练时长/s	训练集合回归拟合 R 值	全部数据回归拟合 R 值
$d=5$	0.0999	0.0178	290.9080	0.5730	0.3908
$d=6$	0.1423	0.0157	293.8092	0.5015	0.0848
$d=7$	0.2396	0.0326	334.0932	0.5232	0.3758
$d=8$	0.0695	0.0093	289.5418	0.9999	0.9995
$d=9$	0.0831	0.0119	290.0725	0.6104	0.9479
$d=10$	0.0809	0.0120	290.5067	0.9035	0.6528

4.5 基于 LLE-WPA-BP 算法的瓦斯涌出量预测

按照上述实验结果分析, 选定 $K=10$, $d=8$ 作为局部嵌入式算法 (LLE) 参数值, 根据第三章理论介绍所述, 利用度量欧几里得距离公式计算出数据样本之间的欧式距离, 通过

对比欧式距离找到每个数据点的 K 个最近邻近数据点, 记为 $X=\{x_1, x_2, \dots, x_N\}$ 。利用公式 3.33 对成本函数进行最小值计算, 从而得到局部重构权值矩阵 W , 且使权值矩阵每行的元素相加为 1。同时每个数据点仅能由其邻近数据点来构造, 若与上述规定不符则该矩阵为 0。根据原始样本的临近点计算出的重构权值矩阵 W 详见表 4.10-4.11。

表 4.10 重构权值矩阵 (序号 1~5)
Table4.10 Reconstructed weight matrix (No. 1 ~ 5)

序号	1	2	3	4	5
1	0.1761	0.0986	-0.3159	0.3293	0.1334
2	0.3419	0.1532	-0.1807	0.0995	0.0100
3	-0.1995	0.2646	-0.3594	0.4105	0.1754
4	0.2179	0.1296	0.0629	-0.0253	0.1358
5	0.4145	0.0812	-0.1684	0.0589	-0.7935
6	0.3273	0.1676	-0.1817	0.1207	-0.1627
7	0.3243	0.1685	-0.1810	0.1221	-0.1654
8	0.3158	0.1742	-0.1805	0.1313	-0.7169
9	-0.0715	-0.2649	0.2316	-0.3039	-0.0974
10	0.3419	0.1532	-0.1807	0.0995	0.1007
11	0.2824	-0.0774	0.4942	1.9633	0.1400
12	0.3238	0.1197	0.3353	-2.0479	-0.1912
13	0.2765	-0.2669	1.6519	-0.1726	-1.3779
14	0.2468	0.3474	0.0966	2.2219	-0.2503
15	0.3079	-0.1145	1.5609	-0.1184	-0.2913
16	0.2689	0.9454	-0.1782	-0.0435	-0.6363
17	1.7683	0.0561	-0.2636	-0.2235	0.3073
18	0.1503	0.4885	-0.0803	0.0622	-0.1559

表 4.11 重构权值矩阵 (序号 6~10)
Table4.11 Reconstructed weight matrix (No. 6 ~ 10)

序号	6	7	8	9	10
1	-0.1739	-0.0348	0.4163	-0.2202	-0.3997
2	-0.4245	-0.0475	1.6363	-0.4433	-1.5553
3	-0.1738	0.0588	0.2350	0.1253	-0.4024
4	0.0632	0.4946	-0.1752	-0.4548	-1.6121
5	-0.1639	1.6073	0.0693	-0.3598	-1.5212
6	-0.1859	1.6411	-1.6081	-0.4646	-1.5644
7	-0.1519	1.6403	-1.7254	-0.4639	-1.5662
8	0.3303	1.6408	-2.4540	-0.4710	-1.5723
9	0.4665	0.7458	0.2102	1.5063	-1.6738
10	-0.4245	-0.0475	1.6363	-0.4434	-1.5553
11	-0.0686	-0.4839	2.6809	-1.6936	0.3708
12	0.1375	-0.3302	2.8443	-1.7215	0.3286
13	1.5902	-1.5763	-0.0748	-0.4612	0.4213
14	-0.2295	0.2441	-1.1001	-1.6321	0.1758

续表 4.11

序号	6	7	8	9	10
15	0.3765	0.0266	-1.5367	-1.6076	0.4060
16	0.0521	-0.1783	1.5197	0.1115	-1.5454
17	-0.3709	-1.8893	1.7082	0.2833	-0.3658
18	-0.3916	0.2627	0.2043	0.3534	-1.5337

通过权重矩阵 W 完成重构, 将 $X=\{x_1, x_2, \dots, x_N\}$ 映射到 $Y=\{y_1, y_2, \dots, y_N\}$, 为最大限度保留高维空间的特性, 根据第三章 LLE 算法, 可将嵌入式误差公式表达为:

$$\begin{aligned}\Phi(Y) &= \sum_{i=1}^N \|Y_i - \sum_{j=1}^N w_{ij} Y_j\|^2 = \sum_{i=1}^N \left\| \sum_{j=1}^K w_{ij} Y_i - \sum_{j=1}^K w_{ij} Y_j \right\|^2 = \sum_{i=1}^N \|Y_i - Y w_i\|^2 \\ &= Y(1-w)(I-w)^T Y^T\end{aligned}\quad (4.2)$$

公式 (4.2) 最小时的低维数据空间 Y 为本文的重构有效因子。因实际数据处理过程中, 有些数据本身存在正负数值, 此时如果立即进行归一化数据处理, 便会丢失原数据所携带的部分特征。故利用公式 (4.3) 将重构有效因子进行归一化数据处理时, 将其范围规定在 $[-1, 1]$ 之间。得到归一化后的 BP 神经网络输入数据, 如表 4.12 所示。

表 4.12 BP 神经网络输入数据

Table 4.12 Input data of Back Propagation Neural Network

序号	Y_1	Y_2	Y_3	Y_4	Y_5	Y_6	Y_7	Y_8
1	-0.2357	-0.3038	-0.1047	-0.0059	0.3257	0.0400	0.1303	0.1287
2	-0.3125	-0.1541	0.1248	-0.0117	0.2948	-0.2539	0.0258	0.1249
3	0.2462	-0.4516	-0.4000	0.2917	-0.0911	-0.1153	-0.1729	-0.0316
4	0.2876	0.0016	0.1631	-0.0396	0.4785	0.2264	-0.2057	-0.2292
5	0.4896	-0.2051	0.0975	-0.1050	0.2749	0.2201	0.1717	0.1820
6	-0.1258	-0.0865	0.0486	0.3749	-0.3488	0.2847	-0.0959	-0.1167
7	0.5946	-0.1902	0.2145	0.2032	-0.4161	0.0529	0.2699	0.4116
8	-0.2694	-0.0188	0.1356	-0.0789	-0.0822	-0.1780	-0.0385	-0.3296
9	-0.8463	0.2117	0.4996	-0.0099	-0.0816	0.0728	-0.1159	-0.2297
10	-0.1568	-0.1791	0.0277	-0.3734	-0.2189	-0.5061	0.1205	-0.3007
11	0.2467	0.1558	-0.2153	-0.1906	-0.1358	0.3629	-0.0720	-0.0426
12	-0.7592	0.0827	-0.4619	-0.1347	-0.1030	-0.0736	-0.1354	-0.2047
13	-0.3618	0.1091	-0.1089	-0.5876	-0.1798	0.2342	-0.2122	0.3966
14	0.6254	0.4311	-0.2112	0.3078	0.0345	0.1237	0.1854	-0.2110
15	-0.9032	0.3845	0.0143	0.2560	0.1045	-0.4451	-0.4791	0.4316
16	0.0987	-0.1465	0.0148	0.1182	0.1589	0.1354	-0.0984	-0.0688
17	-0.2176	0.0146	0.3363	-0.0230	-0.1474	-0.0461	0.0728	-0.0090
18	-0.0879	0.3446	-0.1748	0.0086	0.1328	-0.1352	0.6495	0.0984

$$Y_n = 2 \frac{Y - Y_{\min}}{Y_{\max} - Y_{\min}} - 1 \quad (4.3)$$

式中: Y_n —归一化后的数据;

Y —重构有效因子;

Y_{\max} —重构有效因子最大值;

Y_{\min} —重构有效因子最小值。

选择第 1 组至第 13 组归一化后的数据作为训练组, 将训练组数据输入进 WPA-BP 神经网络模型, 在 Matlab 软件上的实验模拟得到训练组的绝对误差值、相对误差值以及预测值。如表 4.13 所示及图 4.12 所示。由表 4.13 可知训练组平均绝对误差为 $0.0701\text{m}^3/\text{t}$, 平均相对误差为 0.0108。与图 4.12 结合分析可知, LLE-WPA-BP 预测模型有较好的预测性能, 误差精确度满足实验所需, 模拟时长较短。与实际检测得到的马堡煤矿瓦斯涌出量真实值有较高的拟合程度, 尤其在第 8 组到第 10 组真实值与预测值的重合率达到 90%以上。因此可以论证 LLE-WPA-BP 预测模型的可行性。

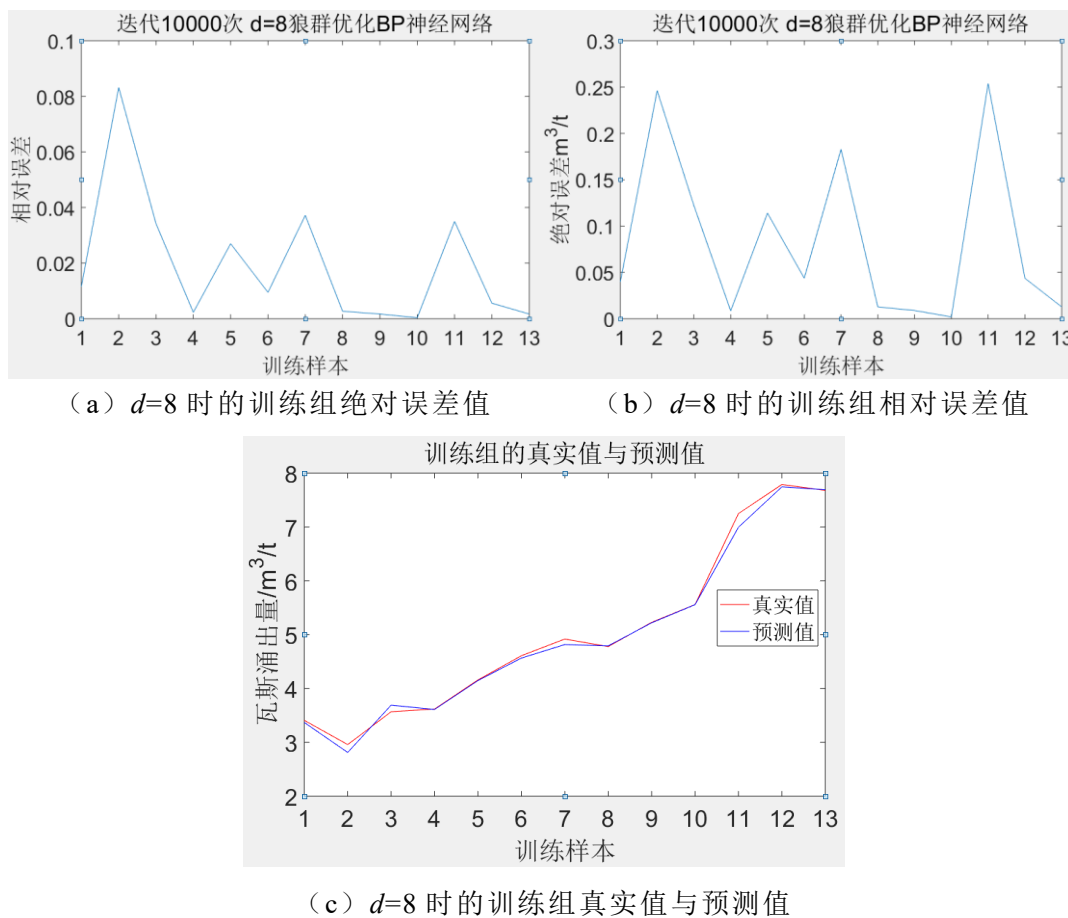


图 4.12 训练组数值模拟的实验结果

Figure4.12 Experimental results of numerical simulation of training group

再通过对比本章第 4 小节所得测试组数值模拟的实验结果, 可更加清晰的得出 d 取 8 时模型预测效果最好。从而经过多次的模拟实验选出具有代表性的测试组实验结果及实验结果图, 如表 4.6 及图 4.9 所示。LLE-WPA-BP 预测模型的数值模拟实验结果为平均时长 289.5418s, 平均绝对误差 $0.0695\text{m}^3/\text{t}$, 平均相对误差 0.0093, 训练集合回归拟合 R 值为 0.9999。全部数据回归拟合 R 值为 0.9995。由 $d=8$ 时实际检测得到的马堡煤矿瓦斯涌出量真实值与预测值放大图 4.13 可以看到 16 号样本至 18 号样本真实值曲线与预测值曲线几乎

重合,通过具体实验数值才可分辨出二者的差别。综上所述对于 LLE 算法中 d 值的选取及 WPA 算法中阈值与权值的寻优使 BP 神经网络达到预测精准度的最佳状态。




图 4.13 $d=8$ 时真实值与预测值的局部放大图

Figure4.13 Partial enlargement of $d=8$ real value and predicted value

表 4.13 训练组的数值模拟实验数据结果

Table4.13 Numerical simulation experimental data results of the training group

序号	真实值/ $\text{m}^3\cdot\text{t}^{-1}$	预测值/ $\text{m}^3\cdot\text{t}^{-1}$	绝对误差值/ $\text{m}^3\cdot\text{t}^{-1}$	相对误差值
1	3.4100	3.3702	0.0398	0.0117
2	2.9600	2.8138	0.1462	0.0494
3	3.5700	3.6921	0.1221	0.0342
4	3.6200	3.6115	0.0085	0.0023
5	4.1600	4.1486	0.1140	0.0270
6	4.6100	4.5662	0.0438	0.0095
7	4.9200	4.8172	0.1028	0.0209
8	4.7800	4.7928	0.0128	0.0026
9	5.2300	5.2211	0.0089	0.0017
10	5.5600	5.5580	0.0020	0.0004
11	7.2500	6.9962	0.2538	0.0350
12	7.7900	7.7463	0.0437	0.0056
13	7.6800	7.6928	0.0128	0.0017

4.6 本章小结

(1) 根据 BP 神经网络特点,选择局部嵌入式算法(LLE)和狼群算法(WPA)优化 BP 神经网络,用来弥补 BP 神经网络容易困在局部极小的位置及训练效率低等缺点。从而构建出 LLE-WPA-BP 预测模型,并交代了该模型的训练步骤及基本流程图;

(2) 在构建出 LLE-WPA-BP 预测模型后,选择马堡煤矿的监测数据及层间岩性数量化处理后的定量数据作为该预测模型的输入数据。1 到 13 组数据作为训练组,用来验证模型的可行性,14 到 18 组数据作为测试组,用来论证模型的精准度;

(3) 在 Matlab 软件上编写实验所需参数代码,由于 LLE 算法中的 d 值决定着原始数

据提取的准确性，从而影响预测结果与真实值间的误差。故分别对 d 取 5、6、7、8、9、10 时所得到的实验结果进行从平均绝对误差、平均相对误差、训练时长、训练集合回归拟合 R 值、全部数据回归拟合 R 值的整合分析。通过对比实验结果得到 d 取 8 时的预测模型精确度最高、时长最短、误差最小、与实际检测得到的马堡煤矿瓦斯涌出量真实值的拟合效果最好；

(4) 选取出最佳 d 值后详细地阐述了 LLE-WPA-BP 预测模型具体的训练过程。利用 LLE 算法计算出重构矩阵及重构有效因子，并将重构有效因子归一化处理代入模型中作为输入数据。通过分析训练组的实验结果，平均绝对误差为 $0.0701\text{m}^3/\text{t}$ ，平均相对误差为 0.0108 等数据，可知该模型在预测瓦斯涌出量方面的可行性，可运用该模型进行真实监测数据的模拟预测。选择 14 到 18 组实验数据作为测试组，实验结果其平均绝对误差为 $0.0695\text{m}^3/\text{t}$ ，平均相对误差为 0.0093。误差较小，满足在实际应用所需误差范围内的要求。实际检测得到的马堡煤矿瓦斯涌出量真实值与预测值的拟合程度较高， R 值均达到了 0.9 以上。因此 LLE-WPA-BP 预测模型可以精准快速的预测出瓦斯涌出量。

5 多种模型瓦斯涌出量预测对比分析

根据第四章的实验结果可以看出 LLE-WPA-BP 预测模型具有较高的预测精准度, 经过多次重复实验后的结果对比可以看出该模型有较高的稳定性。本章利用 BP 模型、GA-BP 模型、WPA-BP 模型三种瓦斯涌出量预测模型对相同的实验样本进行数值模拟, 与基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型在选用 $d=8$ 时的平均数值模拟实验结果进行对比, 用于论证 LLE-WPA-BP 预测模型的优越性能。

5.1 基于 BP 神经网络算法的瓦斯涌出量预测模型

BP 神经网络常用于预测矿井瓦斯涌出量, 其并行分布结构适用于对不同状态下的矿井进行实时的瓦斯涌出量预测。BP 神经网络的非线性相关性可以很好地覆盖到矿井瓦斯涌出量的多种非线性相关的影响因素。BP 神经网络的自主学习及自我适应能力可以在有大量输入样本时仍可以保持预测的精度。但随着智能算法结合应用的发起, BP 神经网络显现出一些不可避免的缺点。BP 神经网络在运行过程中只能随机设置阈值和权值, 这样大大降低了预测精准度。导致其预测精度远不如智能算法结合的预测方法高。并且 BP 神经网络含有冗繁的输入数据, 该数据还包括一些非线性函数关系的输入值, 如果不经数据处理会导致收敛速度过慢。




图 5.1 BP 神经网络预测模型的真实值与预测值

Figure 5.1 True value and predicted value of BP neural network prediction model

如表 5.1 是 BP 神经网络对瓦斯涌出量预测的数值模拟实验结果。经过在 Matlab 软件上的模拟实验可得 BP 神经网络预测模型的平均绝对误差为 $0.1884m^3/t$, 平均相对误差为 0.0254。其预测精度与本文所提的 LLE-WPA-BP 算法预测结果相比较差。图 5.1 可直观对比出真实值与预测值的拟合程度。

表 5.1 BP 模型测试组数值模拟的实验结果

Table5.1 Experimental results of numerical simulation of BP model test groups

序号	真实值/ m^3t^{-1}	预测值/ m^3t^{-1}	绝对误差/ m^3t^{-1}	相对误差
14	8.5100	8.1710	0.3390	0.0398
15	7.9400	8.0700	0.1300	0.0163
16	4.0700	4.1064	0.0364	0.0089
17	4.9200	4.8239	0.0961	0.0195
18	8.0500	8.3905	0.3405	0.0423

5.2 基于 GA-BP 算法的瓦斯涌出量预测模型

遗传算法 (GA) 是极具代表性的启蒙式算法。遗传算法利用多组二进制样本作为算法计算过程的运算对象, 即染色体。所设问题和染色体相互对应。从初始数据样本开始, 使用适应度函数对数据样本进行智能选择。模仿上述所提学说进行交叉变异工作, 从而产生新的数据样本。经过不断的选择交叉变异直至满足整个预测模型的期望条件^[73]。用遗传算法优化 BP 神经网络的参数值, 可以有效防止预测模型在训练过程中难以求出最佳值、后期收敛速度慢等问题。经过在 Matlab 软件上的模拟实验可得 GA-BP 神经网络预测模型的预测结果, 其平均绝对误差为 $0.1535\text{m}^3/\text{t}$, 平均相对误差为 0.0278。如表 5.2 所示。通过对 BP 神经网络参数值的优化使得其预测能力高于上述 BP 神经网络预测模型。但由于没有将繁杂冗长的输入数据进行提炼故平均绝对误差、平均相对误差等实验结果与本文所提的 LLE-WPA-BP 算法的误差差距较大, 稳定性也较差。图 5.2 可直观对比出真实值与预测值的拟合程度。

表 5.2 GA-BP 模型测试组数值模拟的实验结果

Table5.2 Experimental results of numerical simulation of GA-BP model test groups

序号	真实值/ m^3t^{-1}	预测值/ m^3t^{-1}	绝对误差/ m^3t^{-1}	相对误差
14	8.5100	8.3627	0.1473	0.0173
15	7.9400	7.8171	0.1229	0.0155
16	4.0700	4.2861	0.2161	0.0531
17	4.9200	4.6881	0.2319	0.0471
18	8.0500	8.0009	0.0491	0.0061

5.3 基于 WPA-BP 算法的瓦斯涌出量预测模型

WPA-BP 预测模型与本文预测模型不同的是没有使用降维算法将 BP 神经网络的输入数据降维。所以 WPA-BP 预测模型与 LLE-WPA-BP 预测模型不仅需要对比绝对误差、相对误差等精确度量值, 还需要对比训练时长。经过在 Matlab 软件上的模拟实验可得 WPA-BP 神经网络预测模型的预测结果, 其平均绝对误差为 $0.1156\text{m}^3/\text{t}$, 平均相对误差为 0.0222, 平均训练时长为 345.1468s。由于没有将复杂冗长的实验输入数据进行降维计算, 导致 BP 神经网络输入数据过多, 从而导致训练后期的收敛效率过低, 训练时间增加。如表 5.3 所

示。其平均绝对误差、平均相对误差、平均训练时长与本文所提的 LLE-WPA-BP 算法预测结果相比较差。但由第五章第二小节中 GA-BP 算法实验结果明显可以看出 WPA 算法寻优能力强于 GA 算法。图 5.2 可直观对比出真实值与预测值的拟合程度。




图 5.2 GA-BP 神经网络预测模型的真实值与预测值

Figure 5.2 True value and predicted value of GA-BP neural network prediction model




图 5.3 WPA-BP 神经网络预测模型的真实值与预测值

Figure 5.3 True value and predicted value of WPA-BP neural network prediction model

表 5.3 WPA-BP 模型测试组数值模拟的实验结果

Table 5.3 Experimental results of numerical simulation of WPA-BP model test groups

序号	真实值/ $m^3 \cdot t^{-1}$	预测值/ $m^3 \cdot t^{-1}$	绝对误差/ $m^3 \cdot t^{-1}$	相对误差	训练时长/s
14	8.5100	8.4540	0.0056	0.0007	345.1468
15	7.9400	7.9052	0.0348	0.0046	344.0921
16	4.0700	4.2248	0.1548	0.0380	347.6425
17	4.9200	5.1771	0.2571	0.0523	343.4746
18	8.0500	8.1756	0.1256	0.0156	345.1057

5.4 多种模型瓦斯涌出量预测结果分析

通过以上 3 组模型的瓦斯涌出量预测实验结果可以看出，对比实验的 3 组模型的平均

绝对误差、平均相对误差都高于基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型的误差值。根据图 5.4 可以看出, 基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型与真实值的拟合程度高于 BP 神经网络预测模型、基于 GA-BP 算法的预测模型、基于 WPA-BP 算法的预测模型。对比组中基于 WPA-BP 算法的预测模型与真实值的拟合效果相对较高。BP 神经网络预测模型拟合程度最差, 实验效果不理想。




图 5.4 多种模型的真实值与预测值

Figure 5.4 Real and predicted values of various models

利用平均相对变动值作为预测模型性能的又一判断标准进行四组预测模型的对比分析, 可以更好地提高对比分析的准确性、合理性。利用平均相对变动值可以全方位的评断四组预测模型泛化效果。平均相对变动值越小, 表明该瓦斯涌出量预测模型的泛化效果越明显。平均相对变动值的公式为:

$$ARV = \frac{\sum_{i=1}^N (x_i - x_i')^2}{\sum_{i=1}^N (x_i - \bar{x}_i)^2} \quad (5.2)$$

式中: ARV —平均相对变动值;

x_i —真实值;

x_i' —预测值。

通过计算得到 4 组预测模型的平均绝对误差值、平均相对误差值、平均相对变动值, 如表 5.4 所示。通过表 5.4 可以清晰的看出, 基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型的平均绝对误差、平均相对误差、平均相对变动值低于 BP 神经网络预测模型、GA-BP 算法预测模型、WPA-BP 算法预测模型。

从绝对误差、相对误差角度来看, LLE-WPA-BP 算法预测模型的误差值最小, 预测精准度最高。WPA-BP 算法预测模型、GA-BP 算法预测模型、BP 神经网络预测模型的预测精准度依次递减。从平均相对变动值来看, LLE-WPA-BP 算法预测模型的平均相对变动值最小, 其泛化效果最佳。虽然 WPA-BP 算法预测模型的平均绝对误差和平均相对误差仅次

于 LLE-WPA-BP 算法预测模型，但其平均相对变动值却增加了 65.89%，泛化能力大大减弱。LLE-WPA-BP 算法预测模型与没有经过数据降维计算的 WPA-BP 预测模型的泛化能力提高了近 66%效果。同样 BP 神经网络预测模型和 GA-BP 算法预测模型较 LLE-WPA-BP 算法预测模型的平均相对变动值均增加了 300%、100%左右，LLE-WPA-BP 算法预测模型的泛化能力提高了近 1-3 倍。

表 5.4 4 种模型数值模拟的实验结果

Table5.4 Experimental results of numerical simulation of four models

预测模型	平均绝对误差/ $\text{m}^3\cdot\text{t}^{-1}$	平均相对误差	平均相对变动值
BP	0.1884	0.0254	0.0772
GA-BP	0.1535	0.0213	0.0418
WPA-BP	0.1156	0.0222	0.0320
LLE-WPA-BP	0.0695	0.0093	0.0193

综上所述本文提出的基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型有较高的预测精度，泛化能力强，训练速度短等特性。通过对比实验和多次的自身实验模拟可知，利用局部线性嵌入式算法和狼群算法优化 BP 神经网络的方法在预测瓦斯涌出量方面十分可行。在弥补 BP 神经网络不足的同时提高了其预测性能。数据提取降维能力在应对大样本数据的预测工作时预测效果尤为突出。

5.5 本章小结

(1) 为验证基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型的优越性，提出其与 BP 神经网络预测模型、GA-BP 预测模型、WPA-BP 预测模型进行性能对比。将原始样本数据分别输入到 BP 神经网络预测模型、GA-BP 预测模型、WPA-BP 预测模型中，利用 Matlab 软件进行模拟实验；

(2) 将上述三组对比模型的平均绝对误差值、平均相对误差值、平均相对变动值、训练时长这 4 个方面数值模拟的实验结果与基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型进行对比分析，论证了本文所提预测模型的可行性、预测结果的精准性、泛化效果的优越性。

6 结论与展望

6.1 结论

矿井瓦斯涌出造成的灾害事故频发,使得作业人员的人身安全受到威胁,社会经济发展遭到严重损失。由于矿井瓦斯涌出事故影响因素的复杂性,传统方法在预测精准度等方面都存在不同程度的不足。为解决传统预测模型的部分缺点,本文利用局部线性嵌入式算法和狼群算法构成的智能组合算法来完善 BP 神经网络系统,建立了基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型。通过在 Matlab 软件上的模拟实验得出了该模型的预测性能。LLE-WPA-BP 预测模型具有较高的预测精确度、快速的收敛速度和寻优速度、较强的泛化性能和稳定性。本文对矿井瓦斯涌出量预测研究的主要结论如下:

(1) 构建了瓦斯涌出量预测模型指标体系

研究确定了矿井瓦斯涌出规律、影响因素,及预测指标选取的标准,将开采层原始瓦斯含量、煤层埋藏深度、煤层厚度、煤层倾角、开采高度、工作面长度、推进速度、采出率、邻近层原始瓦斯含量、邻近层厚度、邻近煤层层间距、层间岩性、开采强度、井下气压作为瓦斯涌出量的预测指标并构成瓦斯涌出量预测模型指标体系。对预测指标体系内的影响因素进行实际数据的采集,可得到预测模型的输入样本。

(2) 构建了瓦斯涌出量预测模型

根据 BP 神经网络的并行分布结构特征、非线性相关特征、自主学习及自我适应特征,选择其作为本文所用预测模型。为解决 BP 神经网络求最佳值困难、收敛速度慢、权值阈值随机产生等问题,使用智能算法对其进行优化。通过 Matlab 软件将狼群算法、粒子群算法、防碰撞算法对 8 个实验对象进行模拟训练,选出优化性能最好的狼群算法。选择降维算法对 BP 神经网络的高维输入值进行降维计算。由于输入样本间的存在非线性关系,因此选择适合处理非线性关系输入值的局部线性陷入法对其进行降维计算。

(3) LLE-WPA-BP 算法的瓦斯涌出量预测模型的数值模拟实验

在 Matlab 软件上设置基于 LLE-WPA-BP 算法的瓦斯涌出量预测模型的初始参数值。通过对比实验,从绝对误差、相对误差、训练时长、训练集回归拟合 R 值、全部数据回归拟合 R 值这 5 方面的数值模拟实验结果分析,选出影响预测精度的最佳 d 值,最佳 d 值为 8。将 $d=8$ 代入预测模型,利用 Matlab 软件进行模拟训练。通过训练出的重构矩阵得到重构因子。将重构因子归一化,取第 1 组到第 13 组作为训练组输入预测模型中。得到第 1 组到第 13 组的预测值、绝对误差、相对误差,用来验证本文建立的预测模型的可行性和优越性。最终得出第 14 组到第 18 组测试样本的预测数值。

(4) 多种预测模型的对比实验

在 Matlab 软件上输入马堡煤矿实际检测数据,利用 BP 神经网络预测模型、GA-BP 预

测模型、WPA-BP 预测模型进行瓦斯涌出量预测。通过三种预测模型得到的数值模拟实验结果与本文所提预测模型数值模拟实验结果进行对比，实验结果包括预测的瓦斯涌出量与马堡煤矿实际检测瓦斯涌出量之间的绝对误差值、相对误差值，训练时长，相对变动值等。论证本文所提预测模型有较高的预测精准度，泛化能力强，训练速度短等特性。

6.2 展望

鉴于矿井瓦斯涌出量的预测研究是多角度复杂的研究过程，仅仅凭借一种科研技术是没办法代表矿井瓦斯涌出量预测研究的。必须将多种新型科研技术结合在一起，互相取长补短才可以构建出高预测精准度的矿井瓦斯涌出量预测模型。由于本人在该领域的学术研究水平有限，在面对这项研究的出现多种问题的时候还存在研究不够彻底的情况发生。对本文研究工作的进一步完善内容有：

（1）本文在利用瓦斯涌出规律、影响因素、影响因素指标体系筛选标准、马堡煤矿实际情况以及参考多种文献的前提下，选择了对矿井瓦斯涌出量有较大影响的 14 个指标进行模拟实验、对比分析。影响因素方面考虑的还不够全面，没有覆盖一些次要影响的因素。再进一步研究时会更加重视矿井瓦斯涌出量影响因素的研究，使得预测出的数值模拟实验结果更具代表性；

（2）本文提出的预测模型是运用 Matlab 软件进行仿真模拟的，仅与本文所用的实际检测数据做了对比，并没有再次单独在实际矿井进行应用及验证，缺乏实际论证基础。再进一步研究时会设计一些硬件系统对前期的矿井瓦斯相关影响因素的数据进行收集。将实地情况所收集起来的数据输入到上位机中。上位机编程了本文所提出的预测算法。最后将数值模拟实验结果输进画面，进行同步的矿井瓦斯涌出量预测。

参考文献

- [1]戚宏亮.煤矿安全应急管理系统构建与评价研究[D].北京:中国矿业大学,2015.
- [2]郝玉琨.危险化学品生产企业安全审核重点解析[J].山东化工,2019,48(13):232-233.
- [3]李东印.科学采矿评价指标体系与量化评价方法[D].焦作:河南理工大学,2012.
- [4]马瑞孚.宁夏煤矿事故规律及防范对策研究[D].西安:西安科技大学,2018.
- [5]Daning Chen, Mengxin Zhang, Rong Ling. GUI of prediction of gas emission with artificial neural network[J].Journal of Physics: Conference Series,2021,1738(1):112-124.
- [6]Dunmore R. Prediction of gas emission from longwall faces[J].Mining Engineering,1981,140:565-572.
- [7]Lunarzewski L L W. Gas emission prediction and recovery in underground coal mines[J].International Journal of Coal Geology,1998,35(1-4):117-145.
- [8]Noack K. Control of gas emissions in underground coal mines[J].International Journal of Coal Geology,1998,35(1-4):57-82.
- [9]Patrick Booth, Heidi Brown, Jan Nemcik, Ren Ting. Spatial context in the calculation of gas emissions for underground coal mines[J].International Journal of Mining Science and Technology,2017,27(5):58-63.
- [10]Karacan C Ö, Olea R A, Goodman G. Geostatistical modeling of the gas emission zone and its in-place gas content for Pittsburgh seam mines using sequential gaussian simulation[J].International Journal of Coal Geology,2012,90:50-71.
- [11]Shepherd J. Outbursts and geological structures in coal mines[J].International Journal of Rock Mechanics and Mining Sciences,1981,18(4):267.
- [12]Bibler CJ, Marshall JS, Pilcher. Status of worldwide coal mine methane emissions and use RC[J].International Journal of Coal Geology.1998,23(35):283-310.
- [13]Airey E M. Gas emission from broken coal. An experimental and theoretical investigation[J].International Journal of Rock Mechanics & Mining Sciences & Geomechanics Abstracts,1968,5(6):475-494.
- [14]Bandyopadhyay P K, Banerjee B D, Ghosh A K. Studies on Gas Desorption from Coal[J].ResearchGate, 1974,12:299-303.
- [15]Wang N. Study on Visualization of Gas Geology information at tunneling face based on GIS[J].Coal Mine Modernization,2012 (1):75-77.
- [16]Javier Toraño, Susana Torno, Eliseo Alvarez, et al. Application of outburst risk indices in the underground coal mines by sublevel caving[J].International Journal of Rock Mechanics and Mining Sciences,2012,50(1):94-101.
- [17]Karacan C, Ozgen. Forecasting gob gas venthole production perform an cesusing intelligent computingmet hods for optimum methane control in long wall coal mines[J].Elsevier,2009,79(4):131-144.

- [18]Palchik,V. Use of Gaussian distribution for estimation of gob gas drainage well Productivity[J]. Mathematical Geology,2002,34:743-765.
- [19]Leszek(Les) W Lunarzewski. Gas emission prediction and recovery in underground coal mines[J].International Journal of Coal Geology,1998,35(1):117-145.
- [20]Dougherty H N, Karacan C. A new methane control and prediction software suite for long wall mines[J].Computers & Geosciences,2011,37(9):1490-1500.
- [21]Noack K. Control of gas emissions in underground coal mines[J].International Journal of Coal Geology,1998,35(1):57-82.
- [22]Padgett M L, Roppel T A. Neural networks and simulation: modeling for applications[J].Simulation,1992,58(5):295-304.
- [23]Junwei Yuan, Kai Wang, Xiaogai Jiang. Prediction of gas emission quantity based on least square support vector machine[J].Advanced Materials Research,2012,1:619-639.
- [24]薛鹏骞,吴立锋,李海军.基于小波神经网络的瓦斯涌出量预测研究[J].中国安全科学学报,2006(2):22-25.
- [25]Yumin Pan, Yonghong Deng, Quanzhu Zhang, et al. Dynamic prediction of gas emission based on wavelet neural network toolbox[J].Journal of Coal Science and Engineering (China),2013,19(2):174-181.
- [26]Wei Wang, Hanpeng Wang, Bing Zhang, et al. Process safety and environmental protection[J].Process Safety and Environmental Protection,2021,154:329-337.
- [27]Kangping Chen. A new mechanistic model for prediction of instantaneous coal outbursts-Dedicated to the memory of Prof. Daniel D. Joseph[J].International Journal of Coal Geology,2011,87(2):42-46.
- [28]Tianwei Lan, Chaojun Fan, Sheng Li, et al. Probabilistic prediction of mine dynamic disaster risk based on multiple factor pattern recognition[J].Advances in Civil Engineering,2018,7813931:1-6.
- [29]Guowei Dong, Xuanming Liang, Qixiang Wang, et al. A new method for predicting coal and gas outbursts[J].Shock and Vibration,2020,3:1-10.
- [30]Yingjie Li, Yongguo Yang, Bo Jiang. Prediction of coal and gas outbursts by a novel model based on multisource information fusion[J].Energy Exploration&Exploit,2010,38(5):1320-1348.
- [31]陈志雄.钻铤机器人静刚度分析与优化研究[D].成都:电子科技大学,2020.
- [32]齐翠玉.基于改进万有引力算法-KELM 的瓦斯涌出量预测方法研究[D].阜新:辽宁工程技术大学,2019.
- [33]郎咸民.基于瓦斯地质理论的矿井瓦斯含量与涌出量预测[J].煤炭技术,2016,35(10):210-211.
- [34]Yanqiu Chen, Linjiang Zheng, Jing Huang. Prediction of gas emission based on grey-generalized regression neural network[J].IOP Conference Series Earth and Environmental Science,2020,467(1):56-58.
- [35]黄凯波,朱权洁,张尔辉.基于灰色理论与 BP 神经网络瓦斯涌出量预测研究[J].华北科技学院学报,2020,17(2):16-22.

- [36]赵鲲鹏,丛伟,赵亮.基于尺度 UKF 小波网络的混沌时间序列预测[J].火力与指挥控制,2010,35(5):114-116.
- [37]付华,代巍.基于 LLE 与 BA-Elman 的瓦斯涌出量动态预测研究[J].传感技术学报,2016,29(9):1383-1388.
- [38]李俊哲,秦志,周鑫隆.限定记忆的 GM-RBF 瓦斯涌出预测模型[J].煤炭技术,2019,38(1):92-95.
- [39]林海飞,高帆,严敏,等,谢行俊.煤层瓦斯含量 PSO-BP 神经网络预测模型及其应用[J].中国安全科学学报,2020,30(9):80-87.
- [40]李心杰,贾进章.基于 PCA-GA-BP 的回采工作面瓦斯涌出量预测模型研究[J].世界科技研究与发展,2015,37(1):16-20.
- [41]肖鹏,谢行俊,双海清,等.基于 KPCA-CMGANN 算法的瓦斯涌出量预测研究[J].中国安全科学学报,2020,30(5):39-47.
- [42]郑晓亮,来文豪,薛生.MI 和 SVM 算法在煤与瓦斯突出预测中的应用[J].中国安全科学学报,2021,31(1):75-80.
- [43]苏筱丽.基于主成分降维的 SVM 回归模型在煤与瓦斯突出预测中的应用[J].工业计量,2020,30(1):74-77.
- [44]曹博,白刚,李辉.基于 PCA-GA-BP 神经网络的瓦斯含量预测分析[J].中国安全生产科学技术,2015,11(5):84-90.
- [45]王昱舒,吴世跃,李文明.特殊顶板下回采工作面瓦斯涌出量预测[J].煤炭技术,2017,36(4):189-191.
- [46]谢雨诗,何丽娜,徐文燕,等.基于 AFOA-BP 神经网络的燃气轮机研制风险预测[J].热能动力工程,2021,36(10):228-234.
- [47]刘浩然,赵翠香,李轩,等.一种基于改进遗传算法的神经网络优化算法研究[J].仪器仪表学报,2016,37(7):1573-1580.
- [48]陈祖云.煤与瓦斯突出前兆的非线性预测及支持向量机识别研究[D].北京:中国矿业大学,2009.
- [49]吕帅锋.煤层大型水力压裂导流通道特征及削减高阻体研究[D].武汉:中国地质大学,2019.
- [50]郭昕曜.高突矿井瓦斯风险评估方法与管控技术研究[D].武汉:武汉理工大学,2019.
- [51]李全生,李晓斌,许家林,等.岩层采动裂隙演化规律与生态治理技术研究进展[J].煤炭科学技术,2022,50(1):28-47.
- [52]朱红青,常文杰,张彬.回采工作面瓦斯涌出 BP 神经网络分源预测模型及应用[J].煤炭学报,2007,(5):504-508.
- [53]舒龙勇.煤与瓦斯突出的关键结构体致灾机理[D].北京:中国矿业大学,2019.
- [54]许满贵.煤矿动态综合安全评价模式及应用研究[D].西安,西安科技大学,2006.
- [55]Vinayagam Ramesh, Dave Niyam, Varadavenkatesan Thivaharan. Artificial neural network and statistical modelling of biosorptive removal of hexavalent chromium using macroalgal spent biomass[J].

Chemosphere,2022,296:47-52.

- [56]张宝,何健.基于 BP 神经网络的小断层构造区域瓦斯涌出预测方法研究[J].煤炭工程,2020,52(9):106-110.
- [57]Xiucan Guo, Zhiqi Ren, Qingsheng Wang. Prediction of gas emission by BP neural network based on wavelet analysis[J].IOP Conference Series:Earth and Environmental Science,2019,252(5):78-81.
- [58]李志生,张国强,刘建龙,等.基于 BP 神经网络的制冷机组故障检测与诊断[J].流体机械,2006(9):75-79.
- [59]Bowe Zhang, Simao Guo, Hui Jin. Production forecast analysis of BP neural network based on yimin lignite supercritical water gasification experiment results[J].Energy,2022,246:104-107.
- [60]牛江川,韩利涛,李素娟,等.基于 PSO-BP 神经网络的盾构刀具配置研究[J].机械工程学报,2018,54(10):167-172.
- [61]陈正,丁姝,王俊林.全国私人车辆拥有量的 BP 神经网络模型预测与分析-基于附加动量与自适应学习速率相结合的 BP 方法[J].西安财经学院学报,2015,28(6):98-102.
- [62]黄伟军,华猛,吴晨辉.基于改进 BP 神经网络的汽车尾气检测系统设计[J].传感器与微系统,2018,37(10):95-97.
- [63]王昱舒.基于 PCA-AKH-BP 神经网络的面域相结合的煤与瓦斯突出预测模型及其应用研究[D].太原:太原理工大学,2017.
- [64]马金城,石崇,张一平,等.基于改进狼群算法的边坡极限平衡稳定性分析方法研究[J].三峡大学学报,2022,44(2):50-55.
- [65]陈暄,孟凡光,吴吉义.求解大规模优化问题的改进狼群算法[J].系统工程理论与实践,2021,41(3):790-808.
- [66]李新春,赵忠婷,于洪仕.基于局部线性嵌入和梯度提升决策树的信道状态信息室内指纹定位算法研究[J].激光与光电子学进展,2022,59(2):400-410.
- [67]Xiaoyu Yang, Yufei Chen, Xiaodong Yue. Local linear embedding based interpolation neural network in pancreatic tumor segmentation[J].Applied Intelligence,2021,98:1-11.
- [68]Qingqiang Liu, Hongkai He, Yuanhong Liu. Local linear embedding algorithm of mutual neighborhood based on multi-information fusion metric[J].Measurement,2021,186:89-93.
- [69]邓星亮,吴清.LLE 算法及其应用[J].兵工自动化,2005(3):65-66.
- [70]隆能增,袁梅,敖选俊,等.基于 LLE-FOA-BP 模型的煤与瓦斯突出强度预测[J].工矿自动化,2019,45(10):68-73.
- [71]王辉,汪方跃,盛兆秋.LA-ICP-MS 分析中不同莫氏硬度矿物激光剥蚀行为及剥蚀速率研究[J].岩石矿物学杂志,2019,38(1):113-120.
- [72]张璐瑶,季伟东,程昊.基于 LLE 降维思想的自然计算方法[J].系统仿真学报,2020,32(10):1943-1955.
- [73]温廷新,孔祥博.基于 KPCA-GA-BP 的煤矿瓦斯爆炸风险模式识别[J].安全与环境学报,2021,21:19-26.

学位论文原创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的
研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含
其他人已经发表或撰写过的研究成果。其他同志对本研究所做的任何贡献均
已在论文中作了明确的说明并表示了谢意。

本人学位论文与资料若有不实，愿意承担一切的法律责任。

学位论文作者签名：_____

2022 年 6 月 10 日

学位论文数据集

关键词*	密 级*	中图分类号*	UDC	论文资助
瓦斯涌出量;BP神经网络;局部线性嵌入式算法;狼群算法;预测技术	公开	X936	622	国家自然科学基金项目, 52174183
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
辽宁工程技术大学	10147	工学	硕士	
论文题名*	并列题名*	论文语种*		
基于 LLE-WPA-BP 算法的瓦斯涌出量预测研究	Study of gas emission prediction based on LLE-WPA-BP algorithm	简体中文		
作者姓名*	姜杉杉	学 号*	471921030	
培养单位名称*	培养单位代码*	培养单位地址	邮 编	
辽宁工程技术大学	10147	辽宁省阜新市	123000	
学科专业*	研究方向*	学 制*	学位授予年*	
安全管理工程	安全信息工程	3	2022	
提交日期*				
导师姓名*	贾进章	职 称*	教授	
评阅人	答辩委员会主席*		答辩委员会成员	
电子版论文提交格式 文本 () 图像 () 视频 () 音频 () 多媒体 () 其他 ()				
推荐格式: application/msword; application/pdf				
电子版论文出版(发布)者	电子版论文出版(发布)地		权限声明	
论文总页数*		64		
注: 共 33 项, 其中带*为必填数据, 共 22 项。				