



全日制硕士学术论文

基于 SKPCA 与 NEAT 算法的煤与瓦斯突出 预测研究

Research on Prediction of Coal and Gas Outburst Based on SKPCA and NEAT Algorithm

作者姓名: 程业伟

导师姓名: 徐耀松 副教授

工程领域: 控制工程

研究方向: 智能控制与故障诊断技术

完成日期: 2021 年 6 月 20 日

辽宁工程技术大学
Liaoning Technical University

中图分类号 TP183

学校代码 10147

UDC 621.3

密 级 公 开

辽宁工程技术大学
全日制硕士学位论文

**基于 SKPCA 与 NEAT 算法的煤与瓦斯突出
预测研究**
**Research on Prediction of Coal and Gas Outburst
Based on SKPCA and NEAT Algorithm**

作者姓名 程业伟

学 号 471820303

导师姓名 徐耀松（副教授）

副导师姓名 张洪亮（高工）

申请学位 工程硕士

培养单位 电气与控制工程学院

学科专业 控制工程

研究方向 智能控制与故障诊断技术

二〇二一年六月

致谢

时光飞逝，三年的研究生学习生活已接近尾声，感激之心，时刻不能忘怀。在论文完成之际，谨向所有给予过我关心、指导、帮助及鼓励的老师、同学和朋友们致以衷心的感谢。

在这里，我首先要感谢我的导师徐耀松老师，本论文从选题、研究路线确定、研究方法选取到最后论文的一步步修改完稿，徐耀松导师一直都认真仔细的给予指导。没有徐老师专业的修改意见和悉心的指导我不可能顺利完成毕业论文的撰写。徐老师不仅学识渊博，而且教学工作中一丝不苟、平易近人，研究生期间徐老师在学习与生活上都给予无微不至的关怀。在此，谨向细心培育教导我的恩师致以最崇高的敬意和最衷心的感谢！

同时我也要感谢实验室的同学们，感谢他们在每一次学术交流会中毫无保留的分享自己的学习经验和研究成果，使我在学习上少走了许多弯路。感谢付华劳模创新工作室的所有同学对我的帮助和鼓励。

在本论文编写过程中，大量参考及引用国内外相关文献与专著，向有关学者、专家表示由衷的感谢。

最后，向百忙之中参与本论文评审以及参与答辩的各位老师表示衷心的感谢，并衷心地希望得到各位老师的指导！

摘要

煤矿的开采正持续向深部发展，相比与浅部井下环境更加恶劣，对煤与瓦斯突出预警提出了更高要求。本文从多方面进行瓦斯突出预测指标选取，提出新的突出预测指标体系，建立了基于 SKPCA 与 NEAT 算法的煤与瓦斯突出预测模型。

通过对煤与瓦斯突出机理和影响因素进行分析，从瓦斯因素、煤体因素、地质结构因素、地应力因素及其他因素共选取了 15 种能够反映突出信息的二级预测指标。针对各指标之间存在信息重叠和非线性问题，本文使用核主成分分析对突出数据进行处理。由于主成分数据是由所有原始数据进行线性组合得到，主成分可解释性差。本文引入稀疏化方法对核主成分进行稀疏化，将各主成分中不重要元素的载荷系数缩小到零，使每个主成分只保留各自关联原始指标中最主要元素，减少瓦斯突出数据中的噪声干扰，主成分信息更具代表性。对主成分进行贡献率计算后选取前 4 个主成分作为预测模型输入，减小了模型复杂度，能够提高泛化能力。

由于神经网络在进行煤与瓦斯突出预测时容易出现过拟合及局部最优解问题。本文引入增强拓扑神经进化算法 (NEAT)。NEAT 算法采用遗传进化算法的原理，不仅能够对神经网络的权值参数进行寻优，还能优化网络的连接拓扑结构。通过对神经网络连接进行编码，每个连接标记创新号，将创新号排列后作为个体的基因组。对个体基因进行变异、交叉等操作遗传到下一代，经过多代进化后找出最优的预测网络结构。优化后网络结构并非传统的全连接层，大大减少内部参数，避免出现过拟合现象。为了避免优化前期个体适应度差异较大，使网络不能在全局进行寻优，本文引入动态个体适应度参数缩小前期个体适应度差距。将煤与瓦斯突出预测数据分为训练集和测试集，搭建 SKPCA-NEAT 预测模型，输入数据进行训练和预测，将结果与 SKPCA-BP、PCA-NEAT、SKPCA-GA 及 SVM 预测结果进行对比，实验结果表明，SKPCA 相比于 PCA 在煤与瓦斯突出数据处理上效果更佳，NEAT 相比于传统 GA 能够更好的优化神经网络。SKPCA-NEAT 模型具有更好的预测准确度，模型泛化能力更强，能够为保障煤矿安全生产提供依据。

该论文有图 23 幅，表 12 个，参考文献 61 篇。

关键词：煤与瓦斯突出；核主成分分析；主成分稀疏化；NEAT 算法

Abstract

Coal mining continues to develop to the deep, compared with the shallow underground environment is worse, put forward higher requirements for coal and gas outburst warning. In this paper, the gas outburst prediction index is selected from many aspects, a new outburst prediction index system is put forward, and a coal and gas outburst prediction model based on SKPCA and NEat algorithm is established.

Through the analysis of outburst mechanism and influencing factors, 15 secondary prediction indexes which can reflect outburst information are selected from gas factor, coal factor, geological structure factor, in-situ stress factor and other factors. In view of the information overlapping and non-linear problems among the indicators, this paper uses kernel principal component analysis to process the outstanding data. Because the principal component data is obtained by linear combination of all the original data, the interpretability of principal component is poor. In this paper, the sparse method is introduced to sparse the kernel principal components. The load coefficient of the unimportant elements in each principal component is reduced to zero, so that each principal component only retains the most important element in the corresponding original index. Reduce noise interference in gas outburst data, and the principal component information is more representative. After calculating the contribution rate of principal components, the first four principal components are selected as the input of the prediction model, which reduces the complexity of the model and improves the generalization ability.

Overfitting and local optimal solution often appear when neural network is used to predict coal and gas outburst. This paper introduces a new neural network optimization algorithm. NEAT algorithm adopts the principle of genetic evolutionary algorithm, which can not only optimize the weight parameters of the neural network, but also optimize the connection topology of the network. By encoding the neural network connections, each connection is labeled with an innovation number, which is then arranged as an individual's genome. Mutation, crossover and other operations of individual genes are inherited to the next generation, and the optimal prediction network structure is found after multi-generation evolution. The optimized network structure is not the traditional full connection layer, and the internal parameters are greatly reduced to avoid the phenomenon of over-fitting. In order to avoid the large difference of individual fitness in the early stage of optimization, which makes the network unable to search for optimization globally, dynamic individual fitness parameters are introduced in this paper to reduce the gap of individual fitness in the early stage. Divide coal and gas outburst prediction

data into training set and test set, and build SKPCA-NEAT prediction model. Input data for training and prediction, and compare the results with the prediction results of SKPCA-BP, PCA-NEAT, SKPCA-GA and SVM models. The experimental results show that SKPCA is more effective in processing coal and gas outburst data than PCA. The SKPCA-NEAT model has better prediction accuracy and stronger model generalization ability.

The paper has 23 figures, 12 tables and 61 references.

Keywords: coal and gas outburst; kernel principal component analysis; principal component sparsity; neuro-evolution of augmenting topologies

目录

| | |
|--------------------------------|-----------|
| 摘要..... | I |
| 目录..... | IV |
| 图清单..... | VIII |
| 表清单..... | X |
| 变量注释表..... | XI |
| 1 绪论..... | 1 |
| 1.1 课题研究背景..... | 1 |
| 1.2 研究意义..... | 2 |
| 1.3 研究现状..... | 2 |
| 1.4 本文研究内容及论文结构..... | 7 |
| 2 煤与瓦斯突出机理及影响因素..... | 10 |
| 2.1 煤与瓦斯突出机理..... | 10 |
| 2.2 煤与瓦斯突出影响因素..... | 11 |
| 2.3 煤与瓦斯预测指标选取..... | 11 |
| 2.4 本章小结..... | 15 |
| 3 煤与瓦斯突出指数数据处理..... | 16 |
| 3.1 SKPCA 方法原理..... | 16 |
| 3.2 煤与瓦斯突出数据 SKPCA 方法处理..... | 21 |
| 3.3 本章小结..... | 22 |
| 4 煤与瓦斯突出 NEAT 预测算法..... | 23 |
| 4.2 NEAT 算法及改进..... | 23 |
| 4.2 NEAT 神经元优化..... | 23 |
| 4.2 NEAT 算法整体流程..... | 29 |
| 4.3 本章小结..... | 31 |
| 5 预测模型构建及实验结果分析..... | 32 |
| 5.1 矿井概况..... | 32 |
| 5.2 煤与瓦斯突出预测指标测定..... | 32 |
| 5.3 煤与瓦斯突出预测指标降维处理..... | 35 |
| 5.4 煤与瓦斯突出 NEAT 网络搭建及训练..... | 37 |

| | |
|----------------------|-----------|
| 5.5 模型预测结果及对比分析..... | 41 |
| 5.6 本章小结..... | 45 |
| 6 结论与展望..... | 46 |
| 6.1 结论..... | 46 |
| 6.2 展望..... | 46 |
| 参考文献..... | 48 |

Contents

| | |
|--|-------------|
| Abstract..... | II |
| Contents..... | VI |
| List of Figures..... | VIII |
| List of Tables..... | X |
| List of Variables..... | XI |
| 1 Introduction..... | 1 |
| 1.1 Project Research Background..... | 1 |
| 1.2 Research Significance..... | 2 |
| 1.3 Research Status..... | 2 |
| 1.4 Research Content and Structure of Thesis..... | 7 |
| 2 Mechanism and Influence Factors of Coal and Gas Outburst..... | 10 |
| 2.1 Coal and Gas Outburst Mechanism..... | 10 |
| 2.2 Coal and Gas Outburst Influence Factors..... | 11 |
| 2.3 Selection of Coal and Gas Outburst Prediction Indexes..... | 11 |
| 2.4 Chapter Summary..... | 15 |
| 3 SKPCA for Coal and Gas Outburst..... | 16 |
| 3.1 Sparse Kernel Principal Component Analysis..... | 16 |
| 3.2 Advantages of Sparse Kernel Principal Component Analysis..... | 21 |
| 3.3 Chapter Summary..... | 22 |
| 4 Coal and Gas Outburst NEAT Prediction Algorithm..... | 23 |
| 4.1 NEAT..... | 23 |
| 4.2 NEAT Network Neuron..... | 28 |
| 4.3 Overall Flow of NEAT..... | 29 |
| 4.4 Chapter Summary..... | 31 |
| 5 Forecast Model Performance and Experimental Results Analysis..... | 32 |
| 5.1 General Situation of Mine | 32 |
| 5.2 Coal and Gas Outburst Prediction Index Measurement | 32 |
| 5.3 Dimension Reduction of Coal and Gas Outburst Prediction Index..... | 35 |
| 5.4 Construction and Training of NEAT for Coal and Gas Outburst..... | 37 |
| 5.5 Model Prediction Results and Comparative Analysis..... | 41 |
| 5.6 Chapter Summary..... | 45 |

| | |
|--|-----------|
| 6 Conclusions and Prospect..... | 46 |
| 6.1 Conclusions..... | 46 |
| 6.2 Prospect..... | 46 |
| References..... | 48 |

图清单

| 图序号 | 图名称 | 页码 |
|------------|--|----|
| 图 1.1 | 研究路线图 | 9 |
| Figure 1.1 | Research roadmap | 9 |
| 图 2.1 | 煤与瓦斯突出预测指标 | 14 |
| Figure 2.1 | Coal and gas outburst prediction index | 14 |
| 图 3.1 | 稀疏核主成分分析流程图 | 20 |
| Figure 3.1 | Sparse kernel principal component analysis flowchart | 20 |
| 图 4.1 | NEAT 基因编码 | 24 |
| Figure 4.1 | NEAT gene coding | 24 |
| 图 4.2 | NEAT 算法的两种结构变异 | 24 |
| Figure 4.2 | Two structural variations of NEAT algorithm | 24 |
| 图 4.3 | NEAT 杂交操作 | 25 |
| Figure 4.3 | NEAT hybrid operation | 25 |
| 图 4.4 | 动态参数变化图 | 27 |
| Figure 4.4 | Dynamic Parameter Change Chart | 27 |
| 图 4.5 | 神经元结构 | 28 |
| Figure4.5 | Neuron structure | 28 |
| 图 4.6 | ELU 函数曲线 | 29 |
| Figure 4.6 | The ELU curve | 29 |
| 图 4.7 | NEAT 算法的整体流程图 | 30 |
| Figure4.7 | The overall flow chart of NEAT algorithm | 30 |
| 图 5.1 | 变容变压式测量仪器示意图 | 33 |
| Figure 5.1 | Schematic diagram of variable capacity and pressure measuring instrument | 33 |
| 图 5.2 | 声发射检测仪 | 34 |
| Figure 5.2 | Acoustic emission detector | 34 |
| 图 5.3 | 电磁辐射监测仪 | 35 |
| Figure 5.3 | Electromagnetic radiation monitor | 35 |
| 图 5.4 | 种群中个体分布图 | 39 |
| Figure 5.4 | Distribution map of individuals in the population | 39 |
| 图 5.5 | 优化后神经网络网络结构图 | 40 |
| Figure 5.5 | Optimized neural network network structure diagram | 40 |
| 图 5.6 | 种群适应度进化曲线 | 40 |
| Figure 5.6 | Evolutionary curve of population fitness | 40 |
| 图 5.7 | SKPCA-NEAT 模型危险指数预测结果图 | 41 |
| Figure 5.7 | SKPCA-NEAT model risk index prediction result graph | 41 |
| 图 5.8 | SKPCA-BP 模型危险指数预测结果图 | 42 |
| Figure 5.8 | SKPCA-BP model risk index prediction result graph | 42 |
| 图 5.9 | PCA-NEAT 模型危险指数预测结果图 | 42 |
| Figure 5.9 | PCA-NEAT model risk index prediction result graph | 42 |

| | | |
|-------------|--|----|
| 图 5.10 | SKPCA-GA 模型危险指数预测结果图 | 43 |
| Figure 5.10 | SKPCA-GA model risk index prediction result graph | 43 |
| 图 5.11 | 四种模型 RMSE 误差变化图 | 43 |
| Figure 5.11 | RMSE changes of four models | 43 |
| 图 5.12 | 各模型训练和测试时错误率对比图 | 44 |
| Figure 5.12 | Comparison of error rate of each model training and test | 44 |

表清单

| | | |
|-----------|---|----|
| 表 1.1 | 2013-2018 年我国重大瓦斯事故统计 | 1 |
| Table 1.1 | Major gas accidents in China from 2013 to 2018 | 1 |
| 表 1.2 | 突出危险性指标临界值 | 4 |
| Table 1.2 | The critical value of outburst danger | 4 |
| 表 1.3 | D、K 综合指标临界值 | 4 |
| Table 1.3 | D、K critical value of outburst danger | 4 |
| 表 1.4 | 钻屑指标通用临界值 | 5 |
| Table 1.4 | Drill cuttings index general threshold | 5 |
| 表 3.1 | 不同数据处理方法误差对比 | 21 |
| Table 3.1 | Error comparison of different data processing methods | 21 |
| 表 5.1 | 各煤层具体情况 | 32 |
| Table 5.1 | Specific coal seams | 32 |
| 表 5.2 | 煤层各参数测定值 | 33 |
| Table 5.2 | Measurement of parameters of coal seam | 33 |
| 表 5.3 | 部分原始数据 | 35 |
| Table 5.3 | Part of the original data | 35 |
| 表 5.4 | 前 5 项主成分贡献率 | 36 |
| Table 5.4 | Contribution rate of the top 5 principal components | 36 |
| 表 5.5 | 主成分数据 | 37 |
| Table 5.5 | Principal component data | 37 |
| 表 5.6 | 网络参数设定 | 38 |
| Table 5.6 | Network parameter setting | 38 |
| 表 5.7 | 支持向量机模型预测结果对比 | 45 |
| Table 5.7 | SVM model prediction results comparison chart | 45 |

变量注释表

| | |
|-------------|------------------|
| S_{max} | 每米钻孔钻屑量的最大值 |
| Q_{max} | 每米钻孔瓦斯放散初速度的最大值 |
| $D、K$ | 预测综合指标 |
| H | 煤层垂深 |
| P | 煤层瓦斯压力 |
| F | 煤岩体平均坚固性系数 |
| Δp | 煤层的瓦斯放散初速度数值 |
| λ | 特征值 |
| v | 特征向量 |
| K | 核函数 |
| δ | 差异距离 |
| D | 脱落基因个数 |
| E | 过量基因个数 |
| \bar{W} | 两个体之间神经网络权值的平均差值 |
| N | 两个体中基因数较大个体的基因个数 |
| f'_i | 个体调整后适应度 |
| f_i | 调整前适应度 |
| n | 每一代种群的所有个体 |
| λ^m | 个体适应度函数动态参数 |

1 绪论

1.1 课题研究背景

煤炭是我国的主要能源之一，大量的工厂都需要煤炭作为主要能源，我国每年煤炭的产量约为世界的 38%，占有我国的能源消费总量的 60%以上^[1-4]。由于我国煤炭资源的有限，为了满足需求，煤炭的开采正持续向深部发展，平均开采深度已达 700 米，地质环境越来越恶劣，这大大增加了发生煤矿安全事故的风险。

我国一直都十分重视煤矿生产安全，煤矿安全防范措施不断提高，安全事故也有持续减少的趋势，但瓦斯突出事故仍常有发生，其中还包括一些重大煤矿安全事故^[5-6]。2017 年 1 月 4 日，河南省登封市兴峪煤矿发生重大瓦斯突出事故，造成 12 人死亡；2021 年 4 月 9 日贵州东风煤矿由于防突措施不到位发生瓦斯突出事故造成 8 人死亡。煤与瓦斯突出是煤矿事故中死亡人数最多、破坏力最大的灾害之一，据煤矿事故统计，2013-2018 年我国发生的重大瓦斯事故 87 起，具体情况如下表 1.1^[7-8]，可以看出瓦斯事故总体上持续减小，但是死亡人数仍然很多，对煤矿安全事故的防治与预警还需进一步加强。

表 1.1 2013-2018 年我国重大瓦斯事故统计
Table 1.1 Statistics of major gas accidents in China from 2013 to 2018

| 年份 | 2013 | 2014 | 2015 | 2016 | 2017 | 2018 |
|------|------|------|------|------|------|------|
| 事故数量 | 25 | 20 | 15 | 14 | 13 | 11 |
| 死亡人数 | 285 | 166 | 101 | 179 | 78 | 65 |

目前，我国许多煤矿已经进入深部开采，矿井地质条件更加复杂，采掘活动改变煤体应力相对平衡状态，煤体在采动应力、地应力和瓦斯综合作用下发生动态调整，控制煤岩动力灾害发生的煤岩体物性条件、应力环境、瓦斯赋存条件等因素发生很大变化，煤与瓦斯突出、冲击地压等动力灾害相互影响、相互诱导、相互强化、耦合致灾^[9]，成为长期制约煤炭安全高效开采的重要隐患。这种高动静载荷条件下煤岩介质变形破坏，煤岩层裂与瓦斯解吸膨胀相互耦合作用下含瓦斯煤岩变形系统动力失稳并释放能量的过程^[10]，简称复合动力灾害。高应力含瓦斯煤岩复合动力灾害成为深部矿井动力灾害的重要形式，对深部开采构成严重威胁^[11]。因此，深部矿井下煤矿的安全开采对煤与瓦斯突出预警提出了更高的要求。

深部煤与瓦斯突出复合动力灾害的发生原因、机理等较单一动力灾害更为复杂^[12]。与浅部开采相比煤岩体承受更为复杂的应力和能量的影响，原岩应力增大，瓦斯压力增加，煤层强吸附、低渗透的特征越来越明显，高地应力、高瓦斯压力、低渗透的耦合效应在采矿扰动的影响下更强^[13-14]。使用传统的单个或几个预测指标很难准确的预防突出事故发生。因此，近年来许多学者提出将机器学习算法技术应用到瓦斯突出预测中，如 SVM 和 BP

神经网络等，结合多指标数据进行突出预警。随着煤与瓦斯突出预测难度的增大，突出预防任务更加艰巨，如何有效的预警煤与瓦斯突出，已经成为煤矿安全生产工作的重点也是难点。

1.2 研究意义

煤与瓦斯突出发生过程中大量煤体与瓦斯会高速向外喷出，威胁着煤矿工作者的安全。因此，准确的预警瓦斯突出事故对煤矿生产十分重要，关于煤与瓦斯突出的研究具有重大的意义。

随着开采环境的越来越恶劣，煤与瓦斯突出预测复杂度也越来越高。为了准确的预测突出，需要对煤与瓦斯突出机理与影响因素进行深入研究，掘进工作、地质活动、煤体内部瓦斯等的变化都会影响煤与瓦斯突出。在众多因素中选择出能够反映突出信息的参数指标至关重要。

针对煤与瓦斯突出影响因素的复杂，需要搭建更加科学有效的预测模型。随着技术的进步，机器学习等方法被广泛的应用于各种领域，取得了不错的成果。如何将机器学习算法应用到煤与瓦斯突出预测中以提高预测的准确度需要进行大量的实验研究。

1.3 研究现状

煤与瓦斯突出是煤矿开采工作中长期存在的一种自然灾害，能否保证安全开采关乎煤矿工作人员的生命安全，是每一位煤矿从事人员重点关注的问题。研究学者们也提出了大量瓦斯突出预警的方案，主要可分为动态预测方法、静态预测方法和机器学习算法预测。

1.3.1 动态预测方法

煤岩体的内部结构变化是一个动态持续的过程，在此过程中会产生电磁辐射、声发射等现象。通过对相应信号进行不间断监测，从信号中分析出有用信息能够预警煤与瓦斯突出。动态预测方法主要有以下几种。

(1) 声发射技术

声发射是指不同材料在受到力的作用后，内部快速破裂释放能量并产生瞬态弹性应力波的现象^[15]。煤岩体破裂声发射信号变化可分为三个阶段。煤岩体破裂初期，声发射信号的特征参数均处于较低水平，煤岩体内发生微小的、均匀的且较为平缓的破裂，能量的聚集偶尔会出现单个较大的岩体破裂；煤岩体破裂中期，开始集中产生破裂现象，随着能量的聚集，岩体内大裂纹也频繁出现；破裂后期，煤岩体开始出现变形，内部加速破裂，整体结构稳定性直线下降，最终失稳突出。通过对声发射波形进行分析能够对瓦斯突出做出预警。

20 世纪 70 年代，前苏联学者就对煤岩体声发射信号进行分析，将其应用在瓦斯突出

的预警中；20 世纪 80 年代，澳大利亚学者利用双声道的声发射方法进行瓦斯突出预警。世界上许多国家也都对声发射技术应用与煤与瓦斯突出进行了大量研究。我国在这方面也取得了研究成果，邹银辉^[16]利用煤岩损伤理论，分析煤体声发射变化情况；夏善奎^[17]通过对声电信号进行时频特性的研究得出声发射信号的能量值、计数和质心频率可以作为煤与瓦斯突出预测的前兆信息。

（2）微震监测技术

当煤岩体内部破裂更加剧烈后，发出能量更大的声发射信号就称为微震。20 世纪 70 年代，美国研究局特就通过微震技术对煤岩体进行分析，使用低频微震判断瓦斯突出可能性区域，使用高频微震推算出大概时间。煤岩体破裂或微震时，震源处产生声波和震动波，当频率和能量过高时就会发生煤与瓦斯突出现象，瓦斯突出一般由多次断裂引起，异常的微震多发生在煤岩体断裂前 4~45 分钟，因此微震监测技术能够有效预警煤与瓦斯突出。

（3）电磁辐射技术

将电磁辐射技术应用于煤岩体的动态检测方面起步较晚。俄罗斯学者通过大量研究发现煤与瓦斯突出过程中，电磁辐射信号会产生变化；国内学者何学秋等^[18]通过实验研究得出，煤岩体在破裂过程中会产生电磁辐射信号，煤岩体内部的孔隙和瓦斯气体都会对电磁辐射产生影响。

（4）煤层稀有气体浓度变化

煤层中氦气和氢气浓度的变化能够用以预测煤与瓦斯突出。前苏联学者通过对煤矿突出煤层和未突出煤层中所含气体进行研究，发现发生瓦斯突出时，周围涌出气体中氦气和氢气的浓度会急剧升高，这些气体暗示着瓦斯突出的危险性增加。因此通过对氦气和氢气浓度进行监测，利用气体浓度的变化能够预警煤与瓦斯突出。

（5）物探法

物探法全称为无线电波透视探测技术。通过对煤与瓦斯突出附近的地质进行勘探，发现在突出高频发生的区域，其地质结构更加复杂。利用无线电波透视探测技术能够检测出地质具有的不同特征，从而预测煤与瓦斯突出危险性。

1.3.2 静态预测方法

静态预测方法是通过找出与煤与瓦斯突出相关的影响因素，分析这些因素与突出的数据联系，将某些影响因素作为突出预测指标，设定临界值，监测指标数据，根据是否超过设定临界值来判断煤与瓦斯突出的可能性。

（1）R 指标法：该方法指标结合了煤层的最大钻屑量和瓦斯放散初速度进行综合判断^[19]。R 指标越大表示煤与瓦斯突出的可能性越大。

R 指标的计算公式如式（1.1）：

$$R = (S_{\max} - 1.8)(q_{\max} - 4) \quad (1.1)$$

式中: S_{\max} 每一米的最大钻屑量;

q_{\max} 每一米瓦斯放散初速度的最大值。

(2) 单项指标法

影响煤与瓦斯突出的因素主要有煤层物理性质、地应力、瓦斯参数等,该方法通过设定各突出因素的临界值,如果测量值大于临界值则该煤层就有大概率会发生煤与瓦斯突出。我国学者结合各指标的联系提出使用多种指标临界值预测突出^[20-21]。指标临界值可根据实际煤层突出数据分析得出,常用的突出危险性指标临界值如表 1.2 所示:

表 1.2 突出危险性指标临界值
Table1.2 The critical value of outburst danger

| 突出危险性 | 破坏类型 | 煤层瓦斯压力 P/MPa | 瓦斯放散初速度 $\Delta P/\text{mmHg}$ | 坚固系数 f |
|-------|----------|-----------------|-----------------------------------|------------|
| 有 | III IV V | ≥ 0.74 | ≥ 10 | < 0.5 |
| 无 | I II | < 0.74 | < 10 | ≥ 0.5 |

(3) D、K 综合指标法: 由我国煤炭科学研究总院学者研究得出,通过对不同状态煤矿突出进行分析总结,已经成功预测了多起煤与瓦斯突出强度^[22-23]。该方法已经写入到我国煤矿防突细则中,被广泛应用于煤矿安全生产中。

D、K 综合指标计算方法如公式 (1.2) 与公式 (1.3) 所示:

$$D = \left(\frac{0.0075H}{f} - 3 \right) (p - 0.74) \quad (1.2)$$

$$K = \frac{\Delta P}{f} \quad (1.3)$$

式中: D 和 K 为预测综合指标;

H 为煤层垂深;

P 为煤层瓦斯压力;

f 为煤岩体平均坚固性系数;

Δp 为煤层的瓦斯放散初速度数值。

根据公式计算出 D、K 综合指标,不同煤矿可根据煤矿历史数据计算得出针对性的 D、K 综合指标突出临界值。在《防止煤与瓦斯突出细则》中指标临界值如表 1.3 所示^[24]:

表 1.3 D、K 综合指标临界值
Table1.3 D、K critical value of outburst danger

| D | K | 突出危险性 |
|-------------|--------|-------|
| < 0.25 | / | 无 |
| ≥ 0.25 | < 15 | 无 |

≥ 0.25

≥ 15

有

(4) 钻孔瓦斯涌出初速度法

通过对开采面实施钻孔,煤体中瓦斯通过钻孔向外涌出,对于不同破坏程度的煤体,由于结构和赋存瓦斯含量的不同,瓦斯涌出速度也不同,通过测量瓦斯涌出速度能够一定程度反映煤体破坏情况。该方法较为简单,只能初步的判断煤与瓦斯突出可能性。

(5) 钻屑指标法

钻屑法通过在开采煤层上方进行钻孔,对钻孔过程中掉落的钻屑量和钻屑中包含瓦斯含量进行计算。利用最大钻屑量和钻屑瓦斯解吸指标能够判断突出可能性。设定煤矿钻屑指标的临界值,测量值越大突出危险性越大。

钻屑指标通用临界值如表 1.4:

表 1.4 钻屑指标通用临界值
Table 1.4 Drill cuttings index general threshold

| 钻屑质量 (kg/m) | 钻屑体积 (L/m) | 释放瓦斯能量 | 突出可能性 |
|-------------|------------|--------|-------|
| >6 | >5.4 | >20 | 不易 |
| <6 | <5.4 | <20 | 容易 |

1.3.3 基于机器学习算法预测

由于煤与瓦斯突出机理的复杂,煤矿安全研究者们都认同瓦斯突出受多方面因素影响,且各因素之间存在非线性的关系。近年来,大量学者将机器学习分类算法应用于煤与瓦斯突出预测,结合多种指标输入预测模型,机器学习模型能够找出多指标数据中的隐含信息,准确预测煤与瓦斯突出。

(1) 支持向量机算法

20 世纪 90 年代支持向量机算法 (SVM) 被提出^[25],支持向量机通过找到最优超平面将数据分离,各类别中距离超平面最近的数据被称为支持向量。对于非线性数据 SVM 算法通过利用核函数代替数据高维映射后的内积计算,减少数据映射到高维空间后的复杂计算,提高了模型分类能力,支持向量机因此被广泛应用于数据分类中。

杨荣明等将支持向量机方法应用于煤与瓦斯的突出预测中^[26],通过实验得出使用支持向量机进行突出预测有较好的精度提升。郑丽媛^[27]等提出使用粒子群优化算法 (PSO) 对支持向量机参数进行优化,利用该模型进行危险等级预测,大大提高了预测精度。吴雅琴^[28]等先使用灰色关联分析法提取出煤与瓦斯突出主控因素,然后运用 IPSO 方法优化粒子群算法 (PSO) 的早熟收敛性,再使用 Powell 算法优化 SVM 的参数,得到 SVM 最优参数进

行煤与瓦斯突出预测。

（2）模糊理论方法

煤与瓦斯突出受多方面因素影响，突出数据监测比较困难，相关实测数据量较少，且具有较多噪声。对于煤与瓦斯危险性等级划分也没有具体的界线，模糊性较大，因此大量学者将模糊理论应用于突出预测中。

孙艳玲^[29]等使用模糊聚类分析法对数据进行分析，将煤与瓦斯突出等级分为几种模糊模式，计算样本数据与不同等级模糊模式的关联性，有效提高了突出预测准确度。朱志浩^[30]等提出使用模糊数学方法对突出数据进行聚类，根据突出危险性建立标准模式库，对测试数据使用模式识别方法进行预测。

（3）神经网络模型

神经网络是一种模拟人脑神经网络连接的技术，通过搭建神经元之间的网络连接。如今神经网络模型已经由单层感知器向多层感知器神经网络快速发展，提高网络复杂度对数据分析处理效果更好。由于神经网络在数据分类预测上的突出表现，被广泛的运用于各种领域。各大学者通过对神经网络的研究也提出了许多神经网络的优化模型。

曲方^[31]等使用 BP 神经网络搭建了煤与瓦斯突出的预测模型，输入突出数据进行训练后，对突出危险性进行预测，实验结果该模型的预测精度高；朱志浩、张宏伟等^[32]提出使用主成分分析法（PCA）处理煤与瓦斯突出数据得到主成分，然后再输入 BP 神经网络进行突出强度预测；付华^[33]等提出使用神经网络的优化模型极限学习机（ELM）搭建瓦斯突出预测模型，利用粒子群算法优化 ELM，该方法能够提升煤与瓦斯突出强度预测的收敛速度和准确度。

综上所述，经过煤矿安全研究者的努力提出了众多煤与瓦斯突出预测方法，很多方法已经被应用于实际突出的预警中取得了不错的成效。但随着煤矿开采向更深部发展，煤体结构、地应力、瓦斯等因素相比与浅层有较大差别，现有使用单一或几项影响因素预测煤与瓦斯突出的方法已经不能够满足预测准确度要求^[34-35]。

煤矿开采及监测设备也不断发展，应用于瓦斯突出预警的指标也越来越多。目前基于煤与瓦斯突出、冲击地压等动力灾害前兆信号的灾害研究方法至少有数十种，如应力变化、煤体结构变化、瓦斯涌出量、电磁辐射等，但是煤矿复合动力灾害环境影响因素及关系复杂，检测到的各种前兆信号、煤岩体结构、地应力、瓦斯变化等都可能与导致瓦斯突出的机制有关，各种监测指标之间存在相互耦合与影响。如何有效的从获得的各种预警指标参数中发掘出的瓦斯突出信息，对提高瓦斯突出预测精度十分重要。瓦斯突出各指标之间存在着较大的相关性和非线性，需要对原始数据进行处理提取出其中的有效信息。因此，本文采用稀疏核主成分分析方法（SKPCA）对数据进行处理，针对煤与瓦斯突出预警指标之间具有的非线性问题，使用非线性核函数对原始数据进行高维映射处理，再进行主成分降

维，解决数据的非线性问题；由于各主成分由所有原始指标线性组合获得，对煤矿数据进行处理后各主成分中存在许多较小的载荷系数，主成分不具有代表性，提出使用稀疏化方法对主成分数据载荷系数进行稀疏化，将构成各主成分中相应系数较小指标系数降为零，减少各主成分关联的原始指标个数。

神经网络模型作为一种高效的机器学习算法，能够一定程度上解决煤与瓦斯突出数据的复杂与非线性问题。但 BP 神经网络在对煤与瓦斯突出数据进行训练时存在过拟合及局部最优解的问题，神经网络优化算法一般都只优化神经网络权值，不能优化网络的结构，满足不了煤矿深部开采下的预警要求，深部矿井环境更加复杂对煤与瓦斯突出预警提出了更高的要求。本文提出使用增强拓扑神经进化模型（NEAT）进行预测，NEAT 算法利用遗传进化算法的原理，能够同时对神经网络的权值参数和网络连接结构进行训练，提高对煤与瓦斯突出的预警能力。

1.4 本文研究内容及论文结构

1.4.1 研究内容

本文对煤与瓦斯突出机理及突出影响因素进行了深入研究，综合选取能够反映瓦斯突出信息的参数指标，在此基础上提出基于稀疏核主成分分析与增强拓扑神经进化预测模型。对煤与瓦斯突出数据进行稀疏核主成分分析，将主成分数据输入 NEAT 网络进行预测，与其他模型预测结果进行对比验证模型的可靠性。

主要研究内容包括：

（1）总结煤与瓦斯突出的机理假说，分析瓦斯突出的主要影响因素，在此基础上确定瓦斯突出预测参数，使用多指标进行瓦斯突出预测。

（2）提出核主成分分析对监测的多指标数据进行主成分分析，然后使用稀疏化方法对主成分进行稀疏化，使每个主成分只保留各自关联原始数据中最主要指标信息，计算主成分贡献率，根据贡献率选取出主成分预测指标。

（3）引入增强拓扑神经进化算法进行煤与瓦斯突出预测，该算法利用遗传进化算法原理通过对网络连接进行基因编码，对神经网络参数及连接结构进行优化，改进动态适应度函数，提高网络寻优能力最终获得最佳神经网络结构。

（4）构建 SKPCA-NEAT 预测模型，输入数据训练模型后进行预测与其他模型预测效果进行对比。

1.4.2 论文结构安排

本文章节分为六章各章节安排如下：

第一章：绪论，概述煤与瓦斯突出的研究背景与研究意义，详细介绍煤与瓦斯突出预

警方法研究的国内外现状。

第二章：研究煤与瓦斯突出机理，对几种主流的突出机理假说进行介绍，总结了瓦斯突出的主要影响因素。由此建立煤与瓦斯突出的 15 个预测指标。

第三章：介绍核主成分分析原理，阐述了核主成分分析的具体步骤，介绍主成分的稀疏化方法，综合核主成分与稀疏化方法建立稀疏核主成分分析方法，介绍具体数据处理步骤。针对瓦斯突出数据指标的信息重叠和非线性问题，使用稀疏核主成分进行处理。

第四章：详细阐述增强拓扑神经进化算法优化神经网络结构的原理，使用生物遗传进化原理对神经网络参数和结构同时进行优化寻优，使用动态适应度函数使种群在全局开始优化，对 NAEAT 算法神经元结构进行优化。

第五章：搭建稀疏核主成分分析及增强拓扑神经进化算法的煤与瓦斯突出预测模型，将煤矿突出预测数据使用 SKPCA 方法处理后输入模型训练，将预测结果与其他模型进行对比。

第六章：对论文整体研究内容及实验结果进行总结，展望进一步研究方向。

本文研究具体路线如图 1.1 所示：

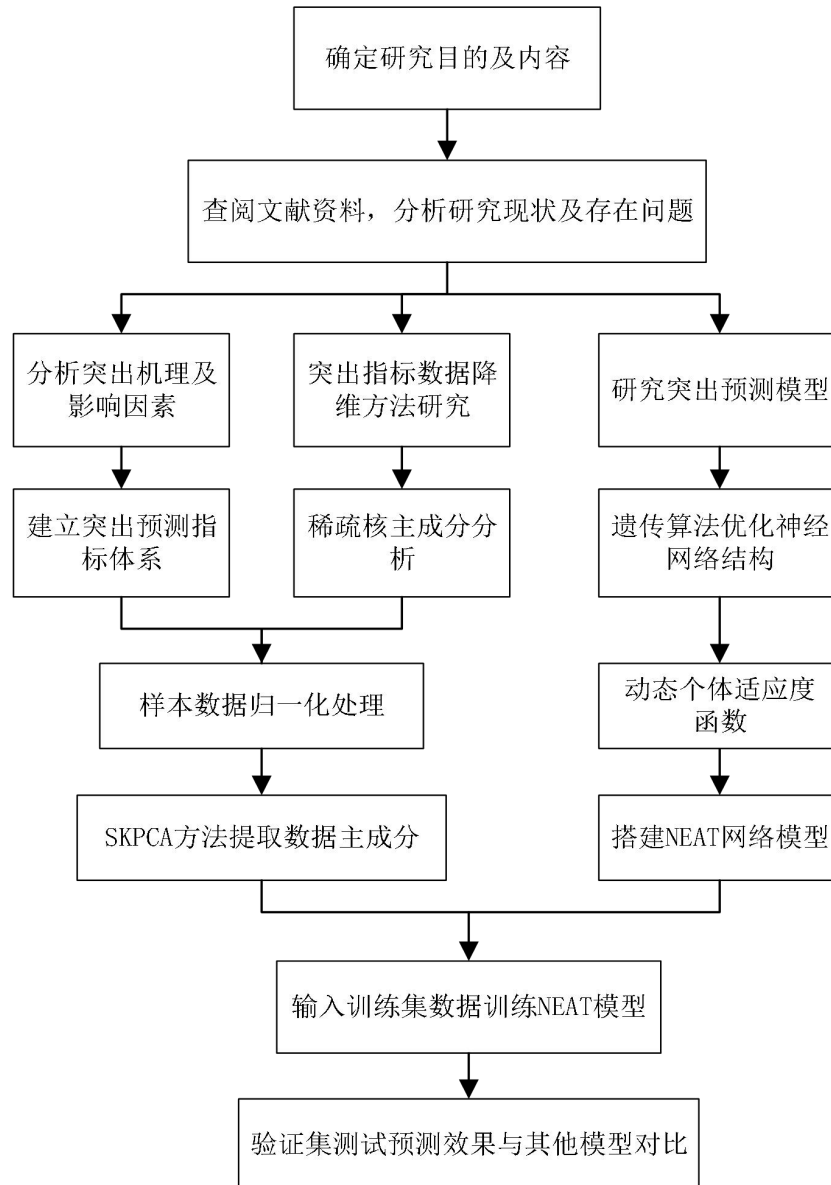


图 1.1 研究路线图
Figure1.1 Research roadmap

2 煤与瓦斯突出机理及影响因素

煤与瓦斯突出是一种极其复杂的灾害，瓦斯突出事故的发生存在较大的不确定性。为了提高瓦斯突出预测准确度，就需要对煤与瓦斯突出机理进行深入研究，分析瓦斯突出各方面影响因素，从而建立多指标预测体系，对各指标进行数据监测。

2.1 煤与瓦斯突出机理

至今关于煤与瓦斯突出机理还没有一个统一的认识。国内外学者通过对突出案例分析及实验研究后提出了一些突出机理假说，其中主流的假说有以下几种。

（1）地应力作用假说

该假说认为煤与瓦斯突出事故中地应力起主导作用^[36]，矿山频繁的地质活动会改变内部地质构造，使煤岩体内部应力发生变化。采掘工作不断推进时，周围煤岩体受采动应力影响后会发生变化重新分布寻找稳定点，当煤岩体不能够承受地质构造应力与采动应力的相互作用时，煤岩体破裂使得煤与瓦斯向外喷出，造成巨大灾害。

（2）瓦斯作用假说

该假说认为煤层由于空隙较少，透气性差使得内部瓦斯大量聚集，瓦斯不能向外扩散压力过高，同时对煤岩体产生强大的压力。其中“瓦斯包说”^[37]认为在煤岩体内部存在一个比周围煤体瓦斯含量高出许多的区域，在外部采掘活动的一同作用下，煤岩体产生裂隙后破裂，大量煤体伴随着瓦斯高速喷出。

（3）化学本质假说

该假说认为受开采环境的作用，煤体内部瓦斯与附近煤体等物质发生反应，产生不稳定化合物，包括像二氧化碳甲烷等气体^[38]，大量不稳定气体引发爆炸产生大量能量，造成煤与瓦斯高速向外喷出，发生严重的突出灾害。

（4）综合作用假说

综合假说认为，瓦斯突出灾害受多种因素相互影响。煤体受外部应力作用，同时由于煤岩体内部结构较差，聚集大量瓦斯，自身强度不能够支撑外部压力而发生煤与瓦斯突出^[39]。该假说综合考虑煤岩体内多种因素的影响，受到了煤矿安全领域许多研究者的认可。除此在外还包括“能量假说”、“振动说”等^[40-41]。

综上所述，这些假说在一定的程度都具有合理性，但对于不同的煤与瓦斯突出事故，各种假说都没有办法合理的解释每一次突出事故发生的原因。瓦斯突出机理一直没有统一，还是停留在假说，仍需要进一步的研究。但是众多学者们提出的突出理论为煤与瓦斯突出预警的研究提供了理论支持，为突出预测指标的选取提供了方向。

2.2 煤与瓦斯突出影响因素

通过上述煤与瓦斯突出机理的分析可以看出突出不只受单一因素的影响，影响煤与瓦斯突出的因素众多。为了提高煤与瓦斯突出的预测准确度，必须对突出影响因素进行分析，从而选取突出预测指标。通过查阅大量文献得出，影响煤与瓦斯突出因素主要有以下几个方向。

（1）地质构造

对于地质活动频发的地段，由于地质运动的不规律，会造成地质构造的变化，煤岩体也随之处于不稳定状态。密封性较好的地质构造，煤层中的瓦斯不易泄露，瓦斯不断聚集后含量升高；对于结构松散、排气性好的地质构造，瓦斯容易向外泄露，瓦斯含量低使得发生突出事故的可能性较低^[42]。

（2）地应力

在地应力的作用下，会产生许多的地质灾害。煤层的地应力过大，会不断挤压煤体使煤体更加紧密，煤层内部孔隙也不断缩小，瓦斯难以向外流散压力不断升高。煤层内部地应力的不平衡也会破坏煤体结构，成为了煤与瓦斯突出的动力。较高的地应力是煤与瓦斯突出的主要因素之一^[43]。

（3）煤体结构及物理学性质

频繁的地质活动会改变煤体的结构，影响煤岩体的自身强度。大量的煤与瓦斯突出事故都发生在地质构造带及煤层的软分层附近，煤岩体受到了严重的破坏，处于软分层煤岩体质地较松软，更易被地应力所破坏。物理学性质指煤体对瓦斯的吸附和解吸的能力，吸附能力强的煤体，其内部的孔隙能够吸附更多瓦斯；而煤体解吸能力弱时，瓦斯不能够从煤体中解吸，煤体内部储存了大量的瓦斯，容易发生煤与瓦斯突出事故^[44-45]。

（4）瓦斯状态

当发生煤与瓦斯突出时，煤体结构发生变化，大量的瓦斯会从煤体中解吸为游离态，在这一过程，瓦斯的内能将转换为膨胀能，巨大的能量会使煤体与瓦斯向外高速喷出^[46-47]。煤体的孔隙越多，吸附能量越强，发生突出事故时涌出的瓦斯量就越多，因此煤体内瓦斯赋存状态是影响煤与瓦斯突出的主要因素之一。

2.3 煤与瓦斯预测指标选取

目前瓦斯突出的机理尚不明确，深部矿井开采环境更加复杂，因此为了使预测模型有更好的预测效果，需要从各方面使用多种指标进行突出预测。选取能够反映出煤与瓦斯突出信息的指标对最终预测的准确度起决定性作用。通过对煤与瓦斯突出影响因素分析后，从瓦斯因素、煤体因素、地质因素、地应力因素及其他因素多方面进行二级指标选取。

（1）地质因素

地质因素方面可选取的指标有地质构造和煤的埋深,地质构造在瓦斯突出发生中起着主控的作用,是瓦斯突出的前提条件。目前,煤矿开采向更深部发展,煤的埋深也是影响瓦斯突出的重要指标。

1) 地质构造

地质构造带的活动会对煤体的结构及性质造成影响,地质结构脆弱的区域发生瓦斯突出事故概率更大。通过对瓦斯突出事故附近地质进行调查,发现突出事故附近多为断层、褶皱等构造,因此地质构造的复杂度可以作为瓦斯突出的预测指标之一^[48-49]。地质构造复杂性分为为无、简单、中等及复杂四种,使用 0~3 代替便于分析。

2) 煤的埋深

煤矿开采深度增加使得井下环境更加恶劣,相比浅部开采煤岩体受到的地应力更加复杂,此外内部压力的增加使得煤体结构更加紧密,从而使储存在煤岩体中的瓦斯无法消散,导致瓦斯压力增加等现象。发生突出强度更大、破坏影响范围更广,煤体内部瓦斯在高应力的情况下快速释放,会导致煤体结构瞬间破坏,深部矿井瓦斯突出机理更加复杂,造成的危害更加严重。

(2) 地应力因素

地应力为煤与瓦斯突出提供了动力。在地应力的作用下煤岩体附近会发生复杂地质变化,影响煤体结构引发各种地质灾害^[50]。煤体地质结构的稳定性在地应力的作用下很可能受到破坏,煤岩体产生裂隙造成煤与瓦斯的突出。

(3) 煤体因素

大量研究表明,处于地质构造带周围的煤体所承受的地应力与瓦斯压力高于其它地方,地质构造带与软分层附近极易发生煤与瓦斯突出,质地较松软的煤体处在瓦斯压力与地应力都相对较高的环境下易遭破坏,且孔隙结构较多,可以存储大量瓦斯,为突出的发展提供能量。能够反映煤体情况的指标主要有以下几种。

1) 煤的破坏类型

煤体形成初期,煤体结构较完整,内部相对稳定,自身强度大。但在频繁的地质活动下,煤体被破坏出现裂缝,自身结构强度大大降低,煤体内部形成的裂隙会储存大量游离态瓦斯,在外部应力作用下很可能使煤体破裂,瓦斯向外释放。如果瓦斯规模足够大就会发生煤与瓦斯突出事故,破坏程度高的煤体发生突出可能性更高。煤的破坏类型可分为:非破坏煤、破坏煤、强烈破坏煤、粉碎煤和全粉煤^[51]。使用 1~5 数字代替进行数据分析。

2) 煤的坚固性系数

煤的坚固性系数用以表示煤体的抗外力冲击的能力。数值越大说明煤体抗外力破坏的能力越强,煤体能够保持内部的稳定。数值越小煤体越易受到外界作用力的影响,突出的概率更大。

3) 软分层厚度

软分层是一种特殊的煤层,煤层在受到外部破坏后煤层质地较软,自身强度较低^[52]。在煤与瓦斯突出事故区域经常发现这种煤层,煤层质地变软预示着突出危险性增加,通过探测软分层厚度及分布情况能够预测煤与瓦斯突出。

4) 钻屑量

研究表明,煤层钻屑量与煤岩体结构强度及外部地质活动存在联系。对于煤岩体强度较弱的煤层,更容易受地应力影响,使钻屑量升高,通过监测钻屑量指标能够反映出瓦斯突出信息。

5) 煤层厚度

煤层中的瓦斯含量与煤层厚度是有关联的,厚度越大的煤层瓦斯存储量越大。煤层厚度的增大导致煤体的稳定性变差,对应的瓦斯压力越大。

6) 煤层倾角

煤层与水平面会有一个夹角,实际开采煤层多数都具有一定倾角。研究表明煤层倾角的越大,瓦斯突出危险性也越大。

(4) 瓦斯因素

瓦斯参数的变化与煤岩体内部变化息息相关。瓦斯含量与煤体变质程度、煤层埋深等因素密切相关,瓦斯压力受地质条件和开采深度的影响,瓦斯放散初速度及瓦斯涌出量都能够间接反映出煤岩体内部情况。

1) 煤层瓦斯含量

煤体瓦斯含量越高发生瓦斯突出的可能性也越高,瓦斯突出的规模也越大。煤层的瓦斯含量不只取决于煤体自身的结构,与煤层附近围岩也相关。煤体结构松散,孔隙较大,能够赋存大量瓦斯,当围岩的结构紧密时,瓦斯不易向外扩散,煤体瓦斯含量就不断增高,瓦斯突出危险性增大。

2) 瓦斯压力

煤体内部储存瓦斯的空間有限,瓦斯含量增加就会造成内部瓦斯压力增加,瓦斯会对煤体内部产生压力,压力越大对煤体的结构要求越高。在内部压力的作用下瓦斯向外喷出就会造成煤与瓦斯突出事故。因此瓦斯压力越大突出危险性也就越大,突出强度也越大。

3) 煤的瓦斯放散初速度

瓦斯放散初速度指煤层中瓦斯向外释放的速度,具体计算方法是:在标准大气压下,煤体样本在 45~60s 释放的瓦斯量与前 10s 释放瓦斯量的差值^[53]。该指标由多种煤层参数共同决定,能够反映突出危险程度,瓦斯放散初速度越大,煤体发生瓦斯突出的概率就越大。

4) 瓦斯涌出量

瓦斯涌出量反映了煤层中瓦斯的含量、瓦斯吸附能力等信息。研究发现瓦斯涌出量在

瓦斯突出期间会发生急剧增加的现象，根据瓦斯涌出量变化情况，在一定程度上能够反映瓦斯突出危险性。

（5）其他因素

1) 声发射事件数

煤与瓦斯突出发生时伴随着煤岩体破裂出现声发射现象，从煤岩体的声发射信号中能够反映出煤岩体的内部变化情况。当外部作用力较小，煤体结构稳定时，声发射事件数量较少，而当煤岩体结构发生变化，内部出现破裂时，声发射事件的数量会急剧升高，声发射事件数能够反映瓦斯突出的危险性。

2) 电磁辐射强度：

大量研究表明，煤体变形破裂时会向外辐射电磁能量，而且当电磁辐射信号出现较大异常变化或强度值突然变大，则表明该处煤层存在发生突出危险的可能性。

从地质、煤体、地应力、瓦斯及其他因素进行瓦斯突出指标选取，共选取出 15 种能够从不同角度反映瓦斯突出信息的二级指标，建立瓦斯突出预测参数体系如图 2.1 所示：

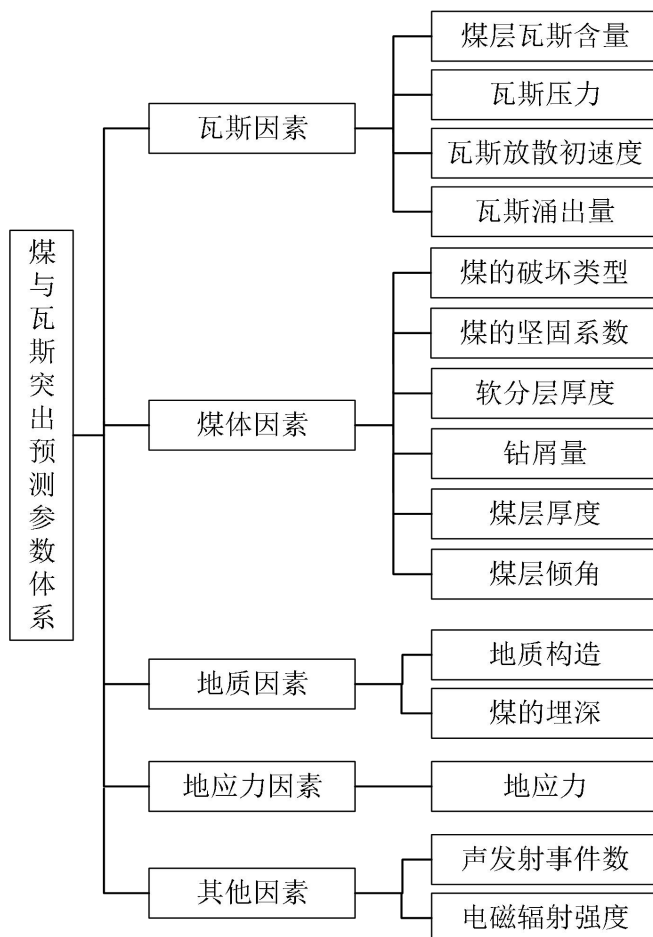


图 2.1 煤与瓦斯突出预测指标
Figure2.1 Coal and gas outburst prediction index

2.4 本章小结

本章介绍了煤与瓦斯突出机理的一些主要假说，从各方面对瓦斯突出影响因素进行了分析，由此从瓦斯、煤体结构、地质结构和地应力及其他方面选取 15 个煤与瓦斯突出综合预测指标。分别介绍各指标与瓦斯突出关系，建立煤与瓦斯突出多指标预测体系，为准确预测瓦斯突出奠定了数据基础。

3 煤与瓦斯突出指标数据处理

为了更加准确的进行煤与瓦斯突出危险性预测, 本文从瓦斯因素、煤体因素、地质结构因素和地应力因素等方向选取了 15 种突出预测指标。各指标能够从不同角度反映出煤岩体内部的变化情况, 但各预测指标之间存在信息重叠的问题。例如, 地质构造的变化往往会影响煤体内部的结构; 煤体结构的不同与其内部瓦斯的状态具有一定的关系; 瓦斯含量、瓦斯压力与瓦斯放散初速度也存在相关性。且选取指标较多, 如果直接作为预测模型的输入, 不仅会增加模型的复杂度, 使模型训练时间更长, 而且参数过多, 瓦斯突出指标之间又存在非线性及相互耦合的情况会使训练时发生过拟合现象, 影响瓦斯突出预测的准确度及泛化能力, 因此需要对原始数据各指标进行分析处理。

主成分分析法是一种广泛应用的数据处理的方法, 能够去除数据中的重复信息。但主成分分析法只能处理非线性数据, 针对煤与瓦斯突出数据的非线性关系, 如果直接进行主成分降维, 主成分累计贡献率不能够满足要求, 会丢失很多信息。使用核函数对原始数据进行高维非线性映射, 然后进行主成分分析降维, 能够很好的解决瓦斯突出数据的非线性问题。主成分分析法获得的各主成分由原始数据中所有参数指标进行线性组合得到, 很难解释降维后主成分数据的具体对应特征, 且由于瓦斯突出数据之间具有相关性, 数据采集自不同煤层也具有一定差异, 在进行处理后主成分线性组合系数中存在许多接近于零的系数指标, 这些指标所含主成分信息很少, 相互作用反而会影响最终预测模型的泛化能力。因此本文引入主成分稀疏化方法对主成分数据负载系数进行稀疏化, 将构成各主成分的原始数据中相应次要元素的系数降为零, 减少各主成分关联的原始指标个数。对煤矿不同工作面采集数据进行稀疏化处理, 能够避免次要指标噪声的影响, 使主成分更加具有代表性, 从数据方面提高预测模型准确度及泛化能力。

3.1 SKPCA 方法原理

本文结合核主成分分析与主成分稀疏化方法, 采用稀疏核主成分法 (Sparse Kernel Principal Component Analysis, SKPCA) 对数据进行分析处理, 利用核函数能够有效解决煤与瓦斯突出数据非线性问题。再对主成分进行稀疏化使各主成分去除载荷系数较小数据信息, 使获得瓦斯突出数据主成分特征更加突出, 更加具有代表性。使用 SKPCA 方法进行数据处理简化了预测模型的复杂度, 加快模型预测速度的同时能够提高煤与瓦斯要突出预测的准确度和泛化能力。

3.1.1 核主成分分析原理

煤与瓦斯突出数据具有非线性关系, 而主成分分析对非线性数据处理效果不佳, 降低维度有限, 降维过多会丢失数据信息。为了更好的处理瓦斯突出数据, 使用 Scholkopf 等

人提出了核主成分分析方法，将核函数运用到主成分分析中^[54]。

核主成分分析就是利用核函数将数据映射到高维空间中，使数据在高维空间线性可分，再对数据运用主成分分析进行降维处理。其基本原理如下：

$X = [x_1, x_2, \dots, x_n]^T \in R^{n \times m}$ 为一组样本数据集， n 为样本数量， m 为数据维度。利用非线性映射 $x \rightarrow \Phi(x)$ 将数据映射到高维空间 F ，则数据的协方差矩阵如式 (3.1) 所示：

$$\bar{C} = \frac{1}{n} \sum_{i=1}^n \Phi(x_i) \Phi(x_i)^T \quad (3.1)$$

假设 λ 和 ν 为所求的协方差矩阵 \bar{C} 的特征值和对应特征向量，则：

$$\bar{C} \nu = \lambda \nu \quad (3.2)$$

将式 (3.1) 代入 (3.2) 可得：

$$\lambda \nu = \frac{1}{n} \sum_{i=1}^n \Phi(x_i) \Phi(x_i)^T \nu \quad (3.3)$$

根据式(3.3)可以看出 ν 存在于 $\Phi(x_1), \Phi(x_2), \dots, \Phi(x_n)$ 张成的空间中，所以存在系数 α_i 使得：

$$\nu = \sum_{i=1}^n \alpha_i \Phi(x_i) \quad (3.4)$$

代入式(3.3)中，两边同乘 $\Phi(x_k)^T$ 可得

$$\lambda \Phi(x_k)^T \sum_{i=1}^n \alpha_i \Phi(x_i) = \Phi(x_k)^T \left(\frac{1}{n} \sum_{i=1}^n \Phi(x_i) \Phi(x_i)^T \right) \sum_{i=1}^n \alpha_i \Phi(x_i) \quad (3.5)$$

上式简化后得：

$$n \lambda K \alpha = K^2 \alpha \quad (3.6)$$

即

$$n \lambda \alpha = K \alpha \quad (3.7)$$

式中 K 为 $n \times n$ 维核矩阵， $K_{ij} = K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$ ， $n \lambda$ 和 α 分别为矩阵 K 特征值和特征向量。

在实际计算时，需要对矩阵 K 进行中心化处理：

$$\begin{aligned} \tilde{K}_{ij} &= \left(\Phi(x_i) - \frac{1}{n} \sum_{l=1}^n \Phi(x_l), \Phi(x_j) - \frac{1}{n} \sum_{m=1}^n \Phi(x_m) \right) \\ &= K_{ij} - \frac{1}{n} \sum_{l=1}^n 1_{il} K_{lj} - \frac{1}{n} \sum_{m=1}^n K_{im} 1_{mj} + \frac{1}{n^2} \sum_{l,m=1}^n 1_{il} K_{lm} 1_{mj} \end{aligned} \quad (3.8)$$

式中 1_{ij} 为全 1 的矩阵。

设 $\lambda = (\lambda_1, \lambda_2, \dots, \lambda_n)$ 表示 K 的特征值且 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ，则 $\alpha^1, \alpha^2, \dots, \alpha^n$ 为对应特征向量。假设 λ_p 为矩阵 K 最后一个非零特征值，则协方差矩阵 \bar{C} 的特征向量为：

$$\nu^m = \sum_{i=1}^n \alpha_i^m \Phi(x_i), m = 1, 2, \dots, p \quad (3.9)$$

则数据 $\Phi(x)$ 在高维空间 F 的特征向量 ν^m 上的投影为需要的主成分数据，如式(3.10)。

$$(\nu^m, \Phi(x)) = \sum_{i=1}^n \alpha_i^m (\Phi(x_i), \Phi(x)), m = 1, 2, \dots, p \quad (3.10)$$

$$(\nu^m, \Phi(x)) = \sum_{i=1}^n \alpha_i^m K(x, x_i) \quad (3.11)$$

由以上核主成分分析介绍可以看出, $K_{ij} = K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$, 核函数相当于高维特征空间的内积。在实际计算时对数据进行高维映射 $\Phi(x)$ 后进行内积计算的复杂度特别高, 利用核函数不需要了解特征映射的具体形式, 使用计算得出核矩阵代替数据高维映射后的内积计算, 大大减小了计算复杂度。

常用的核函数有以下几种:

(1) 线性核函数

$$K(x, x_i) = x \cdot x_i \quad (3.12)$$

(2) P 阶多项式核函数

$$K(x, x_i) = (x, x_i + 1)^p \quad (3.13)$$

(3) 高斯径向基核函数

$$K(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{\sigma^2}\right) \quad (3.14)$$

(4) 多层感知器核函数

$$K(x, x_i) = \tanh[\nu(x, x_i) + c] \quad (3.15)$$

实际分析对比后, 高斯径向基核函数在瓦斯突出数据上效果更加。对于计算出特征值只需取前 k 个贡献率高的, 利用式 (3.11) 计算出 k 个主成分, 前 k 个特征值累计贡献率为计算公式为:

$$L(k) = \sum_{i=1}^k \lambda_i / \sum_{i=1}^n \lambda_i \quad (3.16)$$

特征值贡献率越大表示保留的原始数据特征信息越多, 一般前 k 个特征累计贡献率超过 85% 以上, 就认为前 k 个主成分能够充分体现原始数据信息。

3.1.2 主成分稀疏化原理

主成分分析是对原始数据的各参数进行线性组合, 从而获得主成分, 其实际意义很难解释, 瓦斯突出数据信息较为复杂, 不同煤层之间具有一定差异, 存在噪声干扰, 进行主成分分析后获得的各主成分组合系数中会存在较多系数较小的元素, 这些元素所含主成分信息很少, 相互作用会影响最后预测效果, 降低最终模型的泛化能力。利用稀疏化方法解决瓦斯突出数据问题, 主成分的稀疏化通过对构成主成分线性组合的系数进行稀疏处理, 将各主成分相应不重要原始变量的系数降为零, 使每个主成分只保留各自关联原始数据中最主要指标信息。Zou 等人^[55]首次提出的基于弹性网惩罚结构的稀疏主成分算法。

对 n 组样本值和 p 个变量的回归问题, Y 为因变量, X 为自变量。Lasso 方法加入惩罚

项构造误差函数模型，使用模型系数绝对值即 L1 惩罚作为模型惩罚项，Lasso 解决问题如下：

$$\hat{\beta} = \arg \min \left\| Y - \sum_{j=1}^p X_j \beta_j \right\|^2 + \lambda_1 \sum_{j=1}^p |\beta_j| \quad (3.17)$$

通过最小化式 (3.17) 获得模型系数 $\hat{\beta}$ ，L1 范数惩罚项的性质使得当 λ_1 足够大时，模型系数中较小的系数能够不断减小到零，减少关联指标数量，因此 lasso 可以获得更加稀疏的模型。

弹性网 (Elastic net) 是 lasso 的优化，不仅具有 lasso 的特性，而且还克服 lasso 的缺点。弹性网准则如下式：

$$L(\lambda_1, \lambda_2, \beta) = \|Y - X\beta\|^2 + \lambda_2 |\beta|^2 + \lambda_1 |\beta|_1 \quad (3.18)$$

式中 $|\beta|^2 = \sum_{j=1}^p \beta_j^2$ ， $|\beta|_1 = \sum_{j=1}^p |\beta_j|$ 。

$\hat{\beta}$ 的弹性网估计就是最小化 $L(\lambda_1, \lambda_2, \beta)$ 的解：

$$\hat{\beta} = (1 + \lambda_2) \left(\arg \min_{\beta} \left\| Y - \sum_{j=1}^p X_j \beta_j \right\|^2 + \lambda_2 \sum_{j=1}^p |\beta_j|^2 + \lambda_1 \sum_{j=1}^p |\beta_j| \right) \quad (3.19)$$

可以看成是带惩罚项最小二乘法的过程，令 $\alpha = \lambda_2 / (\lambda_1 + \lambda_2)$ ， $\hat{\beta}$ 的求解等价于求解式 (3.20) 优化问题：

$$\begin{cases} \hat{\beta} = \arg \min_{\beta} \|Y - X\beta\|^2 \\ s, t(1 - \alpha)|\beta|_1 + \alpha|\beta|^2 \leq t, \forall t \end{cases} \quad (3.20)$$

式中 $(1 - \alpha)|\beta|_1 + \alpha|\beta|^2$ 称为弹性网惩罚，是 L1 和 L2 范数惩罚的组合。当 α 为 0，弹性网就变成了 lasso。

将主成分的稀疏化转化为线性模型变量的选择问题，再加入弹性网的惩罚结构得到稀疏主成分，最终计算如下优化问题：

$$\hat{\beta} = \|Z_i - X\beta\|^2 + \lambda|\beta|^2 + \lambda_1|\beta|_1 \quad (3.21)$$

稀疏后的载荷向量 $\hat{V}_j = \frac{\hat{\beta}_j}{\|\hat{\beta}_j\|}$ 。

基于弹性网惩罚结构的稀疏主成分算法具体步骤如下：

(1) 使用主成分分析法计算前 k 个主成分的载荷系数向量 α_j ， $j=1, \dots, k$ 。

(2) 对给定的 $A = [\alpha_1, \alpha_2, \dots, \alpha_k]$ ，求解弹性网回归问题：

$$\beta_j = \arg \min (\alpha_j - \beta)^T X^T X (\alpha_j - \beta) + \lambda \|\beta\|^2 + \lambda_{1,j} \|\beta\|_1 \quad (3.22)$$

β 为稀疏处理的主成分载荷向量， $\|\beta\|^2$ 为 L2 范数， $\|\beta\|_1$ 为 L1 范数， λ ， $\lambda_{1,j}$ 为系数。

(3) 对求出的 $B = [\beta_1, \dots, \beta_k]$ ，计算奇异值分解， $X^T X B = U D V^T$ ，然后更新 $A = U V^T$ 。

(4) 重复步骤 2 和 3，直到收敛。

(5) 标准化 $\hat{V}_j = \frac{\beta_j}{\|\beta_j\|}$ $j=1,2,\dots,k$, \hat{V}_j 为稀疏后的载荷向量。

3.2 煤与瓦斯突出数据 SKPCA 方法处理

结合核主成分分析与主成分稀疏化方法,核主成分分析利用核函数进行数据的高维映射,使用核矩阵特征向量计算获得主成分,解决瓦斯突出数据的非线性问题。根据核矩阵特征值计算累计贡献率,选取贡献率达到要求的前 k 个主成分,然后利用稀疏化方法对特征向量即主成分载荷系数进行稀疏化处理,使最终获得的瓦斯突出主成分数据更加具有代表性。稀疏核主成分分析具体实现流程如图 3.1 所示:

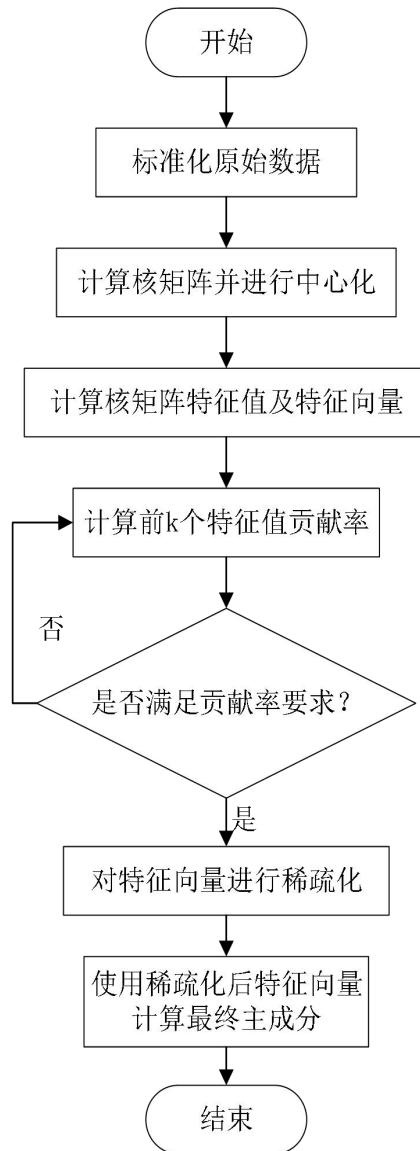


图 3.1 稀疏核主成分分析流程图

Figure3.1 Sparse kernel principal component analysis flowchart

为了验证该方法的实际效果,使用文献[40]中煤与瓦斯突出数据进行对比验证,该数

据包含 50 个样本，9 种瓦斯突出输入指标，使用 SKPCA 方法对数据进行处理具体步骤如下：

- (1) 对瓦斯突出数据进行标准化处理后使用高斯径向基核函数计算核矩阵。
- (2) 对核矩阵进行中心化处理后得到矩阵 \tilde{K}_{ij} 。
- (3) 计算核矩阵 \tilde{K}_{ij} 特征值 λ 和特征向量 α ，前 3 个主成分累计贡献率达到了 85%，取前 3 个主成分特征向量 $A=\alpha_1, \alpha_2, \alpha_3$ 。
- (4) 对特征向量进行稀疏化处理，求解 \tilde{K}_{ij} 主成分载荷系数的弹性网回归问题：
$$\beta_u = \arg \min (\alpha_u - \beta)^T \tilde{K}_{ij}^T \tilde{K}_{ij} (\alpha_u - \beta) + \lambda \|\beta\|^2 + \lambda_{1,u} \|\beta\|_1 \quad (3-23)$$
- (5) 稀疏化收敛后，载荷向量进行标准化， $\hat{V}_u = \frac{\beta_u}{\|\beta_u\|} \quad u=1,2,3$ ， \hat{V}_u 为稀疏后的载荷向量。
- (6) 计算最终主成分 $X = \hat{V}_u^T \tilde{K}_{ij}$ ， $u=1,2,3$ ， X 为稀疏核主成分分析后的最终主成分。

将处理后的主成分数据输入 BP 神经网络，对比使用 KPCA 进行数据处理后的预测效果。如表 3.1：

表 3.1 不同数据处理方法误差对比
Table3.1 Error comparison of different data processing methods

| 数据处理方法 | KPCA | SKPCA |
|--------|-------|-------|
| 训练平均误差 | 0.145 | 0.121 |
| 测试平均误差 | 0.183 | 0.146 |

可以看出使用 SKPCA 方法处理后预测误差更小，KPCA 方法不仅误差较大，而且训练误差与测试误差差别较大，说明对主成分进行稀疏化后，去除了载荷系数较小的部分信息影响，避免瓦斯突出数据噪声的干扰，主成分更具代表性，能够有效提高瓦斯突出预测准确度和预测模型的泛化能力。该方法可以应用于煤与瓦斯突出数据处理，具体在第五章进行实际应用。

3.2.1 稀疏核主成分分析特点

稀疏核主成分分析方法结合了核主成分分析方法和主成分稀疏化方法，对中心化后的核矩阵进行主成分稀疏化操作，最后提取主成分信息，该方法应用煤与瓦斯突出数据处理具有以下特点：

- (1) 各主成分数据之间都具有不相关性，避免了瓦斯突出原始数据之间的信息重叠。
- (2) 提取的主成分能够反映煤与瓦斯突出数据的最主要信息，使输入指标个数减少，能够大大降低预测模型复杂度，避免模型在进行瓦斯突出数据训练时出现过拟合的现象。
- (3) 利用核函数进行原始数据处理，提高对数据进行高维映射能够有效解决数据的非线性问题，对煤与瓦斯突出数据存在的非线性问题，使用核函数是很好的解决办法。

(4) 对主成分进行稀疏化后使每一个主成分只包含原始数据中各自载荷系数大的指标信息，而不是所有指标线性组合，使降维后瓦斯突出数据更具有代表性，对提高模型泛化能力有一定帮助。

3.3 本章小结

本章介绍了核主成分分析方法，介绍核函数处理非线性数据原理。阐述了基于弹性网惩罚结构的稀疏主成分方法的原理。结合两种方法建立稀疏核主成分分析方法，使用文献中瓦斯突出数据进行初步验证具有较好的数据处理效果。最后总结了稀疏核主成分方法在瓦斯数据处理上的特点与优势。

4 煤与瓦斯突出 NEAT 预测算法

目前煤矿的开采不断向深部发展,井下多种因素相互影响,开采环境更加恶劣,对煤与瓦斯突出预测的难度也越来越大,传统预测方法难以满足实际矿井突出的预测要求。近年来,许多学者将神经网络应用于煤与瓦斯突出预测领域。针对神经网络存在的问题大量学者也提出了优化方法如遗传算法、粒子群算法等优化方法^[56-58]。这些方法都只能够优化神经网络权值等参数,虽然在一定程度上提高了模型预测能力,但深部煤与瓦斯突出动力灾害的发生原因、机理等较浅部更为复杂,与浅部开采相比煤岩体承受更加复杂的应力和能量的影响,使得预测难度不断提高。传统神经网络为多层感知器的网络结构,其内部为全连接层,网络中参数过多,在对多指标的瓦斯突出数据进行训练时很容易出现过拟合现象,对于煤矿不同开采工作面采集的数据其预测泛化能力也不强。因此,本文提出使用增强拓扑神经进化算法(Neuro-Evolution of Augmenting Topologies, NEAT)进行突出预警,NEAT 算法利用遗传进化算法的原理,能够同时对神经网络的权值和连接拓扑结构进行优化,神经网络连接结构自主优化获得,从而提高对瓦斯突出预测准确度及泛化能力。引入动态个体适应度计算方法,使得网络在全局开始寻优,避免在对瓦斯突出数据训练时出现局部最优解。

4.1 NEAT 算法及改进

传统的遗传算法优化神经网络,虽然能够一定程度上改善神经网络陷入局部最优解的问题,但遗传算法只对神经网络内部参数进行寻优,不能优化神经网络连接结构,内部神经网络为全连接层,参数过多。由于煤与瓦斯突出指标较为复杂,且不同煤层采集数据具有一定差异,在进行预测存在过拟合现象,泛化能力不强。本文提出使用增强拓扑神经进化算法进行煤与瓦斯突出危险性的预测。Stanley Kenneth O 等人^[59]最先提出了增强拓扑神经进化的神经网络优化理论。NEAT 算法通过对神经网络的连接进行基因编码,利用遗传进化算法同时对网络的权值参数和拓扑结构进行优化,最终找出预测效果最佳的神经网络结构^[60-61]。针对进行瓦斯突出训练时仍然存在的局部最优解情况,提出使用动态个体适应度函数进行优化。

4.1.1 基因编码

在 NEAT 算法中,对神经网络的每个连接使用创新号进行直接编码,当出现新的连接时,会分配一个全局的创新号给它,同时创新号自增等待下一个新的连接。创新号在进行结构的交叉变异操作时至关重要,基因通过创新号进行配对,相同的创新号则代表具有相同的连接。如图 4.1,1-4 节点连接为创新号 1,2-4 节点连接为创新号 2。基因组中包含了节点列表和连接列表。节点列表描述了节点信息,有输入节点、输出节点、隐节点。连接

列表描述了每个连接的信息，输入输出节点、权值大小、连接是否表达、连接创新号。

| 节点列表 | 节点1 输入层 | 节点2 输入层 | 节点3 输入层 | 节点4 输出层 | 节点5 隐含层 | |
|------|---------------------------------------|---|---------------------------------------|---------------------------------------|---------------------------------------|---------------------------------------|
| 连接列表 | 输入 1 输出 4 权重 0.7 表达 创新号 1 | 输入 2 输出 4 权重 -0.5 不表达 创新号 2 | 输入 3 输出 4 权重 0.5 表达 创新号 3 | 输入 2 输出 5 权重 0.2 表达 创新号 4 | 输入 5 输出 4 权重 0.6 表达 创新号 5 | 输入 1 输出 5 权重 0.6 表达 创新号 6 |




图 4.1 NEAT 基因编码
Figure4.1 NEAT gene coding




图 4.2 NEAT 算法的两种结构变异
Figure4.2 Two structural variations of NEAT algorithm


4.2.2 结构变异操作

神经网络结构变异分为连接变异和节点变异，通过连接与节点的突变，包括新增和删

除生成新的网络结构，使基因组发生变化，产生新个体。如图 4.2，基因信息的最上方为不同连接结构的创新号，创新号越小表示该创新号产生的时间越长。图上方为连接变异，在 3-5 之间变异产生新的连接，对新连接会用新的创新号标记，然后添加在基因组末尾。图下部分为节点变异，在原有连接 3-4 中突变出新的节点 6，从而产生新的连接 3-6，6-4，对新产生的连接同样使用新的创新号标记，添加在基因组末尾，而原有连接 3-4 则转变为不表达。删除操作则与新增相反，对原有的连接和节点进行删除。

4.2.3 交叉遗传操作

对两个基因组进行结构交叉遗传时，如图 4.3 先对两个父代基因组按照创新号进行配对，有相同创新号的基因相互对齐，创新号不同的单独排列。配对时对于不匹配基因分为两种。在基因组内部的单独基因称为脱落基因，如 6、7 和 8 创新号，而在基因组末端的无匹配基因称为过量基因，如 9、10 创新号。杂交时父辈具有相同创新号基因随机一个遗传给子代，而创新号不同基因全都遗传给子代。



图

4.3 NEAT 杂交操作
Figure 4.3 NEAT hybrid operation

4.2.4 物种的分化

在使用遗传算法进行瓦斯突出数据训练时需要将种群进行物种的分化，将不同个体分到不同的物种内，使结构和权值参数相似的个体分配到相同的物种内，同物种之间进行竞争和遗传操作。使用物种分化可以使产生的新个体在一个威胁较小的环境生存，新物种有足够时间产生子代，通过不断竞争优化结构。

通过计算个体与其他各物种的代表个体的差异距离来进行个体划分物种。算法中通过脱落基因、过量基因和权值差异来表示基因结构差距，两个基因组脱落基因与过量基因越多，表示基因之间区别越大。个体之间差异的公式（compatibility function）如下：

$$\delta = \frac{c_1 E}{N} + \frac{c_2 D}{N} + c_3 \times \bar{W} \quad (4.1)$$

式中， δ 为差异距离（compatibility）， D 为脱落基因个数， E 为过量基因个数， \bar{W} 为两个体之间神经网络权值的平均差值。 c_1 、 c_2 、 c_3 为三者权重系数， N 为两个体中基因数较大个体的基因个数。利用个体脱落基因、过量基因和权值来共同表达差异距离。

根据瓦斯突出训练时情况设定物种划分的阈值，当差异距离 δ 小于该阈值则被视为是同一物种，当对所有物种的差异距离都大于阈值，则产生一个新物种将其归为这一物种。具体分化过程：

- （1）刚开始时没有物种，将生成的个体放入物种中，第一个放入的个体为物种的代表个体，作为其他个体计算差异的对象。
- （2）将种群中个体与每个物种的代表个体计算差异距离，当差异距离小于阈值时，则将该个体归为代表个体的物种中。
- （3）如果某个个体与种群中所有代表个体差异距离都大于阈值，则将其归为一个新的物种内，将个体设为物种的代表个体。
- （4）重复 2、3 操作直至所有个体都被分到相应物种。

4.2.5 显示适应度共享

在种群的进化过程中，需要保护物种的多样性，防止一个物种因为适应度过高，在进化过程中个体数越来越多逐渐取代整个种群。由于物种根据适应度的大小决定遗传概率，在对物种进行遗传操作前使用显示适应度共享方法（explicit fitness sharing）对个体适应度进行调节。公式如下：

$$f'_i = \frac{f_i}{\sum_{j=1}^n sh(\delta(i, j))} \quad (4.2)$$

f'_i 为个体调整后适应度， f_i 为调整前适应度， n 为每一代种群的所有个体。计算个体与其他个体的差异距离 $\delta(i, j)$ ，通过 sh 函数处理。

$$sh = \begin{cases} 0 & \delta(i, j) > \text{差异阈值} \\ 1 & \delta(i, j) \leq \text{差异阈值} \end{cases} \quad (4.3)$$

当距离高于阈值时通过 sh 函数输出 0；当距离小于阈值时输出 1。利用调整后的适应度来进行繁殖操作，种群中一个物种数量如果过大，个体间差异距离较小，公式中 sh 函数判断后不断累加 1，分母增大，使适应度减小。从而能够做到抑制成熟种群的扩大，鼓励未成熟物种进化。显示适应度共享方法对种群中物种进化起着关键作用。

4.2.6 改进动态个体适应度函数

适应度决定着个体是否进行遗传操作。通过计算个体适应度来反映基因组预测效果的好坏。适应度函数对最终模型的预测准确度起着至关重要的作用。由于初始网络权重为随机选取，而煤与瓦斯突出数据较为复杂，优化时很可能出现局部最优解。在进化初期存在适应度差异较大个体，种群在初始适应度高个体上进行遗传，导致种群在局部进行优化的问题，本文在个体适应度函数中加入随进化代数变化的动态参数，从而缩小进行瓦斯突出数据训练时进化前期各个体适应度的差距，函数如下：

$$F = Z - \sum_{i=1}^n \sqrt{(y'_i - y_i)^2} + \lambda^m \quad (4.4)$$

式中 y'_i 为模型预测值， y_i 为数据实际值， $\sqrt{(y'_i - y_i)^2}$ 为标准差， Z 为设定常数， n 为样本个数。 m 为进化代数，动态参数 λ^m 随着进化代数的增加而变化。 λ^m 的计算方法如下：

$$\lambda^0 = V, \lambda^m = \lambda^{m-1} \cdot r \quad (4.5)$$

初始动态参数为常数 V ， λ^m 由上一代参数乘以权重系数 r 获得，使得动态参数 λ^m 随着进化代数的增加不断缩小。 V 为 20， r 为 0.9 时 λ^m 变化曲线如下图：




图 4.4 动态参数变化图
Figure 4.4 Dynamic Parameter Change Chart

前期 λ^m 参数较大，能够减少种群中较差个体与适应度较高个体的差距，使所有个体都有较高机会进行遗传操作，后期 λ^m 趋于零，避免对最终适应度大小的影响。利用动态变化

参数使得种群在更加广的区域内寻优，以更加平稳的方式进化，避免在对瓦斯突出数据训练时容易出现的局部最优的情况。

4.2 NEAT 神经元优化

神经网络内部每一个节点都是一个神经元，神经元对输入数据进行处理后传入下一个神经元，传统神经元结构如图 4.5 所示。




图 4.5 神经元结构
Figure4.5 Neuron structure

数据由神经元上一层输入，每个输入与权值相乘后输入神经元节点，一般各输入合并计算方法都为求和，再加上一个阈值，最后再通过激活函数计算后作为下一层神经元的输入。数学表达式如式 (4.1)：

$$Y = \varphi \left(\sum_{i=1}^n W_i X_i + b_i \right) \quad (4.6)$$

在 NEAT 算法中输入合并方法也可突变为其他方法，进一步提高优化能力，本瓦斯突出预测模型中初始方法使用求和，可突变为求和、平均值、最大值。

式中 φ 为激活函数， n 为输入个数。在对瓦斯突出数据分析时神经网络激活函数使用非线性函数具有更好的效果。NEAT 算法为了提高寻优能力对于网络激活函数在进化时也可以突变为其他函数，本文选用 ELU 函数作为初始函数，Sigmoid、Tanh、ReLU 函数可作为突变函数。各激活函数如下：

(1) Sigmoid 函数

$$\varphi(x) = \frac{1}{1 + e^{-x}} \quad (4.7)$$

Sigmoid 函数能够将数据处理后输出在 0 至 1 之间，转化为 [0, 1] 区间的概率问题进行分析处理。由于输入数据过大时输出趋近于 0 和 1，存在梯度消失的问题，因此输入数据通常需要进行标准化处理。

(2) Tanh 函数

$$\varphi(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad (4.8)$$

Tanh 函数输出区间在 -1 到 1 之间，同样也存在梯度消失问题。

(3) ReLU 函数

$$\varphi(x)=\begin{cases} x & x>0 \\ 0 & x<0 \end{cases} \quad (4.4)$$

ReLU 函数当输入小于 0 时输出都为 0，大于 0 时为线性函数。能够避免神经网络梯度消失的问题，应用比较广泛。

(4) ELU 函数

$$\varphi(x)=\begin{cases} x & x \geq 0 \\ a(e^x - 1) & x < 0 \end{cases} \quad (4.5)$$

式中 a 为系数，a 取 1 时函数如下图：

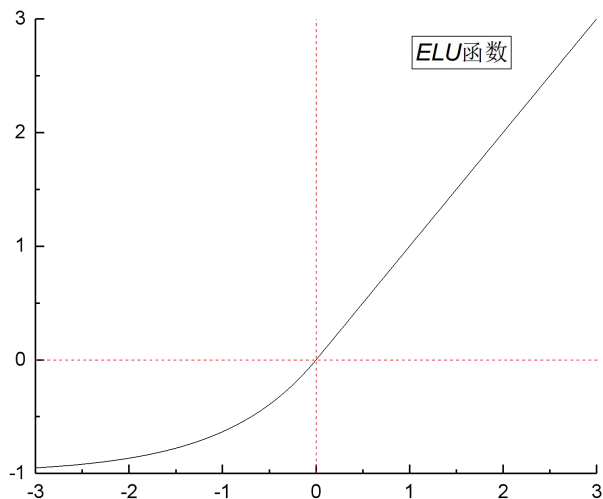


图 4.6 ELU 函数曲线
Figure4.6 The ELU curve

ELU 函数在 ReLu 函数的基础上进行改进，结合了 Sigmoid 与 ReLu 的优势，在输入为负时有一定输出，能够提供抗干扰能力，因此一定程度上能够解决煤与瓦斯突出数据采集时存在的较强外部干扰。选用 ELU 函数作为初始函数，激活函数可突变为其他函数，能够进一步提高优化效果。

4.3 NEAT 算法的整体流程

NEAT 算法从初始没有隐含层的简单网络开始，使用遗传算法对连接结构和权值进行优化，不断改变网络连接结构，使用适应度反映神经网络结构的好坏，对适应度差的个体进行淘汰。相比于全连接的多层神经网络，需要优化的网络参数更少，能够提高煤与瓦斯突出预测的速度。瓦斯突出数据复杂度较高，存在较多干扰噪声，不同煤层数据也有一定环境差异，使用 NEAT 算法能够避免瓦斯突出数据训练时存在过拟合的现象，提高泛化能力。使用动态个体适应度函数也能够进一步改善瓦斯突出数据训练时存在的局部最优解情况。

NEAT 算法进行瓦斯突出数据训练的整体流程图如图 4.7 所示：

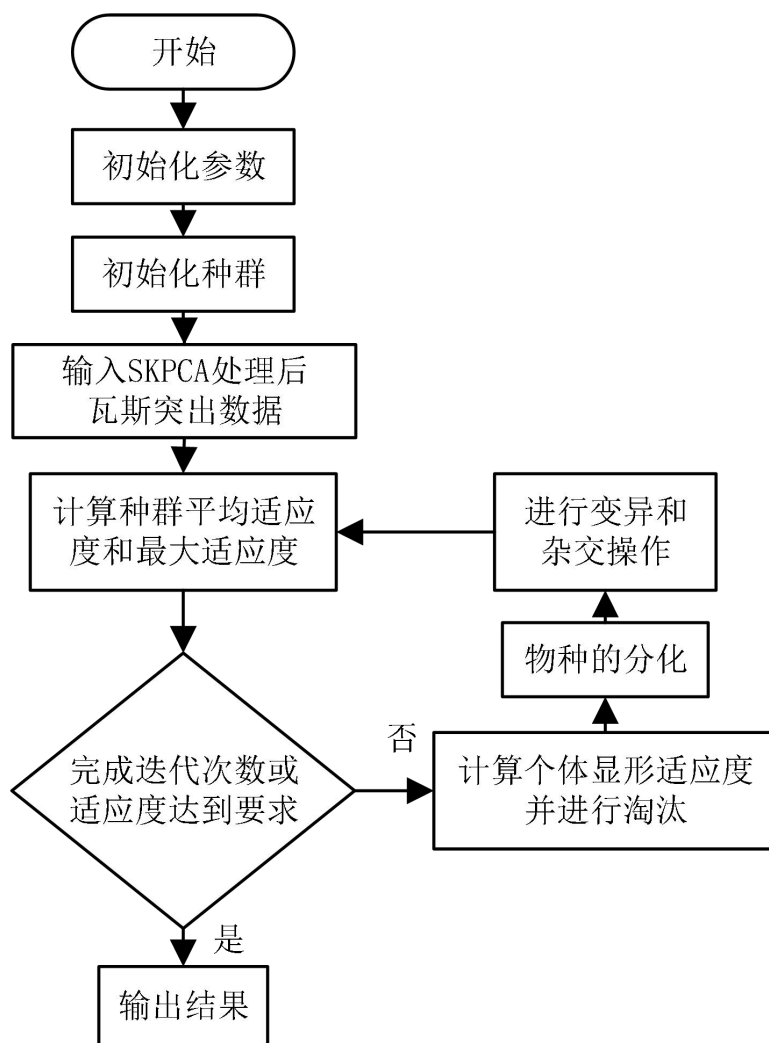


图 4.7 NEAT 算法的整体流程图
Figure4.7 The overall flow chart of NEAT algorithm

- (1) 首先根据 SKPCA 处理后瓦斯突出主成分数据样本个数及输出范围设定最大迭代次数、适应度阈值和动态个体适应度等参数，然后初始化模型参数，初始化种群。
- (2) 使用模型对瓦斯突出数据进行训练，计算个体动态适应度后获得种群的平均适应度和最佳适应度。
- (3) 判断是否达到最大迭代次数或者最佳适应度达到阈值，达到要求则结束，输出优化模型，若没有达到则继续以下操作。
- (4) 计算每个个体显示适应度，将适应度过低个体进行淘汰。
- (5) 进行物种分化，将个体根据差异距离划分到不同的种群。
- (6) 相同物种内进行变异和杂交操作获得下一代个体。
- (7) 重复 2-6 步直到迭代次数或者适应度达到要求。
- (8) 输入测试数据验证预测结果，评价模型准确性及泛化性能，并得出结论。

4.4 本章小结

本章将增强拓扑神经进化算法应用于煤与瓦斯突出预测中。阐述增强拓扑神经进化算法如何利用遗传进化算法原理对神经网络的结构和权值参数同时进行优化。通过对网络连接用创新号进行标记，将网络的创新号作为个体基因进行变异、交叉遗传等操作，从而不断优化获得最佳网络结构。引入动态个体适应度函数解决模型对瓦斯突出数据训练存在局部最优解的情况。

5 预测模型构建及实验结果分析

对煤与瓦斯突出测量数据首先进行标准化后使用 SKPCA 方法进行处理，利用核函数对瓦斯突出数据进行非线性映射，再提取主成分信息，解决瓦斯突出数据的存在非线性问题。利用主成分稀疏化方法对核矩阵载荷系数进行稀疏化，使获得的主成分特征更具代表性。搭建 NEAT 网络模型，设置动态个体适应度函数，输入处理后的主成分数据进行训练，通过遗传进化算法原理对神经网络权值和结构进行优化，本章将对模型性能进行验证。

5.1 矿井概况

本文数据采集自我国西部某矿，该煤矿采掘区域地质结构较复杂，瓦斯压力及地应力较大，喷孔、顶钻等情况时有发生。煤矿中可开采煤层一共有 7 个，全范围能够开采的煤层有 7、9、12 号煤层，局部可开采的有 5、6、8、11 煤层。各煤层情况如下表。

图 5.1 各煤层具体情况
Table 5.1 Specific coal seams

| 煤层序号 | 结构 | 稳定程度 | 可开采程度 |
|------|-----------------|------|-------|
| #5 | 单一结构 时有夹石 1~2 层 | 不稳定 | 部分可采 |
| #6 | 单一结构 时有夹石 1~2 层 | 不稳定 | 部分可采 |
| #7 | 复结构 含夹石 2~3 层 | 稳定 | 全区可采 |
| #8 | 单一结构 时有夹石 1~2 层 | 不稳定 | 部分可采 |
| #9 | 单一结构 时有夹石 1~2 层 | 较稳定 | 全区可采 |
| #11 | 单一结构 时有夹石 1 层 | 极不稳定 | 部分可采 |
| #12 | 单一结构 时有夹石 1~2 层 | 较稳定 | 全区可采 |

5.2 煤与瓦斯突出预测指标测定

根据第二章煤与瓦斯突出预测指标的选取原则，从瓦斯因素、煤体因素、地质构造、地应力及其他因素多方面选取 15 项指标来构建多指标预测系统。部分指标的测定方法如下：

1. 瓦斯压力测定

瓦斯压力直接测量方法通过在煤层打孔取芯，然后使用压力计测量。该方法存在测量时间较长的问题，为了加快测量速度，本文使用瓦斯含量推算压力的间接方法，计算公式如下：

$$W = \frac{abp}{1+bp} \times \frac{100-A-M}{100} \times \frac{1}{1+0.31M} + \frac{10\pi p}{\gamma} \tag{5.1}$$

式中 W 为煤层瓦斯含量； p 为瓦斯压力， A 煤灰水分， M 煤灰灰分； π 是孔隙率； γ 是容重， a, b 为吸附常数。9 号煤层各参数如下表，将不同煤层位置测得瓦斯含量 W 带入


公式可反推出瓦斯压力大小。

表 5.2 煤层各参数测定值
Table 5.2 Measurement of parameters of coal seam

| 煤层 | a | b | M | A | π | γ |
|----|--------|-------|------|------|--------|----------|
| #9 | 22.743 | 0.624 | 0.48 | 7.99 | 0.0231 | 14.211 |

2. 瓦斯放散初速度

本文使用变容变压式仪器测量瓦斯放散初速度 Δp 测定，如图。



1-真空泵 2-玻璃管 3-二通阀 4-固定空间
5-试样瓶 6-三通阀 7-真空汞柱计

图 5.1 变容变压式测量仪器示意图

Figure5.1 Schematic diagram of variable capacity and pressure measuring instrument

测定步骤先取 250g 煤体样本，将样本捣成粉末状，从中取出直径 0.2-0.5mm 区间煤体颗粒，分成重 3.5g 的两份装入试样凭瓶。进行如下操作：

1) 打开图 5.1 中泵 1 和阀 3，使 U 型汞柱液面水平。

2) 关闭阀 3，转动阀 6，同时开始计时，当时间到达 10s 后，关闭阀门 6，读取汞柱高度差 $p_1(\text{mmHg})$ ；当计时达到 45s 时打开阀 6，计时达到 60s，再次切断阀门 6，读取汞柱差 $p_2(\text{mmHg})$ 。

3) 根据公式 $\Delta p = p_2 - p_1$ 求解瓦斯放散初速度 Δp 。

3. 煤的坚固性系数

测定方法：从暴露的新煤层的上中下部分各取块度为 10cm 样品，将煤块制成 20-30mm 小块，以每份 50 克分成 5 份。

使用重 2.4kg 重锤在 600mm 高度自由落体冲击样本，每份冲击 3 次。

将 5 份样本倒入孔径为 0.5mm 筛子，筛分至不漏煤粉后，将筛出粉末倒入计量筒，记录高度 $h(\text{mm})$ ，利用公式 (5.2) 计算煤的坚固性系数 f 。

$$f = \frac{20n}{h} \quad (5.2)$$

式中 n 为敲击煤样次数, h 为煤粉高度。

4. 瓦斯涌出量

瓦斯涌出量通过暴露煤壁涌出瓦斯含量以及破落煤壁涌出瓦斯含量两部分来进行计算的, 公式如下:

$$q = q_1 + q_2 \quad (5.3)$$

$$q_1 = D \times V \times q_0 \times \left(2\sqrt{\frac{L}{V}} - 1 \right) \quad (5.4)$$

$$q_2 = S \times V \times \gamma \times (W_0 - W_c) \quad (5.5)$$

其中, q 掘为所求的瓦斯涌出量; q_1 为所求煤层的煤壁瓦斯涌出量; q_2 为该处煤层中落煤瓦斯涌出量; D 为巷道断面内暴露煤壁面周边长度; V 掘为巷道平均掘进速度; L 掘为所求掘进工作面的煤巷长度; q_0 为煤壁瓦斯涌出初速度; S 为掘进煤巷断面积; γ 为容重。

5. 钻屑量

钻屑量测量方法使用重量法。先在工作面煤体上钻出小孔, 小孔直径为 42mm, 钻孔深度在 8-10m, 对钻孔时获得的煤屑进行收集, 钻孔深度每深入 1m 计量获得煤屑重量, 对比每次称重煤屑重量, 选择最大煤屑重量作为最后的钻屑量。

6. 声发射事件数

本文声发射测试仪器使用型号为 SAEU2S-200 的多通道声发射检测仪, 该仪器由声发射采集箱和笔记本电脑组成, 通过 USB 与电脑实现通信, 使用方便, 能够进行多通道数据采集, 根据要求可实现 1-200 个通道声发射数据采集, 仪器设备如图 5.2 所示。



图 5.2 声发射检测仪
Figure5.2 Acoustic emission detector

6. 电磁辐射强度

电磁辐射测量使用 KBD5 矿用本安型电磁辐射监测仪，该监测仪可自动完成煤矿电磁辐射信号进行定向接收、数据采集、转换、处理、显示及储存等。监测仪装置如图 5.3 所示。



图 5.3 电磁辐射监测仪
Figure5.3 Electromagnetic radiation monitor

5.3 煤与瓦斯突出预测指标降维处理

本次实验数据取自该煤矿的 1376 综采工作面，采矿工作面平均走向长度为 732 米，平均倾斜长度为 181 米，煤层平均厚度为 3.5 米。工作面地质构造较为复杂，顶板稳定性较差，所受压力较大，容易破碎脱落。从该煤矿监测数据及历史记录数据中选择 100 组代表性数据作为原始数据集，随机取 90 组作为突出预测的训练样本，剩余 10 组数据作为预测的测试样本。数据中煤体破坏类型一共五种使用 1~5 代替，地质改造复杂度使用 0~3 代表无、简单、中等和复杂。煤与瓦斯突出危险分为 1~4 四个等级，数字越大危险性越大。数据指标包括：瓦斯压力 $x_1(MPa)$ 、瓦斯含量 $x_2(m^3/t)$ 、瓦斯放散初速度 $x_3(L/min)$ 、煤体坚固系数 x_4 、煤体破坏类型 x_5 、软分层厚度 $x_6(m)$ 、开采深度 $x_7(m)$ 、地质构造 x_8 、地应力 $x_9(MPa)$ 、煤层厚度 $x_{10}(m)$ 、钻屑量 $x_{11}(kg/m)$ 、煤层倾角 $x_{12}(^\circ)$ 、声发射事件数 x_{13} 、电磁辐射强度 $x_{14}(mV)$ 、瓦斯涌出量 $x_{15}(m^3/min)$ 。部分数据如表 5.3：

表 5.3 部分原始数据
Table5.3 Part of the original data

| 编 号 | x_1 MPa | x_2 m^3/t | x_3 L/min | x_4 | x_5 | x_6 m | x_7 m | x_8 | x_9 MPa | x_{10} m | x_{11} kg/m | x_{12} $^\circ$ | x_{13} 次 | x_{14} mV | x_{15} m^3/min | 危 险 指 数 |
|-----|--------------|------------------|----------------|-------|-------|------------|------------|-------|--------------|---------------|------------------|----------------------|---------------|----------------|-----------------------|---------|
| 1 | 2.28 | 8.3 | 15 | 0.39 | 3 | 1.9 | 598 | 2 | 11.2 | 1.79 | 8.24 | 13.5 | 426 | 106 | 6.5 | 2 |
| 2 | 1.34 | 8.7 | 4.5 | 0.71 | 3 | 2.8 | 512 | 3 | 6.5 | 2.14 | 2.36 | 8.7 | 321 | 74 | 4.3 | 2 |

| | | | | | | | | | | | | | | | | |
|----|------|-----|------|------|---|-----|-----|---|------|------|------|------|-----|-----|-----|---|
| 3 | 1.69 | 6.9 | 10.6 | 0.28 | 3 | 4.2 | 582 | 1 | 11.6 | 4.57 | 4.89 | 11.3 | 765 | 158 | 5.8 | 3 |
| 4 | 3.69 | 9.7 | 11.8 | 0.35 | 2 | 5.8 | 756 | 2 | 15.3 | 3.24 | 8.67 | 12.6 | 689 | 197 | 6.8 | 4 |
| 5 | 2.27 | 5.9 | 7.8 | 0.47 | 2 | 1.3 | 483 | 1 | 5.8 | 2.18 | 4.56 | 7.3 | 216 | 104 | 3.2 | 1 |
| 6 | 0.81 | 7.3 | 7.6 | 0.36 | 3 | 3.2 | 395 | 3 | 17.4 | 2.57 | 6.79 | 9.2 | 568 | 201 | 4.2 | 3 |
| 7 | 3.72 | 9.5 | 13.5 | 0.47 | 5 | 3.4 | 876 | 2 | 14.2 | 4.13 | 7.16 | 9.5 | 842 | 187 | 7.8 | 4 |
| 8 | 1.64 | 5.6 | 4.9 | 0.49 | 3 | 17 | 539 | 3 | 3.8 | 1.68 | 3.16 | 6.7 | 156 | 26 | 2.4 | 1 |
| 9 | 1.19 | 9.2 | 8.44 | 0.49 | 4 | 2.9 | 677 | 2 | 13.7 | 2.36 | 5.64 | 12.6 | 367 | 124 | 2.8 | 3 |
| 10 | 3.85 | 8.3 | 7.6 | 0.38 | 2 | 2.7 | 864 | 3 | 16.1 | 4.27 | 6.89 | 10.4 | 518 | 236 | 5.6 | 4 |

对煤与瓦斯突出监测数据使用 SKPCA 方法进行处理，步骤如下：

（1）将煤矿监测的煤与瓦斯突出预测原始数据列成 $n \times m$ 的二维矩阵 X ， n 为样本数等于 100， m 为输入指标 15。

$$X = \begin{bmatrix} a_{11} & \cdots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nm} \end{bmatrix} \tag{5.1}$$

煤与瓦斯突出原始预测数据存在各指标大小数量级不一致的问题，直接进行计算会产生很大的误差。需要对原始数据进行标准化处理，煤与瓦斯突出数据指标都为正值，本文使用最小最大规范化将各指标大小线性变换到[0,1]区间，计算公式如下：

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \tag{5.2}$$

式中 x_{\max}, x_{\min} 为煤与瓦斯突出数据不同指标各自的最大和最小值， x_i 为原始数据指标数值， x'_i 为指标归一化后数值。

（2）对归一化后数据使用核函数进行数据高维映射，本文选择高斯径向基核函数计算核矩阵，该核函数理论上可以将数据映射到无限维，对瓦斯突出非线性数据有很好的处理效果，表达式如第三章公式 (3.14)，设定核函数超参数为 100，计算核矩阵 $K_{ij} = K(x_i, x_j)$ 。对核矩阵进行中心化处理得到矩阵 \tilde{K}_{ij} 。计算核矩阵 \tilde{K}_{ij} 特征值 λ 和特征向量 α 。根据第三章公式 (3.16) 计算特征值累计贡献率如表 5.4：

表 5.4 前 5 项主成分贡献率
Table5.4 Contribution rate of the top 5 principal components

| 主成分 | 方差贡献率/% | 累计贡献率/% |
|-----|---------|---------|
| 1 | 52.76 | 52.76 |
| 2 | 21.78 | 74.54 |
| 3 | 10.02 | 84.56 |
| 4 | 5.85 | 90.41 |

由表可以看出前四项主成分累计贡献率达到 90%以上。因此选择前 4 项主成分作为预测指标。

(3) 主成分进行稀疏化, 前 4 个主成分载荷向量即为特征向量 $A = [\alpha_1, \alpha_2, \alpha_3, \alpha_4]$ 。使用核矩阵 \tilde{K}_{ij} 求解弹性网回归问题:

$$\beta_u = \operatorname{argmin}(\alpha_u - \beta)^T \tilde{K}_{ij}^T \tilde{K}_{ij} (\alpha_u - \beta) + \lambda \|\beta\|^2 + \lambda_{4,u} \|\beta\|_1 \quad (5.3)$$

对求出的 $B = [\beta_1, \beta_2, \beta_3, \beta_4]$, 计算奇异值分解, $\tilde{K}_{ij}^T \tilde{K}_{ij} B = U D V^T$, 然后更新 $A = U V^T$ 。重复优化载荷向量, 直到收敛。对获得载荷向量进行标准化。

$$\hat{V}_u = \frac{\beta_u}{\|\beta_u\|} \quad u = 1, 2, 3, 4 \quad (5.4)$$

\hat{V}_u 为稀疏后的载荷向量。计算主成分 $X_u = V_u^T \tilde{K}_{ij}$, $u=1, 2, 3, 4$, X_u 为稀疏核主成分分析后的最终主成分, 四个主成分指标记为 $X1$ 、 $X2$ 、 $X3$ 、 $X4$ 。稀疏核主成分分析处理后得到 10 组部分数据主成分数据如表 5.5 所示。

表 5.5 主成分数据
Table5.5 Principal component data

| 编号 | X1 | X2 | X3 | X4 |
|----|--------|--------|--------|--------|
| 1 | -0.115 | -0.038 | -0.036 | 0.0128 |
| 2 | -0.042 | -0.067 | -0.002 | -0.055 |
| 3 | -0.027 | -0.009 | -0.188 | 0.0350 |
| 4 | 0.1315 | 0.1555 | 0.0201 | 0.1564 |
| 5 | -0.113 | 0.0858 | 0.0285 | -0.064 |
| 6 | -0.023 | 0.0322 | -0.145 | -0.089 |
| 7 | 0.2436 | -0.004 | 0.1935 | 0.0745 |
| 8 | -0.111 | 0.0060 | -0.011 | -0.082 |
| 9 | 0.0052 | -0.149 | -0.089 | 0.0110 |
| 10 | 0.0826 | 0.0758 | 0.0909 | 0.1540 |

5.4 煤与瓦斯突出 NEAT 网络搭建及训练

5.4.1 个体适应度函数

本文数据共 100 组样本, 瓦斯突出危险性分为 1~4 类, 根据数据情况设定适应度函数中 Z 常数为 100, 迭代次数设为 300, 适应度阈值设为 99, 种群进化达到 300 代或适应度达到 99 将停止迭代。

实际调参后动态参数 λ^m 权重 r 设为 0.95, 常数 V 设为 20, 使得对瓦斯突出数据训练

时进化前期几十代动态参数较大能够均衡适应度差别，种群在全局开始寻优，避免出现局部最优解，100 代后动态参数趋于零对最终适应度没有影响。计算个体适应度，当预测值越接近实际值时适应度 F 越大。

5.4.2 NEAT 网络参数设置

NEAT 网络神经元的激励函数，在进化过程中也能够突变为其他函数，能够进一步优化网络。输出危险性分 1~4 四个等级，根据第四章对激活函数分析，本模型中初始激励函数选择 ELU 函数，如第四章公式 4.5，系数 a 设为 1，突变函数选择 ELU、Sigmoid、Tanh 和 Relu 函数，突变概率为 0.1。神经元输入计算方法本模型中初始方法使用求和，可突变为求和、平均值、最大值，突变概率为 0.1。

设置种群中适应度最大个体代表种群适应度，种群适应度变化停滞超过 20 代将被移除，但适应度最大的 2 个种群不受其影响，从而保护适应度最高种群，淘汰优化停滞种群。根据瓦斯突出数据和调试情况设定参数如下表 5.6:

表 5.6 网络参数设定
Table 5.6 Network parameter setting

| 参数 | 设定值 | 参数作用 |
|---|-----------------------|----------------------|
| <i>num_hidden</i> | 0 | 初始隐含层个数 |
| <i>num_inputs</i> | 4 | 初始输入层个数 |
| <i>num_outputs</i> | 1 | 初始输出层个数 |
| <i>fitness_threshold</i> | 100 | 终止迭代阈值 |
| <i>pop_size</i> | 200 | 个体总数 |
| <i>activation_default</i> | ELU | 默认激活函数 |
| <i>activation_mutate_rate</i> | 0.1 | 激活函数突变概率 |
| <i>activation_options</i> | ELU Relu Tanh Sigmoid | 可突变激活函数 |
| <i>aggregation_default</i> | sum | 默认神经元各输入计算方法 |
| <i>aggregation_mutate_rate</i> | 0.1 | 突变概率 |
| <i>aggregation_options</i> | sum max mean | 可突变计算方法 |
| <i>compatibility_disjoint_coefficient</i> | 1 | 差异距离系数 c_1 , c_2 |
| <i>compatibility_weight_coefficient</i> | 0.5 | 差异距离系数 c_3 |
| <i>conn_add_prob</i> | 0.5 | 新增连接概率 |
| <i>conn_delete_prob</i> | 0.5 | 删除连接概率 |
| <i>node_add_prob</i> | 0.2 | 新增节点概率 |
| <i>node_delete_prob</i> | 0.2 | 删除节点概率 |

5.4.3 训练 NEAT 网络

在 python 软件上搭建 NEAT 网络，设定参数后将经 SKPCA 方法降维后四维主成分数据 X_1 、 X_2 、 X_3 、 X_4 作为算法输入，设置神经网络从最简单没有隐含层网络开始优化，网络训练速度更快，隐含层与连接结构由 NEAT 算法自我进化。将模型输出与实际危险指数一样分为四类：小于 1.5 设为危险指数 1；大于 1.5 小于 2.5 设为危险指数 2，大于 2.5 小于 3.5 设为危险指数 3，大于 3.5 设为危险指数 4。

使用 NEAT 算法对神经网络进行 300 代优化。训练时种群差异距离阈值的设定如果偏大会使种群个数过小，偏小会划分出过多种群使各种群中个体数太少，不利于种群内进行遗传操作，针对本文瓦斯突出数据，通过调节差异距离阈值将其设为 2.8 时种群优化效果最好。得出各种群变化情况如图 5.4，纵坐标不同颜色高度代表种群中个体数，所有种群个体总数为 200，从图中可以看出模型刚开始种群较少，之后逐渐增多，稳定之后种群个数有减少趋势，适应度最高种群始终保持稳定个体数量，没有出现适应度高的种群个体数太多的情况，始终保持着网络结构的“物种多样性”。

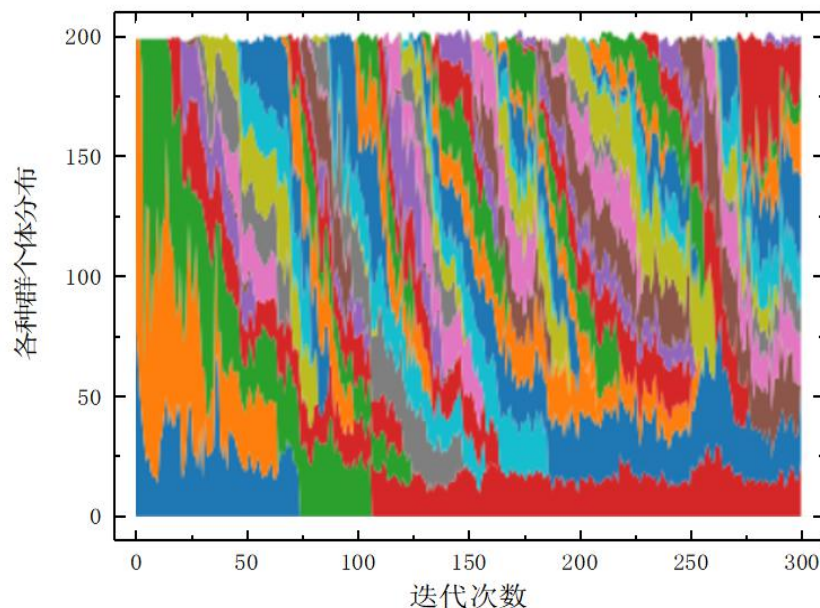


图 5.4 种群中个体分布图

Figure 5.4 Distribution map of individuals in the population

输入煤与瓦斯突出数据，对神经网络结构进行 300 代训练优化后，画出最终优化后神经网络结构如图 5.5。




图 5.5 优化后神经网络网络结构图
Figure5.5 Optimized neural network network structure diagram

图中矩形为输入数据，空白圆形为隐含层，实线表示权值大于零，虚线表示权值小于零，线条宽度和箭头大小代表权值大小。可以看出网络并非全连接，结构更加简洁，但却包含多层网络结构，网络参数相比于多层感知器的神经网络少很多，能够避免瓦斯突出预测时存在的过拟合现象，提高模型预测能力。

统计 NEAT 算法 300 代训练每一代中所有个体的平均适应度和最佳适应度。适应度变化情况如图 5.6 所示：

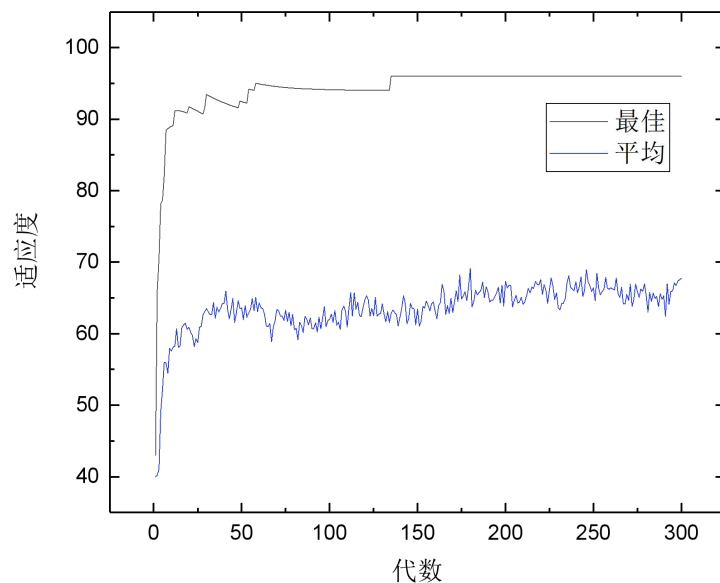


图 5.6 种群适应度进化曲线
Figure5.6 Evolutionary curve of population fitness

从图中可以看出由于设置的动态适应度参数，如果前期连续几代适应度没有提升，会出现最佳适应度部分下降的趋势，但能够保证种群在全局开始优化，在进行瓦斯突出预测时避免出现局部最优解的情况：后期适应度较平稳，动态参数影响效果消失。种群刚开始进化速度很快，60 代后最佳适应度就达到高水平，适应度趋于平稳，表明该方法收敛速度快，130 代时又有细微的增加，表明网络优化能力更强，最终适应度达到 95 以上可以看出网络预测准确度高。种群的平均适应度也呈现不断增加趋势，说明种群通过优胜劣汰，整体的预测能力向着好的方向发展。

5.5 模型预测结果及对比分析

为了避免偶然误差，重复三次从 100 组数据中随机选取 90 组数据输入模型训练神经网络，训练好模型后输入剩余 10 组测试数据预测结果，获得 30 组测试数据预测结果与数据真实值对比如图 5.7，图中五角星为预测危险指数，正方形为真实危险指数，重叠则为预测正确，没有重叠为预测错误。




图 5.7 SKPCA-NEAT 模型危险指数预测结果图

Figure 5.7 SKPCA-NEAT model risk index prediction result graph

从图中可以看出，该模型对 30 组测试数据进行预测，只有一组数据危险指数预测不准确，预测准确度达到 96.6%。因此，基于稀疏核主成分分析与 NEAT 算法的煤与瓦斯突出预测模型达到了预测准确度要求，能够准确预测瓦斯突出危险性。

为了验证稀疏核主成分分析与增强拓扑神经进化算法相比于其他方法有更好的预测效果。同时搭建 SKPCA-BP 神经网络模型、PCA-NEAT 模型和 SKPCA-GA 遗传神经网络模型，同样进行 30 组测试数据危险指数预测，SKPCA-BP 模型预测结果如图 5.8，PCA-NEAT 模型预测结果如图 5.9，SKPCA-GA 遗传神经网络模型如图 5.10：

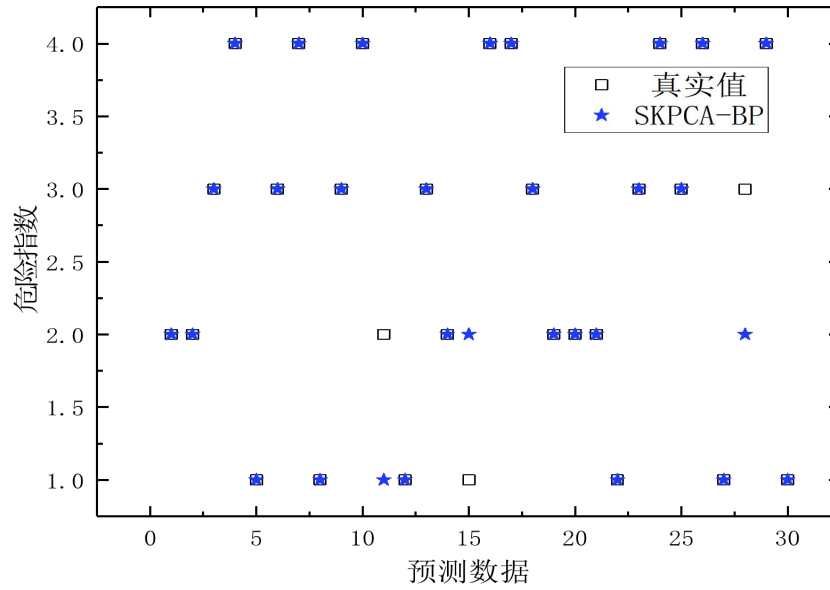


图 5.8 SKPCA-BP 模型危险指数预测结果图
Figure5.8 SKPCA-BP model risk index prediction result graph

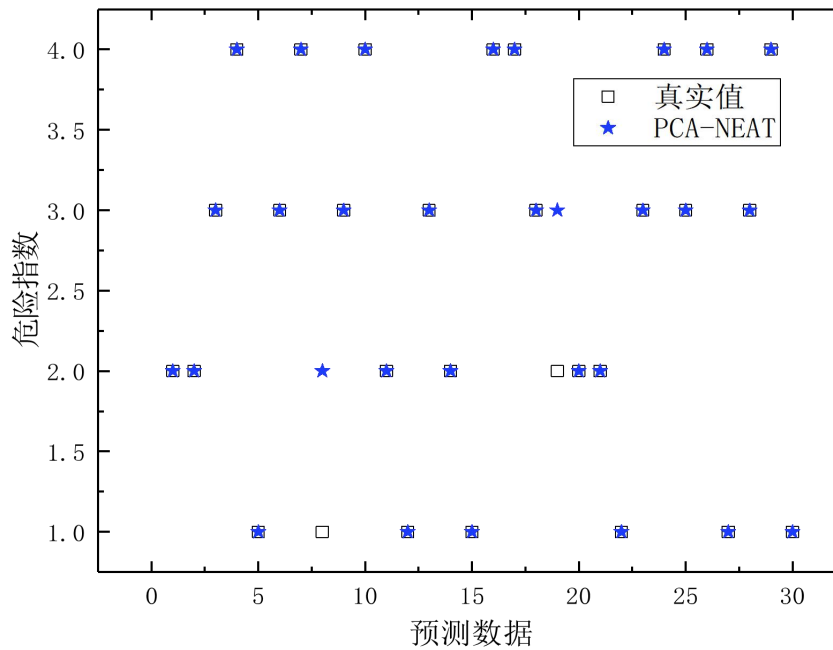


图 5.9 PCA-NEAT 模型危险指数预测结果图
Figure5.9 PCA-NEAT model risk index prediction result graph




图 5.10 SKPCA-GA 模型危险指数预测结果图

Figure5.10 SKPCA-GA model risk index prediction result graph

从图中可以看出，30 组预测数据 SKPCA-BP 模型有三次预测不准确，准确度为 90%，PCA-NEAT 模型有两处预测不准确，准确度 93.3%，SKPCA-GA 神经网络模型也有两处预测不准确，准确度 93.3%，模型预测准确度均不如 SKPCA-NEAT 模型。

对四种模型分别进行 300 代优化，输入 30 组测试数据，计算各代的均方根误差 RMSE，均方根误差计算公式如下：

$$RSME = \sqrt{\frac{\sum_{i=1}^n (X_{obs,i} - X_{model,i})^2}{n}} \quad (5.5)$$

其中 X_{obs} 为预测值， X_{model} 为真实值，RSME 变化如图 5.11：

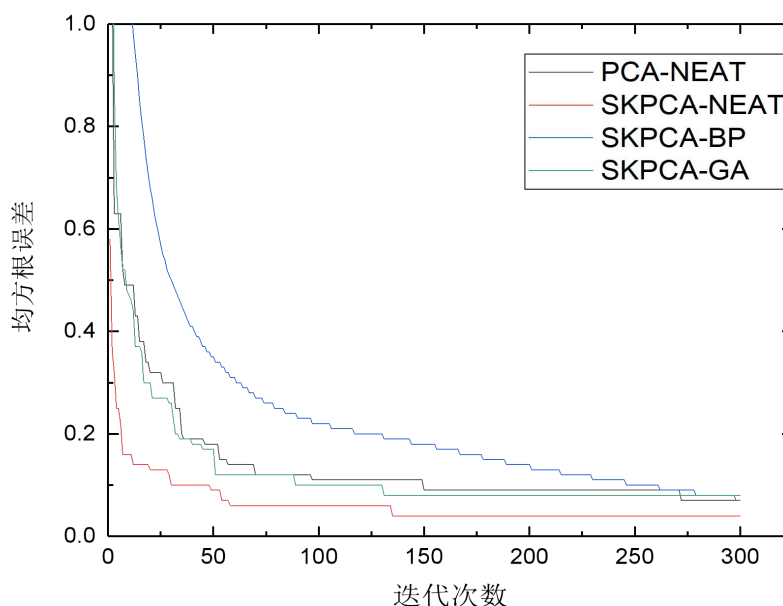


图 5.11 四种模型 RMSE 变化图

Figure5.11 RMSE diagram of four models

从图中可以看出 SKPCA-NEAT 模型收敛的速度最快；PCA-NEAT、SKPCA-GA 模型收敛速度相近，收敛速度慢于 SKPCA-NEAT 模型；SKPCA-BP 模型使用误差反向传播方法优化参数，收敛曲线较为平缓。SKPCA-NEAT 模型相比于其他三种预测模型收敛速度更快，均方根误差更小。由此可以得出 SKPCA 方法相比于 PCA 方法，在煤与瓦斯突出数据降维处理上有更好的效果。NEAT 神经网络模型训练速度更快，准确度更佳。NEAT 算法同时优化网络参数与连接结构，相比 GA 算法只能优化神经网络权值具有更好的神经网络优化效果，能够提高煤与瓦斯突出预测精度。

将未经处理原始数据、经 PCA 处理和经 SKPCA 处理后数据输入模型训练，对比 BP、PCA-BP、SKPCA-BP、NEAT、PCA-NEAT 和 SKPCA-NEAT 模型，同样进行 3 次 100 组数据预测，分别计算各模型训练时 270 组数据和测试时 30 组数据的预测错误率进行对比，如图 5.12:

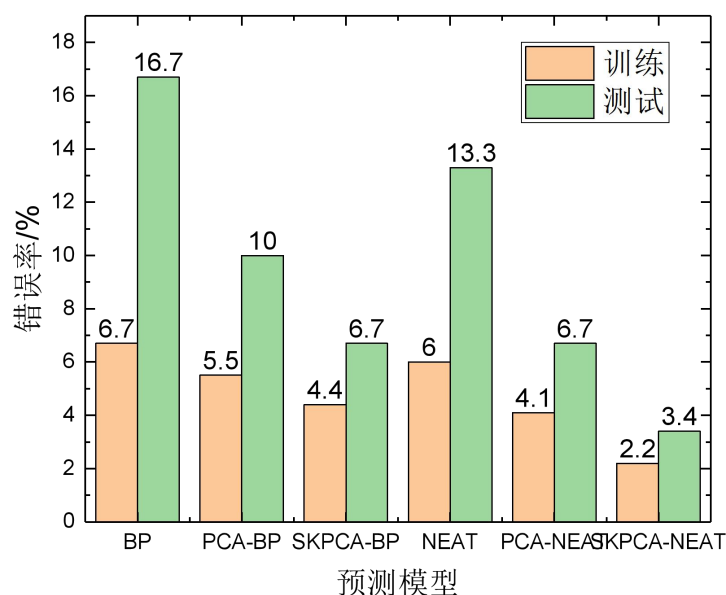


图 5.12 各模型训练和测试时错误率对比图

Figure 5.12 Comparison of error rate of each model training and test

从上图中可以看出原始数据没有经降维处理，使用 BP 和 NEAT 直接进行预测，训练和预测错误率差距较大，说明输入指标过多，提高了模型复杂度使训练模型出现过拟合现象。经 PCA 数据降维后模型错误率差距有所减小，而经 SKPCA 处理后错误率差距最小。表明 SKPCA 方法通过核函数有效解决了数据的非线性问题，主成分稀疏化方法使各主成分只关联载荷系数较大指标，使主成分数据更加具有代表性，能够提高模型预测泛化能力。

除此之外，本文还与煤与瓦斯突出预测中应用较多的 SVM 算法进行了对比，搭建 PCA-SVM、SKPCA-SVM 模型，具体预测结果如下表 5.5:

表 5.5 支持向量机模型预测结果对比

Table5.5 SVM model prediction results comparison chart

| 预测模型 | 预测准确组数 | 预测错误组数 | 准确度 |
|------------|--------|--------|-------|
| SKPCA-NEAT | 29 | 1 | 96.6% |
| PCA-SVM | 26 | 4 | 86.6% |
| SKPCA-SVM | 27 | 3 | 90.0% |

从表中可以看出 NEAT 神经网络模型较传统的 SVM 模型预测准确度有一定的提升。

综合以上对比可以看出，稀疏核主成分分析方法相比主成分分析具有优势，利用核函数能够很好的处理煤与瓦斯突出数据的非线性问题。利用稀疏化方法，使每个主成分只保留各自关联原始数据中最主要指标信息。稀疏核主成分方法进行煤与瓦斯突出数据处理能够使获得的主成分反映出原始数据中的信息，提高模型准确度，同时避免出现过拟合，对提升模型泛化能力有一定作用。增强拓扑神经进化算法（NEAT）利用遗传进化算法优化神经网络权值参数和连接结构，能够提高神经网络优化效果，在避免出现过拟合的同时提高神经网络预测能力，利用动态个体适应度函数能够进一步解决局部最优解情况。SKPCA-NEAT 模型能够应用于煤与瓦斯突出预测领域。

5.6 本章小结

本章对煤矿数据进行标准化后使用稀疏核主成分分析法进行处理，将原始 15 维指标降为 4 维主成分数据。搭建 SKPCA-NEAT 预测模型，设定网络参数，将主成分数据输入模型进行训练和预测，与其他模型预测结果对比，结果表明该模型预测精度高，对瓦斯突出数据预测能力强。

6 结论与展望

6.1 结论

煤与瓦斯突出是煤矿生产过程中危害性巨大的煤矿安全事故之一。我国煤矿采掘深度不断向更深处发展，深部矿井瓦斯突出影响因素更加复杂，瓦斯突出预测也更加艰难，煤与瓦斯突出预警的研究仍是当前安全防护的重点。

本文对煤与瓦斯突出机理和影响因素进行分析，总结出瓦斯突出主要受瓦斯因素、煤体因素、地质构造及地应力因素这四个主要方面影响，从这四个方面出发共选取 15 种二级瓦斯突出预测参数作为最终预测指标。在此基础上提出使用稀疏核主成分分析法对预测指标进行数据处理，使用增强拓扑神经进化算法进行瓦斯突出预测。构建基于 SKPCA 和 NEAT 算法的煤与瓦斯突出多指标预测模型。本文主要结论如下：

针对煤与瓦斯突出数据的非线性问题，使用核函数进行高维映射再提取主成分，主成分数据能够保留更多的原始数据信息，避免主成分降维后信息丢失。由于各主成分线性组合系数中存在近于零的系数，这些指标含有的对应主成分信息较少，相互作用反而会影响最终模型的预测能力。利用主成分稀疏化方法对主成分数据负载因子进行稀疏化，能够减少煤矿监测数据的噪声干扰，使提取出主成分数据更具代表性，从数据方面减少预测模型复杂度，提高模型泛化能力。

传统神经网络优化方法只能够优化网络权值参数，在瓦斯突出预警上准确度有限且容易出现过拟合现象。本文将增强拓扑神经进化算法（NEAT）应用于瓦斯突出预测，通过对网络结构进行基因编码，利用遗传进化算法原理对神经网络权值和连接拓扑结构进行寻优。引入动态个体适应度参数，避免了前期适应度差距较大，种群不能够在全局内开始寻优的问题。将神经网络结构由全连接转变为自我构建，能够有效减少网络复杂度，避免过拟合现象，提高网络预测能力。

构建 SKPCA 与 NEAT 算法的煤与瓦斯突出预测模型，设置网络优化参数及适应度函数后进行训练。将预测结果与 SKPCA-BP、PCA-NEAT、SKPCA-GA 和 SVM 预测结果进行对比。结果表明 SKPCA 方法对煤与瓦斯突出监测数据的处理效果优于 PCA 方法，NEAT 方法较 GA 优化方法能够更好优化神经网络模型。SKPCA-NEAT 方法具有收敛速度快、预测精度高、泛化能力强的优点。

6.2 展望

（1）煤与瓦斯突出机理仍处于假说阶段，还需进行深入研究，总结出具体影响因素，进而提出更加高效的预测方法。

（2）随着科学技术的发展，越来越多的机器学习及优化算法被提出，在各个领域被

广泛应用。由于煤与瓦斯突出机理的复杂，传统的预警方法效果有限，通过对煤矿问题的深入研究，合理的将机器学习和深度学习等高效预测方法应用于煤矿安全预警上，能够有效的减轻煤矿灾害，保障工作人员的生命财产安全。

（3）预测指标数据在测量上很多都需要较长时间，不能够保证时效性，采集预测数据在保证准确度的情况下，需要使用更加快速的测量方法。利用更加及时有效的数据提高模型预测效果。

（4）随着煤矿采集数据越来越多，对大量原始采集数据的清洗、提取等需要耗费大量时间精力。可以将大数据处理框架应用于煤矿数据处理中，使用分布式处理方法提高数据处理速度。

参考文献

- [1] 秦容军.我国煤炭开采现状及政策研究[J].煤炭经济研究,2019,39(01):57-61.
- [2] 孙喜民.煤炭工业高质量发展方略研究与实践[J].煤炭工程,2019,51(01):152-156.
- [3] 徐青云,赵耀江,李永明.我国煤矿事故统计分析及其今后预防措施[J].煤炭工程,2015,47(03):80-82.
- [4] Jun Tang, Chenglin Jiang, Yujia Chen, Xiaowei Li, Gongda Wang, Dingding Yang. Line prediction technology for forecasting coal and gas outbursts during coal roadway tunneling[J]. Journal of Natural Gas Science and Engineering, 2016, 34.
- [5] 张仁松,卜珍虎.不同突出煤层区域预测临界值指标的确定[J].煤炭技术,2018,37(11):178-180.
- [6] 马云波. 武甲煤矿掘进工作面煤与瓦斯突出危险预警及可视化研究[D].中国矿业大学,2017.
- [7] 王建国,傅文,刘颖.2012—2016 年我国煤矿较大以上瓦斯事故发生规律分析研究[J].矿业安全与环保,2018,45(06):108-111+116.
- [8] 宁小亮.2013—2018 年全国煤矿事故规律分析及对策研究[J].工矿自动化,2020,46(07):34-41.
- [9] 潘一山. 煤与瓦斯突出、冲击地压复合动力灾害一体化研究[J]. 煤炭学报. 2016, 41(01): 105-112.
- [10] 尹光志, 李星, 鲁俊, 等. 深部开采动静载荷作用下复合动力灾害致灾机理研究[J]. 煤炭学报. 2017(09): 2316-2326.
- [11] 牟全斌. 我国煤与瓦斯突出区域预测方法研究现状及展望[J]. 煤炭科学技术. 2014, 42(11): 59-63.
- [12] 鲁俊, 尹光志, 高恒, 等. 真三轴加载条件下含瓦斯煤体复合动力灾害及钻孔卸压试验研究[J]. 煤炭学报. 2019: 1-13.
- [13] Wang K, Du F. Coal-gas compound dynamic disasters in China: A review[J]. Process Safety and Environmental Protection. 2020, 133: 1-17.
- [14] 齐庆新, 潘一山, 舒龙勇, 等. 煤矿深部开采煤岩动力灾害多尺度分源防控理论与技术架构[J]. 煤炭学报. 2018, 43(07): 1801-1810.
- [15] 刘璐璐. 基于声发射多参数的煤与瓦斯突出风险预测研究[D].辽宁工程技术大学,2018.
- [16] 邹银辉.煤岩声发射机制初探[J].矿业安全与环保,2004,31(1):31-34.
- [17] 夏善奎. 煤与瓦斯突出演化过程声电信号时频特征研究[D].中国矿业大学,2019.
- [18] 何学秋, 陈庆禄. 电磁辐射法预测突出危险性技术及便携式装备的研究[Z].国家重点科技项目（攻关）计划子专题工作报告.徐州:中国矿业大学,2000.
- [19] 杨国梁. 煤与瓦斯突出预测指标敏感性判定方法的研究及其区域临界值的确定[D].太原理工大学,2010.
- [20] 张登峰.单项指标法鉴定煤与瓦斯突出危险性应用[J].煤炭科技,2018(02):130-131+142.
- [21] 韩建设, 刘军, 黄元乐, 尤海军. 单项指标法鉴定煤与瓦斯突出性的成功应用[J]. 煤炭科技, 2017(01): 64-67.

- [22] Lichtenberger M. Underground Measurements of Electromagnetic Radiation Related to Stress-induced Fractures in the Odenwald Mountains (Germany) [J]. Pure and Applied Geophysics, 2006, 163(08): 1661.
- [23] 陈鹏. 煤与瓦斯突出区域危险性的直流电法响应及应用研究[D]. 北京: 中国矿业大学, 2013.
- [24] 邱微. 基于 KPCA 与改进极限学习机的煤与瓦斯突出预测研究[D]. 辽宁工程技术大学, 2019.
- [25] 刘方园, 王水花, 张煜东. 支持向量机模型与应用综述[J]. 计算机系统应用, 2018, 27(04): 1-9.
- [26] 杨荣明, 陈长华, 李海霞. 煤与瓦斯突出预测模型仿真研究[J]. 计算机仿真, 2016, 33(09): 435-439.
- [27] 郑丽媛, 孙朋, 张素君. 煤矿瓦斯突出预测的 PSO-LSSVM 模型[J]. 仪表技术与传感器, 2014(06): 138-140+143.
- [28] 吴雅琴, 李惠君, 徐丹妮. 基于 IPSO-Powell 优化 SVM 的煤与瓦斯突出预测算法[J]. 工矿自动化, 2020, 46(04): 46-53.
- [29] 孙艳玲, 秦书玉, 梁宏友. 煤与瓦斯突出预报的模糊聚类关联分析法 [J]. 辽宁工程技术大学学报, 2003, 12(04): 492-493.
- [30] 朱志洁, 张宏伟, 刘鑫. 基于模糊模式识别的矿井动力灾害预测[J]. 自然灾害学报, 2014, 23(04): 19-25.
- [31] 曲方, 张龙, 李迎业, 李忠群. 基于 BP 神经网络的煤与瓦斯突出预测系统开发[J]. 中国安全科学学报, 2012, 22(01): 11-16.
- [32] 朱志洁, 张宏伟, 韩军, 宋卫华. 基于 PCA-BP 神经网络的煤与瓦斯突出预测研究[J]. 中国安全科学学报, 2013, 23(04): 45-50.
- [33] 付华, 王馨蕊, 王志军, 王雨虹, 屠乃威, 徐耀松. 基于 PCA 和 PSO-ELM 的煤与瓦斯突出软测量研究[J]. 传感技术学报, 2014, 27(12): 1710-1715.
- [34] 宁小亮. 煤与瓦斯突出预警技术研究现状及发展趋势[J]. 工矿自动化, 2019, 45(08): 25-31+37.
- [35] 张酉年. 掘进工作面煤与瓦斯突出声电瓦斯预警指标优化研究与应用[D]. 中国矿业大学, 2019.
- [36] 郭品坤. 煤与瓦斯突出层裂发展机制研究[D]. 中国矿业大学, 2014.
- [37] 赵希栋. 掘进巷道蝶型煤与瓦斯突出启动的力学机理研究[D]. 中国矿业大学(北京), 2017.
- [38] Lehua Xu, Chenglin Jiang. Initial desorption characterization of methane and carbon dioxide in coal and its influence on coal and gas outburst risk[J]. Fuel, 2017, 203.
- [39] Yanlu Ding, Zhongqi Quentin Yue. An experimental investigation of the roles of water content and gas decompression rate for outburst in coal briquettes[J]. Fuel, 2018, 234.
- [40] Qi Lingling, Tang Xu, Wang Zhaofeng, Peng Xinshan. Pore characterization of different types of coal from coal and gas outburst disaster sites using low temperature nitrogen adsorption approach[J]. International Journal of Mining Science and Technology, 2017, 27(02): 371-377.
- [41] Sun Dongling, Hu Qianting, Miao Fatian. A Mathematical Model of Coal-gas Flow Conveying In the Process of Coal and Gas Outburst and Its Application[J]. Procedia Engineering, 2011(26): 147-153.

- [42]孙利源. 基于灰色关联分析和 PSO-SVM 的煤与瓦斯突出预测应用研究[D].中国矿业大学,2019.
- [43]侯福营.基于改进 PCA-ELM 的煤与瓦斯突出软测量研究[D].阜新:辽宁工程技术大学,2014.
- [44]陈全秋.遗传算法与神经网络相结合在煤与瓦斯突出危险预测中的应用研究[D].太原:太原理工大学,2010.
- [45]王昱舒.基于 PCA-AKH-BP 神经网络的面域相结合的煤与瓦斯突出预测模型及其应用研究[D].太原:太原理工大学,2017.
- [46]Fenghua An,Yu Yuan,Xiangjun Chen,Zhiqiang Li,Liyang Li. Expansion energy of coal gas for the initiation of coal and gas outbursts[J]. Fuel,2019,235.
- [47]Cheng Wu Li,Tian Bao Gao,Shan Yang Wei,Teng Li. The Impact Analysis of Coal's Elastic Energy on the Coal and Gas Outburst Shock Wave[J]. Advanced Materials Research,2013,2117.
- [48]舒龙勇,王凯,齐庆新,张浪.煤巷掘进面应力场演化特征及突出危险性评价模型[J].采矿与安全工程学报,2017,34(02):259-267.
- [49]魏国营,王保军,闫江伟,王蔚,贾天让,张玉柱.平顶山八矿突出煤层瓦斯地质控制特征[J].煤炭学报,2015,40(03):555-561.
- [50]Lin Chao Dai,Guang Cai Wen,Zhen Liu,Hui Ming Yang,Bo Wang. Analysis of Geological Factors Affecting Coal Seam Gas Content and Prediction[J]. Advanced Materials Research,2013,2203.
- [51]孙宇航. 基于改进模糊支持向量机的煤与瓦斯突出预测[D].中国矿业大学,2019.
- [52]梁跃强. 基于地质数据挖掘和信息融合的煤与瓦斯突出预测方法[D].中国矿业大学(北京),2018.
- [53]李尧斌.瓦斯含量法预测煤与瓦斯突出试验研究[D].安徽理工大学,2013.
- [54]SCHOLLKOPF B, ALEXANDER S, KLAUS R. Nonlinear component analysis as a kernel eigenvalue problem[J]. Neural Computation, 1998, 10(5): 1299-1319.
- [55]ZOU H, HASTIE T, TIBSHIRANI R. Sparse principal component analysis[J]. Journal of Computational and Graphical Statistics, 2006, 15: 265-286.
- [56]陈全秋. 遗传算法与神经网络相结合在煤与瓦斯突出危险预测中的应用研究[D].太原理工大学,2010.
- [57]Dadmehr Rahbari. High Performance Data mining by Genetic Neural Network[J]. Brain: Broad Research in Artificial Intelligence and Neuroscience,2013,4(1-4).
- [58]Chengpeng Bi,Michael C. Saunders,Bruce A. McPheron. Wing Pattern-Based Classification of the Rhagoletis pomonella Species Complex Using Genetic Neural Networks.[J]. International Journal of Computer Science & Applications,2007,4(3).
- [59]Stanley Kenneth O,Miikkulainen Risto. Evolving neural networks through augmenting topologies.[J]. Evolutionary Computation,2002,10(2).
- [60]尤一帆. 遗传进化神经网络算法在分类问题中的设计和研究[D].浙江大学,2011.
- [61]吴雷,刘箴,钱平安,刘婷婷,王瑾,柴艳杰.一种基于 NEAT 的智能体路径规划方法[J].计算机与数字工

程,2018,46(07):1320-1326+140

学位论文原创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果。其他同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文与资料若有不实，愿意承担一切的法律责任。

学位论文作者签名：程业伟

2021 年 6 月 21 日

学位论文数据集

| | | | | |
|---|----------------|---|-----------|----------|
| 关键词* | 密 级* | 中图分类号* | UDC | 论文资助 |
| 煤与瓦斯突出；核主成分分析；主成分稀疏化；NEAT 算法 | 公开 | TB183 | 621.3 | 国家自然科学基金 |
| 学位授予单位名称* | 学位授予单位代码* | 学位类别* | 学位级别* | |
| 辽宁工程技术大学 | 10147 | 工学 | 硕士 | |
| 论文题名* | | 并列题名* | | 论文语种* |
| 基于 SKPCA 与 NEAT 算法的煤与瓦斯突出预测研究 | | Research on Prediction of Coal and Gas Outburst Based on SKPCA and NEAT Algorithm | | 中 文 |
| 作者姓名* | 程业伟 | 学 号* | 471820303 | |
| 培养单位名称* | 培养单位代码* | 培养单位地址 | 邮 编 | |
| 辽宁工程技术大学 | 10147 | 辽宁省阜新市 | 123000 | |
| 学科专业* | 研究方向* | 学 制* | 学位授予年* | |
| 控制工程 | 智能控制与故障诊断技术 | 2.5 | 2021 | |
| 论文提交日期* | | 2021 年 6 月 | | |
| 导师姓名* | 徐耀松 | 职 称* | 副教授 | |
| 评阅人 | 答辩委员会主席* | 答辩委员会成员 | | |
| | | | | |
| 电子版论文提交格式 文本 () 图像 () 视频 () 音频 () 多媒体 () 其他 () 推荐格式: application/msword; application/pdf | | | | |
| 电子版论文出版 (发布) 者 | 电子版论文出版 (发布) 地 | 权限声明 | | |
| | | | | |
| 论文总页数* | 51 | | | |
| 注: 共 33 项, 其中带*为必填数据, 共 22 项。 | | | | |