

学校代码: 10259

学 号: 196132104

密 级: 公开

上海应用技术大学

硕士学位论文

(专业学位)

题 目: 基于卷积神经网络的污染场地电阻率与
极化率反演

英文题目: Resistivity and polarizability inversion of
pollution sites based on convolutional
neural network

专业领域: 安全工程

学 院: 城市建设与安全工程学院

姓 名: 刘 宇

校内导师: 黄俊革 教授

企业导师: 陈 敏 高级工程师

2021 年 11 月 7 日

声 明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已注明引用的内容外，本论文不包含任何其他个人或集体已经公开发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

本声明的法律责任由本人承担。

学位论文作者签名：刘宇
2021 年 11 月 7 日

基于卷积神经网络的污染场地电阻率与极化率反演

摘要

为了更好地满足污染场地调查的需要,将间接检测的直流电法与人工智能算法相结合,能够有效提高污染场地电阻率与极化率反演成像的准确率和工程勘察的精度。针对现在已有反演方法所遗留的低辨识度、局部最优和场景限定等问题,基于卷积神经网络进行污染场地电阻率与极化率反演技术的研究,具体的研究内容如下:

(1) 利用基于有限单元法的正演模拟软件对设计的典型污染场景进行了数值模拟,总结分析了视电阻率图和视极化率图的特征及规律。并使用该正演方法采集异常体数量、位置、大小和电阻率、极化率值等多种参数组合变化的视电阻率、视极化率数据,建立样本数据库。主要有单一异常体和混合异常体水平位置及深度变化组合的模型共 8 种,以及 5 组电阻率参数变化范围和 2 组极化率参数变化范围。

(2) 基于 PyTorch 深度学习框架构建卷积神经网络,分别设计了用于电阻率、极化率参数反演和视电阻率、视极化率异常体目标检测的模型。经过多次训练,电阻率反演的总精度达到了 92%,极化率达到了 92.8%,目标位置检测的总识别率达到了 90.05%。其中,单一异常体反演的效果比混合异常体反演的效果好,预测值更贴近于真实值。然后将反演模型与传统的 BP 神经网络反演模型进行对比,结果表明电阻率反演模型比 BP 神经网络模型的均方误差(MSE)降低了 $2.42\Omega\cdot m$,极化率反演模型降低了 2.91%。在实际的场地污染试验中,对实地检测得到的数据进行反演,其中目标检测模型能够对明显的异常体目标进行标注,达到了自动识别的预期效果。

(3) 基于卷积神经网络设计了电阻率与极化率双通道联合反演的模型,使反演的精确度提高了 1.6%,证明了使用电阻率与极化率二者相结合的联合反演模式能够有效减小反演的误差,从而提高反演的准确率和辨识度,为污染场地的调查中运用电阻率法、激发极化法进行更高效的检测和更精确的解译提供了解决方案。

关键字: 污染场地; 电阻率; 极化率; 卷积神经网络; 反演成像

Resistivity and Polarizability Inversion of Pollution Sites Based on Convolutional Neural Network

Abstract

In order to better meet the needs of contaminated site surveys, combining the direct current method of indirect detection with artificial intelligence algorithms can effectively improve the accuracy of contaminated site resistivity and polarizability inversion imaging and the accuracy of engineering surveys. Aiming at the problems of low recognition, local optimization and scene limitation left by the existing inversion methods, the inversion technology of resistivity and polarization of contaminated sites based on convolutional neural network was studied. The specific research contents are as follows:

(1) The forward simulation software based on the finite element method was used to numerically simulate the designed typical pollution scene, and the characteristics and laws of the apparent resistivity and apparent polarizability maps were summarized and analyzed. And a sample database was established by using the forward modeling method to collect the apparent resistivity and apparent polarizability data of the number, location, size, resistivity, and polarizability value of anomalies. There are mainly 8 combination models of single anomaly body and mixed anomaly body whose horizontal position and depth change, as well as 5 groups of resistivity parameter variation ranges and 2 groups of polarizability parameter variation ranges.

(2) A convolutional neural network based on the PyTorch deep learning framework was constructed, and the models for the inversion of resistivity and polarizability parameters and the detection of abnormal objects in apparent resistivity and apparent polarizability were designed. After a lot of training, the total accuracy of resistivity inversion has reached 92%, the polarization rate has reached 92.8%, and the total recognition rate of target position detection has reached 90.05%. Among them, the effect of single anomaly inversion is better than that of mixed anomaly, and the predicted value is closer to the true value. Then the inversion model is compared with the inversion model based on BP neural network. The results show that the mean square error (MSE) of the resistivity inversion model is $2.42 \Omega \cdot m$ lower than that of the BP neural network model, and the polarizability inversion model is 2.91% lower than that of the BP neural network model. In the actual site pollution test, the data obtained from the field detection is inverted, and the target detection model can mark the obvious anomaly targets, achieving the expected effect of automatic identification.

(3) Based on the convolutional neural network, a dual-channel joint inversion model of resistivity and polarizability was designed, which increased the accuracy of the inversion by 1.6%. The inversion mode which is the use of a combination of resistivity and polarizability can effectively reduce the inversion error, thereby improving the accuracy and identification of the inversion and providing the solution which has more efficient detection and more accurate interpretation for the use of the resistivity method and the excited polarization

method in the investigation of contaminated sites.

Key words: Polluted site; Resistivity; Polarizability; Convolutional neural network; Inversion imaging

目录

第 1 章 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	1
1.2.1 直流电法在污染场地调查的研究现状	2
1.2.2 电阻率、极化率反演的发展与研究现状	2
1.3 研究内容	3
1.4 主要创新点	4
1.5 章节安排	4
第 2 章 基于有限单元法的电阻率与极化率正演模拟	6
2.1 直流电法	6
2.1.1 电阻率法	6
2.1.2 激发极化法	7
2.1.3 装置类型	7
2.2 有限单元法	8
2.3 数值模拟试验	10
2.3.1 模型设计与单元剖分	10
2.3.2 污染场景的构建	11
2.3.3 典型模型的正演结果	12
2.4 本章小结	15
第 3 章 卷积神经网络和反演模型的构建	16
3.1 神经网络的基本概念	16
3.2 卷积神经网络	17
3.2.1 卷积层	17
3.2.2 池化层	18
3.2.3 全连接层	19
3.3 反演模型的构建	19
3.3.1 张量	19
3.3.2 损失函数	19
3.3.3 正则化	20
3.3.4 构建方法	20
3.4 本章小节	21
第 4 章 基于卷积神经网络的电阻率与极化率反演	22

4.1 反演流程.....	22
4.2 样本数据库的建立.....	23
4.2.1 样本数据的采集.....	23
4.2.2 样本数据的预处理.....	24
4.2.3 目标图像的标定.....	26
4.3 模型的训练与测试.....	27
4.3.1 电阻率与极化率反演.....	27
4.3.2 电阻率与极化率异常目标检测.....	29
4.4 本章小结.....	31
第 5 章 反演模型的应用与评估.....	33
5.1 反演模型的评价.....	33
5.2 反演模型在行道树地下生态环境中检测中的应用.....	33
5.2.1 实地测量.....	34
5.2.2 目标检测.....	36
5.3 模型的优化.....	37
5.3.1 电阻率与极化率联合反演.....	37
5.3.2 反演算法的优化思路.....	38
5.4 本章小结.....	38
第 6 章 结论.....	40
6.1 研究结论.....	40
6.2 研究展望.....	40
参考文献.....	42
致 谢.....	46
攻读学位期间所开展的科研项目和发表的学术论文.....	47

第 1 章 引言

1.1 研究背景及意义

新时代背景下,“人民城市”的创建对城市的治理与发展有着新的更高要求,而土地是城市工作、人民生活的根本。然而,我国较长期以来的经济发展未能够有效地重视环境保护问题,造成了较为严重的污染,尤其是城市工业用地、垃圾填埋场等废弃或搬迁后,产生了大量复杂的污染场地,给人们的健康生活造成了严重的危害^[1]。

污染场地是对生态环境或人身体健康产生危害的地块区域,除了包含基本的水土外,还包括区域内所有的生物和人工构筑物^[2]。然而,为了土地的可持续发展,对污染场地进行治理、修复和再开发是必要的^[3]。而通常在对污染场地进行修复和使用之前,需要对污染场地进行调查,明确污染的范围和程度,以及场地的地质条件等信息;在修复工作完成之后,还要对治理好的场地进行安全风险评估,只有当各项指标都达到要求后,才可进行再次开发和利用^[4-6]。

因此,污染场地的调查与检测是其修复和再利用的前期基础,目前的检测方法主要分为直接分析和间接检测两大类。采用传统的直接分析方法存在一定的局限性,不适合污染物质多样、空间分布离散性大的工业场地,而间接法主要是使用环境物探技术,通过检测土壤和地下水的电场、磁场、温度场等物理性质的变化,间接检测场地的污染情况,具有无损、低成本、效率高、探测范围广等优点^[7-9],常用的检测方法有高密度电法、地质雷达法^[10,11]和大地电磁法^[12]等地球物理勘查技术。而且,由于污染物本身所含有的各种离子、分子之间,或与土壤和地下水等介质发生反应,或通过土壤空隙进行渗透和扩散后,导致水土的导电性和极化效应发生变化,从而引起电阻率、极化率的改变。这些变化的机理使得电阻率法、激发极化法更适应于污染场地的调查研究。

然而,在污染场地的调查和检测中,通过视电阻率、视极化率图像得到污染物的分布状况,主要是利用专业人士进行人工识别的方法,但具有成本高、效率低、准确率低和耗费人力资源等缺点^[13]。因此,通过计算机自动识别视电阻率图和视极化率图,进行人工智能的反演解译和分析场地的污染情况具有重要的意义。目前,人工智能、深度学习技术的快速发展为传统的物探领域带来了新的机遇,能够进一步提高地球物理反演的准确率和辨识度。鉴于卷积神经网络在深度学习中特征提取方面的独特优势^[14],本文将将其引入到直流电法的污染场地检测中,针对电阻率、极化率的反演问题进行从理论到实践的应用性研究。

1.2 国内外研究现状

目前,国内外对于电法勘探的研究和应用已经比较成熟,但采用多种方法进行综合勘探和联合反演仍是地球物理领域中的主要研究方向^[15]。另外,机器学习在地球物理领域中被广泛应用,许多学者一直在相继研究高辨识度的非线性反演方法,有望可以改进

传统方法所遗留的问题,从而提高反演的精度与实际应用能力。因此,将直流电阻率法、激发极化法与人工智能的反演技术相结合应用于污染场地的调查中能够有效解决工程应用中的实际问题。本文旨在研究利用现在机器学习中兴起的深度学习方法来解决电阻率、极化率的反演优化问题,并应用于污染场地的调查中。

1.2.1 直流电法在污染场地调查的研究现状

上世纪 70 年代,世界工业迅猛发展所产生的工业污染场地开始大量出现,发达国家相继出台各种法律法规,对污染物的排放进行严格管理,并对污染场地的调查、治理和修复展开了探索。由于物探方法在场地调查中具有数据收集快、信息量丰富、成本低等优势,因此国外有大量研究人员将传统的物探技术应用到了污染场地的调查中,陈晦鸣^[16]在环境监测激发极化(IP)国际会议述评中提到:匈牙利利用激发极化法对地下水和地表污染进行了探测,加拿大通过激发极化法来测定水土中硫化物的含量,斯洛伐克利用激发极化法调查有毒废料和油气泄漏污染区等;Olivar^[17]通过采用频谱激发极化法追踪地下污染,取得了不错的探测效果;E.Astodemou 等^[18]利用电阻率法和直流激电法在垃圾填埋场中监测污染物,区分出了垃圾填埋场污染的废物类型;Jorge 等^[19]利用电测深法和地质雷达法探测出垃圾填埋场地下污染物的分布情况;Atekwana 等^[20]通过利用二维地质雷达探测的剖面图,确定了场地污染的深度和范围;Liu 等^[21]设计重金属的土壤污染试验发现电阻率随着污染物浓度的升高而呈现出降低的趋势。

国内在调查和治理污染场地方面,已经有学者对使用多种地质环境调查技术检测被污染的水土开展了一系列的研究。例如,李金铭等^[22]通过试验验证了水的导电率和极化率与污染浓度存在一定的关系;能昌信等^[23]通过设计试验测量了含有铬污染土壤的电性和极化特征;张磊^[24]通过试验论证了重金属污染物浓度与极化率之间的关系;程业勋等^[25]分别对比了高密度电法、地质雷达法、瞬变电磁法等综合物探方法对垃圾填埋场渗滤液扩散范围和深度的检测效果,并且通过钻孔验证得出了被垃圾渗滤液污染的水土呈低电阻率的特性。

综上所述,利用电阻率法、激发极化法进行污染场地的调查是可行的,但为了更好地应用于实际工程中,提高其检测和反演成像的准确率和适应性,还有待继续深入的研究。

1.2.2 电阻率、极化率反演的发展与研究现状

从观测参数反推出物理状态的空间变化及物性结构是地球物理研究中的反演问题,而正演模拟是反演研究的基础,并且正演技术相对比较成熟,常用的方法主要有:有限差分法、边界单元法和有限单元法三种^[26]。随着计算机硬件的飞速发展和地球物理实际问题本身具有的复杂性和多解性,使得有限单元法成为主流,目前还有矢量有限元、非结构化网络的自适应有限元等衍生方法^[27]。本文将选用基于有限单元法的正演模拟方法来支撑电阻率、极化率的反演研究。

上世纪初期兴起的电法探测技术^[28],由于数值模拟技术与计算水平的限制,使得反演研究在 50 年之后才逐渐拉开了序幕^[29],直到发展到今天,主要的反演方法有最小二

乘法^[30]、共轭梯度法^[31]、粒子群算法^[32]、人工神经网络^[33,34]和遗传算法^[35]等。电阻率、极化率的反演技术从一维到三维^[36]，从线性到非线性^[37]，从单一方法到多种方法的联合反演，国内外研究学者仍在不断地继续探究更优的反演方法^[38]。其中，深度学习技术是当前各领域中，人工智能反演方法研究的热点，尤其是在图像和语音识别等领域^[39,40]。

电阻率法与激发极化法通常是通过观察视电阻率图和视极化率图来识别目标或异常体的，但因为地下介质电性分布不均匀，高阻体有排斥电流、低阻体有吸引电流的特性，而且还有各种复杂的地质条件和被测物质产生的激发极化效应，使得观测得到的视电阻率图与视极化率图所反映的并不是地质体真实的电阻率和极化率。因此凭借深度学习在特征提取方面的巨大优势^[41]，能够有效地提高电阻率、极化率反演的精度与准确率。近几年来，已经有不少专家、学者开始将深度学习应用在物探和模型识别等领域。Puzirev^[42]和 Conway 等^[43]使用卷积神经网络进行了深度学习的大地电磁反演，取得了不错的效果；段友祥^[44]使用深度卷积神经网络进行了地震储层预测的反演；林年添^[45]在地震储层中，利用小样本学习训练的神经网络预测出了油气的分布范围和含量；李军健^[46]基于深度卷积神经网络进行了直流电阻率的二维地电模型的识别与方法研究；熊昌信等^[47]基于卷积神经网络和 Sobel 边缘检测算法对场地污染的 ERT(电阻率层析成像法)非线性反演方法进行了研究。而本文为了更高效的获得更准确、可靠的反演结果，将进行基于深度卷积神经网络的电阻率与极化率反演和电阻率、极化率异常体目标检测的研究。

1.3 研究内容

为了解决电阻率、极化率反演方法中非线性反演技术所遗留的辨识度低、准确率低、局部最优和非特定环境中具有不稳定性等问题，在针对使用直流电阻率法、激发极化法进行污染场地调查的反问题求解过程中，应用人工智能的方法技术，构建基于深度卷积神经网络的反演模型，实现污染场地的视电阻率图和视极化率图到对应位置的真实电阻率和极化率反演及视电阻率图和视极化率图中污染物异常体的识别与目标检测，从而提高电阻率、极化率反演成像的准确率和工程勘察的精度。研究需要设计正演模拟试验和实际的测量试验，通过数值模拟获得具有代表性的污染场地的视电阻率和视极化率数据来建立样本数据集，再利用卷积神经网络对这些样本数据进行训练，利用数据与污染物电性和激电效应特征之间的关系来建立反演模型，最后对反演模型得出的污染情况的智能识别结果进行验证和评估。

具体的，使用基于有限单元法开发的三维电阻率、极化率正演模拟软件的自动采集工具和当前较为成熟的多物理场有限元分析软件——COMSOL 进行数据采集；建立基于深度卷积神经网络的污染场地电阻率与极化率反演模型；根据直流电法原理建立不同位置、不同大小、不同电阻率和极化率值的异常体模型样本，进行正演，正演得到的数据经过预处理后，随机组成训练样本（80%）和测试样本（20%），进行训练；然后再根据计算模型输出的误差损失度和目标分类检测输出的准确率对模型进行测试和优化；最

后利用未知的正演模拟数据和实测数据去测试训练好的反演模型，验证模型的有效性和适应性。

根据本文电阻率与极化率反演研究的主要内容，提出了如图 1.1 所示的研究路线。

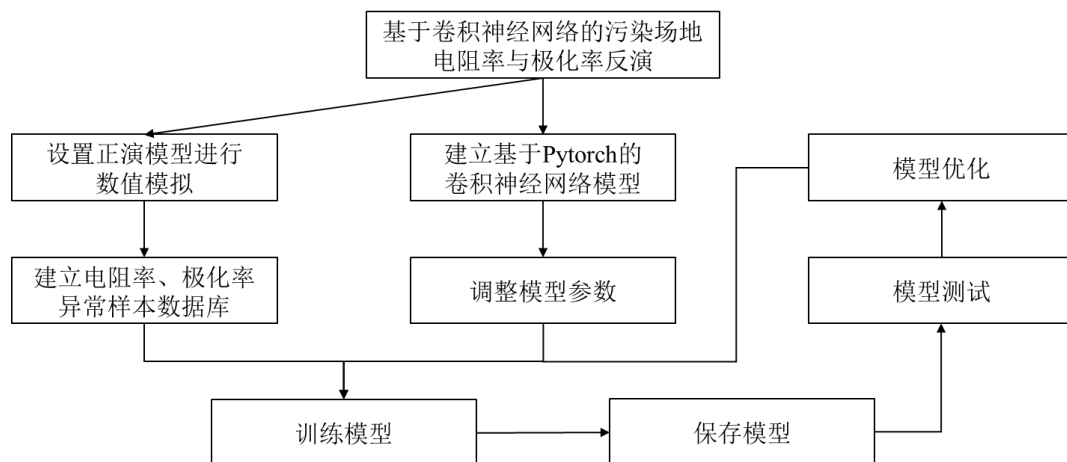


图 1.1 研究路线

Fig. 1.1 The research route

1.4 主要创新点

本文通过采用直流电阻率法、激发极化法检测土壤和地下水的电场变化及激发极化情况，来间接检测土壤和地下水中污染物的赋存情况，能够有效地提高检测的效率和减小检测的成本，再利用人工智能的反演方法提高污染场地的探测精度与准确率，具有较好的适用性；反演研究主要通过样本学习的方式来建立原始数据与污染物特性间的非线性关系模型来自动识别场地污染的范围与分布特征。具体的创新点有：

(1) 从电阻率法、激发极化法的基本理论出发，设计基于卷积神经网络的反演模型与目标检测模型，能够有效改善电阻率与极化率非线性反演中的不稳定性和局部极值等问题。

(2) 电阻率法与激发极化法的深度学习反演技术更贴近于实际情况，将三维空间中不同剖面的视电阻率、视极化率断面图的反演结果相结合后能够更精确地确定污染的位置及范围。

(3) 深度卷积神经网络的多层非线性变换，能够自动地从数据中学习特征，利用不同的卷积、池化和最后输出的特征向量的大小控制整体模型的拟合能力，实现污染物位置、范围和程度的识别。

1.5 章节安排

结合对直流电法在污染场地调查中的研究现状和直流电阻率法、激发极化法反演研究的分析后，本文主要利用深度卷积神经网络对污染场地的电阻率与极化率进行反演研究，共有 6 个章节，其中第二章主要介绍电法勘探原理和两种检测方法的基本理论与正演模拟，第三、第四章是电阻率、极化率的反演，而第五章是反演模型的实际应用与评估，本文具体的章节安排如下：

第一章主要概述研究的背景及意义，以及污染场地调查的研究现状和电阻率、极化率反演技术的发展及研究现状，然后总述了本文的主要研究内容及基于卷积神经网络进行电阻率与极化率反演的主要创新点；

第二章是直流电法中电阻率法和激发极化法的相关理论和方法原理的介绍，主要基于有限单元法进行电阻率与极化率的正演模拟研究，其中还包括对直流电法装置类型的介绍和有限单元法在电阻率、极化率数值模拟中的应用原理。最后对正演模型进行了设计，介绍了有限单元的剖分方法，并对几种典型的污染场景进行了正演；

第三章由浅入深地介绍了卷积神经网络算法，包括人工神经网络的发展和卷积神经网络的基本结构，以及基于 PyTorch 的卷积神经网络反演模型的构建方法和本文准备使用的算法模型；

第四章是基于卷积神经网络的电阻率与极化率的反演，首先对反演的流程进行了介绍，其次开始设计样本模型收集样本数据，包含样本数据的预处理及目标检测样本结果的标定，然后介绍电阻率、极化率反演模型与其异常体目标检测的网络结构、并进行模型的训练与测试，对模型反演的结果进行了初步的分析和评价；

第五章是电阻率、极化率反演模型的对比评价、实际应用和优化。首先，将第四章建立的基于卷积神经网络的电阻率、极化率反演模型与传统的 BP 神经网络反演的结果进行对比分析；其次，介绍了电阻率、极化率在行道树地下生态环境中的检测应用，并利用第四章建立的电阻率、极化率异常体目标检测反演模型对实际检测得到的视电阻率、视极化率图进行了异常检测；最后，建立了电阻率与极化率的双通道反演模型进行联合反演，并提出了反演算法的优化和改进思路。

第六章对全文的研究内容及结论进行了总结，并对目前仍未解决的问题和之后需要继续完善、优化的工作进行了展望。

第 2 章 基于有限单元法的电阻率与极化率正演模拟

直流电阻率法和激发极化法是电法勘探的主要分支方法，也是污染场地调查中高效、便捷的检测手段。本章将主要介绍两种方法和基于有限单元法正演模拟的基本原理和基础理论，并设计具有代表性的典型污染场地的正演模型进行数值模拟来建立反演研究的样本数据。

2.1 直流电法

直流电法是电法勘探中的一种利用直流电场分布特点和规律来解决实际问题的方法，可以利用人工场源，也可以利用天然的自然电场，主要包含直流电位法、电阻率法和激发极化法。本文主要利用人工场源的电阻率法和激发极化法进行研究。

2.1.1 电阻率法

电阻率法是电法勘探中直流电法利用视电阻率反映地质体情况的一种方法^[48]。一般的，由人工建立一个直流电场，这种电场需要将两个异性点电流源 $A(I)$ 、 $B(-I)$ 同时连接介质，直流电流从 A 输入介质，通过 B 由介质中流出，形成闭合回路。如果 A 、 B 相距甚远，那么 A 产生的电场将不会受到 B 产生的电场影响，形成了一个点电流源电场^[49]。

若介质的电阻率为 ρ ，在其表面 A 点处有一点电流源 I ，距 A 为 r 的任意一点 M 处的电位为

$$U = \frac{I\rho}{2\pi} \times \frac{1}{r} \quad (2-1)$$

同理，若在其表面 B 点处连接另一点电流源 $-I$ ，依据电场叠加原理，可得出 A 、 B 在 M 处的电位为

$$U_M = U_{AM} - U_{BM} = \frac{I\rho}{2\pi} \left(\frac{1}{AM} - \frac{1}{BM} \right) \quad (2-2)$$

式中， AM 、 BM 分别为 A 到 M 、 B 到 M 的距离。

同理，可以得出 A 、 B 在另一个观测点 N 处的电位，从而得到 M 、 N 的电位差公式为

$$U_{MN} = U_M - U_N = U_{AM} - U_{BM} - U_{AN} + U_{BN} = \frac{I\rho}{2\pi} \left(\frac{1}{AM} - \frac{1}{BM} - \frac{1}{AN} + \frac{1}{BN} \right) \quad (2-3)$$

若 $U_{MN} \neq 0$ ，可求得介质的视电阻率，即观测电阻率。因为在实际问题中，各种复杂物性条件相互叠加后，使得介质的综合电阻率分布不均匀，所以数值上并不等于介质的真实电阻率值，而被称为视电阻率，它的表达式为

$$\rho_s = k \frac{U_{MN}}{I} = 2\pi \left(\frac{1}{AM} - \frac{1}{BM} - \frac{1}{AN} + \frac{1}{BN} \right)^{-1} \frac{U_{MN}}{I} \quad (2-4)$$

式中， k 为电法的装置系数。

2.1.2 激发极化法

激发极化法^[50]分为直流（或时间域）激发极化法和交流（或频率域）激发极化法，本文主要使用直流激发极化法（简称直流激电法）进行研究。观测的参数是极化率，它是用来描述地质体激发极化效应强弱的参数。直流激发极化法也是采用稳定电流作为激发场源，因此，在人工建立的直流电场中，观测点 M、N 之间的电位差随时间逐渐趋于稳定后，在切断电源的一瞬间，电位差下降得很快，而后变缓，然后慢慢衰减到零。这种现象，可以视为是介质在放电过程中形成了一个电场（称为极化二次场），在电法领域中被称作激发极化效应，如图 2.1 所示。




图 2.1 激发极化效应示意图

Fig. 2.1 The schematic diagram of excited polarization effect

在放电过程中，极化二次电场的电位差 $U_2(t)$ 和放电前时刻的总电位差（又称总场或一次场的电位差） $U_1(T)$ 的比值叫做极化率，计算公式为

$$\eta(T, t) = \frac{U_2(t)}{U_1(T)} \times 100\% \quad (2-5)$$

式中， T 为断电时刻。其中， t 的初始时刻为 T 。

可以看出，极化率只与供电时间和测量时间有关，与电流无关，是二次场与总场的比值参数^[51]。

2.1.3 装置类型

在电法勘探中，按照探测方式的不同，可以分为电剖面法、电测深法和电成像法。在工程检测中，经常使用电剖面法和电测深法相结合的电成像法，然而，根据工作区域和地质情况的不同，需要选择正确、合理的电极布置方式，这种布极方式也被称为电法的观测装置，常见的装置类型有对称四极装置（又称温纳装置）、偶极装置、中间梯度装置和二极、三极装置等。为了提高电法探测的辨识度和抗噪能力，本文选用对称四极装置，其原理如图 2.2 所示， $AM=MN=BN$ ，所以公式(2-4)视电阻率的计算公式可以表达为

$$\rho_s = 2\pi a \frac{U_{MN}}{I} \quad (2-6)$$

式中， a 为极距的大小； ρ_s 为是 MN 中点处的视电阻率。




图 2.2 对称四极装置原理图

Fig. 2.2 The schematic diagram of symmetrical quadrupole device

当电极既改变极距大小又横向（ x 方向）移动时，形成了如图 2.3 所示的记录点位图，极距越大测得的记录点越深，按照图中所示的方式，采用电阻率法和激发极化法测量得到的记录点数据绘制出的图像称为视电阻率图和视极化率图。测量完一组二维剖面后，将测线沿 y 方向移动，测得的几组二维剖面图组成的立体图，即为三维的视电阻率图和视极化率图。




图 2.3 电成像记录点位示意图

Fig. 2.3 The schematic diagram of electrical imaging measuring points

2.2 有限单元法

有限单元法是一种强大的数值分析方法，它的出现解决了许多复杂难解的工程问题。地球物理中的有限单元法，主要是在确定剖分单元的形状和对应的形函数，其余的按照标准公式和相应的算法进行计算即可。本文为了更贴近于实际情况，主要使用 4 结点线性四面体元（如图 2.4(a)所示）和 8 节点空间的六面体单元（如图 2.4(b)所示）进行三维电阻率、极化率的正演模拟。

4 结点线性四面体元的形函数为

$$N_i = L_i \quad (i=1,2,3,4) \tag{2-7}$$

式中， L_i 为点 i 的体积坐标。

8 结点空间的形函数为

$$N_i = \frac{1}{8}(1 + \xi_0)(1 + \eta_0)(1 + \zeta_0) \quad (i=1,2,\dots,8) \quad (2-8)$$




图 2.4 有限单元（母单元）形态

Fig. 2.4 Finite element form

由于结点的函数值 u 和坐标是已知的，所以单元上的 u, L 和 x, y, z 可以表示为

$$\begin{aligned} u &= \sum_{i=1}^4 N_i u_i, \quad L = \sum_{i=1}^4 N_i L_i \\ u &= \sum_{i=1}^8 N_i u_i, \quad x = \sum_{i=1}^8 N_i x_i, \quad y = \sum_{i=1}^8 N_i y_i, \quad z = \sum_{i=1}^8 N_i z_i \end{aligned} \quad (2-9)$$

在电法勘探的应用中，有限单元法的数值模拟经常采用异常电位法进行计算。将全区域的积分分解为每个单元的积分，再将各积分单元相加，可得到方程组^[52]

$$Ku = -K'u_0 \quad (2-10)$$

式中， K 、 K' 为积分系数矩阵； u 为待求的各网格节点的异常电位向量； u_0 为各网格节点的正常电位向量。解方程(2-10)，即可得到各结点的异常电位^[53]，求解公式同公式(2-3)。

而电阻率的正演模拟是在计算各记录点的视电阻率，因此可以根据电位模拟的结果换算出视电阻率，计算公式为

$$\rho_s = k \frac{(u_0 + u_i)}{I} \quad (i=1,2,\dots,M_s) \quad (2-11)$$

式中， k 为装置系数，计算方法与公式(2-4)同理； M_s 为有限单元总数。

根据 Seigel 的体激发极化理论^[54]，当地下介质体具有体极化特性时，极化率的正演模拟可以通过等效电阻率法进行计算，等效电阻率的计算公式为

$$\rho^* = \rho / (1 - \eta) \quad (2-12)$$

式中， ρ 为介质的电阻率； η 为介质的极化率。

由此可以得到各观测点的等效视电阻率公式为

$$\rho_s^* = \rho_s / (1 - \eta_s) \quad (2-13)$$

式中， η_s 为视极化率。

因此，可以通过电阻率的正演模拟结果来计算极化率的模拟结果，由此可以得到视

极化率的计算公式为

$$\eta_s = (\rho_s^* - \rho_s) / \rho_s^* \quad (2-14)$$

由上一节激发极化法的基本原理可知，这里的等效视电阻率是总场的视电阻率，极化二次场的视电阻率是等效视电阻率与介质的视电阻率的差。

2.3 数值模拟试验

本文将使用基于有限单元法开发的三维电阻率、极化率正演模拟软件的自动采集工具和当前较为成熟的多物理场有限元分析软件——COMSOL^[55]进行正演模拟，采集样本数据。

2.3.1 模型设计与单元剖分

通常，间接性污染调查与地球物理勘探一样，目标区域的边界通常远离测量系统，都是基于地表或钻孔内部对介质物性参数的测量，勘测的物理域非常大，以至于可以认为其不受侧面和底部的限制。本文主要研究电阻率法、激发极化法在三维污染场地中的调查，因此设置了如图 2.5 所示的正演模型与单元剖分方法。

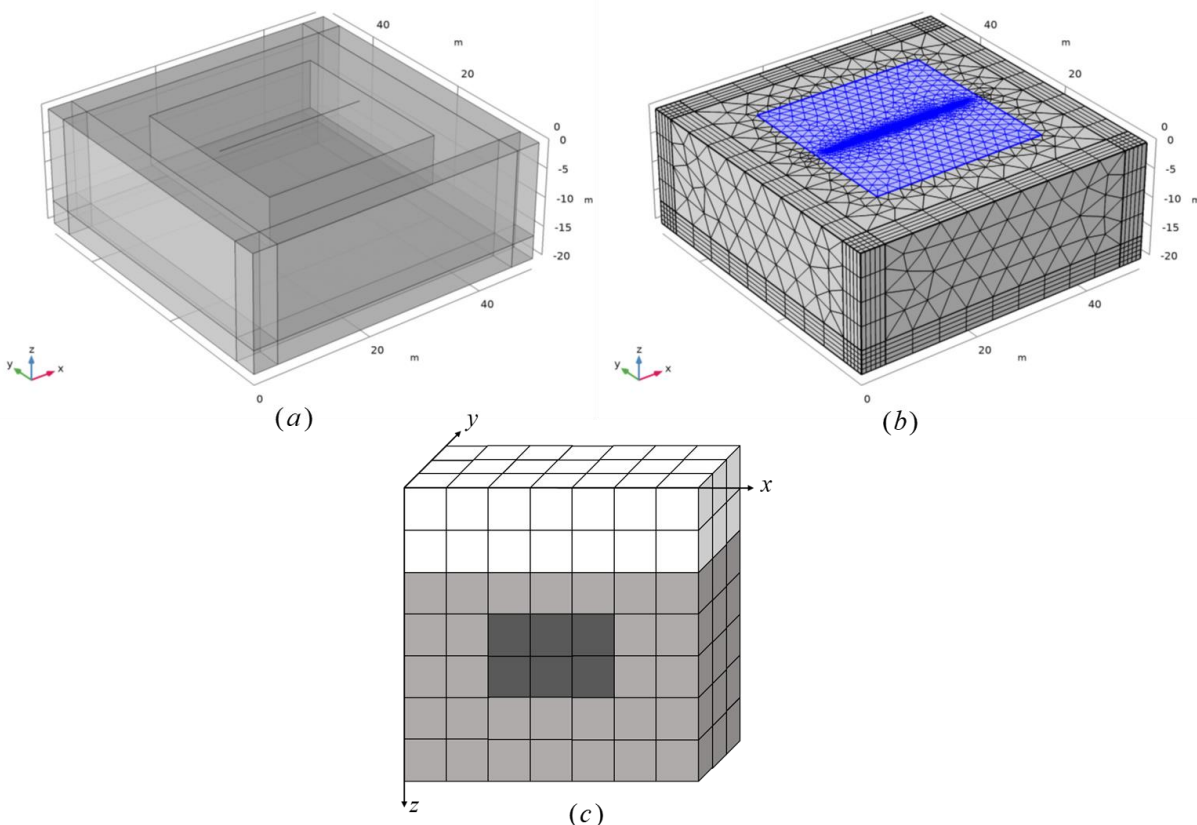


图 2.5 模型与单元剖分示意图

Fig. 2.5 The schematic diagram of model and the element division

图中(a)、(b)分别是用 COMSOL 软件设置的地电模型和单元剖分示意图，中心区域为计算域，以及电极周围是细化的网格剖分，外围为无限元域，使用略扫网格进行剖分；(c)是六面体单元剖分，白色六面体单元为空气，浅灰色六面体为大地，在整个模拟区域中，除了待测目标体（深灰色）以外的单元由小到大地进行非均匀剖分，以模拟

污染场地的无穷远边界^[56]，其尺寸变化类似于斐波那切数列，而待测地质体均采用均匀分布的方式，又由于空气是绝缘的，所以该地质体及大地与空气形成的绝缘边界为零电位边界。

2.3.2 污染场景的构建

使用电阻率法、激发极化法进行污染场地调查，实际上是探测污染后的水土介质的电阻率、极化率是否发生了变化，而水土的电阻率主要由孔隙水和土颗粒的电阻率两部分组成，其电阻率和极化率会受土的孔隙度、类型、含水率、水的离子浓度，以及土壤有机质的含量、温度和饱和度等因素的综合影响。根据有关资料^[57]，列出了与污染场地中水土污染相关的电性参数，如表 2.1 所示。

表 2.1 常见物质的电阻率、相对介电常数

Table 2.1 Resistivity and relative permittivity of common substances

介质名称	电阻率 ($\Omega \cdot m$) ρ	相对介电常数 k
干沙	$10^3 \sim 10^7$	3 ~ 6
饱和含水砂	$10^2 \sim 10^4$	20 ~ 30
粉砂	$10^2 \sim 10^3$	5 ~ 30
饱和含水黏土	1 ~ 10	5 ~ 40
湿土	50 ~ 100	~ 30
垦植土	~ 200	~ 15
岩质土	~ 1000	~ 7
空气	无限大	~ 1
淡水	$30 \sim 10^4$	~ 81
海水	~ 0.25	~ 4
冰	$10^3 \sim 10^5$	3 ~ 4
汽油	$\sim 2.5 \times 10^{11}$	~ 1.9
甲醇	$\sim 2.3 \times 10^5$	~ 30
煤油	$\sim 7.3 \times 10^{12}$	2 ~ 4
苯	$1.6 \times 10^{11} \sim 10^{12}$	1 ~ 2.5
DNAPL (重质非水相液体)	$500 \sim 10^5$	
铁、铅、汞	$1.0 \times 10^{-7} \sim 0.1$	<10
银、铜、金、铝	$1.5 \times 10^{-8} \sim 0.03$	<10

注：单个数字前的“~”表示“大约”。

经实测数据统计得到砂土、粘土、土壤的极化率在 0 ~ 2% 之间，一般岩石的极化率最大值大约为 5%，只有石墨、碳石、黄铜矿石等金属的极化率会高，最高可达 50%^[58]。由此可知，通过电阻率法、激发极化法探查场地的污染情况是可行的，通过分析常见物质的电性参数，结合实际中常见的地质环境常为砂土的条件，可以初步得出污染场地的背景电阻率一般在 10 ~ 1000 之间，介电常数约为 5，极化率在 0 ~ 2% 之间。

通常情况下，污染物的扩散主要是以离子或分子的形式进行的，使受到污染后的水

土的电性和极化特性发生改变。不同类型的污染对其电性的改变也是不同的, 为了便于研究, 通常会把场地水土污染的类型分为无机污染和有机污染两种, 无机污染后的水土一般电阻率会降低, 而有机污染后的水土通常电阻率会升高。无机污染主要有有毒有害金属、重金属和其化合物与酸、碱、盐等, 有机污染主要有有机农药、酚类化合物、石油类等污染物, 按照其电性特征可以分为低阻异常、高阻异常和高极化异常, 一般的无机污染物会呈现低阻高极化特性、有机物会呈现出高阻低极化特性, 除此之外, 还有许多人造垃圾污染, 如城市建设中产生的建筑垃圾往往电阻率很高, 而又因其内部含有钢筋呈现出高阻高极化特性。然而, 因为污染场地具有一定的复杂性, 污染物质和水、土、空气或污染物之间发生反应, 形成不同的化合物和络合物, 其电性参数很难通过普通仪器的测量得到准确值, 但通过它与背景值的差异或电阻率、极化率参数相结合的方式仍然能够对污染情况进行一定程度上的辨别, 并对污染的范围、位置、大小和深度进行确定。

本文将参照根据经验统计初步得出的电性参数值的范围, 设计单一异常体和混合异常体情况下的污染场景模型。污染场地的模型大小为 $25m \times 25m \times 10m$ 的长方体, 测量电极数为 50 个, 极距为 0.5m, 异常体设置为小长方体, 再通过改变其位置、大小和形状来模拟不同的污染物场景, 通过改变场地背景和受污染影响的异常体的材料参数(电阻率、极化二次场的电阻率和相对介电常数)来模拟不同的污染物类型, 从而得到场地的视电阻率断面图和视极化率断面图, 其中视极化率是通过公式(2-14)换算得到的。采集的数据点如图 2.6 所示。




图 2.6 采集模型的数据记录点

Fig. 2.6 Data recording point map of the model

2.3.3 典型模型的正演结果

几种典型的污染场地对应的电阻率、极化率正演结果, 如图 2.7-图 2.12 所示, 其对应的异常类型及电性参数的设置见表 2.2。对比正演模拟结果图可知, 单一异常情况的特征明显、形态清晰, 能够明显地区分出异常类型和异常体的深度、位置和范围。混合异常情况下, 混合高阻的视电阻率断面图中, 也能够清楚地对高阻和较高阻进行区分, 而在视极化率图中, 高阻高极化异常受较高阻高极化的影响, 形态边界特征和视极化率值都表现得较弱; 混合低阻的视电阻率断面图中, 低阻的异常特征明显, 较低阻受其影响, 较难区分, 而在视极化率断面图中, 低阻高极化异常受较低阻高极化的影响, 也呈

现出形态边界特征和视极化率值都较弱情况,但在视电阻率图和视极化率图相结合的情况下,可以对异常体进行比较清楚的分辨,鉴于此特性,将视电阻率图与视极化率图分别呈现的特征相结合,进行联合反演,能够得到更好的结果。

表 2.2 正演模型的电性参数设置

Table 2.2 The electrical parameters setting of forward model

异常类型	背景		异常体	
	电阻率($\Omega \cdot m$) ρ	极化率(%) η	电阻率($\Omega \cdot m$) ρ	极化率(%) η
高阻高极化			1000	
低阻高极化	100		10	
混合高阻高极化		2	500/1000	
混合低阻高极化			10/100	20
高低阻混合高极化	500		10/1000	
高低阻、高极化混合且分层	200/500	1/2	1000/10	

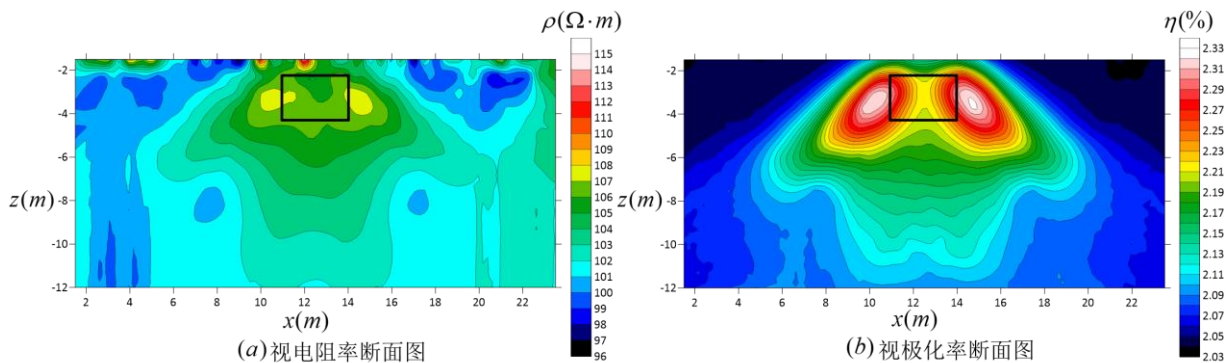


图 2.7 高阻高极化异常

Fig. 2.7 High resistance and high polarization anomaly

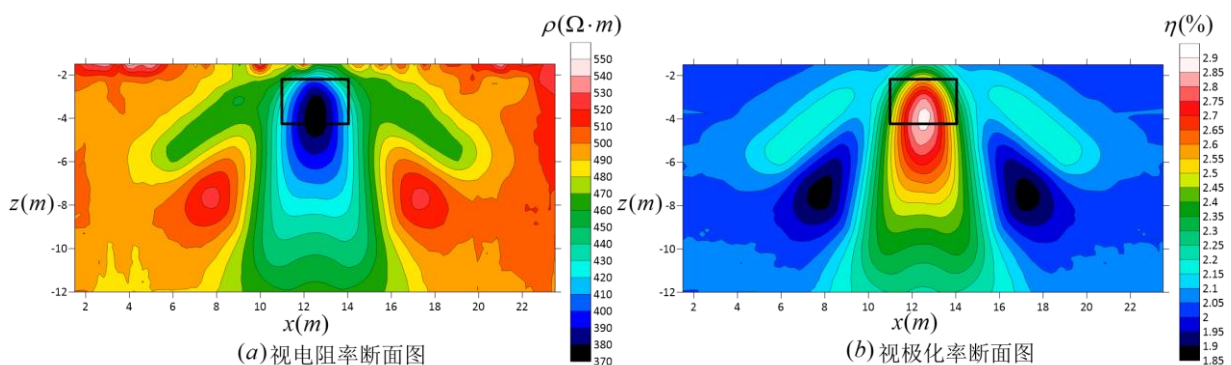


图 2.8 低阻高极化异常

Fig. 2.8 Low resistance and high polarization anomaly

在高低阻混合异常中,通过视电阻率断面图和视极化率断面图可以很明显地区分出异常体的情况,二者相结合后能够更加准确地确定出异常体在探测剖面上的位置及大小,其中,高阻体在视电阻率与视极化率图中都呈现出了等值线向外扩散的特征,而低阻体处的等值线具有向内收紧的特征。

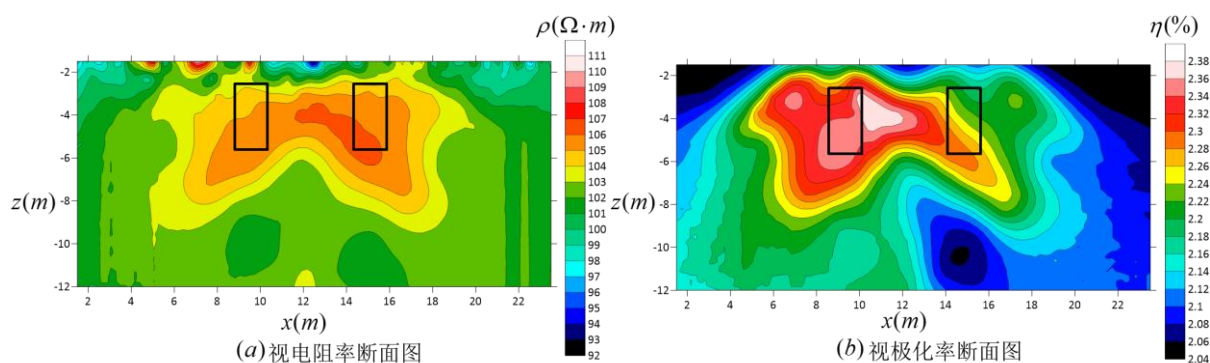


图 2.9 混合高阻高极化异常

Fig. 2.9 Mixed high resistance and high polarization anomaly

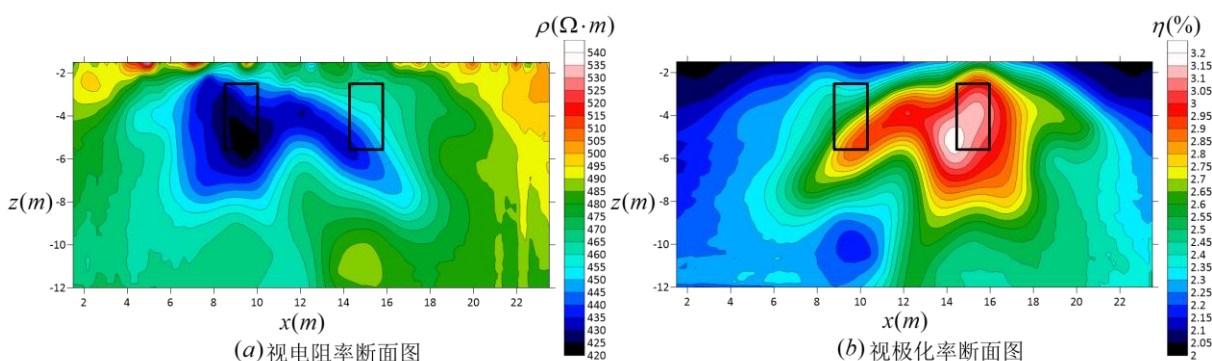


图 2.10 混合低阻高极化异常

Fig. 2.10 Mixed low resistance and high polarization anomaly

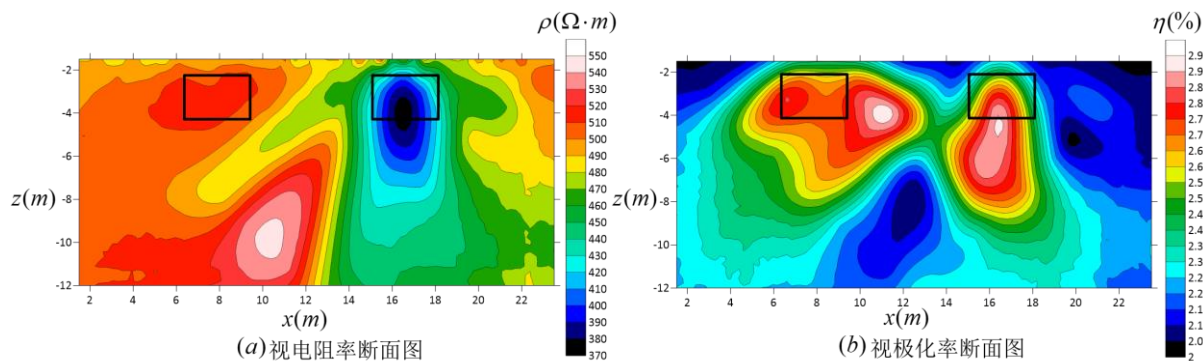


图 2.11 高低阻混合高极化异常

Fig. 2.11 High and low resistance mixed high polarization anomaly

对高低阻混合异常进行背景值的分层模拟后,视电阻率断面图和视极化率断面图的电性变化和异常情况的分布效果也是显著的,只是对下层深度较深的异常体识别相对困难。对此种情况的正演模拟和讨论分析能够使研究更贴近于实际工程的复杂情况,说明正演模拟的有效性,从而增加反演模型的健壮性与泛化能力。

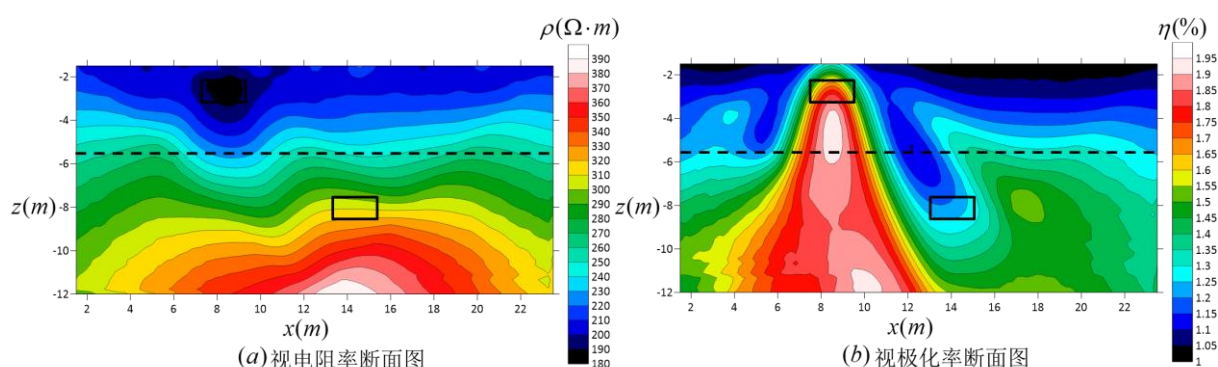


图 2.12 高低阻、高极化异常混合且分层

Fig. 2.12 High and low resistance and high polarization are mixed anomalies and stratified

2.4 本章小结

本章主要介绍了污染场地的间接检测方法——电阻率法和激发极化法，以及基于有限单元法的视电阻率、视极化率正演模拟方法，其中包括直流电法的基本理论、电阻率法、激发极化法探测的方法原理和电法装置的类型，以及有限单元法在电法领域的应用原理和单元剖分方法。然后，构建了污染场景、设计了正演模拟的模型，并对典型的污染场景模型进行了正演模拟。根据正演模拟的结果，分析得到：电阻率、极化率对单一异常情况的检测效果好，异常特征明显、形态清晰，能够清楚地对异常类型进行区分，并能够比较准确地确定异常体的深度、位置和范围；而电阻率、极化率对混合异常情况的分辨能力较弱，主要有以下结论：

- (1) 高阻体处的等值线呈现出向外扩散的特征，而低阻体呈现出等值线向内收紧的特征；
- (2) 异常体的电性与模型的背景值反差较小，会受反差较大的影响而呈现形态边界不清晰、特征不明显的情形；
- (3) 高极化异常体电阻率低时，特征明显，反之，不明显；
- (4) 当视电阻率图与视极化率图相结合、对比分析时，能够更好地对异常情况进行鉴别；
- (5) 异常体位置较深时，会受浅部异常的影响，很难准确地确定出它的位置和范围；
- (6) 模型分层后，有明显的等值线起伏变化的电性和极化特性的分布特征。

第 3 章 卷积神经网络和反演模型的构建

人工智能对许多传统行业都有较大的促进作用，卷积神经网络的兴起更是有效地推动了它的发展。本章主要介绍人工神经网络的基本概念和卷积神经网络的基本原理，以及如何利用 PyTorch 深度学习框架进行电阻率与极化率的反演。

3.1 神经网络的基本概念

人体的神经网络是由神经元细胞构成的，类似的，人工神经网络也是由一个一个的人工神经元构成的，只不过人工神经元是通过带有权重的函数公式和激活函数进行信号传输的，而生物神经元细胞是通过各种不同的细胞突起进行信息的传递，如图 3.1 所示是生物神经元和人工神经元的类比图。




图 3.1 生物神经元与人工神经元

Fig. 3.1 Biological Neurons and Artificial Neurons

许多个人工神经元组成人工神经网络，再加上参数权重可以不断地自动变化和调整，就逐步演变成了机器学习。感知机（Perceptron）^[59]是最简单的人工神经网络，传播方向只能向前，而在感知机中加入隐藏层，包含多个隐藏层和因变量，就形成了多层感知机（MLP），既可以用来预测连续的因变量，又可以进行因变量的分类。此外，多层感知机还可以发现更复杂的数据信息关系，能够很好地处理非线性问题。通常，人们会把多层感知机这样结构称为人工神经网络。而所谓的学习就是通过训练或者学习算法得到各层神经元之间最优的权重等参数组合，构成网络模型用来对以后问题的解决，其中，最具代表性的学习算法是反向传播（Back Propagation, BP）算法。

如图 3.2 所示的是一个经典的三层 BP 神经网络模型，其最大的特点是逆向反馈^[60]。即用均方误差（MSE）来衡量网络模型输出的预测值与真实值之间的误差，并反向传播给上一层进行参数的调整^[61]。

均方误差（MSE）^[62]的计算公式为

$$E(y_j, y'_j) = \frac{1}{n} \sum_{i=1}^n (y_j - y'_j)^2 \quad (3-1)$$

式中, y_j 为真实值, y'_j 为预测值。




图 3.2 三层 BP 神经网络模型

Fig. 3.2 A three-layer BP neural network model

3.2 卷积神经网络

卷积神经网络是具有一系列卷积计算的人工神经网络,它优化了传统神经网络训练出现的参数冗余和过拟合等问题,具有很强的表征学习能力,无论目标被平移到什么位置都能它被识别出来。一般的卷积神经网络架构如图 3.3 所示。包含输入层、卷积层 (Conv)、池化层 (Pool) 和全连接层 (Fc)。




图 3.3 一般卷积神经网络的结构示意图

Fig. 3.3 The schematic diagram of Convolutional neural network

3.2.1 卷积层

卷积是卷积神经网络中的核心运算,它实际上是某个范围内两个变量相乘后求和的结果,又称卷积和。当变量是两组序列 $f(n)$ 和 $g(n)$ 时,卷积公式为

$$f(n) * g(n) = \sum_{i=-\infty}^{\infty} f(n)g(n-i) \quad (3-2)$$

式中, $*$ 表示卷积。

当变量是两个函数 $f(x)$ 和 $g(x)$ 时,卷积公式变为

$$f(x) * g(x) = \int_{-\infty}^{\infty} f(p)g(x-p)dp \quad (3-3)$$

而在卷积神经网络中,通常使用的卷积运算是离散的,也就是序列形式的计算方式,这里用 conv 表示公式(3-2),则卷积神经网络中的卷积计算可表示为

$$y = \text{conv}(x, F) + b \quad (3-4)$$

式中, x 为输入(一组序列), y 为输出; F 表示卷积核(另一组序列,这里相当于一个过滤器); b 表示偏置量。

具体的卷积操作如图 3.4 所示,第一次卷积运算,左边矩阵中灰色部分与中间 3×3 的卷积核对应相乘再相加生成右边矩阵中第一行第一列的数据。如在图 3.3 中,输入了一个 32×32 的二维图像,经过 6 个 5×5 卷积核(filter)步幅(s)为 1(即每次移动一格)的卷积操作之后,形成了 6 张 28×28 的特征图,这个过程可以理解为使用一个卷积核来过滤图像的各个小区域,从而得到这些小区域的特征值。




图 3.4 卷积神经网络的卷积运算

Fig. 3.4 Convolution operation of convolutional neural network

3.2.2 池化层

池化是在卷积层之后为了进一步降低训练参数和模型的过拟合程度而进行的处理,是一种降维操作,一般用来减小特征图的尺寸,提高运算效率、降低噪声而增强特征的健壮性。这里用 pool 表示池化,则池化运算可表示为

$$y' = \text{pool}(y, P) \quad (3-5)$$

式中, y 为卷积操作的输出; P 为池化窗。

池化操作主要是在池化窗内取最大值或平均值,被称为局部池化操作,常见的有最大池化和均值池化,而全局池化是对整张特征图而言的,也分为有全局最大池化和均值池化两种,具体的操作如图 3.5 所示。

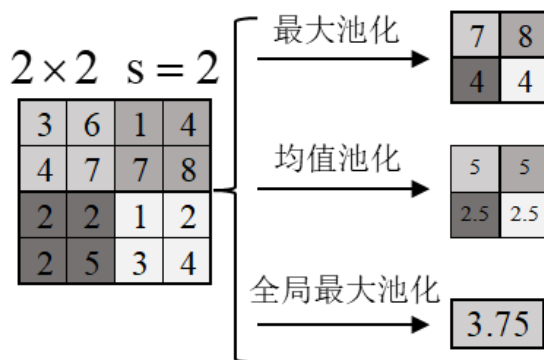


图 3.5 卷积神经网络的池化操作

Fig. 3.5 Pooling operation of convolutional neural network

在图 3.3 中,经过 Conv1 的卷积操作之后,形成了 6 张 28×28 的特征图,直接使

用这些特征图进行特征训练, 不仅计算量巨大而且会出现过拟合现象, 因此要对其进行降采样, 即使用 6 个窗口大小为 2×2 的池化窗进行池化操作, 每次移动的步幅 (s) 为 2, 即可全部池化完成, 得到 6 张 14×14 的特征图。

3.2.3 全连接层

全连接层其实已经是一个深度神经网络了, 但这种传统的神经网络在进行深度学习时, 往往会因为层数太多受到计算资源不足的限制, 同时甚至还会出现梯度消失或梯度爆炸的问题。所以, 卷积神经网络对其进行了很大的改进, 影响深远, 在经过多轮的卷积和池化操作后, 再进行全连接神经网络的训练能够到达最优的效果。一般会设置两个全连接层, 第一层有 2^n 个节点, 第二层为回归预测或分类输出的个数, 而 Softmax 函数 (归一化指数函数) 常被用来解决分类问题。该函数为

$$F_i(y) = \frac{\exp(y_i)}{\sum_j \exp(y_j)} \quad (3-6)$$

它能将训练输出的 K 维向量中的每一个元素的概率范围控制在 (0,1) 之间, 且它们的和为 1。

3.3 反演模型的构建

本文的反演模型是基于深度学习框架 PyTorch 建立的, 它是由 Facebook 团队 2017 年 1 月在科学计算工具 Torch 库的基础上发布的一款基于 Python 语言且开源的深度学习工具包。它与其他大多数开源框架 (如 Theano、TensorFlow、Caffe、MXNet 等) 不同的是采用动态计算图和自动微分机制, 无缝替换 Python 中的 NumPy 库, 具有简洁、便捷等特点。

3.3.1 张量

张量 (Tensor) 是深度学习中特有的数据结构, 可以在 GPU 中进行加速计算。它在 PyTorch 中表示多维数组, 既可以表示一个数 (标量, 也称零维张量), 也可以表示矢量 (一维张量)、矩阵 (二维张量)、矩阵数组 (三维张量), 甚至更高维的数据结构, 存储数据十分灵活方便, 是神经网络计算中最基本的操作对象, 模型的输入、输出和网络参数 (权重 w 和 b 偏差) 等数据都使用张量来表示。

3.3.2 损失函数

损失函数是深度学习训练过程的核心, 用来衡量模型的预测值与真实值之间的误差, 因此模型训练优化的过程实际上是在不断地优化调整损失函数, 使得它最小, 即沿梯度下降最快的方向进行优化。常用的损失函数有交叉熵和均方误差两种, 即在 3.1 节中介绍的均方误差是 BP 神经网络的损失函数, 一般用来解决回归问题, 而交叉熵常用来解决分类问题, 在神经网络模型中, 通常与 Softmax 激活函数一起使用, 因为神经网络模型的输出是向量, 需要先将其进行归一化成概率分布的形式再进行计算。

因此, 交叉熵的计算公式为

$$L_i(y) = -\log \left(\frac{\exp(y_i)}{\sum_j \exp(y_j)} \right) = -y_i + \log \left(\sum_j \exp(y_j) \right) \quad (3-7)$$

式中, y_i 为真实值, y_j 为预测值。

模型网络参数 θ 的损失函数, 则为

$$L_i(y, \theta_i) = \theta_i \left(-y_i + \log \left(\sum_j \exp(y_j) \right) \right) \quad (3-8)$$

3.3.3 正则化

深度学习训练的模型除了要在训练集上表现良好, 同时更重要的是要在测试集上表现良好, 这种能力被称为泛化。而正则化则是为了提高这一能力, 在损失函数的基础上引入额外的信息, 来避免过拟合的现象。在深度学习中, 正则化的方法有很多, 常规的有 L1、L2 正则化, 它们主要是针对过拟合过程中函数值变化剧烈时, 让其权值 w 变小, 又被称为权重衰减。

对于模型参数 θ 的 L1 正则化公式为

$$L1: R(\theta) = \sum_{i=1}^n |\theta_i| \quad (3-9)$$

L2 正则化公式为

$$L2: R(\theta) = \sum_{i=1}^n |\theta_i|^2 \quad (3-10)$$

这种方式的正则化方法又被称为参数规范惩罚, 在正则化之后, 损失函数变为

$$L(\theta) = L_0 + \lambda R(\theta) \quad (3-11)$$

式中, λ 是正则化系数。

除了上述对参数规范进行惩罚的正则化外, 还有 Dropout 等方法, Dropout 的原理是按照一定的概率将神经元随机丢弃, 使得模型更加健壮, 而不会因为依赖某些局部特征过拟合^[63]。

3.3.4 构建方法

本文使用 PyTorch 框架构建基于卷积网络的电阻率与极化率反演模型, 它是一个简单的前馈神经网络, 在获取输入后, 将其一层又一层地馈入, 最后输出结果。大致的构建过程如下:

- (1) 定义神经网络设置可学习参数 (或权重 w);
- (2) 遍历输入数据集;
- (3) 通过网络处理输入;
- (4) 计算损失 L , 参见公式(3-8);
- (5) 将梯度 g 传播回网络参数 θ , 梯度计算公式为

$$g_i = \frac{\partial}{\partial \theta_i} L_i(y, \theta_i) \quad (3-12)$$

(6) 使用更新规则来更新网络的权重，常用的更新规则为

$$\theta_i = \theta_i - r g_i \quad (\text{或 } w_i = w_i - r g_i) \quad (3-13)$$

式中， r 是网络的学习率，会对损失函数和网络造成影响，过大会直接越过全局最优值，过小会降低网络的收敛速度，一般设定为 0.01 或 0.001 即可。

本文将通过上述方法构建电阻率与极化率反演和其异常体目标检测的两种模型，其中，第一种模型是解决电阻率、极化率反演过程中，视电阻率、视极化率到对应位置真实值的回归预测问题；第二种模型是解决视电阻率、视极化率图中异常体位置及大小的标注和分类问题。反演的研究主要以第一种模型为主，第二种模型是为了补充解决第一种模型在复杂情况下反演效果不好、在实际检测中较难适用的情况。

3.4 本章小节

本章介绍了神经网络的基本概念和卷积神经网络的基本结构，及构建卷积神经网络反演模型时涉及的算法。另外，还介绍了通过 PyTorch 深度学习框架构建卷积网络模型的具体方法和本文将要构建的电阻率与极化率反演及其异常体目标检测的两种模型。

第 4 章 基于卷积神经网络的电阻率与极化率反演

为了提高污染场地使用电阻率法、激发极化法调查的效率和电阻率、极化率反演成像的准确率,本文将构建基于 PyTorch 的卷积神经网络模型进行电阻率与极化率的反演和电阻率、极化率异常体的目标检测。本章将从样本数据库的建立、模型的训练与测试三个部分进行介绍。

4.1 反演流程

本文主要使用深度卷积神经网络的反演方法,具体的反演流程如图 4.1 所示。

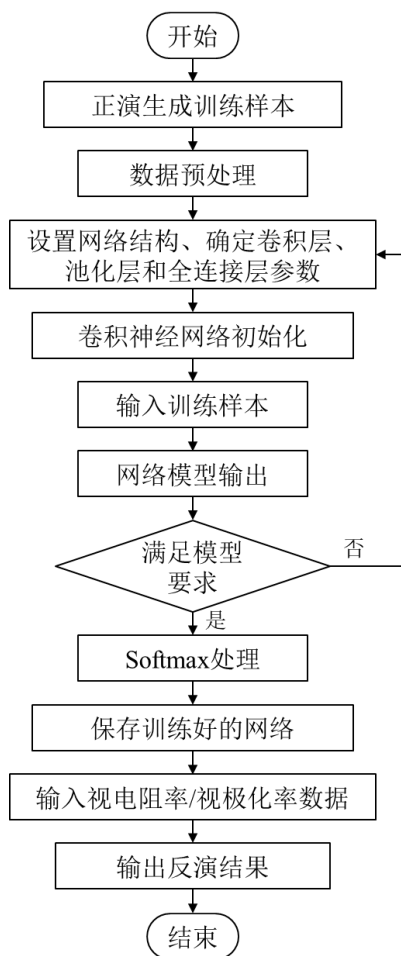


图 4.1 反演流程图

Fig. 4.1 The flow chart of inversion

它与地球物理中其他一般方法的反演思路不同,是通过样本学习的方式来建立视电阻率、视极化率与真实的电阻率、极化率值的非线性关系模型,或者是二维或三维视电阻率、视极化率图像中异常体位置、形态及大小的非线性识别模型,不需要通过不断迭代的方式寻求最优的拟合数据,通常被称为基于样本学习的反演方式。这种方式的反演过程一般包括建立学习样本数据库、建立与训练模型和模型的测试与评估。因此,本文的反演思路是通过正演模拟收集数据,对数据进行预处理,建立样本数据库并划分出训

训练数据集与测试数据集；然后再设置卷积神经网络的结构，开始训练模型；最后对模型进行测试与评估。

4.2 样本数据库的建立

深度学习能够有效提高反演的效率，但也会由于样本数据少、类型不全面的原因而产生局限性。因此，需要设置合理的正演模型来采集样本数据，并具有针对性地对样本数据进行有效的数据预处理。

4.2.1 样本数据的采集

本文在第 2 章已经对几种典型的污染场景进行了正演模拟，根据对正演模拟结果的讨论和分析，又具有针对性地设计了如图 4.2 和图 4.3 所示的 8 种模型。




图 4.2 单异常体模型设置图

Fig. 4.2 The setup diagram of single anomalous body model

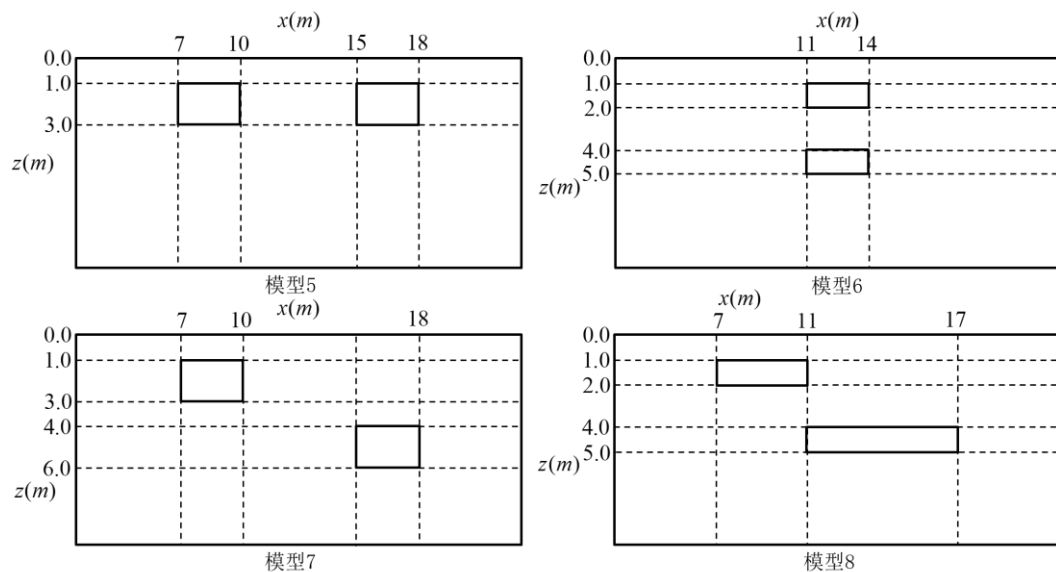


图 4.3 混合异常体模型设置图

Fig. 4.3 The setup diagram of mixed anomalies model

为了能够建立更好的反演模型，需要在图 4.2 和图 4.3 设置的 8 种模型中，根据表 4.1 和表 4.2 设计的模型参数范围内随机抽取与 4 种单异常体模型或 4 种混合异常模型组成样本模型进行数据采集工作，共有 2000 个样本，每个样本有 408 个记录点位，总计 816000 个数据点。

表 4.1 电阻率异常的模型参数

Table 4.1 The model parameters of resistivity anomaly

模型类型	电阻率($\Omega \cdot m$) ρ		样本数量(个)
	背景	异常体	
单体异常 1	10 ~ 100	300 ~ 1000	100
单体异常 2	500 ~ 1000	10 ~ 300	100
混合异常 1	10 ~ 100	300 ~ 1000 / 300 ~ 1000	500
混合异常 2	500 ~ 1000	10 ~ 300 / 10 ~ 300	500
混合异常 3	200 ~ 500 / 500 ~ 200	10 ~ 300 / 800 ~ 1000	500

表 4.2 极化率异常的模型参数

Table 4.2 The model parameters of polarizability anomaly

模型类型	极化率(%) η		样本数量(个)
	背景	异常体	
单体异常	0 ~ 2	5 ~ 50	100
混合异常		5 ~ 50 / 5 ~ 50	200

4.2.2 样本数据的预处理

由于电法检测中，按照布置好的电极采集数据时，每一层的记录点与相邻一层的记录点是错位的，并没有对齐，因此要借助一种插值方法对采集得到的数据进行插值后才能够绘制成平滑的图像或获得满矩阵。

克里金法（Kriging）是一种精确且平滑的插值方法，通过一组具有 z 值的已知分散点生成估计表面的高级地统计过程^[64]，甚至还可以推出超出数据 z 范围的网格值，又被称为空间最优无偏估计器。克里金法的公式为

$$\hat{Z}(s_0) = \sum_{i=1}^N \lambda_i Z(s_i) \tag{4-1}$$

式中， $Z(s_i)$ 表示第 i 个位置处的 z 值； λ_i 表示第 i 个位置处的 z 值的权重； s_0 表示预测位置； N 是位置数。

其中，权重 λ_i 不只是取决于到预测位置的距离，还包括预测位置周围的 z 值之间的空间关系拟合模型，这个模型包括变异函数及协方差，是为了估计数据的空间自相关性来进行未知值预测的。其中，变异函数是区域化变量空间变化的特征和强度，自变量为样本点间的距离 h ，因变量为变异值 γ ，其函数表达式为

$$\gamma(s_i,s_j)=\frac{1}{2}E[Z(s_i)-Z(s_j)]^2$$
$$h=|s_i-s_j|$$

(4-2)

本文通过正演模拟采集的样本数据如表 4.3 所示,通过克里金法可以拟合出如图 4.4 所示的变异函数曲线,是一个线性模型,图中的数值表示变差点的个数,横线为方差。由于电法装置记录点位的特殊性,图 4.4 中标注的是已知样本点,根据克里金法拟合出的模型可估计出图上所示圆中每个位置处的 z 值,最后绘制成第二章正演模拟结果中给出的视电阻率、视极化率断面图。反演完成后,也使用该方法进行插值后再绘制图像。

表 4.3 采集的电阻率、极化率样本数据

Table 4.3 Sample data of collected resistivity and polarizability

水平位置(m) <i>x</i>	深度(m) <i>z</i>	电阻率样本 1	...	极化率样本 1	...
		视电阻率(Ω·m) <i>ρ</i>	...	视极化率(%) <i>η</i>	...
1.5	-1.5	102.58	...	2.04	...
2	-1.5	105.60	...	2.04	...
2.5	-1.5	106.44	...	2.04	...
3	-1.5	107.80	...	2.04	...
3.5	-1.5	101.20	...	2.04	...
...
13.25	-11.25	102.13	...	2.10	...
13.75	-11.25	102.24	...	2.10	...
12	-12	101.92	...	2.10	...
12.5	-12	101.88	...	2.10	...
13	-12	101.94	...	2.09	...

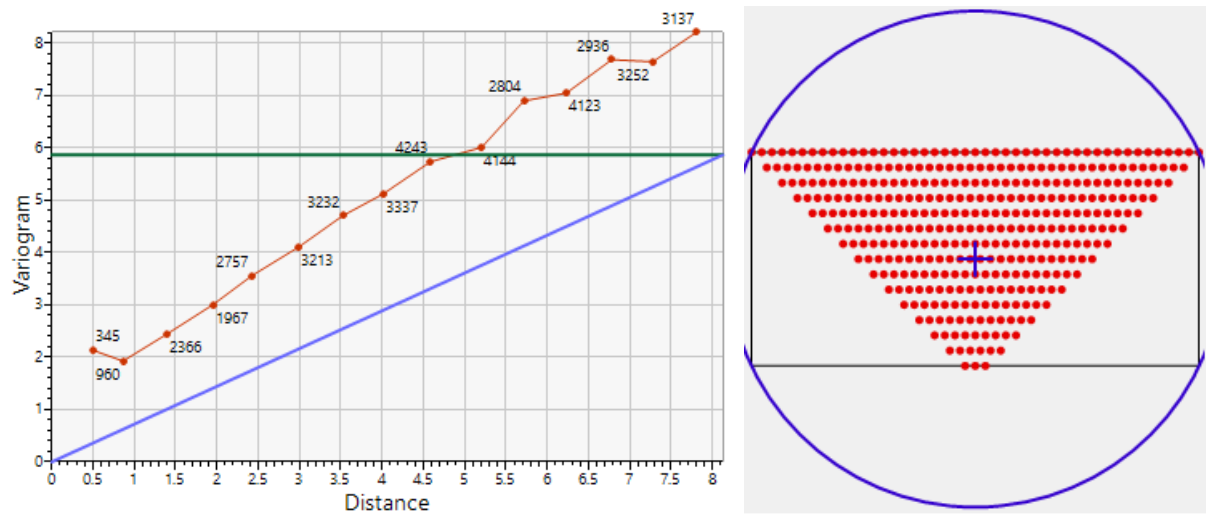


图 4.4 克里金法变异函数及估计范围

Fig. 4.4 Kriging variogram and estimation range

最后,为了方便卷积计算,将样本数据统一处理成尺寸为 48×48 的矩阵,因为本文使用的电法装置探测层数只有 15 层,所以需要在采集不到数据的位置上补零。

4.2.3 目标图像的标定

电阻率、极化率的反演一般从视电阻率、视极化率到真实的电阻率、极化率的演化过程，但污染场地的实际调查中，情况复杂，视电阻率、视极化率图像往往受到噪声的干扰和其他复杂地质条件的影响，从而增大了反演的难度。本文将引入图像识别领域中目标检测的相关算法来补充反演中对目标体位置、范围的识别，从而提升反演的准确率和适用性。与直接反演不同是，目标检测相当于在解决分类问题，而电阻率、极化率值的反演相当于回归预测问题，最直观的是二者使用的输入、输出数据不同，电阻率、极化率值的反演输入的是视电阻率、视极化率数据，输出的是预测的真实值或模型值，而目标检测输入的是视电阻率、视极化率图像，输出的是目标体的标注。另外，在算法中二者使用的损失函数也不同，在第三章的介绍中也曾提到过，回归问题常使用预测值与实际值之间的均方误差（MSE）作为损失函数，而分类问题则先进行归一化后再使用交叉熵作为损失函数。

本文将使用 LabelImg 对目标检测的样本图像进行注释，如图 4.5 所示的是对低阻体和双高阻体的目标图像进行标定，标定参数见表 4.4。由于目标检测是基于视电阻率图像和视极化率图像进行的，然而彩色图像的输入形式是三通道的，而实际的视电阻率、视极化率样本数据是单通道的，因此将使用其灰度图像进行标定并作为输入，尺寸大小为 300×300。主要将目标体分为低阻（lr）、高阻（hr）、极高化（hp）3 个 Classes（类别），各 60 个样本，共 180 个。




图 4.5 低阻体（LR）和双高极化体（HP）的目标图像标定

Fig. 4.5 Target image calibration of low-resistance body (LR) and dual high-polarization body (HP)

表 4.4 标注参数

Table 4.4 Corresponding annotation parameters

类别编号	中心点 X	中心点 Y	宽度 W	高度 Y
1	0.346405	0.172581	0.094771	0.170968
2	0.389706	0.208065	0.047386	0.241935
	0.605392	0.211290	0.047386	0.248387

4.3 模型的训练与测试

反演模型的网络参数设置:

使用的激活函数是 Relu, 其计算公式为

$$f(x) = \max(0, x), \tag{4-3}$$

位于卷积运算之后, 把卷积层输出的结果通过激活函数计算再加上偏移量后的结果作为下一层的输入。当激活函数的输入小于 0 时, 输出 0; 大于 0 时, 则输出该值。

动量参数设置为 0.95, 权重衰减率 0.0005, 学习率 0.001, 迭代次数 2000 次。

运行环境:

CPU: 至强 4210R*2 (10 核心 20 线程 2.4GHZ 13.75MB 缓存), 内存 64GB, 显卡: Nvidia GeForce RTX3090 (24GB), 系统为 64 位 Windows 10 工作站专业版。

4.3.1 电阻率与极化率反演

反演模型的卷积层为 5×5 和 3×3 的卷积核+L2 正则化+Relu 激活函数, 池化层为 2×2 最大池化, 损失函数为均方误差 (MSE), 共三组, 全连接层 (Fc) 有三层, 具体的网络结构如表 4.5 所示。将样本数据集随机分成 80%的训练集和 20%的测试集, 其中训练集中包含 200 个验证样本数据, 训练 5 次, 取平均结果得到表 4.6 的反演结果。

表 4.5 电阻率、极化率反演模型的网络结构

Table 4.5 Network structure of resistivity and polarizability inversion model

层名	网络参数	输出尺寸	数量
输入		48×48	1
Conv1	5×5, s=1, 16filters	44×44	16
Relu1		44×44	16
Pool1	2×2 max pool, s=2, 16filters	22×22	16
Conv2	3×3, s=1, 32filters	20×20	32
Relu2		20×20	32
Pool2	2×2 max pool, s=2, 32filters	10×10	32
Conv3	3×3, s=1, 64filters	8×8	64
Relu2		8×8	64
Pool3	2×2 max pool, s=2, 64filters	4×4	64
Conv	4×4, s=1, 512filters	1×1	512
Fc1		1×1	512
Fc2		1×1	100
Fc3		1×1	408
输出		1×1	408

表 4.6 电阻率、极化率反演结果的比较

Table 4.6 Comparison of the inversion results of resistivity and polarizability

模型类型 评价参数	单一异常		混合异常	
	MSE	精确度(%)	MSE	精确度(%)
电阻率	0.8146	93	6.5028	85

反演结果表明,总体上,极化率的反演结果比电阻率的反演结果好,单一异常反演比混合异常反演的效果好,预测值更贴近于真实值,反演的误差较小。

具体的,在单一异常情况下,电阻率反演与极化率反演的差别不大,均方误差(MSE)略小于极化率,二者的精确度均高于 90%,但极化率的预测效果更好。如图 4.6 和图 4.7 是电阻率为 $10\Omega\cdot m$ 单一低阻异常体在背景电阻率为 $500\Omega\cdot m$ 的场地中的视电阻率图的反演结果和极化率为 20% 的单一高极化异常体在背景电阻率为 2% 的场地中的视极化率图的反演结果。结果表明,在反演后的电阻率、极化率断面图中能够明确出异常体的位置及大小,预测出模型的具体参数值,其中,除了预测的异常值比较接近外,其背景值也较为接近,而且异常体边界处的数值偏大,能够清楚地区分出异常体的形态特征。

然而,在混合异常情况下,电阻率反演的效果明显下降,均方误差(ESM)大,预测精确度约为 85%,极化率反演的效果也有明显下降,但精确度仍在 90%,可见采用极化率反演的特征较电阻率明显。如图 4.8 和图 4.9 是混合异常情况下的反演结果,明显可见,电阻率值为 $10\Omega\cdot m$ 的低阻异常体与电阻率为 $1000\Omega\cdot m$ 的高阻体混合在背景电阻率为 $500\Omega\cdot m$ 的场地中的反演图像,异常体的形态、边界不规则,预测值与目标值的误差较大,异常体内部的参数值不均匀,而两个 20% 的高极化体混合在背景极化率为 2% 的场地中的反演结果较为明显,预测值与目标值误差小,形态边界清晰。

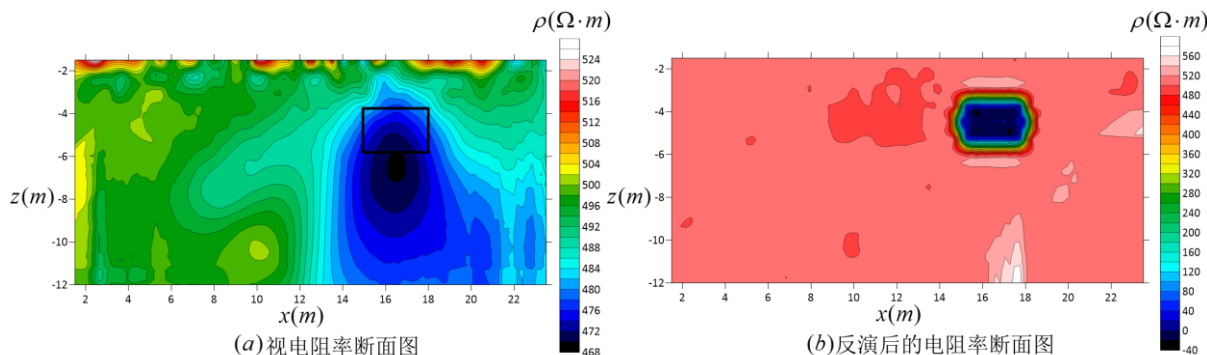


图 4.6 低电阻率单异常体的反演结果

Fig. 4.6 The inversion results of single anomalous body with low resistivity




图 4.7 高极化单异常体的反演结果

Fig. 4.7 The inversion results of single anomalous body with high polarization

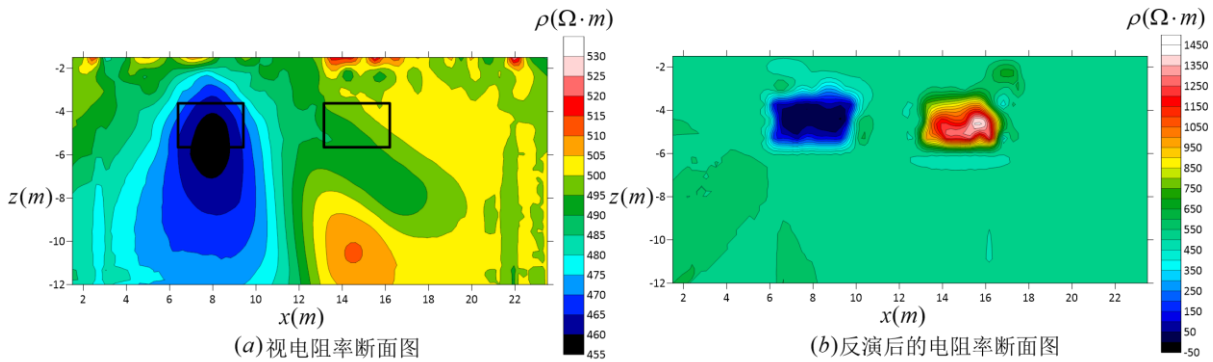


图 4.8 高低阻混合异常的反演结果

Fig. 4.8 The inversion results of high and low resistance mixed anomalies

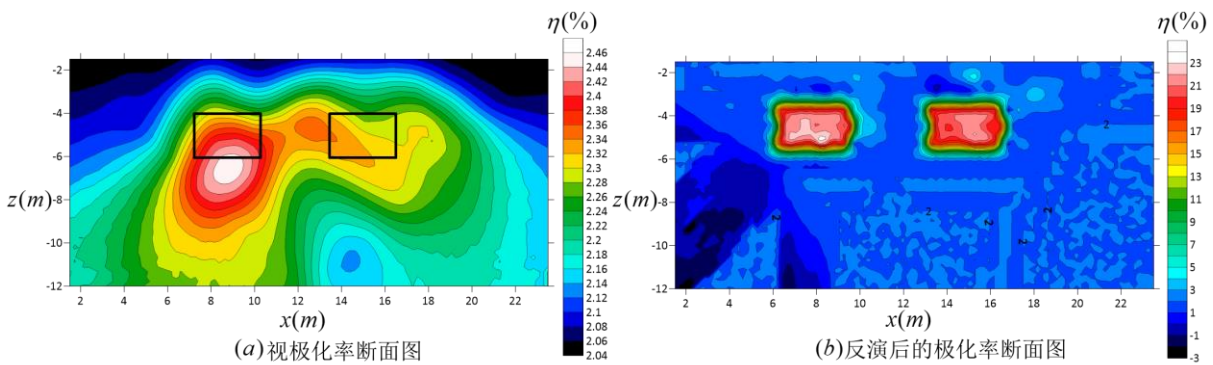


图 4.9 高极化混合异常反演结果

Fig. 4.9 The inversion results of highly polarized mixed anomalies

4.3.2 电阻率与极化率异常目标检测

反演模型的卷积层为 5×5 的卷积核+L2 正则化+Relu 激活函数，池化层为 2×2 、步长为 2 或 4 的最大池化，损失函数为交叉熵，共四组，全连接层（Fc）有三层，最后还有一层 Softmax 层，网络结构如表 4.7 所示。将标注完成的样本数据集随机分成 80% 的训练集和 20% 的测试集，其中训练集中包含 10% 的验证样本，训练 5 次，取平均值得到表 4.8 的结果。

表 4.7 电阻率、极化率异常体目标检测模型的网络结构

Table 4.7 The network structure of the target detection model of resistivity and polarizability anomalous bodies

层名	网络参数	输出尺寸	数量
输入		300×300	1
Conv1	5×5, s=1, 32filters	296×296	32
Relu1		296×296	32
Pool1	3×3 max pool, s=2, 32filters	148×148	32
Conv2	5×5, s=1, 64filters	144×144	64
Relu2		144×144	64
Pool2	2×2 max pool, s=4, 64filters	36×36	64
Conv3	5×5, s=1, 128filters	32×32	128
Relu3		32×32	128
Pool3	2×2 max pool, s=2, 128filters	16×16	128

Conv4	5×5, s=1, 256filters	12×12	256
Relu4		12×12	256
Pool4	2×2 max pool, s=2, 256filters	6×6	256
Conv	6×6, s=1, 512filters	1×1	512
Fc1		1×1	512
Fc2		1×1	10
Fc3		1×1	5
Softmax 层		1×1	5
输出		1×1	5

表 4.8 电阻率、极化率异常目标的检测结果比较

Table 4.8 Comparison of the target detection results of resistivity and polarizability anomalous bodies

模型类型 评价参数	单一异常		混合异常	
	交叉熵损失值	精确度(%)	交叉熵损失值	精确度(%)
高阻异常体	1.2451	91	7.5402	83.33
低阻异常体	0.8879	93	5.2958	89
高极化异常体	0.9897	94	2.3345	90

检测结果表明，目标检测算法能够较好地对电阻率、极化率异常情况进行分类，并标注出异常体的位置和范围，总体上，单一异常的目标检测效果要优于混合异常，极化率异常要优于电阻率异常。如图 4.10-图 4.12 是电阻率、极化率异常目标检测的样本示例与检测效果，图 4.10 高阻异常体目标检测的结果中，左边是一个单一高阻体，右边是高阻低阻混合场景下的高阻体，绿色标注框（hr）表示高阻异常体类别，能够看到其较为准确地对异常范围进行了圈定；图 4.11 是低阻异常体目标检测的结果，图左是单一异常情况，标注的准确率较高，图右是高阻低阻的混合情况，且低阻体深度较深，其检测结果较实际模型略大，因为混合异常情况下深部异常常受浅部异常的影响，而表现出特征较弱的现象。




图 4.10 高阻异常体目标检测的结果

Fig. 4.10 The target detection result of high-resistance anomalous body

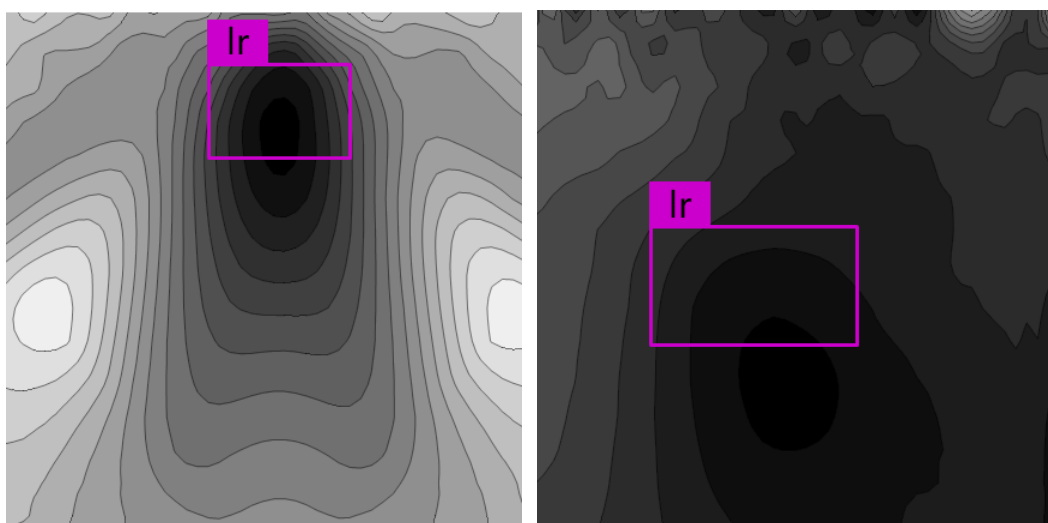


图 4.11 低阻异常体目标检测的结果

Fig. 4.11 The target detection results of low-resistance anomalous body

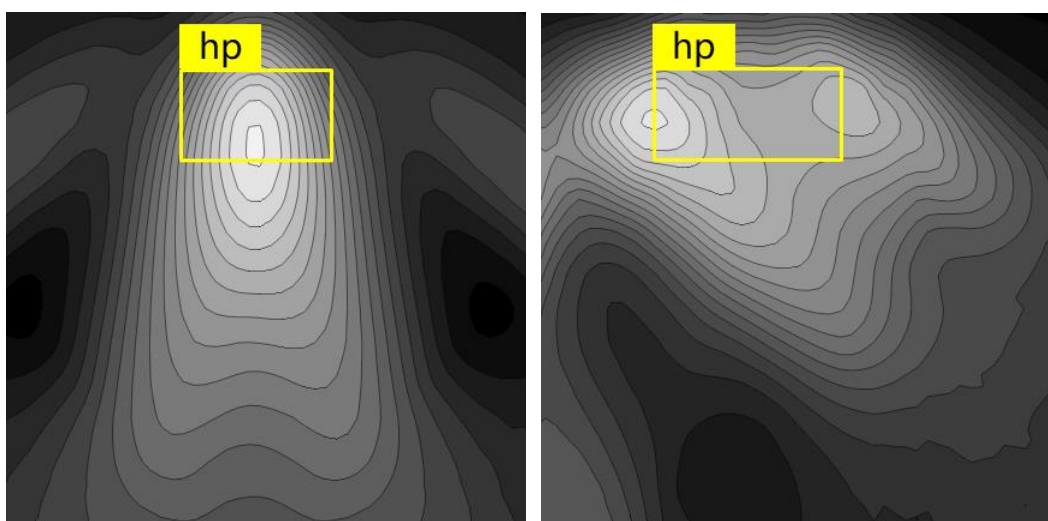


图 4.12 高极化异常体目标检测的结果

Fig. 4.12 The target detection results of highly polarized anomalous body

如图 4.12 是极高化异常体目标检测的结果，图左是单一极高化体，图右是混合高低阻体中的高阻极高化体，其视极化率等值线呈现较单一异常更宽的范围，并且在目标检测时，它的标注框也比实际异常体模型设置的尺寸宽。

4.4 本章小结

本章首先介绍了基于 PyTorch 卷积神经网络的电阻率、极化率反演的基本流程，然后从样本数据的采集、预处理和异常体目标图像的标定三个方面详细描述了电阻率、极化率反演与其异常体目标检测的样本数据库的建立，最后分别从电阻率、极化率值的预测和电阻率、极化率异常体目标检测两个方面对反演进行了具体的描述与结果讨论。反演得到结论如下：

(1) 基于卷积神经网络的极化率的反演结果（精确度 92.8%）比电阻率的反演结

果（精确度 89%）好，单一异常反演的结果（精确度 94.3%）比混合异常反演的结果（精确度 87.5%）好，极化率和单一异常情况的预测值更贴近于真实值，反演的误差较小；

（2）在反演得到的电阻率、极化率断面图中，能够明显直观地看到异常体的位置、大小和模型参数的具体预测值，而且异常体边界处的数值较大，能够清楚地区分出异常体具体的形态特征，但是在电阻率混合异常模型中，该效果表现得略差；

（3）基于卷积神经网络的异常体目标检测反演模型能够较好地对电阻率、极化率异常情况进行分类，并标注出异常体的位置和范围，单一异常的目标检测效果（精确度 92.67%）要优于混合异常（精确度 87.44%），极高化异常的识别结果（精确度 92%）要优于电阻率异常的识别结果（精确度 89.08%）。

第 5 章 反演模型的应用与评估

反演模型的评价、优化与应用是对反演模型的适用性进行评估，不仅要与传统的反演方法进行对比，还要在具体的实际应用中进行检测，最后还要针对反演中出现的问题进行优化，只有这样较为完善的研究才能够实现它的价值。

5.1 反演模型的评价

本文主要建立了基于卷积神经网络的电阻率、极化率反演模型，包括视电阻率、视极化率图对应位置的真实值反演与电阻率、极化率异常体的目标检测。传统的神经网络反演方法有 BP 神经网络，利用 Matlab 神经网络工具箱对第四章建立的样本数据集进行 BP 神经网络模型的训练，设计一个神经元个数分别为 272 和 10 的两个隐藏层和输入层、输出层的神经元个数都为 408 的 BP 神经网络，将训练得出的均方误差（MSE）结果与本文 4.3.1 节给出的结果进行比较，比较结果见表 5.1。

表 5.1 两种算法电阻率、极化率反演结果的比较

Table 5.1 Comparison of resistivity and polarization inversion results between two algorithms				
模型类型	单一异常		混合异常	
评价参数	卷积网络的 MSE	BP 网络的 MSE	卷积网络的 MSE	BP 网络的 MSE
电阻率	0.8146	2.0886	6.5028	10.0749
极化率	0.7315	1.7102	4.8529	9.6953

从表 5.1 的数据中，可以直观地看出，不论模型的类型，BP 神经网络模型反演的电阻率和极化率的均方误差（MSE）均大于本文设计的卷积神经网络模型反演的均方误差（MSE），说明本文模型的反演预测结果优于传统 BP 神经网络反演的结果。在 BP 神经网络模型中，模型的输入是样本数据的坐标值与视电阻率值或视极化率值，输出的是对应位置的真实电阻率与极化率，而且 BP 神经网络在训练过程中将输入输出数据进行了归一化处理，即便对隐藏层和神经元个数进行重设，也很难达到卷积神经网络对视电阻率、视极化率二维矩阵提取特征所表达的效果。

5.2 反演模型在行道树地下生态环境中检测中的应用

植物扎根于大地，对土地的污染情况了如指掌，行道树位于道路两侧，具有许多作用，对路域生态环境的影响很大。学生公寓 1-2 楼东侧的北辰中路两侧的香樟树长势差别极为明显，如图 5.1 所示，道路西侧的 9 棵香樟树长势茂盛、枝叶健壮、叶色浓绿、干直冠美，而道路东侧的 9 棵香樟树长势较差、树干细小且有枯枝残叶。据调研，这一批树为新校区一期学生公寓落成时统一栽种的，已经在这里生长了十几年了。经过专业人士的初步推测，极有可能是其根部的生态环境对树的生长造成了影响，拟采用电法勘探技术对该场地进行调查。

根是植物的营养器官，通常位于地表下面，负责吸收土壤里面的水分、无机盐及可溶性小分子有机质，并且具有支持、繁殖、贮存合成有机物质的作用。同时，土壤中的水分、无机盐及有机质会对土壤的电阻率、极化率造成影响。另外，如果土壤有污染或地下水土的电阻率、极化率差别大、变化大也是树木生长发育不良的影响因素。




图 5.1 行道树实景

Fig. 5.1 The real scene of street tree

5.2.1 实地测量

首先对行道树两侧的土壤进行了取样测量和原位测量，使用岩石标本电性测试架和岩石标本电性测试仪对 10cmPPR 管中的土样进行了测量，并使用对称四极装置和岩石标本电性测试仪在土壤原位进行了小极距法的电性观测，测量装置如图 5.2 所示，电性与含水率测量仪器如图 5.3 所示。测量的结果如表 5.2 所示。



图 5.2 原位测量对称四极装置

Fig. 5.2 The situ measurement device of the symmetrical quadrupole

表 5.2 测量结果

Table 5.2 The measurement result								
测量方式	含水率	VP	IP	RO	M1	M2	M3	M4
西侧原位	18.71%	2.37	15.78	47.10	3.51	2.09	1.18	0.71
西侧标本		310.02	15.80	30.80	1.96	0.81	0.26	0.12
东侧原位	20.15%	2.33	15.79	46.33	1.96	1.03	0.44	0.19
东侧标本		287.23	15.80	28.54	1.93	0.80	0.27	0.13

结合表 5.2 和实地调查的结果可知,西侧(茂盛测)是荫侧,采样土位处植被茂盛、腐叶众多,养分更足,其电阻率与极化率均高于东侧(稀疏测)的土样。



图 5.3 电性与含水率测量仪器

Fig. 5.3 Electricity measuring instrument and Moisture content measuring instrument

然后进行场地调查试验,根据第二章介绍的电法装置进行布线,采用极距为 1m 的对称四极装置进行人工跑极的方法进行测量,使用的仪器是数字幅频激电仪,如图 5.4 所示是装置侧视图和数字幅频激电仪发射机与接收机。测量结果如图 5.5 所示。



图 5.4 测量装置与仪器

Fig. 5.4 Measuring devices and instruments

结合图 5.5 和实际的场地环境,可以得出,行道树地下生态环境的视电阻率变化不大,浅表高阻体与实际路沿底部混凝土位置相对应;深部电阻率变化有规律,在 $8\sim 12\Omega\cdot m$ 之间;东侧(稀疏侧)深部有一处视电阻率有反转,呈类圆形高阻异常,可能是由于金属管线所致,但总体的视电阻率比对侧(西侧,茂盛侧)明显较低。

从图中(c)、(d)所示的视极化率断面图中,不难看出,西侧(茂盛侧)深部极化率较

为稳定, 范围在 1~3%之间, 是原位普通土与富含无机盐或可溶性小分子有机质的正常
值; 东侧(稀疏侧)深部有多处高极化, 成管线状分布, 极化率高达 10~13.5%。初步
推测是由旁边的信息井和上话井引出的管线占据了地下树根大部分的生长环境, 加之这
些管线和地下路灯电线老化释放出的游散电流对树木根部的生长和土质环境造成了影
响或污染。

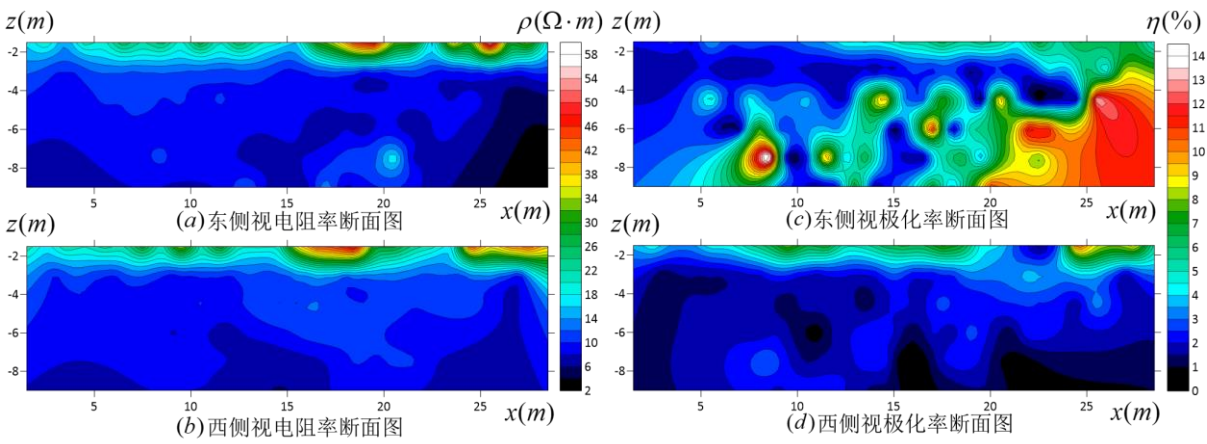


图 5.5 电法检测结果

Fig. 5.5 The results of electrical prospecting

进一步的, 将研究区域道路两侧测得的电性参数进行统计, 得到如表 5.3 所示的结果, 发现西侧(茂盛侧)水土的电阻率、极化率众数值均高于东侧(稀疏侧), 说明西
侧土壤的营养充足或更利于植物的生长。

表 5.3 道路两侧电性参数的统计比较

Table 5.3 Statistical comparison of electrical parameters on both sides of the road

	茂盛侧		稀疏侧	
	电阻率	极化率	电阻率	极化率
平均数	14.63	2.88	13.41	4.16
中位数	10.44	2.12	9.96	3.28
众数	9.65	1.8	8.5	1.5

5.2.2 目标检测

将变化、起伏特征明显的东侧视极化率测量数据按照 4.2.2 节介绍的方式进行预处
理后, 作为高极化率异常反演模型的输入, 进行反演, 反演得到异常体目标检测的结果
如图 5.6 所示, 发现目标检测模型能够对视极化率图中的部分高极化异常体进行标注。
经过实地观察周围井引出的管线方向, 可以基本确定出东侧香樟树下部有众多直径为
20cm 左右的金属管线, 占据了大部分树根生长的空间, 对土壤的通气性和厚度都有影
响, 限制了树根的生长发育, 从而影响了树的长势; 而茂盛侧深部的视极化率变化稳定,
无明显异常体。




图 5.6 行道树东侧地下高极化体目标检测的结果

Fig. 5.6 The target detection results of underground high-polarization bodies on the east side of the street trees

5.3 模型的优化

模型的优化可以从模型结构、算法和样本数据等多个方面进行。本文将主要从反演形式上对模型进行优化，同时提出对算法的改进思路。

5.3.1 电阻率与极化率联合反演

由于本文是通过正演模拟的方式采集样本数据，所以电阻率、极化率使用的正演模型是同源的，因此除了可以使用电阻率、极化率反演结果相结合的形式进行分析讨论外，还可以进行电阻率与极化率的联合反演，则把视电阻率、视极化率数据作为双通道数据输入设计的反演网络结构中进行训练，输出模型中异常体的位置坐标及大小（高度和宽度）。具体的网络模型设置如表 5.4 所示。

表 5.4 电阻率与极化率联合反演模型的网络结构

Table 5.4 The network structure of joint resistivity and polarization inversion model

层名	网络参数	输出尺寸	数量
输入		48×48	2
Conv1	5×5, s=1, 16filters	44×44	16
Relu1		44×44	16
Pool1	2×2 max pool, s=2, 16filters	22×22	16
Conv2	3×3, s=1, 32filters	20×20	32
Relu2		20×20	32
Pool2	2×2 max pool, s=2, 32filters	10×10	32
Conv3	3×3, s=1, 64filters	8×8	64
Relu2		8×8	64
Pool3	2×2 max pool, s=2, 64filters	4×4	64
Conv	4×4, s=1, 512filters	1×1	512
Fc1		1×1	512
Fc2		1×1	10
Fc3		1×1	5
Softmax 层		1×1	5
输出		1×1	5

表 5.5 是电阻率、极化率联合反演的结果，从数据中可以看出，联合反演模型的精确度都有所提升，可见电阻率、极化率双通道联合反演能够有效缩小模型的预测误差，提高模型反演的准确率。

表 5.5 电阻率、极化率联合反演的结果

Table 5.5 The results of joint resistivity and polarizability inversion

模型类型 评价参数	单一异常		混合异常	
	交叉熵	精确度(%)	交叉熵	精确度(%)
位置	0.2464	97	1.9153	89
大小	0.4311	96	3.4502	88

5.3.2 反演算法的优化思路

为了更好地将电阻率法广泛应用于各种工程检测领域，本文研究了基于卷积神经网络的电阻率、极化率反演成像技术，针对现在已有的反演方法所遗留的混合异常情况下的低辨识度和限定异常类型环境等问题，提出了基于深度卷积神经网络与多层特征融合的三维电阻率反演的改进思路。

基于 PyTorch 深度学习框架构建一种 ResNet（深度残差网络）^[65]和 FPN（多层尺度特征融合检测算法）相结合的卷积神经网络用于优化电阻率、极化率的反演能力。因为 ResNet 不再是简单的堆积层数，而是输出两个连续的卷积层，一个按照常规路线，一个通过捷径（Identity 恒等映射），将优化目标转化成了一个残差函数，避免了梯度消失问题，提高了训练效果和速度，而且残差的思想比较符合视电阻率、视极化率与其物理性特征区别较大的特性；而 FPN 是对卷积神经网络的一种增强，在高层特征图上可以检测相对较大的目标，在底层特征图上可以检测相对较小的目标，能够解决实际勘探中目标体大小未知的困难，提高反演的辨识度。二者的结合既能够改变传统神经网络反演所遗留的局部最优解的问题，又能够有效地提高视电阻率、视极化率图像的识别率，当然还可以用于电阻率与极化率的双通道联合反演，进一步加强模型的适用性。

5.4 本章小结

本章主要对反演模型进行了评估：

首先，与传统的 BP 神经网络反演模型进行了对比，结果基于卷积神经网络的电阻率反演模型的均方误差（MSE）3.66 比基于 BP 神经网络的电阻率反演模型的均方误差（MSE）6.08 低了 $2.42\Omega\cdot m$ ，极化率反演模型的均方误差（MSE）2.79 比 BP 神经网络模型的均方误差（MSE）5.70 低了 2.91%。

其次，在实际的行道树地下生态环境的检测中进行了应用，实际应用表明目标检测模型能够对视极化率图中明显的异常体进行简单的标注。

然后，又对模型进行了优化，设计了电阻率与极化率双通道联合反演模型，反演结果表明，联合反演确实能够减小误差，提高反演的准确率（由普通反演 90.9% 的总体精确度提高至 92.5%）。

最后，提出了反演算法下一步基于 ResNet（深度残差网络，另一种卷积神经网络）和 FPN（多层尺度特征融合检测算法）相结合的优化方式和改进思路。同时，简单介绍了 ResNet 网络模型的特点与 FPN 增强算法的优势。

第 6 章 结论

6.1 研究结论

电阻率法和激发极化法是地球物理中传统的探测方法,由于它们具有无损、低成本、效率高、探测范围广等特点,能够有效地应用于场地污染的调查研究中。然而,提高电阻率、极化率反演成像的能力能够极大地增强电阻率法、激发极化法工程勘察的适应性和精度,而对于反演方法的研究也一直是该领域学者研究的重点。本文利用 Pytorch 深度学习框架建立了基于卷积神经网络的电阻率、极化率反演模型,对提高电阻率法、激发极化法在污染场地调查中的准确率和辨识度具有重要意义。具体的研究内容及得到的结论如下:

(1) 基于有限单元法对电阻率、极化率进行了正演模拟,对几种典型的污染场景模型模拟的视电阻率、视极化率断面图进行了讨论分析,结果表明在视电阻率、视极化率图中,单一异常体的特征明显且形态和边界清晰,能够清楚地分辨出异常体的类型、位置及范围;而混合异常情况下,模型异常体的电性参数与背景反差大的较反差小的特征明显,深部异常体会受浅部异常体的影响而呈现出形态、边界不清晰的特征;另外,高阻体处的等值线呈现出向外扩散的特征,而低阻体呈现出等值线向内收紧的特征。

(2) 基于卷积神经网络对电阻率、极化率进行了反演,分别建立了电阻率、极化率值的预测模型和其不同异常情况下的目标检测模型,反演结果表明单一异常体的反演结果(预测模型的精确度为 94.3%,目标检测的精确度为 92.67%)优于混合异常体的反演结果(预测模型的精确度为 87.5%,目标检测的精确度为 87.44%),极化率的反演结果(预测模型的精确度为 92.8%,目标检测的精确度为 92.67%)优于电阻率的反演结果(预测模型的精确度为 92%,目标检测的精确度为 89.08%),并且举例给出了电阻率、极化率反演得出的断面图,图中可以直观地辨别出异常体的位置、大小及具体的参数值。

(3) 在反演模型的对比评价中,与传统的 BP 神经网络反演模型进行了对比,结果基于卷积神经网络的电阻率反演模型的均方误差(MSE)比基于 BP 神经网络的电阻率反演模型降低了 $2.42\Omega\cdot m$,极化率反演模型降低了 2.91%。

(4) 在实际应用中,目标检测算法能够对异常体目标进行简单的标注。电阻率与极化率的双通道联合反演结果表明联合反演的精确度提高了 1.6%,确实能使误差减小,从而提高反演的准确率和辨识度。

6.2 研究展望

对于基于卷积神经网络的污染场地电阻率与极化率反演的研究中,还有一些需要改进和完善的方面,主要有以下几点:

(1) 优化样本库:设计更加全面的正演模型进行模拟或收集典型的污染场地的检测结果与解译资料来建立更加全面的样本数据库,同时适当增加样本的数据记录点,增

大电法检测的分辨率。

（2）优化模型：采用与其他人工智能算法相结合的方法继续对网络模型进行优化，例如采用 ResNet（深度残差网络）和 FPN（多层尺度特征融合检测算法）相结合的优化方式等，增强算法对电阻率、极化率的特征表达。

（3）继续探究联合反演的新方法，例如将三维地质雷达方法也引入到污染场地的检测中，同时与电法探测的结果进行联合反演。

参考文献

- [1] 徐亚, 刘玉强, 胡立堂, 等. 填埋场井筒效应及其对污染监测井监测效果的影响[J]. 中国环境科学, 2018, 38(8): 3113-3120.
- [2] 中华人民共和国生态环境部. 场地环境监测技术导则 HJ 25.2-2014[S]. 中华人民共和国生态环境部, 2014.
- [3] 王旭. 美国“棕色地带”再开发计划和城市社区的可持续发展[J]. 东南学术, 2003(3): 156-162.
- [4] 刘玉强, 李丽, 王琪, 等. 典型铬渣污染场地的污染状况与综合整治对策[J]. 环境科学研究, 2009(2): 248-253.
- [5] 朱勇. 铬污染场地低频复电阻率时域和频域联合探测技术研究[D]. 中国矿业大学(北京), 2013.
- [6] 曾祥永. 基于 Cole-Cole 模型的铬污染土壤时频域联合反演算法的研究[D]. 山东师范大学, 2015.
- [7] Masy T, Caterina D, Tromme O, et al. Electrical resistivity tomography to monitor enhanced biodegradation of hydrocarbons with *Rhodococcus erythropolis* T902.1 at a pilot scale[J]. Journal of Contaminant Hydrology, 2016(184): 1-13.
- [8] Mohamaden M I I, Wahaballa A, El-Sayed H M. Application of electrical resistivity prospecting in wastewater management: a case study (Kharga Oasis, Egypt)[J]. Egyptian Journal of Aquatic Research, 2016, 42(1): 33-39.
- [9] Liao Q, Deng Y, Shi X, et al. Delineation of contaminant plume for an inorganic contaminated site using electrical resistivity tomography: comparison with direct-push technique[J]. Environmental Monitoring & Assessment, 2018, 190(4): 187.
- [10] 杨民, 周红卫, 胡超. 高密度电阻率法和地质雷达在污染探测中的应用[J]. 世界有色金属, 2017(9): 110-112.
- [11] 刘国辉, 徐晶, 王猛, 等. 高密度电阻率法在垃圾填埋场渗漏检测中的应用[J]. 物探与化探, 2011, 35(5): 680-683+691.
- [12] 闫永利, 马晓冰, 袁国平, 等. 大地电磁法在阿苏卫填埋场地下水污染检测的应用研究[J]. 地球物理学报, 2007(6): 1863-1868.
- [13] 能昌信, 王玉玲, 张波, 等. 基于 OTSU 的 ERT 图像中污染区域识别方法研究[J]. 环境科学与技术, 2018, 41(12): 138-143.
- [14] Lecun Y, Bengio Y, Hinton G E. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [15] 陈晓, 于鹏, 邓居智, 等. 地球物理联合反演新框架研究[J]. 石油地球物理勘探, 2017, 52(4): 851-858+883+629.
- [16] 陈晦鸣. 1994 年矿产勘探与环境监测激发极化 (IP) 国际会议述评[J]. 地球物理学进展, 1995(2): 111-113.

- [17] Olivar A L, DeLima, Fabio F S, et al. (王艳君, 陈云升译) 用探地雷达和谱激发极化法追踪地下污染[M]. 物探化探译丛, 1998.
- [18] Astodemou E, Thomas-Betts A. DC resistivity and induced polarization investigations at a waste disposal site and its environments[J]. Journal of Applied Geophysics, 2000(44): 275-302.
- [19] Jorgelp, Waltermf, Wagnerre, et al. The use of GPR and VES in delineating a contamination plume in a land fill site a case study in SE Brazil[J]. Journal of Applied Geophysics, 2004(55): 199-209.
- [20] Atekwanaea, Sauckwa, Werkemadd. Investigations of geoelectrical signatures at a hydrocarbon contaminated Site[J]. Journal of Applied Geophysics, 2000, 40(2-3): 167-180.
- [21] Liu H, Yang H, Yi F. Experimental study of the complex resistivity and dielectric constant of chrome-contaminated soil[J]. Journal of Applied Geophysics, 2016(131): 109-116.
- [22] 李金铭, 张春贺, 肖顺. 水污染的导电性和激电性与污染浓度变化关系的几个实验结果[J]. 地球物理学报, 1999(3): 428-434.
- [23] 能昌信, 刘玉强, 刘豪睿, 等. 铬污染土壤的导电性、频谱激电性和介电特性的实验结果[J]. 环境科学, 2011, 32(3): 758-765.
- [24] 张磊. 土壤污染物的频谱激电响应特征研究[J]. 科技广场, 2016(3): 17-21.
- [25] 程业勋, 刘海生, 赵章元. 城市垃圾污染的地球物理检测工程. 工程地球物理学报, 2004, 1(1): 26 -30.
- [26] 黄俊革. 三维电阻率/极化率有限元正演模拟与反演成像[D]. 中南大学, 2003.
- [27] 范振宇. 基于卷积神经网络的大地电磁深度学习反演研究[D]. 中国地质大学(北京), 2020.
- [28] Dahlin T. The development of DC resistivity imaging techniques[J]. Computers and Geosciences, 2001, 27(9): 1019-1029.
- [29] Pelton W H, Rijo L, Swift Jr C M. Inversion of two-dimensional resistivity and induced polarization data[J]. Geophysics, 1978, 43(4): 788-803.
- [30] Loke M H, Barker R D. Least-squares deconvolution of apparent resistivity pseudo sections[J]. Geophysics, 1995, 60(6): 1682-1690.
- [31] 吴小平. 非平坦地形条件下电阻率三维反演[J]. 地球物理学报, 2005, 48(4): 932-936.
- [32] Shaw R. Particle swarm optimization: A new tool to invert geophysical data[J]. Geophysics, 2007, 72(2): F75-F83.
- [33] El-Qady G, Ushijima K. Inversion of DC resistivity data using neural networks[J]. Geophysical Prospecting, 2001(49): 417-430.
- [34] 戴前伟, 江沸菠. 基于混沌振荡 PSO-BP 算法的电阻率层析成像非线性反演[J]. 中国有色金属学报, 2013, 23(10): 2897-2904.
- [35] 高明亮, 于生宝, 郑建波, 等. 基于 IGA 算法的电阻率神经网络反演成像研究[J]. 地球物理学报, 2016, 59(11): 4372-4382.
- [36] Neyamadpour A, Abdullah W A T, Taib S. Inversion of quasi-3D DC resistivity imaging

- data using artificial neural networks[J]. Journal of Earth System Science, 2010, 119(1): 27-40.
- [37] 江沸菠, 戴前伟, 董莉. 基于剪枝贝叶斯神经网络的电阻率成像非线性反演[J]. 应用地球物理, 2016, 13(2): 267-278.
- [38] 江沸菠. 基于神经网络的混合非线性电阻率反演成像[D]. 中南大学, 2014.
- [39] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]. IEEE Conference on Columbus: USA, 2014: 580-587.
- [40] Abdel-Hamid O, Mohamed A R, Jiang H, et al. Convolutional Neural Networks for Speech Recognition[J]. IEEE/ACM Transactions on Audio Speech and Language Processing, 2014, 22(10): 1533-1545.
- [41] Hinton G E. A practical guide to training restricted Boltzmann machines[J]. Momentum, 2012(9): 599-619.
- [42] Puzyrev V. Deep learning electromagnetic inversion with convolutional neural networks. Geophysical Journal International, 2019, 218(2): 817-832.
- [43] Conway D, Alexander B, King M, et al. Inverting magnetotelluric responses in a three-dimensional earth using fast forward approximations based on artificial neural networks. Computers & Geosciences, 2019(127): 44-52.20.
- [44] 段友祥, 李根田, 孙歧峰. 卷积神经网络在储层预测中的应用研究[J]. 通信学报, 2016(37): 1-9.
- [45] 林年添, 张栋, 张凯, 等. 地震油气储层的小样本卷积神经网络学习与预测[J]. 地球物理学报, 2018, 61(10): 4110-4125
- [46] 李军健. 基于卷积神经网络的直流电阻率法地电模型识别方法研究[D]. 吉林大学, 2019.
- [47] 能昌信, 孙晓晨, 徐亚, 等. 基于深度卷积神经网络的场地污染非线性反演方法[J]. 中国环境科学, 2019, 39(12): 5162-5172.
- [48] 刘宇, 黄俊革, 王瑞, 漆玉茂, 卢思同. 基于粗糙集的盐碱环境混凝土电阻率与极化率影响研究[J]. 混凝土, 2021(8): 64-68.
- [49] 刘胜, 王媛, 田彦. 直流电法电场分布的边界效应研究[J]. 地球物理学进展, 2019, 34(2): 0763-0774.
- [50] 中华人民共和国国土资源部. 时间域激发极化法技术规程 DZ/T 0070-2016[S]. 中华人民共和国国土资源部, 2016.
- [51] 裴健. 盐碱环境下混凝土内部钢筋腐蚀的观测方法研究[D]. 上海应用技术大学, 2020.
- [52] 程勃, 黄俊革, 阮百尧. 有限单元法非均匀剖分对数值模拟影响研究[J]. 地球物理学进展, 2010, 25(5): 1856-1862.
- [53] 程志平. 电法勘探教程[M]. 北京: 冶金工业出版社, 2007.
- [54] Seigel, H O. Mathematical formulation and type curves for induced polarization[J]. Geophysics, 1959, 24(3): 547-565.

- [55] Craig W B, Stanley H W. Three-dimensional mise-a-la-masse modeling applied to mapping fracture zones [J]. Geophysics, 1986, 51(1): 98-113.
- [56] 徐世浙. 地球物理中的有限单元法[M]. 北京: 科学出版社, 1994.
- [57] 中华人民共和国生态环境部. 地下水污染地球物理探测技术指南(试行)[S]. 中华人民共和国生态环境部, 2020.
- [58] 何继善. 双频电法的物理基础[M], 北京: 高等教育出版社, 2006.
- [59] Rosenblatt F. The perceptron: A probabilistic model for information storage and organization in the brain[J]. Psychological Review, 1958, 65(6): 386-408.
- [60] 黄俊革, 刘宇, 王瑞, 等. 基于微服务与机器学习的煤矿安全监测系统[J]. 应用技术学报, 2020, 20(3): 250-253.
- [61] 陈通, 周晓辉. 基于 BP 神经网络的深层感知器预测模型[J]. 计算机与数字工程, 2019, 47(12): 2978-2981+3009.
- [62] Omid B H, Mahboubeh Z M, Mehri A D, et al. A self-tuning ANN model for simulation and forecasting of surface flows[J]. Water Resources Management volume, 2016(30): 2907-2929.
- [63] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [64] 王欢. 湘东地区水田土壤镉元素分布特征及其影响因素研究[D]. 湖南师范大学, 2020.
- [65] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

致 谢

金桂飘香，伴随着我硕士学位论文的完成，我的研究生生涯也即将告一段落。我的心中充满了不舍之情，同时也充满着对各位师长、同学的感激之情和对母校的感恩之情。

感谢在我的整个研究生阶段和硕士论文的写作中，不厌其烦地给予我帮助和指导的导师——黄俊革教授。无论是在科学研究上，还是工作生活中，您都是我永远学习的榜样，您两次援疆、为祖国边疆教育事业用心倾情的精神令我万分敬佩，我将永远牢记您的教诲，继续在今后的科研、学习和工作中努力奋斗，为祖国和社会贡献自己的力量。同时，我还要感谢我的师母史少利老师，在我的研究生学习与生活中给予了极大关怀和照顾，也正是因为有黄老师和您这样的恩师，才有师门的硕果累累。

另外，我还想感谢在我研究生阶段的科研和工作中，给予我帮助、启发和指导的同济大学的于鹏教授、张新兵博士，桂林理工大学的吕玉增副教授，我校的杨瑞君副教授、齐良锋副教授，以及上海市岩土工程检测中心的陈敏高级工程师、袁家余高级工程师。非常感谢各位老师及评阅和答辩专家提出的宝贵意见。

感谢我的同门漆玉茂、裴健、卢思同、张彧、鲁宁琦、刘先翠、王继豪在生活和科研上的相互鼓励与相互学习，以及室友沈博扬、施支鸿、蔡加熙在生活和学习上的关心和帮助。

感谢父母多年来对我的培养和支持，以及亲人、朋友和同学们在学习和生活上的鼓励和陪伴。

最后，我要感谢上海应用技术大学对我的培养，使得我在计算机、安全工程和地球物理等领域有了更深层次的了解和认识，积累了一定的科学研究和工作经验，非常有利于我今后的发展。

再次感谢各位老师、亲人和同学们，在我的科研学习和工作生活中给予的关心和帮助。谢谢大家！

攻读学位期间所开展的科研项目和发表的学术论文

科研项目：

- (1) 上海应用技术大学研究生高水平应用型科研成果培育项目“基于卷积神经网络的电阻率反演成像技术研究”(已结题)
- (2) 国家自然科学基金项目(41564005)“盐碱环境下混凝土内部介质的激发极化效应研究”(参与)
- (3) “联盟计划”项目(LM201903)“工业污染环境下的土壤间接检测方法研究”(参与)

学术论文：

- [1] 刘宇, 黄俊革, 王瑞, 漆玉茂, 卢思同. 基于粗糙集的盐碱环境混凝土电阻率与极化率影响研究[J]. 混凝土, 2021(8): 64-68. (北大核心)
- [2] 刘宇, 黄俊革, 卢思同, 宋雨晴. 海湾大学城汽车行驶工况与交通安全分析[J]. 公路与汽运, 2021(1): 24-28.
- [3] 黄俊革, 刘宇, 王瑞, 卢思同. 基于微服务与机器学习的煤矿安全监测系统[J]. 应用技术学报, 2020, 20(3): 250-253.

发明专利：

- [1] 黄俊革, 刘宇, 漆玉茂, 张彧, 裴健, 卢思同, 鲁宁琦, 谢圣. 有限空间电场分布确定方法及系统[P]. 上海市: CN110865247B, 2021-09-28. (已授权)
- [2] 黄俊革, 刘宇, 裴健, 王瑞, 卢思同, 鲁宁琦, 漆玉茂, 张彧. 一种桩体质量电法检测方法[P]. 上海市: CN111522066A, 2020-08-11. (公开)