

文章编号:1001-4098(2020)03-0132-09

基于 BN-ELM 的煤矿瓦斯安全态势预测方法^{*}

李 爽^{1,2}, 李丁炜^{1,2}, 犹梦洁^{1,2}, 曹庆仁^{1,2}

(1. 中国矿业大学 管理学院, 江苏 徐州 221100;

2. 中国矿业大学 安全科学与应急管理研究中心, 江苏 徐州 221100)

摘 要:控制瓦斯风险在煤矿安全生产中至关重要。本文将安全态势概念引入煤矿,提出了基于风险预测的煤矿瓦斯安全态势预测一般方法,将煤矿整体瓦斯安全状态直观地展示出来。首先,引入非实时监测数据,通过贝叶斯网络构建安全态势多级指标体系;其次,结合贝叶斯网络和极限学习机,对风险进行二级预测;最后,根据风险预测结果计算瓦斯安全态势值,并绘制安全态势走向图。并以中国山西省一座大型高瓦斯实验煤矿为例进行瓦斯风险及瓦斯安全态势预测。结果表明,本方法可以为煤矿管理者控制瓦斯风险提供决策支持。

关键词:机器学习;BN-ELM;安全态势;风险预测;瓦斯爆炸

中图分类号:C934

文献标识码:A

1 引言

我国是煤炭生产、消费大国,专家预测,到 2050 年我国煤炭消费量仍将占中国能源消费总量的 50% 左右,未来一段时间内煤炭资源在我国仍将占据能源体系中的主体地位^[1],煤炭的安全开采是支撑我国能源安全与经济稳定的重要基础。然而,煤炭行业灾害重、风险大、下井人员多、危险岗位多,是最典型的高危行业。近年来,随着煤矿信息化和自动化水平的提高,我国煤矿事故发生率和死亡人数虽然得到了有效降低,但仍然高于世界平均水平,中国煤矿事故死亡人数约占全球煤矿事故死亡人数的 70%^[2,3]。为了有效减少煤矿安全事故,应将工作重点由事后响应向事前预防转变,宏观把握整个煤矿的安全状态,对风险进行全面评估,做到防范于未然,从源头上遏制煤矿安全风险。

中国煤矿事故类型多样,其中,煤矿瓦斯事故被认为是最危险的,致死性和伤害性最大的灾害事故^[4]。随着煤矿开采深度的增加,煤矿瓦斯事故成为我国煤炭开采战略的主要威胁之一,瓦斯爆炸更是其中极为常见的一种^[5]。此外,由于我国煤矿多采取地下开采,煤矿生产系统具有危险源多、涉及的环节和层次多、生产条件恶劣^[6]的特点。因此,如何从时间、空间等维度更为全面地考量瓦斯风险

对煤矿的影响,对于把控煤矿安全具有十分重要的意义。

安全态势是从时间和空间的维度提取全部安全相关的因素,并通过对其的理解和分析来获得对系统整体安全状态的评估^[7],为了全面理解煤矿的安全状态以保障安全生产,可以将安全态势引入煤矿领域。目前,国内外针对安全态势的研究主要集中在计算机网络、电网及交通等领域。LU J 等通过支持向量机融合多源数据,得到网络总体态势^[8],为防御网络攻击提供帮助。Siaterlis 等将证据理论 D-S 引入到网络安全态势预测的应用中,对网络安全的发展趋势进行预测^[9]。张勇等将博弈理论应用于网络安全态势中,基于 Markov 博弈模型动态评估系统安全态势^[10]。孙玮喜等通过 PSO 对 SVM 进行优化,构建了具有收敛速度快、泛化能力强等优点的网络安全态势预测模型^[11]。在网络安全以外的领域中,Webb 等提出了一种态势感知信息安全风险管理模型(SA-ISRM),通过在企业范围内收集分析与风险相关的信息来解决信息安全风险评估实践中的不足之处^[12]。总体上,安全态势可以为防范系统风险提供全面的决策支持,但在煤矿等行业中尚未得到应用。

随着人工智能技术的发展,机器学习被越来越多地应用于瓦爆预测中。Tomizuka 等通过 CFD 方法对瓦爆进行数值模拟,以预测其危害程度^[13]。张宁等通过贝叶斯

^{*} 收稿日期:2019-11-03;修订日期:2020-03-26

基金项目:国家自然科学基金资助项目(71573256;71972176);国家重点研发计划项目(2017YFC0804408)

作者简介:李爽(1978-),女,江苏徐州人,教授,安全科学与应急管理研究中心主任,研究方向:安全管理,数据挖掘。。

网络确定瓦爆事故的关键影响因素^[14],为瓦爆预测提供了帮助。王永文等将多种优化算法与 ELM 相结合,对煤矿瓦斯涌出量进行预测^[15],实现了瓦爆风险单指标的高精度预测。Zhang, Tianjun 等使用 Adam 优化算法对 LSTM 循环神经网络进行优化,在此基础上构建煤矿瓦斯浓度预测模型,并取得了良好的预测效果^[16]。蔡斐等使用灰色 BP 神经网络通过对瓦斯爆炸风险的影响因素的预测^[17],实现了瓦斯爆炸风险的较高精度预测。然而,这些研究成果都有适用范围和局限性:风险预测时往往无法考虑人的行为的影响;预测模型多依赖于大量的训练数据并局限于特定的场景,且结果不以风险概率的形势给出;不能从系统的角度评估风险对煤矿整体的威胁程度。因此,难以为煤矿瓦斯安全态势的预测提供足够的支持。

综上,本文以煤矿瓦斯爆炸风险为切入点,提出一种基于风险预测的煤矿瓦斯安全态势预测的通用方法。由于优化的极限学习机(ELM)在瓦爆风险单指标预测方面有着优秀的性能^[18,19],同时贝叶斯网络(BN)模型可以发挥专家主观能动性在风险预测模型构建中的重要作用,本文结合 BN 与 ELM 构建瓦爆风险二级预测模型,并在此基础上获得煤矿瓦斯安全态势的预测值,以反映煤矿中瓦爆风险的概率及其影响范围。结果表明,该方法可以有效地反映出试点煤矿的瓦斯安全状态及其瓦斯风险控制能力,为煤矿管理者的安全决策、煤矿安全风险预控的研究提供了理论和实践支持。

2 方法设计

本文中,煤矿瓦斯安全态势预测以瓦斯爆炸风险预测为基础,反映了瓦斯爆炸风险对煤矿整体安全的影响。因此煤矿瓦斯安全态势的预测分为三个部分:①基于 BN 的瓦斯安全态势预测多级指标体系构建;②基于 BN 和 ELM 结合应用的瓦爆风险预测;③煤矿瓦斯安全态势预测。

2.1 基于 BN 的指标体系构建

(1) 贝叶斯网络(BN)

BN 是一种图形化地表示一组随机变量之间概率关系的信念网络^[20]。一个 BN 可以定义为: $BN = (G, \theta)$, G 是 X 上的联合概率分布的有向无环图, θ 表示网络的参数。 X 上的联合概率分布定义如下:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i | \text{Pa}(X_i)) \quad (1)$$

式中, X_i 表示第 i 个节点, $\text{Pa}(X_i)$ 表示第 X_i 的父节点。根据贝叶斯链式规则,可以将式(1)进一步写成:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i | X_1, X_2, \dots, X_{n-1}) \quad (2)$$

根据式(2),当根节点的先验概率和各节点的条件概

率已知时,可以计算全部节点的联合概率。因为 BN 的概率分布和网络拓扑结构不仅限于对样本统计数据分析和处理,还可以通过相关领域专家的先验知识得到^[21]。因此,当地区煤矿的事故数据由于监测条件不足而缺失甚至无法提供时,可以通过地区煤矿专家经验来调整贝叶斯网络节点及其概率分布。在此基础上,通过对瓦斯爆炸风险致因链的分析将影响风险的指标分为一级指标和多级指标。

(2) 基于 BN 的多级指标体系构建

通过 BN 构建煤矿瓦斯安全态势预测多级指标体系的步骤如下:

①根据全国煤矿瓦斯事故记录或地区记录,辨识煤矿瓦斯爆炸危险源,并构建 BN 拓扑模型以及确定 BN 中节点的概率。通常地方煤矿瓦斯爆炸事故数据较少,全国事故数据不适用于地方煤矿,因此地区煤矿专家应根据经验完善和调整贝叶斯网络。

通过对我国 2000~2018 年煤矿瓦斯爆炸事故数据的分析,构建贝叶斯网络,并根据地方煤矿专家意见调整贝叶斯网络中节点概率。网络拓扑如图 1 所示。

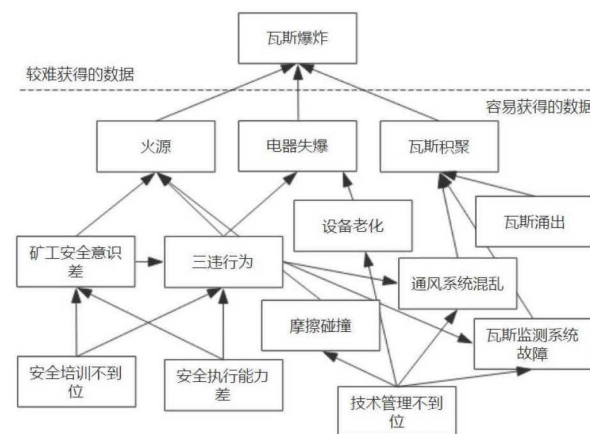


图1 瓦斯爆炸事故贝叶斯网络结构

②从 BN 结构中提取风险致因链,划分指标为一级指标和多级指标。

由图 1 可知,风险直接因素有火源、电器失爆、瓦斯积聚三项,称这些对风险直接因素为一级指标,记为 F_i 。通过对贝叶斯网络的分析,得到了所有一级指标的致因链,火源、电器失爆、瓦斯积聚的致因链如图 2 所示,根据致因链可以确定对一级指标存在影响的因素,称之为多级指标,记为 M_j 。

火源 F_1 对应的多级指标为:安全培训不到位 M_1 、安全执行能力弱 M_2 、技术管理不到位 M_3 、矿工安全意识低 M_4 、摩擦撞击 M_5 、三违行为 M_6 。

电器失爆 F_2 对应的多级指标为:安全培训不到位 M_1 、安全执行能力弱 M_2 、技术管理不到位 M_3 、矿工安全意识低 M_4 、三违行为 M_6 、设备老化 M_7 。

瓦斯积聚 F_3 对应的多级指标为:安全执行能力弱 M_2 、技术管理不到位 M_3 、三违行为 M_6 、通风系统混乱 M_8 、瓦斯监控系统故障 M_9 、瓦斯涌出 M_{10} 。

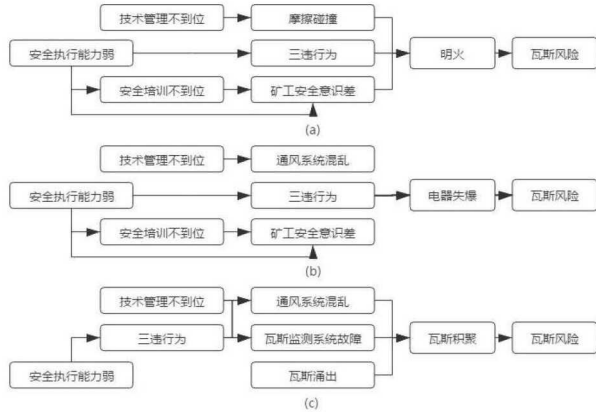


图2 一级指标致因链

③此外,由于矿井条件限制,部分数据无法实时监测获得,需要对指标中的非实时数据进行归类。依据专家意见为其设定相应的效应时间 T ,当非实时数据上传至系统后,在其发生时间 t_1 至 $t_1 + T$ 时间内,将其视为实时数据用于风险预测。

2.2 基于 BN-ELM 的风险预测

(1) 极限学习机 (ELM)

ELM 是一种快速学习算法,通过随机初始化输入权重和偏置并得到相应的输出权重来求解单隐层神经网络。设 N 个任意样本 (X_i, t_i) , 其中 $X_i = [X_{i1}, X_{i2}, \dots, X_{in}]^T \in R^n$, $t_i = [t_{i1}, t_{i2}, \dots, t_{im}]^T \in R^m$, 一个有 L 个隐层节点的单隐层神经网络可以表示为:

$$\sum_{i=1}^L \beta_i g(W_i X_j + b_i) = o_j, \quad j = 1, 2, \dots, N \quad (3)$$

式中, $g(x)$ 、 W_i 、 β_i 、 b_i 、 o_j 分别为激活函数、输入权重、输出权重、第 i 个隐层单元的偏置以及神经网络的输出。为使得经过学习后的输出的误差最小,需要满足存在 β_i 、 W_i 、 b_i , 使:

$$\sum_{i=1}^L \beta_i g(W_i X_j + b_i) = t_j, \quad j = 1, 2, \dots, N \quad (4)$$

表示为矩阵形式: $H\beta = T$, H 是隐层节点输出, β 为输出权重, T 为期望输出。ELM 是计算 $\|H\beta - T\|$ 的误差最小值, 也即求得损失函数的最小值:

$$E = \sum_{j=1}^N \left(\sum_{i=1}^L \beta_i g(W_i X_j + b_i) - t_j \right)^2 \quad (5)$$

ELM 在开始训练之前先随机产生输入权重 W_i 和第 i 个隐层单元的偏置 b_i , 一旦这两者被随机确定, 隐层节点的输出矩阵 H 也唯一确定, 并且输出权重 β 也可以得到, 计算公式为:

$$\beta' = H^+ T \quad (6)$$

其中, H^+ 为 H 的 Morre-Penrose 广义逆矩阵。

(2) 基于 ELM 的一级指标预测模型

一级指标预测阶段实现对风险直接影响因素的预测。煤矿系统作为一个整体, 其各个子系统、各部分间会相互影响。通过风险致因链的分析可知, 一级指标与其对应的多级指标集间存在致因关系, 而这种致因关系往往是一种隐含的非线性映射关系。ELM 作为一种高效、泛化能力强的分类器, 具有强大的探究变量间的非线性映射关系的能力^[22,23], 本文使用 ELM 构建一级指标预测模型。

由于 ELM 随机生成输入权重 W_i 和隐层偏置 b_i , 使得结果具有随机性, 这会影响到 ELM 模型在实际中的预测应用, 因此可以使用优化算法确定 W_i 和 b_i 两者的最优值。常用的 ELM 优化方法有遗传算法^[24]、粒子群算法^[25]、蚁狮优化算法^[26]等, 本文使用遗传算法对 ELM 进行优化。

设 N 组监测样本 (M_i, F_i) , F_i 为一级指标, M_i 为其对应的多级指标集合, 则 F_i 的 GA-ELM 预测模型构建过程为:

①编码种群个体。由 $(n+1)L$ 位编码组成, L 为隐层节点个数, n 为输入向量维数。以火源预测模型为例, $n=5+5(M_6)$ 实际划分为 5 个子指标, 后述), 并随机生成有 i 个个体的初始种群。

②计算个体适应度。通过 ELM 算法计算每一个个体取值下的 F_i 预测准确度率作为该个体的适应度 $Fitness_i$, 计算种群平均适应度 $Fitness$ 。

③选择、交叉和变异。选取 $Fitness_i > Fitness$ 的个体遗传至下一代, 并进行交叉和变异操作形成新的种群, 重复以上步骤, 直至达到最大迭代次数。

④找到最优适应度个体, 得到最优输入权重 W_i 和隐层偏置 b_i , $i=1, 2, \dots, L$ 。

⑤选择隐层神经元的激活函数 $g(x)$, 并计算隐层输出矩阵 H 和连接权值 $\beta' = H^+ T$ 。

(3) 基于 BN 的风险概率预测

根据式(2), 可以得到瓦斯爆炸风险概率预测模型。假设 $U = \{F_1, F_2, \dots, F_n, G\}$ 为一个离散变量集合, 其中 F_i 为风险一级指标, G 为瓦斯风险, $F = \{F_1 = f_1, F_2 = f_2, \dots, F_n = f_n\}$ 是 F_i 的取值集合, $G = Y$ 表示风险出现。当一级指标取值为集合 F 时, $G=Y$ 的概率表示为式(7):

$$P(G=Y | F=f) = \frac{P(G=Y) \cdot P(F=f | G=Y)}{P(F=f)} \quad (7)$$

为了对不同程度的风险采取相应的措施, 需要根据风险概率对其分类。根据风险概率的预测结果, 将风险分为无风险、低风险、中风险、高风险和极高风险五个等级。风险分类如表 1 所示。当某区块的风险等级达到中风险以上时, 需要对该区域进行风险预警, 然后再对瓦斯安全状况进行评估。

表 1 风险等级

序号	风险概率	风险等级	等级权重
1	0	无风险	0
2	(0, 0.3]	低风险	1
3	(0.3, 0.6]	中风险	2
4	(0.6, 0.8]	高风险	3
5	(0.8, 1]	极高风险	4

2.3 态势预测

预测某一时刻煤矿瓦斯安全态势需要考虑该时间所有区域存在的风险,并综合风险概率、影响范围、风险等级等因素的影响。考虑到评估煤矿生产安全等级的一个重要指标为百万吨死亡率,风险的影响范围应当主要考虑人的因素。因此,本文以区域常规工作人数衡量风险的影响范围。 t 时刻煤矿瓦斯安全态势值为 $S_G(t)$,如式(8)所示:

$$S_G(t) = \max W_i + \frac{\sum_{i=1}^N S_i(t)}{\max W_i \cdot \theta_i \cdot \sum_{i=1}^N C_i} \quad (8)$$

式中, i 为区块编号, n 为区块数量, W_i 表示风险对应的等级权重, θ 表示 $\max W_i$ 所对应的等级的风险概率上界,例如:当风险等级为低风险时, $\max W_i = 2, \theta = 0.6$ 。 C_i 为风险的影响范围。 $S_i(t)$ 表示区块 i 的瓦斯安全态势值,如式(9)所示:

$$S_i(t) = P_i W_i C_i \quad (9)$$

式中, P 为风险概率。

煤矿瓦斯安全态势值传达了两项主要信息:

其一是煤矿中可能存在的最严重的风险,通过 $S_i(t)$ 小数点左侧的数值来表达。当该值为1时,煤矿中各区可能存在的最严重的风险为低风险,当该值为4时,表明煤矿各区块中存在极高风险。同时, $S_i(t)$ 小数点右侧的数值反应了受到该等级风险影响的人数与煤矿总人数的期望比值,该值越接近1,表明各区块中有越多人受到这个等级风险的影响。

其二是煤矿整体的瓦爆风险情况,当 $S_i(t)$ 为0时,表明煤矿中不存在任何哪怕是微小的风险;当 $S_i(t)$ 为5时,表明全部区块瓦爆风险概率都是100%,整个煤矿处于极为严重的危险当中。当 $S_i(t)$ 处于0到5之间时,值越大,整个煤矿的风险越严重。

3 实验分析

本文建模和测试数据来源于山西省长治市一座高瓦斯大型煤矿的实验物联网。实验物联网通过人员定位系统、摄像监控系统以及人工排查对井下作业人员的三违数据进行监测。其他数据由传统的监测传感器提供,部分数

据由手动上传。目前,该高瓦斯矿井有三个试验区,分别为1区、2区和3区。

3.1 指标体系构建

在前文多级指标体系构建的基础上,根据煤矿实际情况对指标体系进行调整。其中,三违行为实际上是由多个子指标构成,这些子指标会对一级指标产生不同的影响。笼统地将三违行为作为一个指标无法很好地解释它的具体含义,也难以确定它对各项一级指标的作用。因此,本文根据煤矿数据库对三违行为的分类将其划分为五个子指标,替代三违行为作为细化的多级指标用于一级指标预测模型建模。如表2所示。

表 2 违规行为分类

类别	违规行为描述
劳动纪律	用大锤砸钢丝绳
	巷道有人,开皮带打料
	携带超长物品坐猴车
	使用多处损伤的风带作业
	高空作业不带安全带……
火工品管理	装药未拉警戒
	做好的炮头没有用雷管脚线缠绕
	炸药与炮头混放在同一个炸药箱
	放炮未使用电爆网络
	采面反向装药……
行为规范	无故旷工
	不佩戴防尘口罩
	睡觉
	在矿广场内吸烟
	闯红灯……
操作行为	喷浆时未开全断面洒水喷雾
	皮带打料时未设警戒
	皮带停运后未及时停电闭锁
	一人卸料无人看管信号
	松车快到底车场时速度过快……
违章指挥	中部钻机压死,强令工人开机
	切眼综掘机不停电闭锁让人员进入迎头作业
	带领全班人员用皮带运送架棚材料……

根据式(7),可以得到风险概率预测模型。设一级指标取值集合为 $F=f=\{F_1=f_1, F_2=f_2, F_3=f_3\}$,在 $F=f$ 的情况下,瓦斯爆炸风险 $G=Y$ 的概率为 $P(G=Y|F=f)$,如式(10)所示:

$$\begin{aligned}
 & P(G=Y | F_1=f_1, F_2=f_2, F_3=f_3) \\
 & \frac{P(G=Y | f_1)P(f_1)}{P(G=Y)} \frac{P(G=Y | f_2)P(f_2)}{P(G=Y)} \frac{P(G=Y | f_3)P(f_3)}{P(G=Y)} \\
 & = \frac{P(f_1)P(f_2)P(f_3)}{P(G=Y)} \\
 & = \frac{P(G=Y | f_1)P(G=Y | f_2)P(G=Y | f_3)}{\sum_{i=1}^n (P(G=Y | F_{1i})P(F_{1i})) \sum_{j=1}^n (P(G=Y | F_{2j})P(F_{2j}))} \\
 & \quad (10)
 \end{aligned}$$

此外,在收集指标数据之前,需要对定性指标进行量化。根据矿山物联网建设情况及相关研究^[27,28]指标量化结果如表 3 所示。

表 3 量化的指标

初始指标	量化的指标	
火源 F_1	存在火源	$\{0,1\}$
电器失爆 F_2	电器失爆等级	$\{0,1,2,3,4\}$
瓦斯积聚 F_3	瓦斯浓度	%
安全培训不到位 M_1	安全培训参与率	$[0\%, 100\%]$
安全执行能力差 M_2	平均受教育年限	Ycars
技术管理不到位 M_3	技术管理人员不在岗时间	$[0\%, 100\%]$
矿工安全意识低 M_4	安全考核合格率	$[0\%, 100\%]$
摩擦撞击 M_5	存在摩擦撞击	$\{0,1\}$
设备老化 M_7	设备寿命	$[0\%, 100\%]$
通风系统混乱 M_8	通风系统故障率	$[0\%, 100\%]$
瓦斯监控系统故障 M_9	瓦斯监控系统故障率	$[0\%, 100\%]$
瓦斯涌出 M_{10}	绝对瓦斯涌出	m^3/min
劳动纪律 M_{11}	劳动纪律分数	
火工品管理 M_{12}	火工品管理分数	
行为规范 M_{13}	行为规范分数	
操作行为 M_{14}	操作行为分数	
违章指挥 M_{15}	违章指挥分数	

表 3 中, M_1 、 M_2 、 M_4 、 M_{11} 、 M_{12} 、 M_{13} 、 M_{14} 、 M_{15} 均为非实时数据。 M_1 与率 M_4 的效应时间持续到下一次煤矿安全培训, M_2 的效果时间持续到下一次煤矿区人员更换。

对于 M_{11} 、 M_{12} 、 M_{13} 、 M_{14} 、 M_{15} , 专家根据每种违规行为的特点和发生地点为每一项违规行为设定效应时间和权重。在某时刻, 将处于效应时间内的相同类型的违规行为按权重相加, 作为该指标的监测值。如, 9:30 在 3 区发生两起违规行为: “12080 机巷二部皮带停运后未及时停电闭锁”, 基本作用时间为 3 小时, 权重设为 100; “12080 工作面风巷睡觉”, 基本作用时间为 1 小时, 权重设为 10。两者分别属于操作行为和行为规范, 在 10:00 时, 两项指标的分数分别为 100 和 10。

3.2 风险预测

监测指标数据每两小时上传一次, 本文收集了 3 个区

域的样本数据各 160 组。将 70% 的样本数据作为训练集, 30% 作为测试集, GA 初始种群数量为 20, 迭代次数 100, 代沟取 0.9, 交叉概率取 0.7, 变异概率取 0.1, 并将预测结果与原始数据进行对比。1、2、3 区的一级指标预测结果如图 3(a)、(b)、(c) 所示。




图 3 一级指标预测结果

根据预测结果,三个区域的瓦斯浓度预测结果准确度分别为 83.734%、90.404%和 82.994%,可见,对于连续变量—瓦斯浓度,模型能较好地预测三个区块瓦斯浓度的变化趋势。存在火源预测仅出现 3 次错误,而电器失爆等级的变化在预测结果中得到了及时的表现,这种变化是因为老化的设备得到了更换。因此,对于存在明火和电器失爆等级这类离散变量,模型预测结果与原始数据有着很高的拟合度。结果表明,一级指标与其对应的多级指标之间存在映射关系,ELM 模型能够很好地反映这种关系,从而准确地预测风险一级指标数据。

瓦爆风险概率预测结果如图 4 所示。通过对比三个区域的预测结果可知,由于火源的出现、瓦斯浓度的升高以及电器失爆等级的提高,风险概率会增加。在 1、3 区中风险概率出现了一定波动,但由于瓦斯浓度仍处于安全水平,在采样时间内没有出现风险预警。由于电器失爆等级较高,2 区的风险概率高于 1、3 区。在火源、瓦斯浓度升高和电器失爆等级较高共同作用下,风险等级一度达到中等风险。在工作人员及时处理后,2 区瓦斯爆炸风险概率恢复至正常水平。




图 4 风险预测结果

3.3 态势预测

根据风险预测结果获得各区瓦斯安全态势值和整个矿井的瓦斯安全态势值。结果如表 4 所示。1、2、3 区常规工作人数分别为 30、24 和 28 人。

表 4 安全态势值

No.	1 区	2 区	3 区	整体	No.	1 区	2 区	3 区	整体	No.	1 区	2 区	3 区	整体
1	0.69	1.488	0.644	1.1147	17	0.69	1.488	0.644	1.1147	33	0.69	4.752	2.884	1.3385
2	3.09	1.488	0.644	1.2123	18	0.69	4.752	0.644	1.2474	34	3.09	5.352	0.644	1.3693
3	0.69	1.488	2.884	1.2058	19	0.69	19.536	2.884	2.2349	35	3.09	1.488	0.644	1.2123
4	0.69	1.488	0.644	1.1147	20	3.09	1.488	2.884	1.3033	36	3.09	0.552	0.644	1.1742
5	0.69	1.488	0.644	1.1147	21	0.69	1.488	2.884	1.2058	37	0.69	0.552	0.644	1.0767
6	3.09	1.488	0.644	1.2123	22	3.09	1.488	2.884	1.3033	38	0.69	0.552	0.644	1.0767
7	0.69	1.488	0.644	1.1147	23	0.69	1.488	0.644	1.1147	39	0.69	3.24	0.644	1.1859
8	3.09	1.488	0.644	1.2123	24	0.69	4.752	0.644	1.2474	40	3.09	0.552	0.644	1.1742
9	0.69	4.752	0.644	1.2474	25	0.69	1.488	2.884	1.2058	41	0.69	0.552	2.884	1.1677
10	0.69	4.752	0.644	1.2474	26	0.69	1.488	0.644	1.1147	42	0.69	0.552	0.644	1.0767
11	0.69	4.752	2.884	1.3385	27	0.69	4.752	0.644	1.2474	43	4.05	0.552	0.644	1.2133
12	0.69	1.488	0.644	1.1147	28	0.69	1.488	0.644	1.1147	44	3.09	0.552	0.644	1.1742
13	0.69	1.488	2.884	1.2058	29	0.69	4.752	0.644	1.2474	45	0.69	0.552	0.644	1.0767
14	0.69	1.488	0.644	1.1147	30	3.09	1.488	0.644	1.2123	46	0.69	0.552	0.644	1.0767
15	4.05	5.352	0.644	1.4084	31	3.09	4.752	0.644	1.3450	47	0.69	0.552	0.644	1.0767
16	0.69	1.488	0.644	1.1147	32	3.09	4.752	0.644	1.3450	48	0.69	0.552	0.644	1.0767

瓦斯安全态势走向如图 5 所示。绝大多数时间内, $S_i(t)$ 小于 2,表明样本时间内煤矿的瓦爆风险概率较低,不需要风险预警。在第 36 小时 $S_i(t)$ 提高至 2.2349,煤矿

中存在中风险,且可能受到该等级风险影响的人数占全矿的 23.49%。在第 38 小时, $S_i(t)$ 恢复至 1.3033,表明工作人员采取了相应的措施,将瓦斯风险消除。




图5 瓦斯安全态势

根据对瓦斯安全态势走向图的分析可以认为,该煤矿可以较好地控制瓦斯风险。即使由于种种原因导致瓦斯风险概率升高,该煤矿也有能力及时采取措施防止事故的发生。

3.4 实验结果分析

风险预测模型的构建往往需要大量的训练数据^[29]。随着煤矿安全水平的提升,事故记录较少,难以为风险预测模型的训练提供足够的数据。许多研究使用人为设定的风险评估值来代替缺失的事故记录^[30,31],但这种主观设定的风险评估值缺少实际的解释含义,也不具备普适性。本文将风险预测分为两级,使用全国瓦斯爆炸事故数据通过 BN 构建风险概率预测模型,并由地方煤矿专家对模型加以修正,因此在数据不足时风险预测模型可以建立。

煤矿事故原因中,不安全行为的因素占有极大的比重^[32],进行煤矿瓦爆风险预测必须考虑人的行为,需要将不安全行为的影响量化并应用于风险预测。实验结果表明,根据违规行为对煤矿的影响程度为其设置权重并进行量化,量化后的违规行为多级指标可以用于的一级指标预测。

最后,对于煤矿瓦斯爆炸风险的预测结果,根据其他研究中的计算方式计算瓦斯安全态势值^[33,34],结果如图6所示。(a)的数值含义代表每个时间节点煤矿中最大的风险概率,(b)表示不同等级风险的期望影响范围的加权相加。相比于这两种计算方式,本文提出的安全态势值计算方法具有更大的信息量,具有一定的先进性。

4 结论

本文以煤矿瓦斯爆炸风险为切入点提出了一种瓦斯安全态势预测的一般方法。提出了基于 BN 和历史事故数据分析的煤矿瓦斯安全态势指标体系构建流程,并给出了包括矿工违规行为等多种非实时指标的量化方法,充分考虑了人的行为对瓦斯爆炸风险的影响。为了降低对事故数据依赖度、减少建模中的主观因素,采用多级预测对瓦斯爆炸风险进行预测,以提高预测的准确性。在此基础上,提出了一种适用于煤矿领域的新型安全态势预测方

法。实验分析表明,本研究可以实际应用于煤矿当中并具有较高的预测准确性,可以有效地反映出煤矿的瓦爆风险控制能力。该方法的主要不足之处在于,不安全行为指标的量化方法仍不够细致,未来的研究中需要进一步完善不安全行为效应时间和权重的设置方法,对不安全行为影响的严重程度进行更为科学的划分。




图6 其他安全态势计算方法结果

参考文献:

- [1] 张爱玲,赵柔嘉,谢和平. 加大科技创新提升煤炭行业的科技力量[J]. 中国安全生产,2017,12(3):13.
- [2] Tong Q. China's coal mine accident statistics analysis and one million tons mortality prediction[J]. IETI Trans,2016,2(1):61~72.
- [3] Liu Q L, Li X C, Hassall M. Evolutionary game analysis and stability control scenarios of coal mine safety inspection system in China based on system dynamics[J]. Safety Science,2015,80:13~22.
- [4] Chen H, et al. Research on 10-year tendency of China coal mine accidents and the characteristics of human factors[J]. Safety Science,2012,50(4):745~750.
- [5] 蒯亚兵等. 彬长低阶煤高瓦斯矿区瓦斯地质及其涌

- 出特征[J]. 煤炭学报, 2019, 44(7): 2151~2158.
- [6] 张力. 我国煤矿安全生产形势分析[J]. 能源政策研究, 2010, (2): 28~31.
- [7] Bass T. A glimpse into the future of id[Z]. 2001: 40~45.
- [8] Lu J, et al. Support vector machine-based multi-source multi-attribute information integration for situation assessment [J]. Expert Systems with Applications, 2008, 34(2): 1333~1340.
- [9] Siaterlis C, Maglaris B. Towards multisensor data fusion for DoS detection[Z]. 2004: ACM.
- [10] 张勇等. 基于 Markov 博弈模型的网络安全态势感知方法[J]. 软件学报, 2011, 22(3): 495~508.
- [11] 孙卫喜. SVM-PSO 在网络安全态势预测中的应用研究[J]. 信息技术, 2019, (2): 58~61.
- [12] Webb J, et al. A situation awareness model for information security risk management[J]. Computers & Security, 2014, 44: 1~15.
- [13] Tomizuka T, et al. A study of numerical hazard prediction method of gas explosion[J]. International Journal of Hydrogen Energy, 2013, 38(12): 5176~5180.
- [14] 张宁, 盛武. 基于贝叶斯网络的煤矿瓦斯爆炸事故致因分析[J]. 工矿自动化, 2019, 45(7): 53~58.
- [15] 王永文. 基于 HHT-CS-ELM 的瓦斯涌出量时序预测[J]. 煤矿安全, 2017, 48(9): 5~8.
- [16] Zhang T, et al. Research on gas concentration prediction models based on LSTM multidimensional time series[J]. Energies, 2019, 12(1): 161.
- [17] 蔡斐等. 基于灰色 BP 神经网络的瓦斯爆炸的预测[J]. 微计算机信息, 2011, 27(5): 42~43+151.
- [18] 李胜, 胡海永. 基于 KPCA 和改进极限学习机的煤与瓦斯突出危险性判识[J]. 计算机应用研究, 2018, 35(1): 172~176.
- [19] 徐耀松等. 基于小波 KPCA 与 IQGA-ELM 的煤与瓦斯突出预测研究[J]. 传感技术学报, 2018, 31(5): 720~725.
- [20] Pearl J. Fusion, propagation, and structuring in belief networks [J]. Artificial Intelligence, 1986, 29(3): 241~288.
- [21] de Campos L M, Castellano J G. Bayesian network learning algorithms using structural restrictions[J]. International Journal of Approximate Reasoning, 2007, 45(2): 233~254.
- [22] Huang G, et al. Extreme learning machine: Theory and applications[J]. Neurocomputing, 2006, 70(1~3): 489~501.
- [23] Huang G, Ding X, Zhou H. Optimization method based extreme learning machine for classification [J]. Neurocomputing, 2010, 74(1~3): 155~163.
- [24] 温廷新等. 参数优化 GA-ELM 模型在露天煤矿抛掷爆破的预测[J]. 煤炭学报, 2017, 42(3): 630~638.
- [25] 赵睿智, 丁云飞. 基于粒子群优化极限学习机的风功率预测[J]. 上海电机学院学报, 2019, 22(4): 187~192.
- [26] 尹洪红等. 一种基于蚁狮优化的极限学习机[J]. 计算机应用与软件, 2019, 36(8): 230~234.
- [27] 王龙康. 煤矿安全隐患层次分析与预警方法研究[Z]. 中国矿业大学(北京), 2015: 195.
- [28] 汪莹, 蒋高鹏. RS-SVM 组合模型下煤矿安全风险预测[J]. 中国矿业大学学报, 2017, 46(2): 423~429.
- [29] Pavlou M, et al. How to develop a more accurate risk prediction model when there are few events [Z]. BMJ, 2015: 351.
- [30] 何叶荣, 李慧宗, 王向前. 煤矿企业安全管理风险预测模型研究——基于 RS-SVM[J]. 华东经济管理, 2014, 28(10): 159~163.
- [31] 李爽, 刘海洋, 杨勇. 基于矿工不安全行为的煤矿安全预测评价模型[J]. 煤矿安全, 2017, 48(8): 242~245.
- [32] Chen H, Qi H, Feng Q. Characteristics of direct causes and human factors in major gas explosion accidents in Chinese coal mines: Case study spanning the years 1980-2010 [J]. Journal of Loss Prevention in the Process Industries, 2013, 26(1): 38~44.
- [33] 王春雷等. 基于知识发现的网络安全态势感知系统[J]. 计算机科学, 2012, 39(7): 11~17+24.
- [34] 谢丽霞, 王亚超, 于巾博. 基于神经网络的网络安全态势感知[J]. 清华大学学报(自然科学版), 2013, 53(12): 1750~1760.

Coal Mine Gas Security Situation Forecasting Method Based on BN-ELM

LI Shuang^{1,2}, LI Ding-wei^{1,2}, YOU Meng-jie^{1,2}, CAO Qing-ren^{1,2}

(1. School of Management, China University of Mining and Technology, Xuzhou 221100, China; 2. Safety Science and Emergency Management Research Center, China University of Mining and Technology, Xuzhou 221100, China)

Abstract: Controlling the gas risk of is very important in coal mine safety production. In this paper, we introduce the concept of security situation into coal mine, and put forward the general method of gas security situation forecasting based on risk forecasting. Firstly, non-real-time monitoring data is introduced to construct a multilevel indicator system of security situation through Bayesian Network. Secondly, the gas explosion risk is forecasted by Bayesian Network and Extreme Learning Machine. Finally, the gas security situation value is calculated according to the risk forecasting result, and the trend map of the gas security situation is drawn. Taking a large high gas experimental coal mine in Shanxi Province as an example, the gas explosion risk and gas security situation were forecasted. The result shows that this method can provide decision support for coal mine managers to control gas risk.

Key words: Machine Learning; BN-ELM; Security Situation; Risk Forecasting; Gas Explosion