

何运康,李庆春,刘兴业.基于注意力机制和双向长短时记忆网络的横波速度预测方法及应用[J].石油物探,2023,62(2):225-235
HE Yunkang,LI Qingchun,LIU Xingye.Shear wave velocity prediction based on bidirectional long short-term memory networks with attention mechanism[J].Geophysical Prospecting for Petroleum,2023,62(2):225-235

基于注意力机制和双向长短时记忆网络的 横波速度预测方法及应用

何运康^{1,2},李庆春²,刘兴业^{3,4}

(1.中煤科工西安研究院(集团)有限公司,陕西西安 710077;2.长安大学地质工程与测绘学院,陕西西安 710054;3.成都理工大学地球勘探与信息技术教育部重点实验室,四川成都 610059;4.成都理工大学地球物理学院,四川成都 610059)

摘要:横波速度信息对油气勘探而言至关重要,但实际测井资料中常常缺失横波速度资料。横波速度与测井参数之间存在非线性相关性,二者关系复杂难以用解析解表征。为此,提出了一种基于注意力机制和双向长短时记忆网络的横波速度预测方法(AT-BLSTM)。该方法首先利用注意力机制为测井参数分配权重,自动聚焦对横波速度预测贡献大的测井参数,然后利用双向长短时记忆网络以及横波速度曲线纵向上的时序特征,挖掘各种测井参数与横波速度之间的相关关系,获得各种测井参数与横波速度之间的学习模型,再输入优选测井参数,最终可直接获得横波速度的预测结果。将上述方法应用于挪威北海 Volve 油田和我国西南某工区的实际测井资料进行横波速度预测,并将预测结果与常规双向长短时记忆网络、门控循环神经网络以及基于经验公式的传统方法的预测结果进行对比。结果表明,利用基于注意力机制和双向长短时记忆网络的横波速度预测方法得到的测井参数权重分配合理,横波速度预测结果与实测横波速度误差较小、相关系数较高,有效提高了横波速度预测精度,预测结果具有良好的稳定性。

关键词:测井参数;横波速度预测;深度学习;注意力机制;双向长短时记忆网络

中图分类号:P631

文献标识码:A

文章编号:1000-1441(2023)02-0225-11

DOI:10.3969/j.issn.1000-1441.2023.02.004

Shear wave velocity prediction based on bidirectional long short-term memory networks with attention mechanism

HE Yunkang^{1,2},LI Qingchun²,LIU Xingye^{3,4}

(1.Xi'an Research Institute (Group) Co.,Ltd.,China Coal Technology and Engineering Group Corp.,Xi'an 710077,China;2.School of Geological Engineering and Geomatics,Chang'an University,Xi'an 710054,China;3.Key Laboratory of Earth Exploration and Information Technology of Ministry of Education,Chengdu University of Technology,Chengdu 610059,China;4.College of Geophysics,Chengdu University of Technology,Chengdu 610059,China)

Abstract: Shear wave information plays an important role in oil and gas reservoir exploration and development, but is often lacking in actual logging data. There is a relationship between reservoir parameters and shear wave velocity, but it is too complex to obtain analytical solutions. Considering the correlation between the shear wave velocity and other reservoir parameters, shear wave velocity prediction can be real-

收稿日期:2022-01-11。

第一作者简介:何运康(1995—),男,硕士,主要从事地震资料处理及构造解释的研究工作。Email:543340420@qq.com

通信作者:刘兴业(1991—),男,教授,研究方向为地震反演、储层地球物理与人工智能。Email:lwxyh506673@126.com

基金项目:国家重点研发计划(2021YFA0716902)和国家自然科学基金项目(41874123)共同资助。

This research is financially supported by the National key R&D Program of China(Grant No.2021YFA0716902) and the National Natural Science Foundation of China(Grant No.41874123).

ized by deep learning. In this study, we propose a shear wave velocity prediction method based on the attention mechanism and bidirectional long short-term memory network (AT-BLSTM). First, the weight of logs is automatically assigned by the attention mechanism, and the logs that contribute the most to shear wave velocity prediction become the focus, whereas the logs with low sensitivity are ignored. In other words, human supervision can be avoided by using the proposed method when selecting features for shear wave prediction. Next, the influence of the upper and lower formation parameters on the shear velocity and the sequence characteristics of the longitudinal log data were fully considered to obtain the learning model that relates the shear velocity to the other parameters. Lastly, the optimal reservoir parameters can serve as the input in the learning model, and the prediction results of the shear wave velocity can thus be obtained. The proposed method was applied to the actual well logging data of the Volve oilfield on the Norwegian continental shelf and a land area in southwest China, and the results were compared with those obtained using the conventional gate recurrent unit neural network, bidirectional long short-term memory network (LSTN), and the conventional prediction method based on empirical formulas. The results showed that the error between the results predicted by the model and the measured shear wave velocity was smaller and the correlation coefficient was higher, demonstrating that the proposed method can effectively reduce the influence of manual characteristic curve selection and improve the shear wave prediction accuracy.

Keywords: reservoir parameter, shear wave velocity prediction, deep learning, attention mechanism, bidirectional long short-term memory

纵波速度和横波速度是地震数据处理和油气储层评价的关键参数。横波相对纵波具有速度低、波长短的特点,横波速度在叠前反演以及 AVO 属性分析中具有非常重要的作用,联合纵波和横波信息的反演有助于降低储层预测的不确定性,提高储层识别的精度^[1-2]。人们通常通过实验室岩心分析或者偶极横波测井中获得横波速度参数^[3]。实验室岩心分析不能得到目标层的连续横波信息,并且受成本和技术限制,很难采集到深层的岩心样品。横波测井费用高昂,并且很难获得全波列测井曲线,实际测井数据中只有部分井包含横波速度信息。此外,很多老井也缺乏横波信息,这对于老油田的精细探测十分不利。因此,利用已有测井参数预测横波速度非常必要,高精度的横波速度预测结果有助于油气储层的勘探与开发。

预测横波速度的常规方法主要有两种。第一种方法为经验公式法,该方法对各类岩层的纵波速度和横波速度进行统计学分析,得到纵、横波速度的经验公式。PICKETT^[4]根据大量的实验分析结果,确定了经典的石灰岩纵横波速度经验公式;CASTAGNA 等^[5]在分析了含水弹性硅酸盐岩纵、横波速度间的关系的基础上,提出了著名的“泥岩线”公式;HAN 等^[6]对不同压力条件下的砂岩孔隙度与粘土含量进行测量,提出了砂岩纵、横波速度的线性回归方程;此外,多位学者在前人研究的基础上提出了多种改进的经验公式,取得了良好的效果^[7-9]。经验公式法具有效率高,操作简单等特点,但是拟合得到的经验公式适用范围和精度均有限^[10-11]。第二种方法是基于岩

石物理模型的横波速度预测方法。LEE^[12]利用计算压实砂岩干岩石的固结参数预测横波速度;郭栋等^[13]提出利用叠前波形反演的方法预测横波速度,该方法在目标区域取得了良好的效果;孙福利等^[14]、白俊雨等^[15]、张广智等^[16]、张秉铭等^[17]、刘兰锋等^[18]和刘致水等^[19]分别提出了不同的岩石物理模型,均取得了良好的研究成果。此类方法可以精确地计算出岩石弹性参数,建立弹性参数与横波速度的岩石物理关系,但各类岩石物理模型的假设条件限制了预测结果精度的进一步提升,且岩石物理建模过程复杂,成本高,效率低。

近年来,机器学习方法广泛应用于各个领域。机器学习可以挖掘数据特征,寻找相关数据间的非线性关系,为横波预测工作带来了新思路。在特征挖掘和相关数据间关系建立等复杂问题上,机器学习表现出巨大潜力,尤其是深度学习方法^[20-21]。MALEKI 等^[22]、BAGHERIPOUR 等^[23]、ANEMANGELY 等^[24]和 BUKAR 等^[25]利用支持向量机预测横波速度,取得了有效的成果。ASOODEH 等^[26]和 HE 等^[27]分别利用人工神经网络预测横波速度。孙宇航等^[11]利用 GRU 神经网络构建横波预测模型,实际应用结果表明该模型具有较高的精度。杨庭威等^[28]设计了一种利用接收函数预测横波速度的卷积神经网络,成功预测了台站下方的横波速度。单博等^[29]使用二次型寻优算法替代 Adam 算法预测砂泥岩地层横波速度,简化了网络结构,有效提高了预测效率。上述研究所采用的常规机器学习方法不能有效利用

数据的深层特征,且横波预测精度有限。基于深度学习理论的横波速度预测方法可弥补常规机器学习方法的不足,但现有相关研究较少。

利用传统深度学习可以构建出横波速度与其它测井数据之间的复杂映射关系。由于地层的沉积作用是时序渐变的,并且测井曲线是地层沉积特征的响应,具有一定的时序特征,因此横波速度测井曲线与储层深度变化趋势及上、下层数据之间存在一定的关联性^[30]。传统深度学习未考虑曲线趋势对横波速度的影响,只建立了点与点之间的映射关系,预测的横波速度只与其处于同一深度的其它测井信息有关。因此,在深度学习理论的基础上,考虑横波速度纵向变化趋势及地层时序关联性,可以提高横波预测精度。

在预测横波速度时,选择合适的输入测井曲线可以有效提高预测性能^[10]。不同的测井参数从不同的角度反映了不同的地层信息,不同的测井参数对横波速度的敏感性存在差异,敏感性较弱的参数对横波速度的预测贡献度较低。因此,有必要过滤冗余,优选敏感属性作为深度学习的输入,简化计算。

针对传统方法的不足和上述问题,本文提出一种基于注意力机制和双向长短时记忆(bidirectional long short-term memory, BLSTM)网络的横波速度预测方法(AT-BLSTM),该方法利用常规测井参数预测横波速度。将其应用于挪威北海大陆架 Volve 油田和我国西南某工区的横波速度预测,并与基于常规 BLSTM 和门控循环单元(gate recurrent unit, GRU)神经网络以及两种经典经验公式的预测结果进行对比分析,证明了本文方法的可行性及稳定性。

1 方法原理

1.1 注意力机制基本原理

注意力机制思想来自于人类视觉神经,将有限的注意力集中在重点信息上,从而节省资源,快速获得最有效的信息,深度学习的注意力机制便是受这一过程启发。注意力机制首先应用于图像领域,2014 年, MNH 等^[31]在 RNN 模型上使用注意力机制进行图像分类,取得了良好的效果。横波速度预测中,首先将输入特征矩阵 \mathbf{x} 以列为单位进行归一化处理,消除不同测井曲线量纲影响, \mathbf{x} 为二维矩阵,行数 m 为输入测井曲线纵向序列长度,列数 n 为输入测井曲

线的数量, \mathbf{x} 归一化处理后用 $\bar{\mathbf{x}}$ 表示,每列数据 \mathbf{x}_i 归一化后的 $\bar{\mathbf{x}}_i$ 可用公式表示为:

$$\bar{\mathbf{x}}_i = \frac{\mathbf{x}_i - x_{\min}}{x_{\max} - x_{\min}} \quad i = 1, 2, \dots, n \quad (1)$$

式中: \mathbf{x}_i 为 \mathbf{x} 第 i 列数据; x_{\max} 和 x_{\min} 分别为 \mathbf{x}_i 的最大值和最小值。构建注意力机制层的 3 个步骤如下,示意图如图 1 所示。

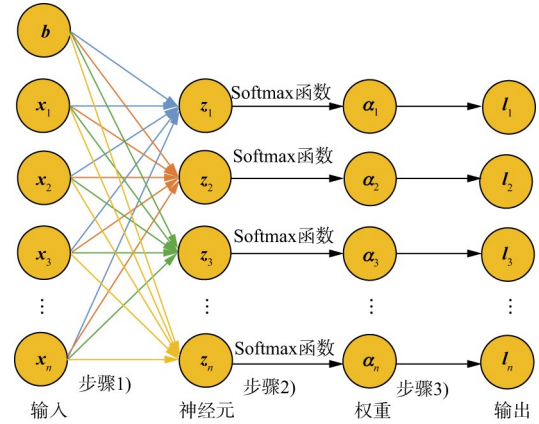


图 1 注意力机制层示意

1) 通过全连接层获取每个元素的注意力分布,输出维度与特征数量一致,计算公式如下:

$$\mathbf{z} = \mathbf{w} \cdot \bar{\mathbf{x}} + \mathbf{b} \quad (2)$$

式中: $\bar{\mathbf{x}}$ 代表归一化后的输入特征矩阵; \mathbf{z} 代表全连接层神经元, \mathbf{z} 中的元素数量与 $\bar{\mathbf{x}}$ 的列数数目一致; \mathbf{w} 为权重矩阵; \mathbf{b} 为每个神经元的偏置项。

2) 通过 Softmax 函数将 \mathbf{z} 归一化到 (0,1), 得到不同测井曲线的权重 α , α 的每一行元素的和为 1。计算公式为:

$$\alpha = \text{Softmax}(\mathbf{z}) \quad (3)$$

3) 将权重矩阵与输入特征矩阵对应元素相乘得到注意力机制层的输出值 \mathbf{l} , 即为 BLSTM 层的输入值, 计算公式如下:

$$\mathbf{l} = \alpha \otimes \mathbf{x} \quad (4)$$

式中: \otimes 代表两个矩阵对应元素相乘。

1.2 双向长短时记忆网络基本原理

BLSTM 神经网络的基本单元是 LSTM 单元。因此首先介绍 LSTM 单元的基本结构及原理, LSTM 神经网络由 HOCHREITER 等^[32]提出, 该神经网络通过引入门控制单元很好地解决了传统循环神经网络中长期记忆缺失、梯度爆炸等问题。

一个完整的 LSTM 单元内部结构如图 2 所示,

LSTM 单元包括 3 个门控制单元,分别为输入门 i_t 、遗忘门 f_t 和输出门 O_t 。




图 2 LSTM 单元内部结构示意图

令 h_{t-1} 为上一时刻($t-1$)的输出向量,反映短期记忆; l_t 为注意力机制层输出结果,反映当前 t 时刻的输入特征;当前时刻 LSTM 的输入向量 M 由 l_t 和 h_{t-1} 共同组成,向量 M 为:

$$M = \begin{bmatrix} l_t \\ h_{t-1} \end{bmatrix} \quad (5)$$

信息在更新过程中存在两种状态,分别为候选态向量 \tilde{c}_t 和细胞态向量 c_t 。 \tilde{c}_t, i_t, f_t 和 O_t 均为关于 M 的函数。

候选态代表已经归纳出来待存入细胞态的新知识,对当前时间输入向量 M 进行非线性变换,得到新的输入向量 \tilde{c}_t :

$$\tilde{c}_t = \tanh(W_c \cdot M + b_c) \quad (6)$$

\tilde{c}_t 并不会全部进入 LSTM,而是通过输入门控制输入量。

输入门用于控制 LSTM 对输入量的接收程度,决定了多少信息被存入细胞态。输入门的控制变量来自于 M, i_t 可以表示为:

$$i_t = \sigma(W_i \cdot M + b_i) \quad (7)$$

遗忘门作用于 LSTM 细胞态向量,选择性地将细胞态中的信息遗忘,有条件地控制上一个时刻的 c_{t-1} ,并选择当前时刻所需信息。遗忘门可以表示为:

$$f_t = \sigma(W_f \cdot M + b_f) \quad (8)$$

细胞态代表长期记忆,在遗忘门和输入门的控制下,LSTM 有选择地读取了上一个时间的记忆细胞态和当前时间的候选态,细胞态向量的刷新方式为:

$$c_t = i_t \tilde{c}_t + f_t c_{t-1} \quad (9)$$

输出门选择性地将细胞态中的信息输出,可由

O_t 表示为:

$$O_t = \sigma(W_o \cdot M + b_o) \quad (10)$$

(6)式至(10)式中的 W_c, W_i, W_f, W_o 分别为对应门待训练的参数张量, b_c, b_i, b_f, b_o 分别为对应门待训练的偏置项, \tanh 和 σ 为不同的激活函数,可以将门限的范围控制为 $[0, 1]$, σ 一般采用 Sigmoid 激活函数。

更新后的细胞态向量经过激活函数 \tanh 与输出门作用,得到 LSTM 单元的输出 h_t :

$$h_t = o_t \cdot \tanh(c_t) \quad (11)$$

由于 $o_t \in [-1, 1]$, $\tanh(c_t) \in [-1, 1]$, 因此 LSTM 的输出 $h_t \in [-1, 1]$ 。

以上为 LSTM 单元的更新过程基本原理, LSTM 神经网络是一种时间递归神经网络,通过引入“门”控制,考虑了神经网络的短时记忆和长时记忆。单向的 LSTM 神经网络只考虑了上层信息对预测结果的影响,但是测井数据与上、下层数据均存在相关性,因此本文提出基于 BLSTM 方法的新型横波速度预测框架。该框架在两个方向上(正向和反向)进行学习,充分考虑了上、下层数据对横波速度的影响,挖掘测井数据纵向上的时序特征,可以更准确地预测横波速度。因此,将向前 LSTM 与向后 LSTM 组合得到 BLSTM 网络,该网络可以将未来信息和过去信息相结合来预测当前信息。

连接两个时间序列相反的 LSTM 隐藏层得到 BLSTM,前向 LSTM 和后向 LSTM 可以用 \vec{h}_t 和 \overleftarrow{h}_t 表示为:

$$\vec{h}_t = \overrightarrow{\text{LSTM}}(h_{t-1}, l_t, c_{t-1}), t \in [1, T] \quad (12)$$

$$\overleftarrow{h}_t = \overleftarrow{\text{LSTM}}(h_{t+1}, l_t, c_{t+1}), t \in [1, T] \quad (13)$$

式中: T 为序列长度。BLSTM 神经网络的输出值为:

$$h_t = [\vec{h}_t, \overleftarrow{h}_t] \quad (14)$$

1.3 AT-BLSTM 方法基本原理

AT-BLSTM 方法包含预处理及如图 3 所示的 4 个步骤(结构),具体如下。

1) 预处理:主要包括初步选取特征序列、去异常值、归一化和数据划分。根据实际工区已有的测井曲线,初步选取可能与横波速度有关的测井曲线作为特征序列,并去除异常值。将测井数据归一化到 $[0, 1]$,以消除不同测井曲线量纲影响,便于训练收敛,本文采用的归一化公式如(1)式所示。

2) 输入层:输入与测井参数对应的特征测井曲

线,将输入特征序列矩阵记作 x , x 为二维矩阵,列数为特征序列的个数,行数为采样点数。

3) 注意力机制层:注意力机制层可以为不同的特征序列自动分配权重。首先计算各特征曲线元素与标签间的相似度得到权值,在时间步长上共享相同权值;然后使用 Softmax 归一化函数将权值归一化得到不同特征序列的权重矩阵 α ;最后将 α 与 x 的对应元素相乘得到注意力机制层的输出矩阵 l 。

4) BLSTM 层:利用双向长短时记忆网络得到特征序列与横波速度的深层非线性关系。

5) 输出层:输出横波速度。

采用本文方法训练神经网络时,首先将输出层的

输出结果 h_i 反归一化后与标签数据比较,然后求取误差,反向传播,最后迭代更新参数直至训练结束。保存训练完毕的模型参数,输入需要预测的数据,即可得到横波速度预测结果。由本文方法的基本原理可知,本文方法首先利用注意力机制层为不同的特征曲线分配权重,然后在正反两个方向充分考虑序列数据纵向的相关性来提高预测精度,最后得到横波速度预测结果。本文通过 Python3.7.4 及 Tensorflow2.0 库构建横波速度预测模型(AT-BLSTM)以及对比组神经网络(BLSTM 和 GRU),将估算横波速度与实际横波速度的均方误差(MSE)作为目标函数,采用 Adam 算法对训练过程进行优化,以提高收敛速度。

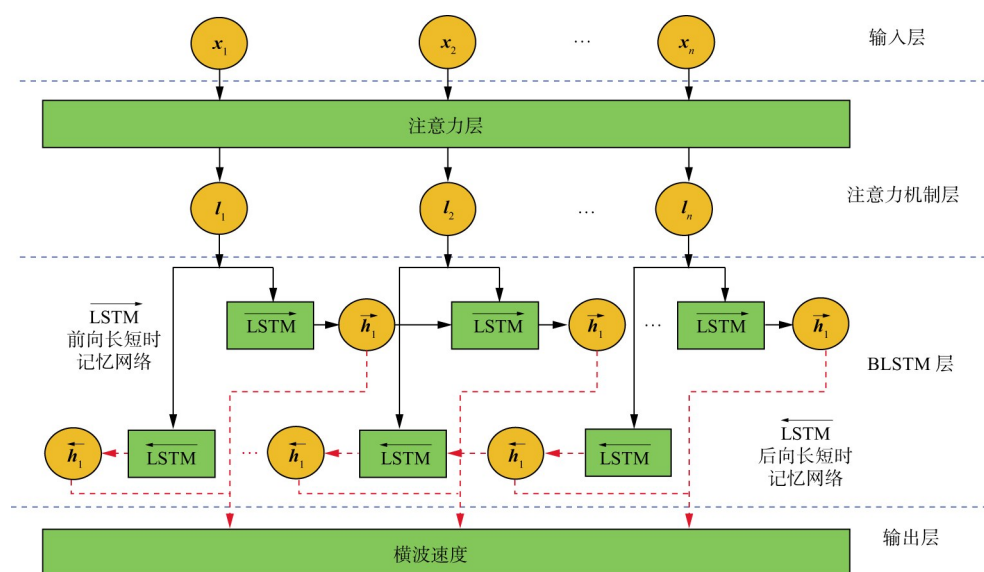


图3 AT-BLSTM方法原理示意

2 应用实例

利用挪威北海大陆架 Volve 油田和我国西南某工区的实际测井数据对本文方法的有效性和可靠性进行验证,并将预测结果与利用常规 BLSTM 和 GRU 的两种神经网络方法得到的预测结果以及根据两种经典经验公式得到的预测结果进行对比分析。

2.1 Volve 油田横波速度预测实例

Volve 油田数据包含 4 口井,共计 42665 组可用样本(A 井 10126 组、B 井 2813 组、C 井 11041 组、D 井 18685 组)。首先将 B 井、C 井、D 井共计 32539 组样本作为训练测试数据集,其中训练集 30000 组,测试集 2539 组,将 A 井作为预测集来检验预测效

果。测井数据包含纵波速度、横波速度、自然伽马、中子孔隙度、光电吸收截面指数、密度、深侧向地层真电阻率、井径、地层真电阻率 9 条测井曲线数据。

为了证明本文方法可以合理分配权重,首先利用 Pearson 相关系数(R)定量分析横波速度与其它测井参数的关联度,初步优选出对横波速度敏感的主要参数:纵波速度、密度、中子孔隙度和伽马射线。它们与横波速度的相关系数分别为 0.91, 0.72, -0.88, -0.52,而后,将这 4 个测井曲线作为输入特征曲线。图 4 为 A 井特征测井曲线与横波速度曲线交会结果,可以看出,纵波速度、密度与横波速度呈明显的正相关关系,中子孔隙度、自然伽马与横波速度呈负相关关系。由于影响因素众多,导致它们与横波速度之间的关系异常复杂,难以得到关系式。

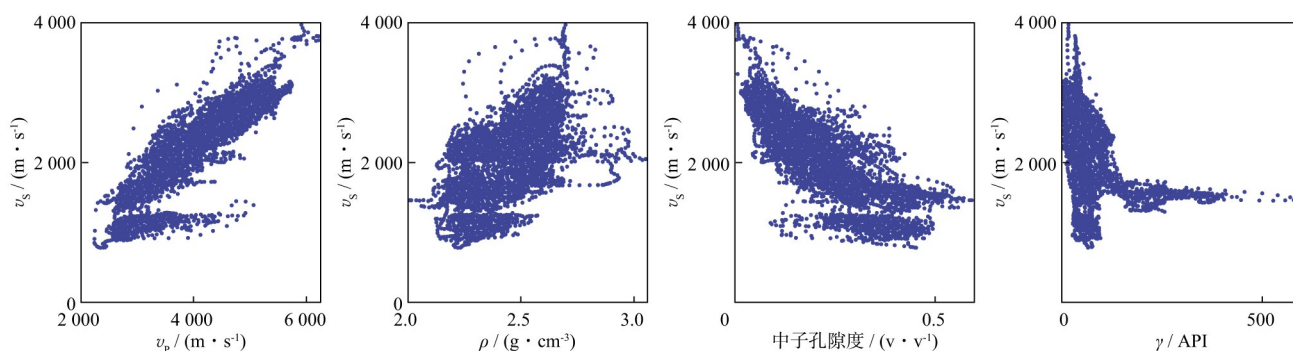


图 4 A 井特征测井曲线与横波速度曲线交会结果

超参数的调整及激活函数的选择是提高模型估算精度的关键。为了获得最优的超参数,需要系统地改变参数,反复测试评估。最终确定的网络结构包括单层注意力层和双层 BLSTM 层,超参数中神经元数均为 10 个、时间步长为 8、学习率为 0.001、迭代次数为 50 次,激活函数为 Sigmoid 函数。本实例以此结构来构建 AT-BLSTM 及对比组 (GRU、BLSTM) 神经网络。

为了进一步评估本文方法预测横波速度的精度,根据两个经典经验公式:Pickett 公式^[4]和 Eskandari 公式^[33],对横波速度进行预测,并将预测结果与本文方法的预测结果进行对比分析,具体公式如下:

$$v_s = \frac{v_p}{1.9} \quad (15)$$

$$v_s = -0.123\ 6v_p^2 + 1.612\ 0v_p - 2.035\ 7 \quad (16)$$

其中,(15)式为 Pickett 公式,(16)式为 Eskandari 公式。

将训练数据依次输入到构建好的神经网络中进行训练,作为对比组,将同样的训练数据分别输入到 BLSTM 和 GRU 神经网络中进行训练。然后将 A 井数据输入到上述训练好的神经网络中,分别输出横波速度预测值。

图 5 为 A 井各方法的横波速度预测值与真实值的对比结果,其中黑色曲线为横波速度实际值,其它颜




图 5 A 井各方法的横波速度预测值与真实值的对比

色为对应方法的预测结果。根据 Pickett 公式得到的预测结果在较浅位置(2800~3350 m)符合较好,深层较差;根据 Eskandari 公式得到的预测结果在较深位置(3350~3650 m)符合较好,浅层较差。GRU 及 BLSTM 神经网络的预测效果在较浅层及目标层(3350~3450 m)均劣于本文方法。将图 5 中 2900~3200 m 层段各方法的横波速度预测放大,结果如图 6 所示,可以看到本文方法预测精度与利用 Pickett 公式得到的预测结果精度相当,明显优于其它 3 种预测方法。

图 7a 为 A 井数据(2900~3200 m)各方法的预测结果与真实值的概率密度曲线,可以看出,本文方

法预测结果的概率密度与真实值最接近。求取预测结果与真实值的均方根误差(root mean square error, RMSE)、平均绝对误差(mean absolute error, MAE)和 R 来定量分析预测精度,结果如表 1 所示,可以看出:本文方法预测结果的均方根误差为 113.2 m/s,平均绝对误差为 85.7 m/s,低于其它 4 种方法;本文方法预测值与真实值的 R 为 0.94,高于其它 4 种方法得到的 R 。4 个特征曲线训练时,注意力机制层分配权重的平均值如图 7b 所示,可以看出,权重分配情况基本与相关性分析结果一致,纵波速度与中子孔隙度权重较高,这说明注意力层可以有效聚焦注意力,找到重点特征,并




图 6 A 井(2 900~3 200 m)各方法的横波速度预测值与真实值的对比

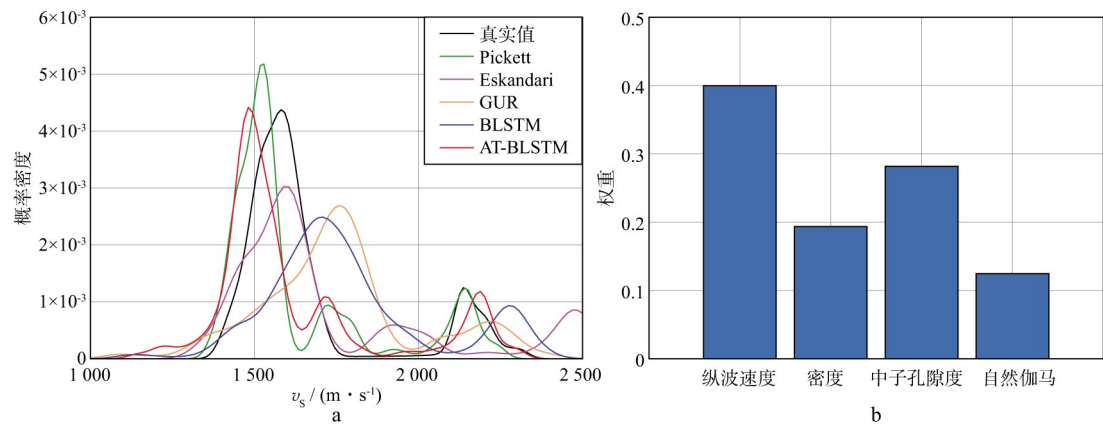


图 7 A 井(2 900~3 200 m)各方法的横波速度预测结果概率密度曲线(a)及注意力层特征曲线权重平均值(b)

表 1 A 井各方法的预测结果与真实值误差及相关性分析结果

方法	RMSE/($\text{m} \cdot \text{s}^{-1}$)	MAE/($\text{m} \cdot \text{s}^{-1}$)	R
AT-BLSTM	113.2	85.7	0.94
BLSTM	136.2	112.3	0.93
GRU	141.9	114.3	0.92
Pickett	163.7	118.9	0.92
Eskandari	239.7	213.7	0.92

合理分配权重,进而提高预测精度。

2.2 我国西南某工区横波速度预测实例

我国西南某工区测井数据包括 5 口可用井数据,将 A1 井、B1 井、C1 井、D1 井共计 69910 组样本作为训练测试数据集,其中,训练集为 62000 组,测试集为 7910 组,将 E1 井(15714 组样本)作为预测集来检验预测效果。本实例通过提高特征曲线数量,检验各种方法寻找重点特征曲线的效果。输入曲线分别为井径、密度、伽马射线、深侧向电阻率、浅侧向电阻率及纵波速度曲线。

本实例网络结构及确定的参数分别为:单层注意力层和双层 BLSTM 层,其神经元数均为 32 个,时间步长为 8,学习率为 0.001,迭代次数为 50 次,激活函数为 Sigmoid 函数。

图 8 为 E1 井各方法的横波速度预测值与真实

值的对比结果,其中黑色曲线为横波速度实际值,其它颜色为对应方法的预测结果,可以看出,本文方法的预测结果与真实值更接近。将深度为 2200~2600 m 的数据局部放大,结果如图 9 所示,可以看出本文方法预测结果的误差更小。图 10a 为该段各方法的横波预测结果概率密度曲线,可以看出,本文方法预测结果与真实值更接近,这说明本文方法的预测精度高于其它 4 种方法。E1 井各方法的预测结果与真实值误差及相关性分析结果如表 2 所示,可以看出,本文方法预测结果的均方根误差为 111.4 m/s、平均绝对误差为 84.9 m/s,与真实值的相关系数为 0.94。利用 GRU 和 BLSTM 神经网络得到的预测结果相关系数均为 0.92,两个经验公式得到的预测结果相关系数为 0.93,低于本文方法预测结果的相关系数,两个经验公式得到的预测结果均方根误差和平均绝对误差高于本文方法预测结果的均方根误差和平均绝对误差。

图 10b 为 6 个特征曲线训练时注意力机制层分配权重的平均值,纵波速度分配的权重最大,这与实际情况相符,说明本文方法可以自动聚焦敏感参数。将图 8 和图 10a 中本文方法和 BLSTM 方法横波速度预测结果与真实值对比,可以看出增加注意力层可以提高预测精度。图 10b 中的密度权重相比图 7b 有所下降,原因在于随着特征曲线数量的增加,尤其是




图 8 E1 井各方法的横波速度预测值与真实值对比




图 9 E1 井(2 200~2 600 m)各方法的横波速度预测值与真实值的对比

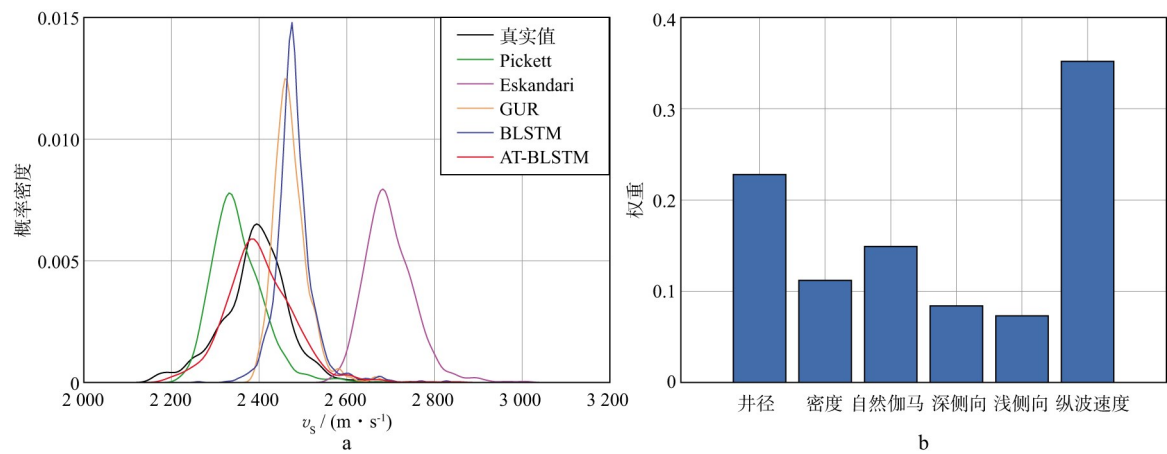


图 10 E1 井(2 200~2 600 m)各方法的横波速度预测结果概率密度曲线(a)及注意力机制层特征曲线权重平均值(b)

表 2 E1 井各方法的预测结果与真实值误差及相关性分析结果

方法	RMSE/($\text{m} \cdot \text{s}^{-1}$)	MAE/($\text{m} \cdot \text{s}^{-1}$)	R
AT-BLSTM	111.4	84.9	0.94
BLSTM	119.5	87.8	0.92
GRU	113.0	85.6	0.92
Pickett	129.1	104.8	0.93
Eskandari	251.9	220.6	0.93

增加了井径曲线而分散了权重,使密度权重有所下降,图 10b 中密度权重比自然伽马权重低,这是因为本文两个实例相距较远,受采集技术以及地层影响,测井参数间的相关性也随之变化,因此注意力机制层能够根据实际数据情况为特征曲线分配不同权重。

3 结论与认识

本文提出了一种基于注意力机制和双向长短时

记忆神经网络的横波速度预测方法(AT-BLSTM),将其应用于两个工区的实际数据进行横波速度预测,并将预测结果与基于经验公式和常规深度学习方法得到的预测结果进行对比分析,得到以下认识。

1) 本文方法在两个工区的横波速度预测结果与真实值的相关系数为 0.94,均方根误差均小于 115 m/s,表明方法具有较高的预测精度,证明了方法的有效性。

2) 对比本文方法与基于 BLSTM 神经网络方法的预测结果可知,因为引入了注意力机制,所以本文方法的预测结果与真实值相关系数较高,误差较小。表明本文方法可以自动聚焦敏感测井曲线,合理分配权重,提高横波速度预测精度。将本文方法与基于经验公式及基于 GRU 神经网络的预测方法对比,本文方法的预测结果具有较强的稳定性。这是因为横波速度除了和纵波速度表现出一定的相关性外,与其它测井曲线也具有一定的相关性。本文方法综合考虑了其它测井参数的影响以及横波速度测井曲线在纵向上的相关性,因此,与基于经验公式及常规深度学习方法相比,在横波速度预测中有更好的表现。

本文方法是基于深度学习中有监督学习神经网络建立的,因此预测精度依赖于训练集的数量及精度。若训练集的标签精度不足或数量不足,可能导致横波速度预测结果的精度下降,因此可进一步研究基于半监督或无监督深度学习的横波速度预测方法来缓解标签数量及精度对预测结果的制约。此外,网络参数调整影响预测精度,需要不断地尝试调整,下一步可以深入研究智能化算法优化网络结构及参数,减少人工调参对预测结果的影响。

参 考 文 献

- [1] LIU X Y, CHEN X H, LI J Y, et al. Facies identification based on multikernel relevance vector machine[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(10): 7269-7282
- [2] LIU X Y, GE Q, CHEN X H, et al. Extreme learning machine for multivariate reservoir characterization[J]. Journal of Petroleum Science and Engineering, 2021, 205: 108869
- [3] GHOLAMI R, MORADZADEH A, RASOULI V, et al. Shear wave velocity prediction using seismic attributes and well log data[J]. Acta Geophysica, 2014, 62(4): 818-848
- [4] PICKETT G R. Acoustic character logs and their applications in formation evaluation[J]. Journal of Petroleum Technology, 1963, 15(6): 659-667
- [5] CASTAGNA J P, BATZLE M L, EASTWOOD R L. Relationships between compressional-wave and shear-wave velocities in clastic silicate rocks[J]. Geophysics, 1985, 50(4): 571-581
- [6] HAN D H, NUR A, MORGAN D. Effects of porosity and clay content on wave velocities in sandstones[J]. Geophysics, 1986, 51(11): 2093-2107
- [7] GREENBERG M L, CASTAGNA J P. Shear-wave velocity estimation in porous rocks: Theoretical formulation, preliminary verification and applications I [J]. Geophysical Prospecting, 1992, 40(2): 195-209
- [8] 李庆忠. 岩石的纵、横波速度规律[J]. 石油地球物理勘探, 1992, 27(1): 1-12
- [9] LI Q Z. Velocity regularities of P and S-waves in formations[J]. Oil Geophysical Prospecting, 1992, 27(1): 1-12
- [9] 王玉梅, 姚逢昌, 甘利灯, 等. 数值求解地球物理反问题的非线性过程控制[J]. 石油地球物理勘探, 2002, 37(6): 589-593
- [9] SHI Y M, YAO F C, GAN L D, et al. Non-linear process control for numeric solution of geophysical inverse problem[J]. Oil Geophysical Prospecting, 2002, 37(6): 589-593
- [10] WANG J, CAO J X, YUAN S. Shear wave velocity prediction based on adaptive particle swarm optimization optimized recurrent neural network[J]. Journal of Petroleum Science and Engineering, 2020, 194: 107466
- [11] 孙宇航, 刘洋. 利用 GRU 神经网络预测横波速度[J]. 石油地球物理勘探, 2020, 55(3): 484-492
- [11] SUN Y H, LIU Y. Prediction of S-wave velocity based on GRU neural network[J]. Oil Geophysical Prospecting, 2020, 55(3): 484-492
- [12] LEE M W. A simple method of predicting S-wave velocity[J]. Geophysics, 2006, 71(6): F161-F164
- [13] 郭栋, 印兴耀, 吴国忱. 横波速度计算方法与应用[J]. 石油地球物理勘探, 2007, 42(5): 535-538
- [13] GUO D, YIN X Y, WU G C. Computational approach of S-wave velocity and application[J]. Oil Geophysical Prospecting, 2007, 42(5): 535-538
- [14] 孙福利, 杨长春, 麻三怀, 等. 横波速度预测方法[J]. 地球物理学进展, 2008, 23(2): 470-474
- [14] SUN F L, YANG C C, MA S H, et al. An S-wave velocity predicted method[J]. Progress in Geophysics, 2008, 23(2): 470-474
- [15] 白俊雨, 宋志翔, 苏凌, 等. 基于 Xu-White 模型横波速度预测的误差分析[J]. 地球物理学报, 2012, 55(2): 589-595
- [15] BAI J Y, SONG Z X, SU L, et al. Error analysis of shear-velocity prediction by the Xu-White model[J]. Chinese Journal of Geophysics, 2012, 55(2): 589-595
- [16] 张广智, 李呈呈, 印兴耀, 等. 基于修正 Xu-White 模型的碳酸盐岩横波速度估算方法[J]. 石油地球物理勘探, 2012, 47(5): 717-722
- [16] ZHANG G Z, LI C C, YIN X Y, et al. A shear velocity estimation method for carbonate rocks based on the improved Xu-White model[J]. Oil Geophysical Prospecting, 2012, 47(5): 717-722
- [17] 张秉铭, 刘致水, 刘俊州, 等. 富有机质泥页岩岩石物理横波速度预测方法研究[J]. 石油物探, 2018, 57(5): 658-667
- [17] ZHANG B M, LIU Z S, LIU J Z, et al. A new S-wave velocity estimation method for organic-enriched shale[J]. Geophysical Prospecting for Petroleum, 2018, 57(5): 658-667
- [18] 刘兰锋, 尹龙, 黄捍东, 等. 一种基于岩石物理建模的横波预测方法[J]. 物探与化探, 2021, 45(6): 1482-1487

- LIU L F, YIN L, HUANG H D, et al. Research on the method of shear wave prediction based on rock physics modeling[J]. *Geophysical and Geochemical Exploration*, 2021, 45(6): 1482-1487
- [19] 刘致水, 刘俊州, 董宁, 等. 富有机质岩石横波速度预测方法[J]. *石油地球物理勘探*, 2021, 56(1): 127-136
- LIU Z S, LIU J Z, DONG N, et al. Investigation to shear-wave velocity prediction method for organic-rich rock[J]. *Oil Geophysical Prospecting*, 2021, 56(1): 127-136
- [20] LIU X Y, ZHOU L, CHEN X H, et al. Lithofacies identification using support vector machine based on local deep multi-kernel learning[J]. *Petroleum Science*, 2020, 17(4): 954-966
- [21] LIU X Y, LI J Y, CHEN X H, et al. Bayesian discriminant analysis of lithofacies integrate the Fisher transformation and the kernel function estimation[J]. *Interpretation*, 2017, 5(2): SE1-SE10
- [22] MALEKI S, MORADZADEH A, RIABI R G, et al. Prediction of shear wave velocity using empirical correlations and artificial intelligence methods[J]. *NRIAG Journal of Astronomy and Geophysics*, 2014, 3(1): 70-81
- [23] BAGHERIPOUR P, GHOLAMI A, ASOODEH M, et al. Support vector regression based determination of shear wave velocity[J]. *Journal of Petroleum Science and Engineering*, 2015, 125: 95-99
- [24] ANEMANGELY M, RAMEZANZADEH A, AMIRI H, et al. Machine learning technique for the prediction of shear wave velocity using petrophysical logs[J]. *Journal of Petroleum Science and Engineering*, 2018, 174: 306-327
- [25] BUKAR I, ADAMU M B, HASSAN U. A machine learning approach to shear sonic log prediction[J]. *Proceedings of the Nigeria Annual International Conference and Exhibition*, 2019; <https://doi.org/10.2118/198764-MS>
- [26] ASOODEH M, BAGHERIPOUR P. Prediction of compression, shear, and stoneley wave velocities from conventional well log data using a committee machine with intelligent systems[J]. *Rock Mechanics and Rock Engineering*, 2012, 45(1): 45-63
- [27] HE J B, MISRA S. Comparative study of shallow learning models for generating compressional and shear traveltime logs[J]. *Petrophysics*, 2018, 59(6): 826-840
- [28] 杨庭威, 曹丹平, 杜南樵, 等. 基于深度学习的接收函数横波速度预测[J]. *地球物理学报*, 2022, 65(1): 214-226
- YANG T W, CAO D P, DU N Q, et al. Prediction of shear-wave velocity using receiver functions based on the deep learning method[J]. *Chinese Journal of Geophysics*, 2022, 65(1): 214-226
- [29] 单博, 张繁昌, 丁继才. 利用二次型寻优网络预测砂泥岩地层横波速度[J]. *石油地球物理勘探*, 2022, 57(1): 26-33
- SHAN B, ZHANG F C, DING J C. S-wave velocity prediction method for sand-shale formation based on quadratic optimization network[J]. *Oil Geophysical Prospecting*, 2022, 57(1): 26-33
- [30] 王俊, 曹俊兴, 尤加春. 基于 GRU 神经网络的测井曲线重构[J]. *石油地球物理勘探*, 2020, 55(3): 510-520
- WANG J, CAO J X, YOU J C. Reconstruction of logging traces based on GRU neural network[J]. *Oil Geophysical Prospecting*, 2020, 55(3): 510-520
- [31] MNIH V, HEES N, GRAVES A, et al. Recurrent models of visual attention[EB/OL]. (2014-06-24) [2022-1-11]. <https://arxiv.org/abs/1406.6247>
- [32] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735-1780
- [33] ESKANDARI H, REZAEE M R, MOHAMMADNIA M. Application of multiple regression and artificial neural network techniques to predict shear wave velocity from wireline log data for a carbonate reservoir South-West Iran[J]. *CSEG Recorder*, 2004, 29(7): 40-48

(编辑: 朱 珠)